

UNCUYO | FACULTAD DE INGENIERÍA

UNIVERSIDAD NACIONAL DE CUYO

TESINA FINAL DE GRADO

Licenciatura en Ciencias de la Computación

Diseño y Evaluación de algoritmos metaheurísticos multiobjetivo y modelos generativos para el diseño de fármacos aplicados al cáncer colorrectal

Autor: Carlos Eduardo Perez Melendez

Tutor: Dr. Pablo Javier Vidal

Co-Tutor: Dr. Matías Gabriel Rojas

Septiembre 2026

A quien le dedicas la tesis.

A tus padres o al profesor ese que nunca confió en ti.

*La tolerancia llegará a tal nivel
que las personas inteligentes
tendrán prohibido pensar
para no ofender a los imbéciles.*

Fiódor Dostoyevski

AGRADECIMIENTOS

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

RESUMEN

ABSTRACT

TABLA DE CONTENIDOS

Índice de Figuras

Índice de Tablas	1
------------------	---

1. Introducción	3
-----------------	---

1.1. Motivación	3
---------------------------	---

1.2. Objetivos	4
--------------------------	---

1.3. Organización del Documento	5
---	---

2. Marco Teórico	7
------------------	---

2.1. Diseño y Descubrimiento de Fármacos	7
--	---

2.1.1. Pipeline Tradicional	7
---------------------------------------	---

2.1.2. Diseño de Fármacos Asistido por Computadora (CADD)	9
---	---

2.2. Representación de Moléculas	10
--	----

2.2.1. SMILES (Simplified Molecular Input Line Entry System)	10
--	----

2.2.2. SELFIES (Self-Referencing Embedded Strings)	11
--	----

2.3. Métricas de Evaluación y Propiedades Moleculares	12
---	----

2.3.1. Reglas de Lipinski y Propiedades Físicoquímicas	12
--	----

2.3.2. QED (Quantitative Estimate of Drug-likeness)	13
---	----

2.3.3. Accesibilidad Sintética (SA Score)	13
---	----

2.3.4. Fracción de Carbonos sp^3 (Fsp3)	14
---	----

2.3.5. Métodos de Docking Molecular y Afinidad de Unión	14
---	----

2.4. Modelos Generativos Aplicados al Diseño de Fármacos	14
--	----

2.4.1. Autoencoders Variacionales (VAE)	14
---	----

2.5. Optimización Multi-Objetivo	14
--	----

2.5.1.	Aproximaciones Basadas en la Frontera de Pareto	14
2.5.2.	Indicadores de Rendimiento Multiobjetivo	14
2.5.3.	Metaheurísticas Consideradas en las Experimentaciones	14
2.6.	Proteína 1 de Resistencia a Múltiples Fármacos (MRP1)	14
2.7.	Trabajos Relacionados (Estado del Arte)	14
2.7.1.	Diseño de Fármacos Mediante Redes Generativas y VAEs	14
2.7.2.	Optimización del Espacio Latente Mediante Metaheurísticas	14
2.7.3.	Diseño de Fármacos Inhibidores de la Proteína MRP1	14
3.	Metodología	15
3.1.	Visión General de la Metodología	15
3.2.	Ajuste de Hiperparámetros Mediante Generación de Fármacos Genéricos	15
3.2.1.	Variables Optimizadas	15
3.2.2.	Funciones Objetivo	15
3.3.	Diseño de Inhibidores de la Proteína MRP1	15
3.3.1.	Preparación de la Proteína	15
3.3.2.	Funciones Objetivo	15
3.4.	Configuración Experimental	15
3.4.1.	Representación de la Solución	15
3.4.2.	Conjunto de Datos y Preprocesamiento	15
4.	Resultados y Discusión	17
4.1.	Generación de Fármacos Genéricos para el Ajuste de Hiperparámetros	17
4.1.1.	Análisis de Calidad de Generación de Moléculas	17
4.1.2.	Comparación Contra Algoritmos del Estado del Arte	17
4.2.	Generación de Inhibidores de la Proteína MRP1	17
4.2.1.	Análisis de Calidad de Generación de Moléculas	17
4.2.2.	Comparación Contra Algoritmos del Estado del Arte	17
4.2.3.	Análisis Detallado de las Mejores Moléculas Candidatas	17

TABLA DE CONTENIDOS

5. Conclusiones y Trabajo Futuro	19
5.1. Conclusiones	19
5.2. Trabajo Futuro	19
 Apéndices	
 A. Showcasing the First Appendix	21
 Anexos	
 L. Showcasing the First Annex	23
 Bibliografía	25
 Glosario	27
 Siglas	29

ÍNDICE DE FIGURAS

2.1. Pipeline tradicional de diseño y desarrollo de fármacos	8
2.2. Bifurcación de las estrategias de diseño de fármacos asistido por computadora (CADD) en métodos basados en estructura (SBDD) y basados en ligando (LBDD), convergiendo en el cribado virtual. Adaptado de [12, 15].	9
2.3. Representación de la molécula de aspirina en notación SMILES y correspondencia con su grafo 2D.	10
2.4. Representación de la molécula de aspirina en notación SELFIES y correspondencia con su grafo 2D.	11

ÍNDICE DE TABLAS

INTRODUCCIÓN

1.1. Motivación

El cáncer es un conjunto de enfermedades de las que se tiene registro desde el antiguo Egipto y la Grecia clásica [1], pero que aun con los avances modernos continúa representando uno de los mayores desafíos sanitarios a nivel global, alcanzando más de 20 millones de nuevos diagnósticos anuales [2]. Dentro de este panorama, los cánceres del tracto gastrointestinal representan alrededor del 36 % de la mortalidad oncológica mundial [3]. En este grupo se encuentra el cáncer colorrectal, posicionado como el tercero de mayor incidencia y la segunda causa de muerte por cáncer en el mundo [2]. Si bien hoy en día existen tratamientos quimioterapéuticos estándar basados en fármacos como el 5-fluorouracilo y el oxaliplatino, cerca del 50 % de los pacientes afectados por esta enfermedad en estadios avanzados desarrolla resistencia y sufre recaídas [3, 4]. Estos fracasos en el tratamiento están estrechamente relacionados con la resistencia a múltiples fármacos (MDR), un proceso mediante el cual proteínas transportadoras de la familia ABC expulsan los medicamentos fuera de la célula tumoral y reducen su concentración intracelular [3, 4]. En este escenario, la proteína MRP1 (ABCC1) es una de las principales responsables al impedir la apoptosis y provocar resistencia frente a las terapias habituales [4, 5]. Por ello, es de interés diseñar inhibidores que reduzcan su actividad en las células cancerígenas y así mitigar los efectos de la resistencia frente a los tratamientos convencionales [5].

El descubrimiento de fármacos mediante métodos tradicionales de laboratorio es un proceso lento y costoso, condicionado por el tamaño del espacio químico estimado en más de 10^{60} moléculas posibles [6, 7]. Además, el diseño de fármacos es un problema intrínsecamente multiobjetivo, ya que una molécula viable no solo debe ser capaz de interactuar con la proteína objetivo con alta afinidad, sino también cumplir con perfiles farmacológicos adecuados y una sintetizabilidad viable [7, 8].

Para abordar esta dificultad el diseño de fármacos asistido por computadora y los modelos generativos, como los Autoencoders Variacionales (VAE), permiten comprimir la información molecular en un espacio latente continuo desde el cual generar nuevas estructuras [6]. En este enfoque un codificador aprende a mapear representaciones moleculares discretas a vectores continuos, mientras que un decodificador realiza el proceso

inverso, reconstruyendo o generando nuevas moléculas a partir de puntos de dicho espacio latente [6]. No obstante, muestrear este espacio de manera aleatoria no garantiza la obtención de compuestos con actividad biológica real ni con propiedades farmacológicas adecuadas [6].

Para guiar la exploración de este espacio hacia moléculas útiles es oportuno incorporar métodos de optimización, dentro de este enfoque las metaheurísticas son algoritmos de búsqueda aproximada diseñados para encontrar buenas soluciones en problemas complejos y de gran tamaño [9]. Específicamente, las metaheurísticas multiobjetivo permiten optimizar simultáneamente distintas metas que suelen entrar en conflicto entre sí, como lograr una alta afinidad con la proteína, asegurar que la molécula sea fácil de sintetizar y mantener un buen perfil farmacológico, ofreciendo un conjunto de soluciones compromiso [7, 9].

Esta tesina propone un esquema computacional de dos etapas. En la primera etapa, se entrena un modelo generativo VAE con bases de datos moleculares para crear un espacio latente continuo de compuestos químicos válidos. En la segunda etapa, se integran algoritmos metaheurísticos multiobjetivo para guiar la búsqueda dentro del espacio latente, evaluando iterativamente la aptitud de las moléculas generadas según su afinidad de unión y sus propiedades farmacológicas deseadas.

Bajo esta premisa, la presente tesina de grado se centra en el desarrollo y evaluación de un enfoque computacional que combina la capacidad generativa de los VAEs con la optimización guiada de algoritmos metaheurísticos multiobjetivo, con el propósito de descubrir moléculas candidatas viables y eficaces para inhibir la proteína MRP1.

1.2. Objetivos

El objetivo general de este trabajo final de grado consiste en desarrollar y evaluar un enfoque computacional híbrido que combine modelos generativos con algoritmos metaheurísticos multiobjetivo, con el fin de obtener moléculas capaces de inhibir la resistencia a quimioterápicos en cáncer colorrectal. A partir de este objetivo general, se plantean los siguientes objetivos específicos:

- Diseñar, implementar y evaluar modelos metaheurísticos multiobjetivo para optimizar moléculas generadas por un modelo generativo.
- Generar moléculas que tengan propiedades estables y que sean eficaces para inhibir la resistencia a quimioterápicos en cáncer colorrectal.

1.3. Organización del Documento

Esta tesina de grado se organiza en capítulos donde se establecen los fundamentos teóricos, se detallan los aspectos metodológicos y experimentales, y se presentan los resultados y las conclusiones alcanzadas. El contenido se estructura de la siguiente manera:

- **Capítulo 1 (Introducción):** Expone la motivación, el problema a abordar, los objetivos del trabajo y la estructura general de la tesina.
- **Capítulo 2 (Marco Teórico):** Brinda los fundamentos sobre diseño de fármacos por computadora (CADD), representación molecular, métricas de evaluación, modelos generativos (VAE), optimización multiobjetivo y la proteína MRP1, junto con los trabajos relacionados en el área.
- **Capítulo 3 (Metodología):** Describe el enfoque propuesto, detallando el ajuste de hiperparámetros mediante fármacos genéricos, el diseño de inhibidores específicos contra MRP1 y la configuración experimental utilizada.
- **Capítulo 4 (Resultados y Discusión):** Presenta los resultados obtenidos, analizando la calidad de las moléculas generadas, la comparación con el estado del arte y el estudio de los mejores compuestos candidatos.
- **Capítulo 5 (Conclusiones y Trabajo Futuro):** Resume las principales conclusiones del trabajo, las dificultades encontradas y las líneas de trabajo futuro.

MARCO TEÓRICO

En este capítulo se hace una revisión de los conceptos teóricos que dan base a esta tesis de grado. Se abordan temas como el diseño de fármacos asistido por computadora, las formas de representar moléculas, las métricas de evaluación y el acoplamiento molecular. También se explica el funcionamiento de los autoencoders variacionales y los métodos de optimización multiobjetivo para buscar soluciones en espacios latentes. Finalmente, se describe el rol de la proteína MRP1 en el cáncer colorrectal y se resume el estado del arte en relación con el diseño computacional de fármacos.

2.1. Diseño y Descubrimiento de Fármacos

El descubrimiento de nuevos fármacos es un proceso mediante el cual se buscan, identifican, diseñan y validan nuevas moléculas con el objetivo de tratar enfermedades mediante la inhibición o activación de una proteína diana. Se trata de un proceso largo y costoso, que puede requerir entre 10 y 15 años de investigación y desarrollo, con una inversión que puede superar los 1.000 millones de dólares [10].

Frente a estos desafíos, en la actualidad el diseño de fármacos involucra con frecuencia el uso de herramientas computacionales. En términos generales, es posible distinguir dos perspectivas complementarias dentro de este campo: por un lado, el pipeline tradicional, basado en etapas sucesivas de identificación y validación de blancos, ensayos y optimización de candidatos; por otro lado, el diseño de fármacos asistido por computadora (CADD), que incorpora técnicas y métodos computacionales y de tecnologías de la información para acelerar y optimizar el proceso [11]. A continuación, se describe el pipeline tradicional (subsección 2.1.1) y luego se profundiza en el enfoque computacional (subsección 2.1.2).

2.1.1. Pipeline Tradicional

Históricamente, el descubrimiento de fármacos tiene su origen en pruebas de ensayo y error sobre extractos naturales o compuestos aislados, evaluados directamente en células o animales, sin un blanco molecular específico previamente definido [12].

La figura 2.1 ilustra este proceso metódico y secuencial surgido con el desarrollo de la industria farmacéutica, el cual en términos generales se agrupa en tres fases: el descubrimiento del fármaco, el desarrollo preclínico y los ensayos clínicos en humanos, hasta alcanzar la aprobación regulatoria necesaria [13].




Figura 2.1: Pipeline tradicional de descubrimiento y desarrollo de fármacos, ilustrando la reducción progresiva de candidatos, tiempos e inversión requerida hasta la aprobación regulatoria. Adaptado de [10, 12].

En primera instancia, el descubrimiento temprano de fármacos empieza con la identificación y validación del blanco terapéutico, es decir, la proteína, receptor o vía biológica cuya interacción con el fármaco se espera que tenga un efecto terapéutico. La idea de un blanco puede surgir tanto de la investigación académica y clínica como del sector comercial, y suele requerir años de evidencia de respaldo antes de justificar el inicio de un programa de descubrimiento [10].

En esta etapa se diseña un ensayo que mide si un compuesto interactúa con su diana. Este ensayo se aplica sobre grandes bibliotecas de compuestos mediante un cribado de alto rendimiento, un proceso automatizado que permite probar miles de moléculas en poco tiempo. Los compuestos que dan resultado favorable en este cribado son posteriormente evaluados y optimizados, modificando su estructura para mejorar su perfil farmacológico, hasta llegar a una molécula candidata [10].

Con la molécula candidata definida, se realiza el desarrollo preclínico, donde se estudia la seguridad y la toxicidad en pruebas *in vitro* y con animales, antes de probarse en seres humanos. Si los resultados son satisfactorios, el compuesto avanza a los ensayos clínicos, evaluando la seguridad y la dosis en un grupo reducido de personas, midiendo su eficacia en pacientes y confirmándola finalmente en poblaciones más grandes [13]. Superada esta etapa, el fármaco pasa a la aprobación regulatoria, donde organismos como la ANMAT o la FDA autorizan su comercialización [13, 14].

Este recorrido completo explica por qué el desarrollo de fármacos puede extenderse entre 12 y 15 años y superar los 1.000 millones de dólares de inversión [10]. Miles de compuestos evaluados en las primeras etapas son rechazados posteriormente por distintos factores: falta de interacción con el objetivo, bajo perfil farmacológico, dificultad de

síntesis, entre otros. Solo un número reducido llega a fases preclínicas y de aprobación, lo que evidencia la enorme tasa de descarte de candidatos en cada etapa [12].

2.1.2. Diseño de Fármacos Asistido por Computadora (CADD)

El diseño de fármacos asistido por computadora (CADD) se originó en la década de 1960, cuando la capacidad de generar modelos moleculares tridimensionales por medios computacionales permitió superar las limitaciones de las representaciones bidimensionales de los compuestos. Desde entonces, evolucionó hasta dividirse en dos enfoques principales según la información disponible sobre el blanco terapéutico: el diseño basado en la estructura (SBDD), que parte de la estructura tridimensional del blanco, y el diseño basado en el ligando (LBDD), que se basa en un conjunto de compuestos con actividad biológica ya conocida contra ese blanco [12].




Figura 2.2: Bifurcación de las estrategias de diseño de fármacos asistido por computadora (CADD) en métodos basados en estructura (SBDD) y basados en ligando (LBDD), convergiendo en el cribado virtual. Adaptado de [12, 15].

En el diseño basado en la estructura, el blanco se obtiene mediante cristalografía de rayos X, resonancia magnética nuclear (RMN) o, en ausencia de datos experimentales, mediante modelado por homología a partir de una proteína homóloga. Este diseño presenta dos técnicas principales, el diseño de novo, que construye ligandos nuevos dentro de las restricciones del sitio de unión, y el acoplamiento molecular, que evalúa cómo encajan distintos compuestos en ese sitio y califica su afinidad mediante funciones de puntuación [15]. En el diseño basado en el ligando, se asume que las moléculas con estructuras semejantes tienden a exhibir actividades biológicas similares, su metodología más extendida es el modelado QSAR, el cual correlaciona variaciones estructurales con la actividad biológica observada [12].

Como se observa en la figura 2.2, el cribado virtual converge con ambos enfoques, ya que puede orientarse a partir de la estructura del blanco o de los ligandos de referencia.

Asimismo, este proceso no se restringe a predecir afinidades de unión, sino que cumple un papel esencial al filtrar candidatos según su perfil ADMET (absorción, distribución, metabolismo, excreción y toxicidad), descartando compuestos con baja viabilidad [15]. En años recientes, estas herramientas han incorporado distintas metodologías, tales como redes neuronales profundas para mejorar la capacidad predictiva, así como estrategias híbridas que integran SBDD y LBDD dentro de un mismo flujo de trabajo [12].

2.2. Representación de Moléculas

El diseño de fármacos asistido por computadora requiere describir eficientemente la estructura de las moléculas para que los algoritmos puedan procesarlas y analizarlas. En este contexto, existen diversos formatos, que van desde conformaciones tridimensionales y grafos moleculares hasta secuencias lineales. Estas últimas describen la estructura del compuesto mediante una cadena de texto, lo cual facilita su almacenamiento, indexación y procesamiento. Entre las notaciones lineales más extendidas se destacan SMILES y SELFIES, ambas abordadas en este trabajo.

2.2.1. SMILES (Simplified Molecular Input Line Entry System)

La notación SMILES es una representación lineal ampliamente usada para describir la estructura bidimensional de las moléculas mediante cadenas de texto [16]. Cada átomo se representa por su símbolo químico y los enlaces por caracteres especiales. Su sintaxis captura la conectividad molecular, qué átomos están enlazados entre sí, utilizando paréntesis y dígitos para ciclos. Esta notación es concisa, legible y compatible con la mayoría de las bases de datos químicas (PubChem, ChEMBL, ZINC), lo que facilita su integración en flujos de trabajo computacionales.




Figura 2.3: Representación de la molécula de aspirina en notación SMILES y correspondencia con su grafo 2D.

Como se observa en la figura 2.3, la estructura de la aspirina se divide en tres partes dentro de la secuencia SMILES. A la izquierda se presenta el grafo bidimensional y a la

derecha su correspondencia en texto, donde las ramificaciones se indican con paréntesis y el anillo aromático se delimita con números que abren y cierran el ciclo.

SMILES se ha consolidado como la representación estándar en modelos generativos de moléculas basados en secuencias, análogos a los modelos de lenguaje. Arquitecturas basadas en redes neuronales pueden aprender las reglas químicas implícitas en las cadenas SMILES y generar nuevas estructuras válidas [17-19]. Se ha demostrado además que el uso de SMILES aleatorizados mejora la diversidad y calidad de las moléculas generadas al ampliar el espacio químico de entrenamiento [20].

Sin embargo, SMILES presenta limitaciones. Su sintaxis es sensible a pequeños errores que pueden producir moléculas inválidas o distintas. Además, una misma molécula puede tener múltiples representaciones válidas, lo que complica su comparación directa.

2.2.2. SELFIES (Self-Referencing Embedded Strings)

SELFIES es una representación lineal alternativa a SMILES, diseñada para ser robusta en términos de validez química. Introducida por Krenn et al. entre 2019 y 2020, su objetivo fue eliminar los errores sintácticos comunes de SMILES. En SELFIES, cada símbolo (token) de la cadena corresponde a un elemento químico o una relación estructural, y la gramática está restringida de manera que cualquier secuencia SELFIES decodifica una molécula válida. Es decir, no existen “SELFIES inválidos”, y hasta una cadena aleatoria genera una estructura respetando las valencias permitidas [21].




Figura 2.4: Representación de la molécula de aspirina en notación SELFIES y correspondencia con su grafo 2D.

Como se observa en la figura 2.4, la misma molécula se representa mediante una secuencia de símbolos entre corchetes. Cada parte de la estructura se define con instrucciones directas, donde las ramas y el cierre del anillo indican de forma exacta los enlaces necesarios para mantener la validez molecular.

La principal ventaja de SELFIES es esta robustez, lo que resulta crucial en modelos generativos. Si se emplea en un VAE, RNN o GAN, prácticamente todas las moléculas generadas serán químicamente válidas, eliminando la necesidad de filtrar salidas inválidas como ocurre con SMILES [21]. Esto permite a los algoritmos enfocarse en optimizar propiedades en lugar de aprender reglas gramaticales. SELFIES puede representar las mismas moléculas que SMILES, evitando combinaciones inválidas.

Entre sus limitaciones, las cadenas SELFIES pueden ser menos intuitivas para químicos, ser más largas que su SMILES equivalente y no reflejar de manera simple ciertas transformaciones moleculares. Al igual que SMILES, no incorpora información 3D ni conformacional, y la validez de la secuencia no garantiza que la molécula sea fácil de sintetizar o realista [21].

2.3. Métricas de Evaluación y Propiedades Moleculares

En el diseño de fármacos asistido por computadora, la calidad de las moléculas generadas no depende de una única característica; para que un compuesto sea viable como candidato a fármaco, debe cumplir con una serie de propiedades para asegurar un perfil farmacológico adecuado. Estas propiedades abarcan desde características fisicoquímicas hasta su viabilidad de síntesis y afinidad de unión con el objetivo terapéutico.

2.3.1. Reglas de Lipinski y Propiedades Fisicoquímicas

Uno de los primeros criterios para estimar si un compuesto químico puede cumplir alguna función farmacológica o actividad biológica es la Regla de los Cinco (*Rule of Five*) [22], propuesta en 1997 a partir de un análisis retrospectivo de las propiedades fisicoquímicas de fármacos que habían alcanzado con éxito ensayos clínicos de fase II. La regla establece que una molécula con buena biodisponibilidad oral debe cumplir con las siguientes condiciones:

- Peso Molecular ≤ 500 g/mol
- Coeficiente de partición octanol-agua (LogP) ≤ 5
- Número de aceptores de enlace de hidrógeno ≤ 10
- Número de donadores de enlace de hidrógeno ≤ 5

Esta regla se convirtió en un filtro en las primeras etapas del cribado virtual y diseño de fármacos; sin embargo, no es una regla absoluta, ya que existen fármacos que no cumplen con estas condiciones y son exitosos. Por ello, suele complementarse con métricas más detalladas para evaluar el perfil del compuesto.

2.3.2. QED (Quantitative Estimate of Drug-likeness)

El Quantitative Estimate of Drug-likeness (QED) es una métrica que permite evaluar la probabilidad de que una molécula sea un fármaco viable a partir del análisis de las propiedades fisicoquímicas de una colección de fármacos aprobados [23]. El QED toma un valor entre 0 y 1, donde un valor cercano a 1 indica una mayor probabilidad de que la molécula sea un fármaco viable.

El QED se construye a partir de ocho propiedades moleculares relevantes en el diseño de fármacos:

- Peso molecular (MW)
- Coeficiente de partición octanol-agua (ALOGP)
- Número de donadores de enlace de hidrógeno (HBD)
- Número de aceptores de enlace de hidrógeno (HBA)
- Área de superficie polar (PSA)
- Número de enlaces rotables (ROTB)
- Número de anillos aromáticos (AROM)
- Número de alertas estructurales (ALERTS)

Cada una de estas propiedades se transforma mediante una función de deseabilidad, derivada de la distribución de estas propiedades en fármacos aprobados; el QED final se calcula como la media geométrica ponderada de estas ocho funciones de deseabilidad.

QED se ha convertido en una de las métricas más utilizadas en los pipelines de diseño de fármacos, debido a que, a diferencia de los filtros discretos como Lipinski, genera una puntuación suave y continua [24].

2.3.3. Accesibilidad Sintética (SA Score)

La accesibilidad sintética es un criterio que evalúa la dificultad de síntesis de una molécula. Esta propiedad constituye un filtro común en el diseño de fármacos asistido por computadora, ya que permite que un compuesto prometedor pueda fabricarse de forma viable y eficiente, afectando directamente tanto la etapa de diseño y optimización de moléculas como la viabilidad de su posterior implementación experimental.

Para cuantificar la accesibilidad sintética se suele utilizar el SA Score [25]; esta métrica asigna a cada molécula un valor entre 1 (fácil de sintetizar) y 10 (difícil de sintetizar). Dicho valor se calcula a partir del número de fragmentos moleculares y la complejidad de las conexiones entre ellos. En la optimización molecular suele emplearse junto con el QED, donde el QED optimiza la deseabilidad farmacológica y el SA Score la viabilidad práctica de obtenerla [24].

2.3.4. Fracción de Carbonos sp^3 (Fsp3)

2.3.5. Métodos de Docking Molecular y Afinidad de Unión

2.4. Modelos Generativos Aplicados al Diseño de Fármacos

2.4.1. Autoencoders Variacionales (VAE)

2.5. Optimización Multi-Objetivo

2.5.1. Aproximaciones Basadas en la Frontera de Pareto

2.5.2. Indicadores de Rendimiento Multiobjetivo

2.5.3. Metaheurísticas Consideradas en las Experimentaciones

2.6. Proteína 1 de Resistencia a Múltiples Fármacos (MRP1)

2.7. Trabajos Relacionados (Estado del Arte)

2.7.1. Diseño de Fármacos Mediante Redes Generativas y VAEs

2.7.2. Optimización del Espacio Latente Mediante Metaheurísticas

2.7.3. Diseño de Fármacos Inhibidores de la Proteína MRP1

METODOLOGÍA

3.1. Visión General de la Metodología

3.2. Ajuste de Hiperparámetros Mediante Generación de Fármacos Genéricos

3.2.1. Variables Optimizadas

3.2.2. Funciones Objetivo

3.3. Diseño de Inhibidores de la Proteína MRP1

3.3.1. Preparación de la Proteína

3.3.2. Funciones Objetivo

3.4. Configuración Experimental

3.4.1. Representación de la Solución

3.4.2. Conjunto de Datos y Preprocesamiento

RESULTADOS Y DISCUSIÓN

4.1. Generación de Fármacos Genéricos para el Ajuste de Hiperparámetros

4.1.1. Análisis de Calidad de Generación de Moléculas

4.1.2. Comparación Contra Algoritmos del Estado del Arte

4.2. Generación de Inhibidores de la Proteína MRP1

4.2.1. Análisis de Calidad de Generación de Moléculas

4.2.2. Comparación Contra Algoritmos del Estado del Arte

4.2.3. Análisis Detallado de las Mejores Moléculas Candidatas

CONCLUSIONES Y TRABAJO FUTURO

5.1. Conclusiones

5.2. Trabajo Futuro

Apéndice

SHOWCASING THE FIRST APPENDIX

Writing Guidance

Appendices contain supplementary material **created by the author** that enhances the reader's understanding of the dissertation while not being essential for following the primary narrative. These sections often include detailed tables, figures, complex calculations, or materials like survey questions and interview transcripts produced in the course of the research. The appendices allow readers to explore the research in greater detail, offering a deeper insight into methods and findings without interrupting the main body of work.

Anexos

SHOWCASING THE FIRST ANNEX

Writing Guidance

Annexes are supplementary sections in a dissertation that provide additional information or external documents not essential to the main arguments but that support or complement the research. Unlike appendices, **annexes generally contain material that was not developed by the author**, such as reports, legal documents, or published datasets from external sources. This information is placed separately to keep the main content concise, allowing readers access to relevant external references without disrupting the dissertation's flow.

BIBLIOGRAFÍA

- [1] American Cancer Society. *Breve historia del cáncer*. <https://www.cancer.org/es/cancer/entendimiento-del-cancer/historia-del-cancer.html>. Accedido: 2026. 2026.
- [2] Hyuna Sung et al. «Global cancer statistics 2024: GLOBOCAN estimates of incidence and mortality worldwide for 34 cancers in 186 countries». En: *CA: A Cancer Journal for Clinicians* 76.4 (2026), e70090. DOI: 10.3322/caac.70090.
- [3] Jose J. G. Marin et al. «Expression of Chemoresistance-Associated ABC Proteins in Hepatobiliary, Pancreatic and Gastrointestinal Cancers». En: *Cancers* 14.14 (2022), pág. 3524. DOI: 10.3390/cancers14143524.
- [4] Fang-fang Qi et al. «Long non-coding RNAs: Key regulators in oxaliplatin resistance of colorectal cancer». En: *Biomedicine & Pharmacotherapy* 128 (2020), pág. 110329. DOI: 10.1016/j.biopha.2020.110329.
- [5] Dongxing Cao et al. «The role of MRP1 in the multidrug resistance of colorectal cancer». En: *Oncology Letters* 13.4 (2017), págs. 2471-2476. DOI: 10.3892/ol.2017.5741.
- [6] Uddalak Das. «Generative AI for drug discovery and protein design: the next frontier in AI-driven molecular science». En: *Medicine in Drug Discovery* 27 (2025), pág. 100213. DOI: 10.1016/j.medidd.2025.100213.
- [7] Sohvi Luukkonen et al. «Artificial intelligence in multi-objective drug design». En: *Current Opinion in Structural Biology* 79 (2023), pág. 102537. DOI: 10.1016/j.sbi.2023.102537.
- [8] Zijian Zhang et al. «Molecular Knowledge Representations in the Era of Artificial Intelligence». En: *ChemRxiv* (2026). DOI: 10.26434/chemrxiv.15002830/v1.
- [9] El-Ghazali Talbi. *Metaheuristics: From Design to Implementation*. Hoboken, New Jersey: John Wiley & Sons, 2009. ISBN: 978-0-470-27858-1. DOI: 10.1002/9780470496916.
- [10] J. P. Hughes et al. «Principles of early drug discovery». En: *British Journal of Pharmacology* 162.6 (2011), págs. 1239-1249. DOI: 10.1111/j.1476-5381.2010.01127.x.
- [11] Shujun Zhang et al. «The role and application of bioinformatics techniques and tools in drug discovery». En: *Frontiers in Pharmacology* 16 (2025), pág. 1547131. DOI: 10.3389/fphar.2025.1547131.

- [12] Pooja A. Chawla et al., eds. *Computational Drug Discovery: Molecular Simulation for Medicinal Chemistry*. De Gruyter, 2024. ISBN: 978-3-11-120711-7. DOI: 10.1515/9783111207117.
- [13] Grazyna Biala et al. «Research in the Field of Drug Design and Development». En: *Pharmaceuticals* 16.9 (2023), pág. 1283. DOI: 10.3390/ph16091283.
- [14] Carlos E. Durán et al. «Regulatory reliance to approve new medicinal products in Latin American and Caribbean countries». En: *Revista Panamericana de Salud Pública* 45 (2021), e10. DOI: 10.26633/RPSP.2021.10.
- [15] Stephani Joy Y. Macalino et al. «Role of computer-aided drug design in modern drug discovery». En: *Archives of Pharmacal Research* 38.9 (2015), págs. 1686-1701. DOI: 10.1007/s12272-015-0640-5.
- [16] David Weininger. «SMILES, a chemical language and information system. 1. Introduction to methodology and encoding rules». En: *Journal of Chemical Information and Computer Sciences* 28.1 (1988), págs. 31-36. DOI: 10.1021/ci00057a005.
- [17] Weiya Kong et al. «Application of SMILES-based molecular generative model in new drug design». En: *Frontiers in Pharmacology* 13 (2022), pág. 1046524. DOI: 10.3389/fphar.2022.1046524.
- [18] Marwin H. S. Segler et al. «Generating focused molecule libraries for drug discovery with recurrent neural networks». En: *ACS Central Science* 4.1 (2018), págs. 120-131. DOI: 10.1021/acscentsci.7b00512.
- [19] Marcus Olivecrona et al. «Molecular de-novo design through deep reinforcement learning». En: *Journal of Cheminformatics* 9 (2017), pág. 48. DOI: 10.1186/s13321-017-0235-x.
- [20] Josep Arús-Pous et al. «Randomized SMILES strings improve the quality of molecular generative models». En: *Journal of Cheminformatics* 11 (2019), pág. 71. DOI: 10.1186/s13321-019-0393-0.
- [21] Mario Krenn et al. «SELFIES: a robust representation of semantically constrained graphs with an example application in chemistry». En: *Machine Learning: Science and Technology* 1.4 (2020), pág. 045024. DOI: 10.1088/2632-2153/aba947.
- [22] Christopher A. Lipinski et al. «Experimental and computational approaches to estimate solubility and permeability in drug discovery and development settings». En: *Advanced Drug Delivery Reviews* 23.1-3 (1997), págs. 3-25. DOI: 10.1016/S0169-409X(96)00423-1.
- [23] G. Richard Bickerton et al. «Quantifying the chemical beauty of drugs». En: *Nature Chemistry* 4.2 (2012), págs. 90-98. DOI: 10.1038/nchem.1243.

- [24] Yuhang Xia et al. «A comprehensive review of molecular optimization in artificial intelligence-based drug discovery». En: *Quantitative Biology* 12.1 (2024), págs. 15-29. DOI: 10.1002/qub2.30.
- [25] Peter Ertl et al. «Estimation of synthetic accessibility score of drug-like molecules based on molecular complexity and fragment contributions». En: *Journal of Cheminformatics* 1 (2009), pág. 8. DOI: 10.1186/1758-2946-1-8.
- [26] Siddhartha Reddy N et al. «Leveraging Latent Evolutionary Optimization for Targeted Molecule Generation». En: *arXiv preprint arXiv:2407.13779* (2024). DOI: 10.48550/arXiv.2407.13779.
- [27] Gordon Chalmers. «Introducing ligand GA, a genetic algorithm molecular tool for automated protein inhibitor design». En: *Scientific Reports* 12.1 (2022), pág. 20877. DOI: 10.1038/s41598-022-22281-2.
- [28] Mingyang Wang et al. «Deep learning approaches for de novo drug design: An overview». En: *Current Opinion in Structural Biology* 72 (2022), págs. 135-144. DOI: 10.1016/j.sbi.2021.10.001.
- [29] Xiangru Tang et al. «A survey of generative AI for de novo drug design: new frontiers in molecule and protein generation». En: *Briefings in Bioinformatics* 25.4 (2024), bbae338. DOI: 10.1093/bib/bbae338.
- [30] Frank Lovering et al. «Escape from Flatland: Increasing Saturation as an Approach to Improving Clinical Success». En: *Journal of Medicinal Chemistry* 52.21 (2009), págs. 6752-6756. DOI: 10.1021/jm901241e.
- [31] Frank Lovering. «Escape from Flatland 2: complexity and promiscuity». En: *MedChemComm* 4.3 (2013), págs. 515-519. DOI: 10.1039/C2MD20347B.
- [32] Oleg Trott et al. «AutoDock Vina: Improving the speed and accuracy of docking with a new scoring function, efficient optimization, and multithreading». En: *Journal of Computational Chemistry* 31.2 (2010), págs. 455-461. DOI: 10.1002/jcc.21334.
- [33] Hakime Öztürk et al. «DeepDTA: deep drug-target binding affinity prediction». En: *Bioinformatics* 34.17 (2018), págs. i821-i829. DOI: 10.1093/bioinformatics/bty593.
- [34] Amit Gangwal et al. «Generative artificial intelligence in drug discovery: basic framework, recent advances, challenges, and opportunities». En: *Frontiers in Pharmacology* 15 (2024), pág. 1331062. DOI: 10.3389/fphar.2024.1331062.

GLOSARIO

Término Descripción o definición del término de ejemplo.. (p. 27)

SIGLAS

SIGLA Significado de la sigla de ejemplo. (*p.* 27)

