UNCUYO
UNIVERSIDAD NACIONAL DE CUYO

FACULTAD DE INGENIERÍA

TESINA FINAL DE GRADO

Licenciatura en Ciencias de la Computación

Diseño y evaluación de algoritmos metaheurísticos multiobjetivo y modelos generativos para el diseño de fármacos aplicados al cáncer colorrectal

---

Autor: Carlos Eduardo Perez Melendez

Tutor: Dr. Pablo Javier Vidal

Co-Tutor: Dr. Matías Gabriel Rojas

Noviembre 2026

La tolerancia llegará a tal nivel
que las personas inteligentes
tendrán prohibido pensar
para no ofender a los imbéciles.

Fiódor Dostoyevski

Agradecimientos

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetuer id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Resumen

Abstract

Tabla de Contenidos

Índice de Figuras xiii

Índice de Tablas 1

1. Introducción 3

1.1. Motivación . . . 3

1.2. Objetivos . . . 4

1.3. Organización del Documento . . . 5

2. Marco Teórico 7

2.1. Diseño de fármacos asistido por computadora (CADD) . . . 7

2.1.1. Representación de moléculas . . . 9

2.1.2. Métricas de evaluación química y propiedades moleculares . . . 10

2.1.2.1. Regla de Lipinski y propiedades fisicoquímicas . . . 11

2.1.2.2. Estimación cuantitativa de atributos de fármacos (QED) 11

2.1.2.3. Accesibilidad sintética . . . 12

2.1.2.4. Fracción de carbonos sp^3 . . . 12

2.1.2.5. Métodos de docking molecular y afinidad de unión . . . 13

2.1.3. Técnicas computacionales aplicadas al diseño de fármacos . . . 14

2.1.3.1. Autoencoders variacionales (VAE) . . . 14

2.1.3.2. Metaheurísticas multi-objetivo . . . 16

2.2. Caso de estudio: Proteína 1 de resistencia a múltiples fármacos (MRP1) . 18

2.3. Trabajos Relacionados . . . 20

2.3.1. Diseño de Fármacos Mediante Redes Generativas y VAEs . . . 20

2.3.2. Optimización del Espacio Latente Mediante Metaheurísticas . . . 24

3. Metodología **29**

3.1. Visión General de la Metodología 29

3.2. Datos de Entrada 30

3.2.1. Conjuntos de Datos y Preprocesamiento 30

3.2.2. Representaciones Moleculares y Decodificación 31

3.3. FASE 1: Ajuste de Hiperparámetros y Evaluación en Fármacos Genéricos 32

3.3.1. Ajustes de Hiperparámetros del VAE 32

3.3.2. Ajuste de Hiperparámetros de las Metaheurísticas 33

3.3.2.1. Metaheurísticas Consideradas 33

3.3.2.2. Funciones Objetivo y Restricciones 34

3.3.2.3. Protocolo Experimental del Ajuste 35

3.3.2.4. Operadores e Hiperparámetros de los Algoritmos Genéticos 36

3.3.2.5. Operadores e Hiperparámetros de CMOPSO 37

3.3.2.6. Etapas del Protocolo Experimental 37

3.4. FASE 2: Diseño de Inhibidores de la Proteína MRP1 38

3.4.1. Preparación de la Proteína y Sitio de Unión 38

3.4.2. Funciones Objetivo y Acoplamiento Molecular 42

3.4.3. Protocolo de Generación de Candidatos 43

3.5. Métricas de Evaluación del Rendimiento de los Modelos Considerados . 43

3.5.1. Métricas de Calidad de Generación 43

3.5.2. Indicadores de Rendimiento Multiobjetivo 44

3.6. Herramientas y Tecnologías de Implementación 47

4. Resultados y Discusión **49**

4.1. Resultados del Modelo Generativo (VAE) 49

4.1.1. Ajuste de Hiperparámetros: Fase 1 (Arquitectura y Representación) 49

4.1.1.1. Análisis de la Fase 1 51

4.1.1.2. Selección de modelos 52

4.1.2. Ajuste de Hiperparámetros: Fase 2 (Optimización de Entrenamiento) 52
4.1.2.1. Análisis de la Fase 2 53
4.1.2.2. Análisis por Modelo 54
4.1.3. Evaluación en el Benchmark MOSES 55
4.1.3.1. Modelo seleccionado 55
4.1.3.2. Comparación con el estado del arte 55
4.2. Calibración de Metaheurísticas en Fármacos Genéricos 56
4.2.1. Ajuste de Hiperparámetros y Comparativa de Operadores 56
4.2.2. Análisis de Calidad de Generación de Moléculas 56
4.2.3. Comparación Contra Algoritmos del Estado del Arte 56
4.3. Generación de Inhibidores de la Proteína MRP1 56
4.3.1. Análisis de Calidad de Generación de Moléculas 56
4.3.2. Comparación Contra Algoritmos del Estado del Arte 56
4.3.3. Análisis Detallado de las Mejores Moléculas Candidatas 56

5. Conclusiones y Trabajo Futuro **57**
5.1. Conclusiones 57
5.2. Trabajo Futuro 57

Apéndices

Anexos

L. Showcasing the First Annex **61**

Bibliografía **63**

Siglas **69**

Índice de Figuras

2.1. Pipeline tradicional de diseño y desarrollo de fármacos 8

2.2. Bifurcación de las estrategias de diseño de fármacos asistido por computadora (CADD) en métodos basados en estructura (SBDD) y basados en ligando (LBDD), convergiendo en el cribado virtual. Adaptado de [13, 15]. 8

2.3. Representación de la molécula de aspirina en notación SMILES y correspondencia con su grafo 2D. 10

2.4. Representación de la molécula de aspirina en notación SELFIES y correspondencia con su grafo 2D. 11

2.5. Diagrama esquemático del proceso de docking molecular. 13

2.6. Diagrama esquemático del funcionamiento de un Autoencoder Variacional (VAE) 15

2.7. Frente de Pareto (soluciones no dominadas) y soluciones dominadas en el espacio de objetivos (f_1 y f_2 a minimizar). El frente delimita el límite óptimo de compromiso entre ambos criterios, adaptado de [10]. 18

2.8. Estructura tridimensional de la proteína MRP1 (código PDB: 8VUX). Obtenido de RCSB PDB. 19

3.1. Visión general de la metodología: arquitectura del VAE preentrenado con MOSES y ciclo iterativo de optimización multiobjetivo en el espacio latente para la generación de moléculas candidatas contra MRP1. 30

3.2. Ejemplos de moléculas del conjunto de datos MOSES y su correspondiente representación lineal en formato SMILES. 31

3.3. Ejemplo de secuencia y tokenización para una molécula en formatos SMILES y SELFIES, incorporando los tokens especiales de inicio (`[SOS]`), fin (`[EOS]`) y relleno (`[PAD]`). 32

3.4. Flujo metodológico en cinco etapas para el modelado de MRP1: preparación del receptor, identificación del bolsillo de unión, calibración con ligando de referencia, delimitación de la caja de docking sobre la cavidad y evaluación de las moléculas candidatas mediante docking. 38

3.5. Irinotecán dentro de la cavidad de proteína 1 asociada a la resistencia a múltiples fármacos (*Multidrug Resistance-associated Protein 1*, MRP1). Las partes coloreadas en naranja corresponden a los residuos de interés. 40

3.6. Posición del irinotecán respecto de los cinco aminoácidos que más frecuentemente interactúan con él y de otros aminoácidos cercanos. 41

3.7. Interpretación geométrica de los principales indicadores de rendimiento multiobjetivo evaluados en un espacio bidimensional a minimizar: (a) región dominada acotada por el punto de referencia $\mathbf{r}$ (HV); (b) distancia mínima desde los puntos de referencia Z a las soluciones aproximadas A (IGD^+); (c) traslación requerida para dominar el frente de referencia (indicador ϵ aditivo); y (d) homogeneidad en la distribución espacial de las soluciones obtenidas (*Spacing*). 46

4.1. Distribuciones de QED y SA de las moléculas válidas generadas por SM-L 2 frente al conjunto de prueba de MOSES. 55

Índice de Tablas

2.1. Modelos generativos para diseño molecular. 21

2.2. Métricas de evaluación de los modelos generativos. 21

2.3. Optimización del espacio latente mediante metaheurísticas en diseño de fármacos. 25

3.1. Espacio de búsqueda de hiperparámetros del VAE dividido por fases. 33

3.2. Combinaciones de tamaño de población y generaciones evaluadas. Todas mantienen un total fijo de 100 000 evaluaciones. 36

3.3. Espacio de hiperparámetros para los algoritmos genéticos (NSGA-II, NSGA-III, MOEA/D, AGE-MOEA). 36

3.4. Espacio de hiperparámetros para CMOPSO. Se evalúan todas las combinaciones del grid, resultando en $3 \times 3 \times 3 = 27$ configuraciones por tamaño de población, para un total de 81 configuraciones. 37

3.5. Aminoácidos que con mayor frecuencia se ubicaron a menos de 4 Å del irinotecán en las poses generadas por Vina. 40

3.6. Distancia entre los aminoácidos de interés y los átomos del irinotecán en la pose analizada. 41

4.1. Fase 1: Resultados Experimentales de Generación Molecular (100 Épocas) . 50

4.2. Fase 1: Resultados Experimentales de Generación Molecular (300 Épocas) . 50

4.3. Fase 2: Resultados de Optimización (Mejores 4 Modelos) 53

4.4. Comparación con el estado del arte utilizando el dataset MOSES 56

1

Introducción

1.1. Motivación

El cáncer es un conjunto de enfermedades de las que se tiene registro desde el antiguo Egipto y la Grecia clásica [1], pero que aun con los avances modernos continúa representando uno de los mayores desafíos sanitarios a nivel global, alcanzando más de 20 millones de nuevos diagnósticos anuales [2]. Dentro de este panorama, los cánceres del tracto gastrointestinal representan alrededor del 36 % de la mortalidad oncológica mundial [3]. En este grupo se encuentra el cáncer colorrectal, posicionado como el tercero de mayor incidencia y la segunda causa de muerte por cáncer en el mundo [2].

Si bien hoy en día existen tratamientos quimioterapéuticos estándar basados en fármacos como el 5-fluorouracilo, el oxaliplatino y el irinotecán, cerca del 50 % de los pacientes afectados por esta enfermedad en estadios avanzados desarrolla resistencia y sufre recaídas [3-5]. Estos fracasos en el tratamiento se han asociado con el desarrollo de resistencia a múltiples fármacos (*Multidrug Resistance*, MDR) adquirida, un proceso en el que cobran especial relevancia proteínas transportadoras de la familia de casetes de unión a ATP (*ATP-Binding Cassette*, ABC), las cuales expulsan los medicamentos fuera de la célula tumoral y reducen su concentración intracelular [3-5].

La MRP1, perteneciente a la familia de transportadores ABC, se ha asociado con la resistencia a distintos agentes quimioterapéuticos en cáncer colorrectal [4-6]. En este contexto, la inhibición de su actividad constituye una estrategia de interés para reducir el eflujo de fármacos y, potencialmente, mitigar la resistencia frente a los tratamientos convencionales [6].

El descubrimiento de fármacos mediante métodos tradicionales de laboratorio es un proceso lento y costoso, condicionado por el tamaño del espacio químico estimado en más de 10^{60} moléculas posibles [7, 8]. Además, el diseño de fármacos es un problema intrínsecamente multiobjetivo, ya que una molécula viable no solo debe ser capaz de interactuar con la proteína objetivo con alta afinidad, sino también cumplir con perfiles farmacológicos adecuados y una sintetizabilidad viable [8, 9].

Para abordar esta dificultad, el diseño de fármacos asistido por computadora (*Computer-Aided Drug Design*, CADD) y los modelos generativos, como los autoencoders variacio-

nales (*Variational Autoencoders*, VAEs), permiten comprimir la información molecular en un espacio latente continuo desde el cual generar nuevas estructuras [7]. En este enfoque un codificador aprende a mapear representaciones moleculares discretas a vectores continuos, mientras que un decodificador realiza el proceso inverso, reconstruyendo o generando nuevas moléculas a partir de puntos de dicho espacio latente [7]. No obstante, muestrear este espacio de manera aleatoria no garantiza la obtención de compuestos con actividad biológica real ni con propiedades farmacológicas adecuadas [7], por lo que resulta necesario el diseño de métodos que permitan explorar el espacio latente de manera efectiva.

La exploración del espacio dirigida a moléculas con características de interés puede ser vista como un problema de optimización combinatoria. Entre los enfoques para abordarlo, las metaheurísticas han cobrado gran interés debido a que pueden encontrar soluciones destacadas en espacios de búsqueda de elevada complejidad y tamaño, sin incrementar la complejidad computacional considerablemente [10]. Específicamente, las metaheurísticas multiobjetivo permiten optimizar simultáneamente distintas metas que suelen entrar en conflicto entre sí, como lograr una alta afinidad con la proteína, asegurar que la molécula sea fácil de sintetizar y mantener un buen perfil farmacológico, ofreciendo un conjunto de soluciones compromiso [8, 10].

Esta tesina propone un esquema computacional de dos etapas. En la primera etapa, se entrena un modelo generativo VAE con bases de datos moleculares para crear un espacio latente continuo de compuestos químicos válidos. En la segunda etapa, se integran algoritmos metaheurísticos multiobjetivo para guiar la búsqueda dentro del espacio latente, evaluando iterativamente la aptitud de las moléculas generadas según su afinidad de unión y sus propiedades farmacológicas deseadas.

Bajo esta premisa, la presente tesina de grado se centra en el desarrollo y evaluación de un enfoque computacional que combina la capacidad generativa de los VAEs con la optimización guiada de algoritmos metaheurísticos multiobjetivo, con el propósito de descubrir moléculas candidatas viables y eficaces para inhibir la proteína MRP1.

1.2. Objetivos

El objetivo general de este trabajo final de grado consiste en desarrollar y evaluar un enfoque computacional híbrido que combine modelos generativos con algoritmos metaheurísticos multiobjetivo, con el fin de obtener moléculas capaces de inhibir la resistencia a quimioterápicos en cáncer colorrectal. A partir de este objetivo general, se plantean los siguientes objetivos específicos:

- Diseñar, implementar y evaluar modelos metaheurísticos multiobjetivo para optimizar moléculas generadas por un modelo generativo.

- Generar moléculas que tengan propiedades estables y que sean eficaces para inhibir la resistencia a quimioterápicos en cáncer colorrectal.

1.3. Organización del Documento

Esta tesina de grado se organiza en capítulos donde se establecen los fundamentos teóricos, se detallan los aspectos metodológicos y experimentales, y se presentan los resultados y las conclusiones alcanzadas. El contenido se estructura de la siguiente manera:

- **Capítulo 1 (Introducción):** Expone la motivación, el problema a abordar, los objetivos del trabajo y la estructura general de la tesina.
- **Capítulo 2 (Marco Teórico):** Brinda los fundamentos sobre CADD, representación molecular, métricas de evaluación, modelos generativos (VAE), optimización multiobjetivo y la proteína MRP1, junto con los trabajos relacionados en el área.
- **Capítulo 3 (Metodología):** Describe el enfoque propuesto, detallando el ajuste de hiperparámetros mediante fármacos genéricos, el diseño de inhibidores específicos contra MRP1 y la configuración experimental utilizada.
- **Capítulo 4 (Resultados y Discusión):** Presenta los resultados obtenidos, analizando la calidad de las moléculas generadas, la comparación con el estado del arte y el estudio de los mejores compuestos candidatos.
- **Capítulo 5 (Conclusiones y Trabajo Futuro):** Resume las principales conclusiones del trabajo, las dificultades encontradas y las líneas de trabajo futuro.

2

Marco Teórico

En este capítulo se hace una revisión de los conceptos teóricos que dan base a esta tesina de grado. Se abordan temas como el diseño de fármacos asistido por computadora, las formas de representar moléculas, las métricas de evaluación y el acoplamiento molecular. También se explica el funcionamiento de los autoencoders variacionales y los métodos de optimización multiobjetivo para buscar soluciones en espacios latentes. Finalmente, se describe el rol de la proteína MRP1 en el cáncer colorrectal y se resume el estado del arte en relación con el diseño computacional de fármacos.

2.1. Diseño de fármacos asistido por computadora (CADD)

El descubrimiento de nuevos fármacos es un proceso mediante el cual se buscan, identifican, diseñan y validan nuevas moléculas con el objetivo de tratar enfermedades mediante la inhibición o modulación de una proteína diana. Se trata de un proceso largo y costoso, que puede requerir entre 10 y 15 años de investigación y desarrollo, con una inversión que puede superar los 1.000 millones de dólares [11].

En la actualidad, es posible distinguir dos perspectivas complementarias dentro de este campo: por un lado, el pipeline tradicional, basado en etapas sucesivas de identificación y validación de blancos, ensayos y optimización de candidatos; por otro lado, el CADD, que incorpora técnicas y métodos computacionales y de tecnologías de la información para acelerar y optimizar el proceso [12].

Históricamente, el descubrimiento de fármacos tiene su origen en pruebas de ensayo y error sobre extractos naturales o compuestos aislados, evaluados directamente en células o animales, sin un blanco molecular específico previamente definido [13]. Tradicionalmente, este proceso sigue un flujo secuencial estructurado en tres fases principales: el descubrimiento temprano, el desarrollo preclínico y los ensayos clínicos en humanos, tal como se ilustra en la figura 2.1 [11, 14].

Este recorrido explica por qué el desarrollo de fármacos puede extenderse por más de una década y superar los 1.000 millones de dólares de inversión [11]. Miles de compuestos evaluados en las primeras etapas son rechazados posteriormente por distintos factores: falta de interacción con el objetivo, bajo perfil farmacológico, dificultad de sín-

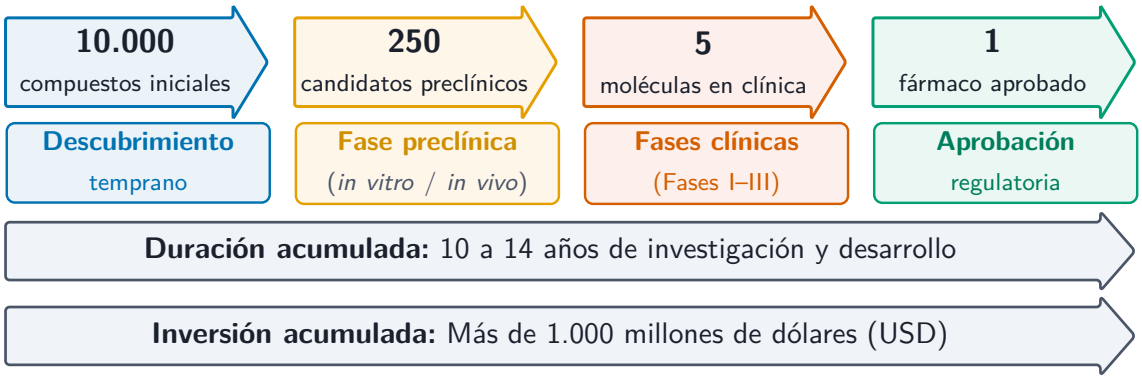


Figura 2.1: *Pipeline tradicional de descubrimiento y desarrollo de fármacos, ilustrando la reducción progresiva de candidatos, tiempos e inversión requerida hasta la aprobación regulatoria. Adaptado de* [11, 13].

tesis, entre otros. Solo un número reducido llega a fases preclínicas y de aprobación, lo que evidencia la enorme tasa de descarte de candidatos en cada etapa [13].

El CADD se originó en la década de 1960, cuando la capacidad de generar modelos moleculares tridimensionales por medios computacionales permitió superar las limitaciones de las representaciones bidimensionales de los compuestos. Desde entonces, evolucionó hasta dividirse en dos enfoques principales según la información disponible sobre el blanco terapéutico: el diseño de fármacos basado en la estructura (*Structure-Based Drug Design*, SBDD), que parte de la estructura tridimensional del blanco, y el diseño de fármacos basado en el ligando (*Ligand-Based Drug Design*, LBDD), que se basa en un conjunto de compuestos con actividad biológica ya conocida contra ese blanco [13].

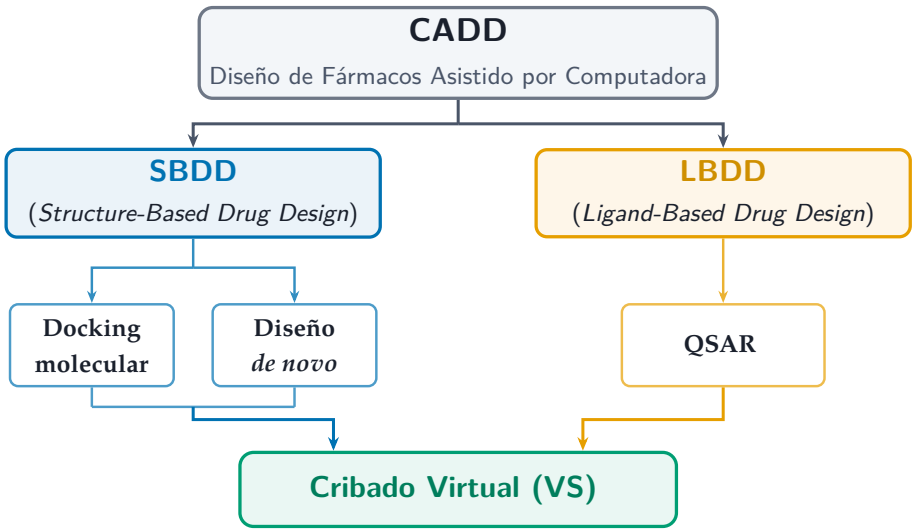


Figura 2.2: *Bifurcación de las estrategias de diseño de fármacos asistido por computadora (CADD) en métodos basados en estructura (SBDD) y basados en ligando (LBDD), convergiendo en el cribado virtual. Adaptado de* [13, 15].

En el diseño basado en la estructura, el blanco se obtiene experimentalmente mediante cristalografía de rayos X, resonancia magnética nuclear (*Nuclear Magnetic Resonance*, RMN) o criomicroscopía electrónica (*Cryogenic Electron Microscopy*, Cryo-EM), o bien por medios computacionales en ausencia de estructuras experimentales, ya sea

mediante modelado por homología o mediante modelos de inteligencia artificial como AlphaFold [16]. Este diseño presenta dos técnicas principales, el diseño de novo, que construye ligandos nuevos dentro de las restricciones del sitio de unión, y el acoplamiento molecular, que evalúa cómo encajan distintos compuestos en ese sitio y califica su afinidad mediante funciones de puntuación [15]. En el diseño basado en el ligando, se asume que las moléculas con estructuras semejantes tienden a exhibir actividades biológicas similares, su metodología más extendida es el modelado de relación cuantitativa estructura-actividad (*Quantitative Structure–Activity Relationship*, QSAR), el cual correlaciona variaciones estructurales con la actividad biológica observada [13].

Como se observa en la figura 2.2, el cribado virtual converge con ambos enfoques, ya que puede orientarse a partir de la estructura del blanco o de los ligandos de referencia. Asimismo, este proceso no se restringe a predecir afinidades de unión, sino que cumple un papel esencial al filtrar candidatos según su perfil de absorción, distribución, metabolismo, excreción y toxicidad (*Absorption, Distribution, Metabolism, Excretion, and Toxicity*, ADMET), descartando compuestos con baja viabilidad [15]. En años recientes, estas herramientas han incorporado distintas metodologías, tales como redes neuronales profundas para mejorar la capacidad predictiva, así como estrategias híbridas que integran SBDD y LBDD dentro de un mismo flujo de trabajo [13].

2.1.1. Representación de moléculas

El diseño de fármacos asistido por computadora requiere describir eficientemente la estructura de las moléculas para que los algoritmos puedan procesarlas y analizarlas. En este contexto, existen diversos formatos, que van desde conformaciones tridimensionales y grafos moleculares hasta secuencias lineales. Estas últimas describen la estructura del compuesto mediante una cadena de texto, lo cual facilita su almacenamiento, indexación y procesamiento. Entre las notaciones lineales más extendidas se destacan sistema simplificado de entrada de líneas moleculares (*Simplified Molecular Input Line Entry System*, SMILES) y cadenas integradas autorreferenciadas (*Self-Referencing Embedded Strings*, SELFIES), ambas abordadas en este trabajo.

La notación SMILES es una representación lineal ampliamente usada para describir la estructura bidimensional de las moléculas mediante cadenas de texto [17]. Cada átomo se representa por su símbolo químico y los enlaces por caracteres especiales. Su sintaxis captura la conectividad molecular, qué átomos están enlazados entre sí, utilizando paréntesis y dígitos para ciclos. Esta notación es concisa, legible y compatible con la mayoría de las bases de datos químicas (PubChem, ChEMBL, ZINC) [18-20], lo que facilita su integración en flujos de trabajo computacionales. SMILES se ha consolidado como la representación estándar en modelos generativos de moléculas basados en secuencias, análogos a los modelos de lenguaje. Arquitecturas basadas en redes neuronales pueden aprender las reglas químicas implícitas en las cadenas SMILES y generar nuevas estructuras válidas [21-23]. Sin embargo, SMILES presenta limitaciones. Su sintaxis es sensi-

ble a pequeños errores que pueden producir moléculas inválidas o distintas. Además, una misma molécula puede tener múltiples representaciones válidas, lo que complica su comparación directa.

Como se observa en la figura 2.3, la estructura de la aspirina se divide en tres partes dentro de la secuencia SMILES. A la izquierda se presenta el grafo bidimensional y a la derecha su correspondencia en texto, donde las ramificaciones se indican con paréntesis y el anillo aromático se delimita con números que abren y cierran el ciclo.

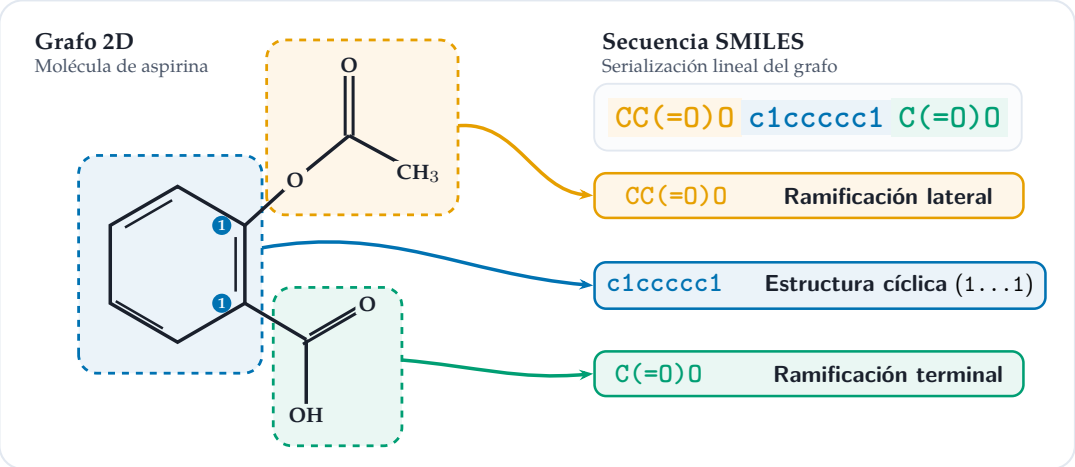


Figura 2.3: *Representación de la molécula de aspirina en notación SMILES y correspondencia con su grafo 2D.*

SELFIES es una representación lineal alternativa a SMILES, diseñada para ser robusta en términos de validez química. Introducida por Krenn et al. entre 2019 y 2020, su objetivo fue eliminar los errores sintácticos comunes de SMILES. En SELFIES, cada símbolo (token) de la cadena corresponde a un elemento químico o una relación estructural, y la gramática está restringida de manera que cualquier secuencia SELFIES decodifica una molécula válida. Es decir, no existen "SELFIES inválidos", y hasta una cadena aleatoria genera una estructura respetando las valencias permitidas [24]. La principal ventaja de SELFIES es esta robustez, que permite eliminar la necesidad de filtrar salidas inválidas de modelos generativos, como ocurre con SMILES [24]. Sin embargo, no está libre de limitaciones: las cadenas SELFIES pueden ser menos intuitivas, más largas que su SMILES equivalente y no reflejar de manera simple ciertas transformaciones moleculares.

La figura 2.4 ilustra cómo se representa la misma molécula en formato SELFIES mediante una secuencia de símbolos entre corchetes. Cada parte de la estructura se define con instrucciones directas, donde las ramas y el cierre del anillo indican de forma exacta los enlaces necesarios para mantener la validez molecular.

2.1.2. Métricas de evaluación química y propiedades moleculares

En el diseño de fármacos asistido por computadora, la calidad de las moléculas generadas no depende de una única característica, para que un compuesto sea viable como

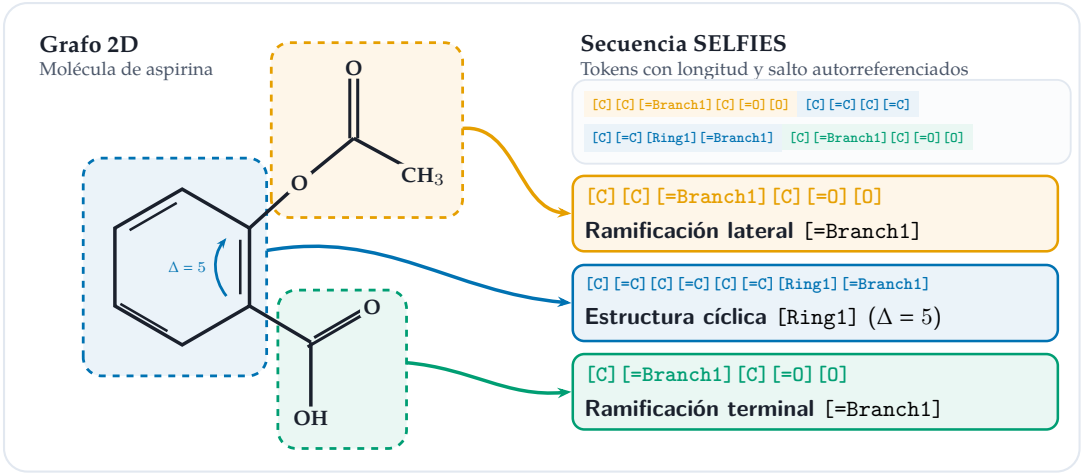


Figura 2.4: *Representación de la molécula de aspirina en notación SELFIES y correspondencia con su grafo 2D.*

candidato a fármaco, debe cumplir con una serie de propiedades para asegurar un perfil farmacológico adecuado. Estas propiedades abarcan desde características fisicoquímicas hasta su viabilidad de síntesis y afinidad de unión con el objetivo terapéutico.

2.1.2.1. Regla de Lipinski y propiedades fisicoquímicas

Uno de los primeros criterios para estimar si un compuesto químico puede cumplir alguna función farmacológica o actividad biológica es la Regla de los Cinco (*Rule of Five*) [25], propuesta en 1997 a partir de un análisis retrospectivo de las propiedades fisicoquímicas de fármacos que habían alcanzado con éxito ensayos clínicos de fase II. La regla establece que una molécula con buena biodisponibilidad oral debe cumplir con las siguientes condiciones:

- Peso Molecular ≤ 500 g/mol
- Coeficiente de partición octanol-agua (LogP) ≤ 5
- Número de aceptores de enlace de hidrógeno ≤ 10
- Número de donadores de enlace de hidrógeno ≤ 5

Esta regla se convirtió en un filtro en las primeras etapas del cribado virtual y diseño de fármacos, sin embargo, no es una regla absoluta, ya que existen fármacos que no cumplen con estas condiciones y son exitosos. Por ello, suele complementarse con métricas más detalladas para evaluar el perfil del compuesto.

2.1.2.2. Estimación cuantitativa de atributos de fármacos (QED)

La estimación cuantitativa de la similitud a fármaco (*Quantitative Estimate of Drug-likeness*, QED) es una métrica que permite evaluar la probabilidad de que una molécula sea un fármaco viable a partir del análisis de las propiedades fisicoquímicas de una co-

lección de fármacos aprobados [26]. El QED toma un valor entre 0 y 1, donde un valor cercano a 1 indica una mayor probabilidad de que la molécula sea un fármaco viable.

El QED se construye a partir de ocho propiedades moleculares relevantes en el diseño de fármacos:

- Peso molecular (*Molecular Weight*, MW)
- Coeficiente de partición octanol-agua basado en átomos (*Atom-based LogP*, ALOGP)
- Número de donadores de enlaces de hidrógeno (*Hydrogen Bond Donors*, HBD)
- Número de aceptores de enlaces de hidrógeno (*Hydrogen Bond Acceptors*, HBA)
- Área de superficie polar (*Polar Surface Area*, PSA)
- Número de enlaces rotables (*Rotatable Bonds*, ROTB)
- Número de anillos aromáticos (*Aromatic Rings*, AROM)
- Número de alertas estructurales (*Structural Alerts*, ALERTS)

Cada una de estas propiedades se transforma mediante una función de deseabilidad, derivada de la distribución de estas propiedades en fármacos aprobados, el QED final se calcula como la media geométrica ponderada de estas ocho funciones.

QED se ha convertido en una de las métricas más utilizadas en los pipelines de diseño de fármacos, debido a que, a diferencia de los filtros discretos como Lipinski, genera una puntuación suave y continua [27].

2.1.2.3. Accesibilidad sintética

La accesibilidad sintética es un criterio que evalúa la dificultad de síntesis de una molécula. Esta propiedad constituye un filtro común en el diseño de fármacos asistido por computadora, ya que permite que un compuesto prometedor pueda fabricarse de forma viable y eficiente, afectando directamente tanto la etapa de diseño y optimización de moléculas como la viabilidad de su posterior implementación experimental.

Para cuantificar la accesibilidad sintética se suele utilizar la puntuación de accesibilidad sintética (*Synthetic Accessibility Score*, SAS) [28]; esta métrica asigna a cada molécula un valor entre 1 (fácil de sintetizar) y 10 (difícil de sintetizar). Dicho valor se calcula a partir del número de fragmentos moleculares y la complejidad de las conexiones entre ellos. En la optimización molecular suele emplearse junto con el QED, donde el QED optimiza la deseabilidad farmacológica y la SAS la viabilidad práctica de obtenerla [27].

2.1.2.4. Fracción de carbonos sp^3

La fracción de carbonos F_{sp^3} es una métrica que evalúa la proporción de carbonos saturados respecto al número total de átomos de carbono:

$$F_{sp^3} = \frac{\text{Número de carbonos } sp^3}{\text{Número total de carbonos}} \tag{2.1}$$

Sus valores oscilan entre 0 para moléculas completamente planas y 1 para moléculas totalmente saturadas.

Esta métrica fue propuesta en el trabajo "Escape from Flatland" [29], donde se observó que las moléculas candidatas a fármacos que tendían a ser excesivamente planas mostraban tasas menores de éxito clínico. A través de un análisis de bases de datos de compuestos en distintas etapas se encontró una correlación positiva entre el grado de saturación Fsp3 y la probabilidad de que un compuesto avance a fases clínicas avanzadas. Asimismo, se encontró una correlación positiva entre el Fsp3 y la solubilidad acuosa. Un trabajo posterior [30] expandió este análisis, relacionando nuevamente la saturación sp3 con la promiscuidad farmacológica, es decir, la tendencia de una molécula a interactuar con dianas biológicas no deseadas, por lo que a mayor complejidad tridimensional, las moléculas tienden a reducir la promiscuidad y con ello el riesgo de efectos adversos fuera de la diana.

2.1.2.5. Métodos de docking molecular y afinidad de unión

El docking molecular es una técnica computacional que permite estimar la afinidad de una molécula pequeña hacia una diana, usualmente una proteína. Esta herramienta se utiliza para predecir la fuerza de dicha unión, conocida como afinidad de unión, y la orientación tridimensional de la molécula dentro del sitio de unión de la proteína.

En la figura 2.5 se muestra un diagrama esquemático con las etapas principales del proceso de docking molecular.

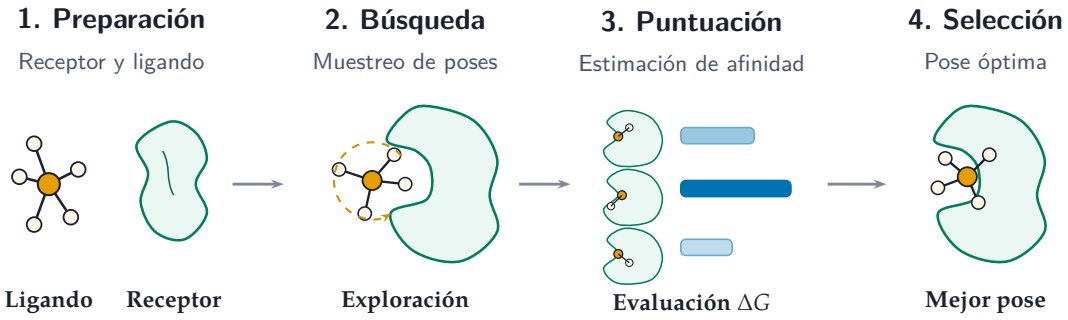


Figura 2.5: *Diagrama esquemático del proceso de docking molecular.*

Una herramienta de docking consiste en general de dos componentes, un algoritmo de búsqueda que explora el espacio de poses del ligando dentro del sitio de unión, y de una función de puntuación que evalúa cada pose y estima la energía de unión de cada pose y permite ordenarlas [31]. Existen distintas implementaciones que combinan estos componentes, cada una con su propia metodología de búsqueda y de puntuación.

Entre esas herramientas se encuentra AutoDock Vina [32], que combina un algoritmo de búsqueda local iterativo con una función de puntuación híbrida, usando información de estructuras de complejos proteína-ligando ya conocidos y de afinidades medidas en experimentos. El docking demanda recursos computacionales considerables cuando se tiene una gran cantidad de ligandos que evaluar, para reducir este costo existen implementaciones aceleradas por unidad de procesamiento gráfico (*Graphics Processing Unit*, GPU), entre ellas Uni-dock [33] que permite procesar moléculas en lotes. El resultado de la función de puntuación se da como una energía de unión estimada (ΔG) en kcal/mol [31] en la que un valor más negativo indica una unión más favorable.

2.1.3. Técnicas computacionales aplicadas al diseño de fármacos

Los métodos basados en inteligencia artificial pueden mejorar enormemente el proceso de diseño de fármacos, en especial los modelos generativos, los cuales son capaces de aprender representaciones del espacio químico para generar nuevos compuestos con propiedades deseadas. Al apoyarse en técnicas de aprendizaje profundo, estos modelos no evalúan únicamente las moléculas conocidas, sino que aprenden las reglas y patrones de la representación molecular para generar nuevos compuestos. Entre estos modelos, los Autoencoders Variacionales destacan por su capacidad de estructurar un espacio latente navegable.

Sin embargo, navegar este espacio latente para generar nuevos compuestos no es una tarea trivial, la optimización molecular requiere equilibrar propiedades que suelen competir entre sí, tales como maximizar la afinidad hacia una diana, mientras se preserva la facilidad de síntesis o la similitud a fármacos conocidos. Al no existir una solución que satisfaga todos estos criterios, la optimización multiobjetivo aborda este desafío identificando las mejores soluciones compromiso.

2.1.3.1. Autoencoders variacionales (VAE)

Los VAEs son una arquitectura de aprendizaje profundo de tipo generativo [34]. Su estructura se basa en dos redes neuronales conectadas: un codificador que procesa los datos y un decodificador que intenta reconstruirlos.

Para entender su funcionamiento, es necesario contrastarlos con los autoencoders tradicionales. Un autoencoder tradicional toma un dato de entrada y lo comprime en un vector fijo en el espacio latente. El problema de este enfoque es que, por sí solo, no puede generar directamente ejemplos nuevos a partir de la distribución de los datos [35].

El VAE trata con este problema modificando la naturaleza del espacio latente. En lugar de codificar la entrada como un punto fijo, la red predice una distribución estadística, definida por una media y una desviación estándar [34]. En la figura 2.6 se ilustra este flujo, desde la estimación de μ y σ hasta la reconstrucción de la entrada a partir de z.

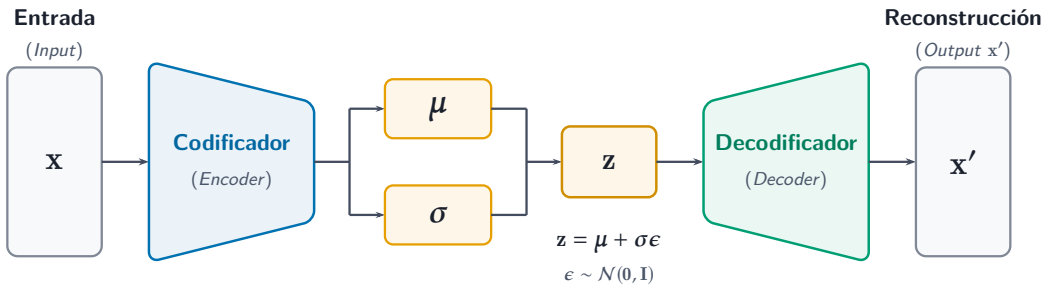


Figura 2.6: *Diagrama esquemático del funcionamiento de un Autoencoder Variacional (VAE). Adaptado de [36].*

En el diseño de fármacos, la entrada x es una molécula representada como una cadena de texto (SMILES o SELFIES). El codificador convierte esa cadena en una distribución sobre el espacio latente, de la que se toma una muestra z, y el decodificador convierte z de nuevo en una cadena. Como este espacio es continuo, se pueden generar moléculas nuevas decodificando vectores aleatorios, perturbando moléculas conocidas o interpolando entre ellas, y también aplicar métodos de optimización para buscar moléculas con mejores propiedades [37].

El entrenamiento de los VAEs presenta un desafío técnico, para generar datos el modelo necesita tomar una muestra aleatoria de esa distribución estadística, pero fijar el vector latente a un valor muestreado bloquea la propagación del error hacia el codificador, por lo que sus pesos no se pueden actualizar [35]. Para solucionarlo se emplea el «truco de reparametrización» [34], que obtiene el vector latente z mediante una ecuación que separa la aleatoriedad de los parámetros aprendibles:

$$z = \mu + \sigma \odot \epsilon \tag{2.2}$$

Donde μ y σ son la media y la desviación estándar que predice el codificador, $\odot$ es el producto elemento a elemento y ϵ es un ruido aleatorio externo que debe seguir una distribución normal estándar. De esta forma, la red puede usar la aleatoriedad para generar variedad, pero mantiene una conexión matemática directa que le permite propagar los gradientes hacia el codificador.

Función de pérdida. Para que el modelo generativo aprenda correctamente, no basta con medir la precisión con la que reconstruye los datos de entrada. Es fundamental asegurar también que el espacio latente posea una estructura estadística coherente que permita la generación de nuevas muestras. Para lograr esto, se utiliza una función de pérdida con dos términos:

$$\mathcal{L} = \mathcal{L}_{recon} + \beta \cdot \mathcal{D}_{KL}\left(q_\phi(z|x) \,\|\, p(z)\right) \tag{2.3}$$

Donde $q_\phi(z|x)$ es la distribución que predice el codificador y $p(z)$ es una distribución normal estándar $\mathcal{N}(0, I)$ [34]. Cuando $\beta = 1$, esta función corresponde al negativo de la cota inferior de la evidencia (*Evidence Lower Bound*, ELBO), la cota inferior que el VAE busca maximizar [34, 35]; el coeficiente β permite ponderar la divergencia KL. En la práctica, este peso puede variar durante el entrenamiento: en *Chemical VAE*, por ejemplo, la pérdida variacional se introduce con un calendario sigmoide (*annealing*) [37].

Esta ecuación actúa como un mecanismo de balance entre dos objetivos contrapuestos durante el entrenamiento:

- **Pérdida de reconstrucción ($\mathcal{L}_{recon}$):** Es el primer término de la ecuación. Su función es comparar el dato generado por el decodificador con el dato original de entrada. Cuanto mayor sea la diferencia o el error en la recuperación de la información, mayor será este valor. Su objetivo es forzar a la red a mantener la fidelidad respecto a los datos reales.
- **Divergencia de Kullback-Leibler ($\mathcal{D}_{KL}$):** Es el segundo término y actúa como un regularizador [34] ponderado por el coeficiente β. Mide la discrepancia entre la distribución aprendida por el codificador y la distribución a priori. Este término funciona como un componente variacional que organiza el espacio latente. Su objetivo principal es forzar a que la distribución que aprende el modelo se parezca lo más posible a la distribución normal estándar, creando un espacio continuo y ordenado.

El objetivo final de esta función es encontrar un equilibrio óptimo: reconstruir los datos con alta precisión sin perder la capacidad de generar nuevas muestras válidas al interpolar en el espacio latente.

2.1.3.2. Metaheurísticas multi-objetivo

La optimización de soluciones en la naturaleza frecuentemente requiere explorar espacios de búsqueda vastos y de alta dimensionalidad, donde los métodos exactos resultan inviables. Estos problemas raramente se pueden reducir a un único objetivo a optimizar, sino que presentan múltiples metas u objetivos en conflicto.

En estos problemas la solución óptima no es única, sino que es un conjunto de soluciones definidas como soluciones óptimas de Pareto, donde no es posible mejorar un objetivo específico sin que ello conlleve al deterioro de otro. Es decir, estas soluciones representan un compromiso entre diferentes objetivos en conflicto por lo que la finalidad es encontrar este conjunto óptimo, y consecuentemente la Frontera de Pareto [10].

Problema de optimización multiobjetivo. Un problema de optimización multiobjetivo puede definirse como [10]:

$$\begin{cases} \text{Min } F(x) = (f_1(x), f_2(x), \ldots, f_n(x)) \\ \text{s.c. } x \in S \end{cases} \tag{2.4}$$

Donde $F(x)$ es el vector de los n objetivos a optimizar $(n \geq 2)$, mientras que x y S mantienen las definiciones de variables de decisión y espacio factible ya establecidas. En este contexto, la búsqueda se orienta a encontrar un equilibrio entre los distintos criterios de aptitud en conflicto.

Los objetivos a maximizar se transforman en problemas de minimización invirtiendo su signo, por lo que la formulación (2.4) abarca ambos sentidos de optimización [10].

Dominancia de Pareto. Un vector objetivo $u = (u_1, \ldots, u_n)$ domina a $v = (v_1, \ldots, v_n)$ $(u \prec v)$ si ninguna componente de v es menor que la correspondiente de u y al menos una es estrictamente menor [10]:

$$\forall i \in \{1, \ldots, n\} : u_i \leq v_i \wedge \exists i \in \{1, \ldots, n\} : u_i < v_i \tag{2.5}$$

Dominancia Débil $(u \preceq v)$. u domina débilmente a v si [10]:

$$\forall i \in \{1, \ldots, n\}, \quad u_i \leq v_i \tag{2.6}$$

Dominancia restringida. Cuando el problema de optimización multiobjetivo incorpora restricciones, la comparación entre soluciones debe contemplar además su factibilidad. Bajo el principio de *dominancia restringida*, una solución x_i domina a una solución x_j si se verifica alguna de las siguientes condiciones [38]:

1. x_i es factible y x_j no lo es.
2. Ambas soluciones son infactibles, pero x_i presenta una menor violación de restricciones.
3. Ambas soluciones son factibles y x_i domina a x_j en el sentido de la ecuación (2.5).

Este criterio permite incorporar restricciones sin recurrir a funciones de penalización, que exigirían el ajuste de parámetros adicionales [38].

Optimalidad de Pareto. Una solución $x^* \in S$ es *Pareto óptima* si para cada $x \in S$, $F(x)$ no domina a $F(x^*)$, es decir, $F(x) \not\prec F(x^*)$ [10].

En general, la búsqueda en un problema mono-objetivo conduce al hallazgo de una única solución óptima global. Un problema de optimización multiobjetivo puede tener un conjunto de soluciones conocido como el *conjunto Pareto óptimo*. La imagen de este conjunto en el espacio de objetivos se denomina el frente de Pareto [10].

Frente de Pareto. Para un problema de optimización multiobjetivo (F, S) dado y su conjunto óptimo de Pareto P^*, el **frente de Pareto** se define como [10]:

$$PF^* = \{F(x) \mid x \in P^*\} \tag{2.7}$$

El frente de Pareto es la imagen del conjunto óptimo de Pareto en el espacio de los objetivos, y su obtención constituye el propósito central de la optimización multiobjetivo. Dado que este frente puede ser sumamente extenso, se busca una aproximación finita que garantice tanto la convergencia hacia la frontera teórica como una distribución uniforme de las soluciones sobre la misma [10].

En la figura 2.7 se ilustra la representación de soluciones dominadas y soluciones pertenecientes al frente de Pareto en un espacio bidimensional.

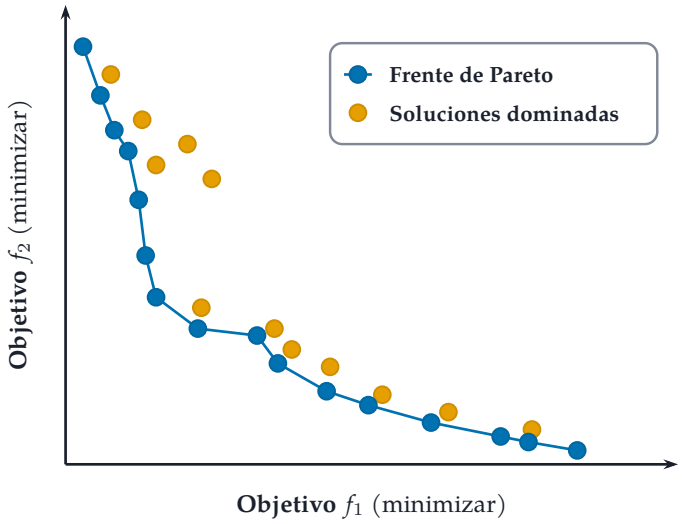


Figura 2.7: *Frente de Pareto (soluciones no dominadas) y soluciones dominadas en el espacio de objetivos (f_1 y f_2 a minimizar). El frente delimita el límite óptimo de compromiso entre ambos criterios, adaptado de [10].*

2.2. Caso de estudio: Proteína 1 de resistencia a múltiples fármacos (MRP1)

El tratamiento del cáncer colorrectal avanzado se maneja principalmente con regímenes de quimioterapia basados en fármacos citotóxicos como el 5-fluorouracilo (*5-Fluorouracil*, 5-FU), el oxaliplatino y el irinotecán. Sin embargo, la efectividad de estos fármacos se ve comprometida debido al desarrollo de MDR, lo cual provoca recaídas en una elevada proporción de pacientes [3, 4].

MRP1 es una proteína transportadora de la familia ABC que usa energía del trifosfato de adenosina (*Adenosine Triphosphate*, ATP) para expulsar moléculas desde el interior

de las células hacia el exterior [39, 40]. Entre estas moléculas se encuentran diversos fármacos quimioterápicos; al ser expulsados, se reduce su concentración intracelular y la célula tumoral adquiere resistencia a los mismos. Esta capacidad de reconocer y transportar activamente un amplio conjunto de quimioterápicos explica la resistencia farmacológica asociada a su sobreexpresión [39, 40].

En el cáncer colorrectal existe evidencia experimental sobre el papel de MRP1 en la resistencia a los fármacos mencionados [6], además de que MRP1 funciona como biomarcador de resistencia al irinotecán [3]. Se encontró que al reducir su producción en células tumorales resistentes, la sensibilidad a dichos fármacos se restablece y la muerte celular de las mismas vuelve a activarse. MRP1 contribuye entonces a la resistencia del cáncer colorrectal, lo que la convierte en un blanco terapéutico de interés [6].

Si bien MRP1 cumple funciones fisiológicas en tejidos sanos, su sobreexpresión en tumores colorrectales representa una barrera terapéutica, por lo que diseñar inhibidores que reduzcan su actividad en células tumorales es un desafío significativo.

Se conoce la estructura tridimensional de MRP1 y el sitio donde se aloja el sustrato que transporta [41]. En la Figura 2.8 se observa la conformación tridimensional de esta proteína (código Banco de Datos de Proteínas (*Protein Data Bank*, PDB): 8VUX). Dicho sitio de unión está dividido en dos partes, una con carga positiva y otra hidrofóbica (que repele el agua), y varios de sus aminoácidos cambian de posición cuando una molécula se une. Esa flexibilidad explica por qué la proteína reconoce ligandos tan distintos entre sí, y a la vez ofrece un blanco delimitado contra el cual evaluar moléculas candidatas mediante acoplamiento molecular [41].

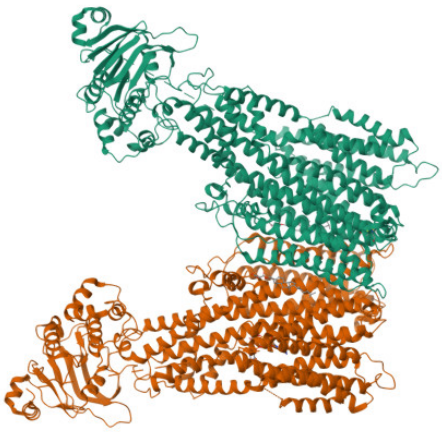


Figura 2.8: *Estructura tridimensional de la proteína MRP1 (código PDB: 8VUX). Obtenido de RCSB PDB.*

El diseño de inhibidores de MRP1 se basó durante décadas en probar, mediante campañas de cribado masivo de la industria farmacéutica, compuestos ya conocidos por

otras propiedades (como el verapamilo o la ciclosporina A) y una amplia variedad de productos naturales. Ninguno de estos compuestos llegó a aprobarse como fármaco [42]. En paralelo, desde que se resolvió por cristalografía de rayos X una parte de MRP1 en 2006, varios trabajos computacionales combinaron esa estructura parcial con modelos por homología del resto de la proteína para buscar inhibidores mediante virtual screening y acoplamiento molecular. Rungsardthong et al. [43] identificaron 20 compuestos candidatos dirigidos a esa parte, y Dhasmana et al. [44] propusieron el citrato de potasio como el mejor candidato de una biblioteca de fármacos aprobados por la Administración de Alimentos y Medicamentos (*Food and Drug Administration*, FDA).

La estructura completa de MRP1, resuelta por Cryo-EM en 2017, reveló por primera vez otra parte de la proteína: la zona donde se une a los fármacos que va a expulsar, distinta de la que usaron los trabajos anteriores. Belhadj et al. [45] utilizan esa estructura para caracterizar ZW-1226, un compuesto que mediante acoplamiento molecular ocupa esa zona de enganche, y que en líneas celulares revierte la resistencia mediada por MRP1 a dos fármacos de quimioterapia.

2.3. Trabajos Relacionados

En este trabajo se propone un enfoque híbrido, en el que mediante un modelo generativo y metaheurísticas multiobjetivo se busca, en una primera instancia, optimizar el diseño y búsqueda de moléculas con propiedades farmacológicas para, posteriormente, enfocarse en candidatos capaces de unirse a la proteína MRP1. Por lo tanto, esta sección revisa los antecedentes de modelos generativos para el diseño molecular y la optimización del espacio latente mediante metaheurísticas.

2.3.1. Diseño de Fármacos Mediante Redes Generativas y VAEs

En esta subsección se revisan los principales modelos generativos aplicados al diseño de moléculas. La Tabla 2.1 resume las características de cada uno: el conjunto de datos con el que fue entrenado, la arquitectura sobre la que se construye, la representación molecular que emplea y el año de publicación. La Tabla 2.2 reúne, para esos mismos modelos, las métricas de calidad de generación que reporta cada trabajo, es decir, la validez, la unicidad y la novedad de las moléculas producidas.

En [37], Gómez-Bombarelli et al. presentan el *Chemical Variational Autoencoder* (Chemical VAE), uno de los primeros modelos en mapear representaciones moleculares discretas (SMILES) a un espacio latente continuo. Entrenado con los conjuntos QM9 y ZINC, permitió explorar y optimizar moléculas mediante operaciones continuas en dicho espacio. Aunque introdujo una base sólida para modelos generativos posteriores, su principal limitación radica en la generación de moléculas inválidas debido a la rigidez sintáctica de

Tabla 2.1: *Modelos generativos para diseño molecular.*

Modelo	Dataset	Arquitectura	Representación molecular	Año
Chemical VAE	QM9 / ZINC	VAE (CNN Enc / GRU Dec)	SMILES	2018
MolGAN	QM9	Implicit GAN (Relational GCN + RL)	Grafo molecular	2018
MOLER	ZINC	Reward shaping sobre JTVAE	Grafo molecular	2022
D-MolVAE	QM9 / ZINC	Graph-based VAE	Grafo molecular	2022
PS-VAE	ZINC250K / QM9	Junction Tree VAE	Subgrafos (Grafos)	2022
PCF-VAE	MOSES	VAE (RNN)	GenSMILES	2025
FRATTVAE	MOSES	Graph Transformer VAE	Grafo molecular	2025
RGCVAE	QM9 / ZINC	Relational Graph VAE	Grafo molecular	2025

Tabla 2.2: *Métricas de evaluación de los modelos generativos.*

Modelo	Dataset	Validez (%)	Unicidad (%)	Novedad (%)
Chemical VAE	ZINC	73.00–79.00	–	–
MolGAN	QM9	98.10	10.40	94.20
MOLER	ZINC	–	–	–
D-MolVAE	QM9	100.00	98.66	95.85
PS-VAE	ZINC250K	100.00	99.70	99.70
PCF-VAE	MOSES	98.01	100.00	93.77
FRATTVAE	MOSES	100.00	99.97	97.42
RGCVAE	QM9	99.90	94.00	96.40

Nota: el guion (–) indica que el trabajo original no reporta dicha métrica.

SMILES. En sus experimentos, el modelo alcanzó una validez del 73–79 % al decodificar puntos cercanos a moléculas reales.

En [46], De Cao y Kipf presentan MolGAN, un modelo generativo adversario que opera directamente sobre grafos moleculares pequeños. El modelo genera de manera simultánea los átomos y los enlaces e incorpora, junto con el entrenamiento adversario, una red de recompensa basada en aprendizaje por refuerzo para guiar la generación hacia mejores propiedades químicas (p. ej., QED, $\log P$ y sintetizabilidad). Está orientado a moléculas de tamaño reducido (entrenado en QM9). Sus principales limitaciones radican en una baja unicidad debido al colapso de modos y dificultades de escalabilidad a grafos mayores. En QM9 reporta una validez del 98.10 %, una unicidad del 10.40 % y una novedad del 94.20 %.

Fu et al. [47] proponen MOLER, un esquema de optimización condicionada que incorpora recompensas a nivel molecular para guiar modelos generativos basados en grafos (acoplable a arquitecturas como JTVAE, VJTNN y CORE). El método añade términos de recompensa y penalización orientados a maximizar la similitud con el compuesto de partida y penalizar la desviación de tamaño, manteniendo así la proximidad estructural mientras se optimiza una propiedad objetivo (QED, afinidad DRD2 o $\log P$). En sus evaluaciones, MOLER incrementa consistentemente la tasa de éxito y la mejora de propiedades respecto de las líneas base (hasta ~20 %) con bajo costo computacional y alta novedad. Como limitaciones, está concebido para optimización local en lugar de generación totalmente *de novo*, no reporta validez ni unicidad bajo protocolos estandarizados (como MOSES o GuacaMol) y su desempeño depende de la calibración de los pesos de similitud y tamaño.

Du et al. [48] introducen *D-MolVAE*, un autoencoder variacional sobre grafos moleculares enfocado en el aprendizaje de representaciones desentrelazadas (*disentangled representation learning*). Esta arquitectura permite aislar factores latentes asociados a distintas propiedades químicas, generando moléculas válidas, únicas y novedosas con una mayor interpretabilidad del espacio latente. Como limitación, el modelo se enfoca en propiedades globales y el desacoplamiento latente se realiza de manera no supervisada, lo que restringe el control determinista sobre propiedades dirigidas específicas.

Kong et al. [49] proponen *PS-VAE* (*Principal Subgraph Variational Auto-Encoder*), un marco generativo que introduce el concepto de «subgrafos principales»: motivos estructurales recurrentes extraídos automáticamente del conjunto de datos mediante un algoritmo de minería *merge-and-update*, prescindiendo de vocabularios predefinidos manualmente. El modelo sigue un procedimiento en dos etapas: primero emplea un VAE con decodificador autorregresivo (GRU) para generar una secuencia de subgrafos y, posteriormente, ensambla dichos fragmentos prediciendo las conexiones interfragmentarias mediante una red neuronal de grafos (GNN). Este enfoque preserva la valencia química y reduce la dependencia del orden de permutación. En el benchmark GuacaMol sobre ZINC250K, PS-VAE alcanza una validez del 100 % (respaldada por verificación de valen-

cias en inferencia), con 99.70 % de unicidad y 99.70 % de novedad. Como contrapartida, la granularidad a nivel de subgrafos dificulta modificaciones atómicas mínimas en tareas de optimización molecular altamente restringidas.

Bhadwal et al. [50] desarrollan *PCF-VAE* (*Posterior Collapse-Free Variational Autoencoder*), una arquitectura condicional orientada a mitigar el problema del colapso del espacio latente (*posterior collapse*). El modelo utiliza la representación *GenSMILES*, la cual simplifica las reglas sintácticas convencionales de SMILES e incrementa la tasa de estructuras químicamente viables. Adicionalmente, implementa una función de pérdida con ponderación dinámica y una capa de control de diversidad estructural. En el benchmark MOSES, reporta una validez del 98.01 %, una unicidad del 100.00 % y una novedad del 93.77 %. No obstante, niveles elevados de diversidad inducen estructuras químicamente inestables, y el desempeño global permanece condicionado a los hiperparámetros de regularización y al preprocesamiento de GenSMILES.

Inukai et al. [51] presentan *FRATTVAE* (*Fragment Tree-Transformer based VAE*), un modelo generativo que representa cada molécula como una estructura de árbol en la que los nodos corresponden a fragmentos moleculares. Sobre dicha representación, se aplica una codificación posicional en árbol que preserva las relaciones jerárquicas y un mecanismo de autoatención tipo Transformer para capturar dependencias de largo alcance entre fragmentos. Este diseño busca resolver las limitaciones de los modelos basados en cadenas lineales ante compuestos de alta complejidad topológica. Evaluado en el benchmark MOSES, reporta una validez del 100.00 %, una unicidad del 99.97 % y una novedad del 97.42 %. Entre sus limitaciones, el espacio de generación depende estrechamente de las reglas de fragmentación adoptadas y el costo computacional de la atención en árbol es considerable frente a modelos recurrentes tradicionales.

Rigoni et al. [52] proponen *RGCVAE* (*Relational Graph Conditioned Variational Autoencoder*), un modelo generativo para grafos moleculares que incorpora en su codificador una red *Relational Graph Isomorphism Network* (RGIN). Esta red es capaz de capturar atributos relacionales complejos, tales como órdenes de enlace y estereoquímica tridimensional. La decodificación se ejecuta en dos pasos paralelizables: primero se seleccionan los tipos atómicos conforme a restricciones de valencia y luego se predicen simultáneamente las conexiones entre ellos. Este esquema agiliza los tiempos de convergencia y asegura una alta precisión de reconstrucción. No obstante, el modelo muestra sensibilidad al equilibrio de hiperparámetros: priorizar la exactitud de reconstrucción reduce la diversidad y unicidad de las moléculas generadas en conjuntos complejos como ZINC.

En resumen, los antecedentes recopilados muestran que los modelos generativos presentan distintas limitaciones según la representación y la arquitectura empleada, existiendo un balance entre la complejidad computacional y la validez química. Modelos generativos basados en representaciones tridimensionales conllevan una mayor carga de procesamiento, muchas veces requiriendo datasets reducidos debido a esta limitación. Esto motiva en este trabajo el desarrollo de un VAE sobre representaciones lineales, explorando distintas configuraciones con un benchmark común con el fin de evaluar la

configuración que mejor favorezca la generación de candidatos a fármacos para su posterior optimización.

2.3.2. Optimización del Espacio Latente Mediante Metaheurísticas

En esta subsección se revisan los principales métodos metaheurísticos que operan sobre el espacio latente de modelos generativos moleculares. La Tabla 2.3 resume las características de cada uno: la descripción del método y el modelo generativo sobre el que actúa, la configuración experimental empleada, las métricas de evaluación reportadas y el blanco terapéutico u objetivo de optimización abordado.

Winter et al. [53] proponen *Molecule Swarm Optimization* (MSO), un método que combina una representación continua del espacio químico con el algoritmo metaheurístico de optimización por enjambre de partículas (PSO). El modelo utiliza un espacio latente preentrenado mediante una arquitectura codificador-decodificador que procesa representaciones SMILES, lo que permite desacoplar la generación de moléculas del proceso de optimización multiobjetivo. Su principal innovación radica en el empleo de PSO para explorar dicho espacio latente, lo que reduce drásticamente el costo computacional y permite manejar con eficiencia la alta dimensionalidad del espacio de búsqueda. MSO logró generar moléculas con alta afinidad predicha hacia los blancos biológicos EGFR y BACE1. Como limitaciones, los autores señalan que al depender de modelos predictivos de relación estructura-actividad cuantitativa (QSAR) para evaluar la función objetivo, el algoritmo puede ser conducido hacia regiones fuera del dominio de aplicabilidad o generar moléculas con artefactos estructurales si no se imponen restricciones adecuadas durante la optimización.

Abouchekeir et al. [54] presentan *ADEL* (*Adversarial Deep Evolutionary Learning*), un marco que combina autoencoders adversariales (AAE) y algoritmos evolutivos para el diseño de fármacos. A diferencia de enfoques previos, emplea redes recurrentes (LSTM) junto con un discriminador para estructurar de forma más regular el espacio latente de cadenas SMILES. Posteriormente, aplica el algoritmo genético multiobjetivo NSGA-II para operar mediante cruce y mutación sobre los vectores latentes, refinando el modelo de manera iterativa al incorporar las nuevas soluciones generadas a la población de entrenamiento. En sus evaluaciones, ADEL generó compuestos que optimizan simultáneamente múltiples propiedades fisicoquímicas (QED, $\log P$ y accesibilidad sintética), identificando moléculas con favorable energía de unión en simulaciones de acoplamiento molecular contra el biomarcador tumoral CA9. Como limitación metodológica, la optimización evolutiva se restringe a descriptores generales, delegando la selectividad hacia el blanco a una etapa posterior de filtrado sobre la última población.

Tabla 2.3: *Optimización del espacio latente mediante metaheurísticas en diseño de fármacos.*

Método (Año)	Descripción	Configuraciones	Métricas	Target / Objetivo
MSO (2019)	*Particle Swarm Optimization* (PSO) sobre un espacio latente continuo construido a partir de representaciones SMILES.	50 o 200 partículas; 100 o 200 iteraciones. Puntos de inicio: benceno o ChEMBL.	Continuas: afinidad a blanco, QED, $\log P$ penalizado, SA y solubilidad. Binarias: filtros de toxicidad y peso molecular.	Optimización mono y multiobjetivo para compuestos contra los blancos EGFR y BACE1.
ADEL (2022)	*Deep Evolutionary Learning* (DEL) sobre el espacio latente continuo de un autoencoder adversarial (AAE) entrenado con secuencias SMILES, con reentrenamiento iterativo incorporando nuevas moléculas generadas.	Población de 20 000 individuos, 10 generaciones.	Continuas: QED, $\log P$, SAS y afinidad de unión (*docking*). Binarias: validez, novedad y unicidad.	Optimización multiobjetivo (QED, $\log P$ y SAS). Filtrado de la última población para cribado virtual contra CA9.
LEOMol (2024)	Algoritmos evolutivos (GA y evolución diferencial) en el espacio latente continuo de un VAE que utiliza representación SELFIES.	Población de 20 individuos, 20 generaciones, tasa de cruce de 0.8 y mutación de 0.4.	Continuas: $\log P$, QED, peso molecular y similitud de Tanimoto. Binarias: restricción de toxicidad.	Optimización maximizando propiedades fisicoquímicas ($\log P$, QED).
Transformer + MO (2024)	MOEA/DD, GrEA, HypE, KnEA, A-NSGA-III y NMPSO sobre un espacio latente continuo basado en SELFIES.	Predicción ADMET con MTL-BERT y *docking* con QuickVina2-GPU.	Continuas: afinidad, SA, $\log P$ y toxicidad aguda (LD_{50}). Binarias: validez, unicidad, novedad y filtros de toxicidad (ClinTox).	Optimización de solubilidad y biodisponibilidad minimizando toxicidad, SAS y afinidad al receptor LPA1.

Continúa en la siguiente página...

Tabla 2.3 – *Continuación*

Método (Año)	**Descripción**	**Configuraciones**	**Métricas**	**Target / Objetivo**
MOMO (2024)	Marco de optimización multiobjetivo basado en dominancia de Pareto para guiar la búsqueda evolutiva en el espacio latente de un modelo codificador-decodificador entrenado con secuencias SMILES.	Población inicial perturbada con ruido gaussiano. Operadores: selección por torneo binario, cruce lineal combinado y mutación ($p = 0.5$).	Continuas: QED, similitud de Tanimoto, eficiencia del ligando (LE), puntuación de *docking*, actividad DRD2, inhibición de GSK3β y SA.	Optimización simultánea multiobjetivo (de 2 a 4 propiedades). Evaluación contra blancos biológicos 1SYH y 4LDE.
MO-LSO (2024)	Optimización multiobjetivo en el espacio latente continuo de un JT-VAE mediante reentrenamiento iterativo ponderado por eficiencia de Pareto.	Entrenamiento inicial con ZINC. Reentrenamiento iterativo ajustado por parámetro de peso (k). Exploración latente por muestreo aleatorio.	Continuas: $\log P$, SAS, similitud a productos naturales (NP score) y probabilidad de inhibición de DRD2 mediante aprendizaje automático.	Optimización multiobjetivo simultánea (hasta 3 propiedades) para maximizar $\log P$, NP score e inhibición de DRD2, y minimizar SAS.
Paddy (2025)	Algoritmo evolutivo basado en el *Paddy field algorithm*, aplicado sobre el espacio latente continuo de un JT-VAE.	Operadores evolutivos inspirados en la dispersión de plantas de arrozal, con tasa de dispersión adaptativa que regula la proximidad y número de nuevas soluciones.	Continuas: $\log P$, SA, número de ciclos con más de 6 átomos y similitud de Tversky.	Optimización de múltiples parámetros integrados en una función objetivo.

El modelo *LEOMol*, introducido por Siddartha Reddy et al. [55], aborda el diseño de fármacos integrando un autoencoder variacional con algoritmos genéticos y evolución diferencial. Al adoptar la representación robusta SELFIES, el sistema garantiza un 100 % de validez química. Su principal ventaja radica en explorar el espacio latente mediante operadores estocásticos poblacionales en lugar de métodos basados en gradientes continuos, lo que facilita optimizar funciones de aptitud complejas evaluadas con herramientas quimioinformáticas estándar. En sus experimentos, demostró alta eficacia para generar compuestos que satisfacen múltiples criterios concurrentes, destacando la generación de moléculas exentas de toxicidad. No obstante, el algoritmo presenta dificultades para converger hacia soluciones viables cuando se le exige preservar una elevada similitud estructural con respecto a un compuesto de partida.

Aksamit et al. [56] proponen un marco de trabajo que integra la arquitectura Transformer con algoritmos metaheurísticos de muchos objetivos (*many-objective optimization*) para el diseño molecular. Este enfoque busca optimizar simultáneamente perfiles farmacocinéticos ADMET y la afinidad de unión estimada mediante acoplamiento molecular. Empleando el modelo ReLSO para proyectar las moléculas en un espacio latente continuo basado en SELFIES, el estudio evalúa y compara el desempeño de diversas metaheurísticas (tales como MOEA/DD, GrEA, HypE, KnEA, A-NSGA-III y NMPSO) en la búsqueda de ligandos dirigidos al receptor LPA1. Como principal limitación, los autores destacan el elevado costo computacional derivado de evaluar el acoplamiento molecular en cada evaluación de aptitud, lo que restringe la sintonización exhaustiva de los hiperparámetros del optimizador.

Xia et al. [57] desarrollan *MOMO* (*Multiobjective Molecule Optimization*), un marco metodológico que guía la búsqueda evolutiva en el espacio químico fundamentándose en el principio de dominancia de Pareto. El método utiliza un codificador-decodificador preentrenado sobre secuencias SMILES para mapear las estructuras moleculares a vectores continuos, sobre los cuales aplica selección por torneo binario, cruce lineal combinado y perturbaciones de mutación. Su fortaleza radica en superar el rendimiento de algoritmos convencionales del estado del arte, reportando mejoras notables en tasa de éxito, novedad e hipervolumen en problemas de optimización de dos a cuatro propiedades simultáneas (incluyendo afinidad contra dianas 1SYH y 4LDE). Como debilidad, el modelo manifiesta susceptibilidad a producir ciertas estructuras químicamente poco realistas si no se imponen restricciones de valencia y filtros estructurales rigurosos durante la fase de decodificación.

Abeer et al. [58] introducen *MO-LSO* (*Multi-Objective Latent Space Optimization*), un método que optimiza el espacio latente de modelos preentrenados tipo JT-VAE a través de un esquema de reentrenamiento iterativo ponderado por la eficiencia de Pareto de las moléculas muestreadas. Esta estrategia permite equilibrar compromisos entre propiedades fisicoquímicas contrapuestas, generando moléculas de alta calidad (como potenciales inhibidores del receptor DRD2) incluso a partir de conjuntos de datos iniciales

desprovistos de ligandos activos. Como contrapartida, el procedimiento iterativo tiende a concentrar las soluciones en regiones localizadas del espacio químico, reduciendo la diversidad estructural de los compuestos finales, a lo que se suma el incremento del costo computacional derivado de los ciclos sucesivos de reentrenamiento.

Beck et al. [59] presentan *Paddy*, un algoritmo de optimización evolutiva inspirado en la dispersión reproductiva de las plantas de arrozal (*paddy field algorithm*), diseñado para explorar sistemas y espacios químicos complejos. A diferencia de los algoritmos genéticos convencionales que dependen de operadores de recombinación cromosómica, Paddy propaga soluciones en el espacio latente de un modelo JT-VAE mediante mutaciones gaussianas reguladas por la densidad local de las soluciones y su aptitud. Esto proporciona una exploración rápida y flexible del espacio paramétrico continuo. Sin embargo, en su formulación para optimización molecular monoproyectada sobre una única función escalar agregada, el método tiende a simplificar las relaciones de compromiso no lineales inherentes a la optimización multiobjetivo de propiedades farmacológicas.

En general, los trabajos revisados muestran la capacidad de las metaheurísticas para navegar espacios latentes, aunque en muchos casos la afinidad a una diana terapéutica se evalúa como un filtrado posterior y no como una función objetivo. De igual manera, son escasos los antecedentes que integran directamente el acoplamiento molecular en una optimización multiobjetivo frente a proteínas transportadoras como MRP1. Asimismo, la mayoría de los estudios se limita a evaluar uno o dos algoritmos aislados, sin realizar una comparación sistemática entre ellos. Esto motiva en este trabajo de grado a evaluar la búsqueda en el espacio latente mediante un enfoque multiobjetivo, contrastando diferentes algoritmos representativos para optimizar simultáneamente la afinidad hacia MRP1 y propiedades farmacológicas deseadas.

3

Metodología

En este capítulo se describe la metodología empleada en esta tesina de grado. Se explica el proceso de ajuste de hiperparámetros y evaluación de metaheurísticas multiobjetivo en el reccorido del espacio latente del modelo generativo, seguido por la formulación del problema de diseño de inhibidores dirigidos a la inhibición de la extracción de quimioterapeúticos del interior de la célula tumoral por parte de MRP1.

3.1. Visión General de la Metodología

Se propone un esquema estructurado en dos etapas. La primera abarca el desarrollo, ajuste y evaluación comparativa de un VAE. La segunda consiste en la exploración de su espacio latente mediante metaheurísticas multiobjetivo para la generación de moléculas. El objetivo de la primera etapa es determinar la configuración con mejor desempeño en la generación molecular y utilizar dicha configuración como base para la posterior búsqueda y optimización de compuestos dirigidos a la diana MRP1.

En la primera etapa se entrena un VAE sobre el benchmark conjuntos moleculares (*Molecular Sets*, MOSES) [60]. El propósito del modelo es comprimir la estructura química de los compuestos en un espacio latente continuo. Su evaluación se realiza bajo el protocolo y las métricas estándar de MOSES para seleccionar la mejor combinación de representación molecular, arquitectura e hiperparámetros.

En la segunda etapa se emplean algoritmos metaheurísticos multiobjetivo para explorar el espacio latente continuo del VAE. Este proceso se divide en dos fases:

1. **Ajuste de hiperparámetros y evaluación en fármacos genéricos:** Se optimizan simultáneamente propiedades fisicoquímicas para comparar el desempeño de los algoritmos y calibrar sus hiperparámetros mediante indicadores químicos y multiobjetivo.
2. **Diseño de inhibidores de MRP1:** Primero se identifica el sitio de unión del sustrato. Con base en esto, se emplean las mejores configuraciones de los algoritmos para optimizar la afinidad hacia la diana, dirigiendo la búsqueda hacia moléculas con interacciones en ese sitio.

La Figura 3.1 resume este flujo de trabajo, combinando el VAE con las metaheurísticas para la búsqueda de moléculas candidatas.

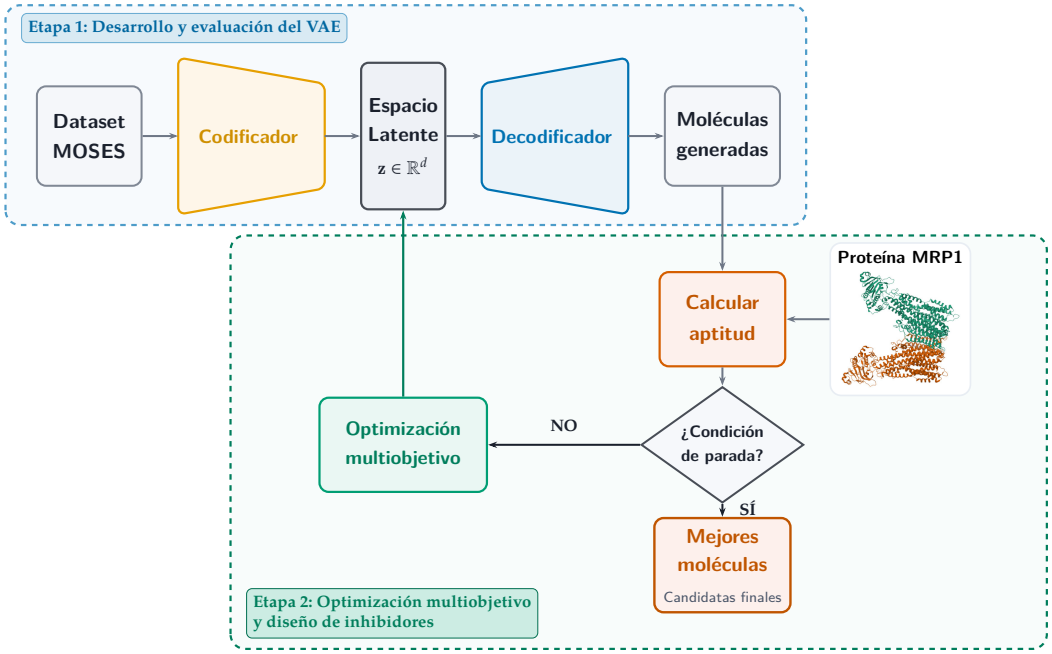


Figura 3.1: *Visión general de la metodología: arquitectura del VAE preentrenado con MOSES y ciclo iterativo de optimización multiobjetivo en el espacio latente para la generación de moléculas candidatas contra MRP1.*

A partir de este esquema se analiza el rendimiento de los algoritmos y la calidad de las moléculas generadas, comparando además los frentes de Pareto obtenidos. Posteriormente en los experimentos dirigidos hacia la diana, se evalúa su afinidad de unión y la formación de interacciones en el sitio de interés. En las siguientes secciones se explica cada uno de estos pasos con mayor detalle.

3.2. Datos de Entrada

En esta sección se presentan los datos y las codificaciones utilizadas para el entrenamiento del modelo generativo. Se detalla el conjunto de datos químicos empleado, sus características y las particiones adoptadas. Se describen ademas las representaciones moleculares evaluadas, sus esquemas de tokenización y los mecanismos de decodificación a partir del espacio latente.

3.2.1. Conjuntos de Datos y Preprocesamiento

Para el entrenamiento del modelo generativo se utiliza el conjunto de datos MOSES [60], obtenido a partir de la colección *Clean Leads* de la base de datos pública ZINC [20]. Este conjunto reúne aproximadamente 1.93 millones de moléculas en formato SMILES con propiedades de compuestos tipo fármaco, previamente filtradas para descartar estructuras inestables, reactivas o con propiedades farmacológicas desfavorables. Estas

moléculas son genéricas y no están dirigidas a ninguna diana biológica en particular. Cuentan con un peso molecular de entre 250 y 350 Da, $\log P \leq 3.5$, hasta 7 enlaces rotables, ciclos de no más de 8 átomos y están formadas únicamente por átomos de C, N, O, S, F, Cl, Br e H.

Para los experimentos se utilizan las particiones oficiales del conjunto de datos, utilizando el conjunto de entrenamiento (~1.58 millones de moléculas) para ajustar el modelo y el conjunto de prueba (~176 mil moléculas) para evaluar su desempeño.

La Figura 3.2 muestra seis moléculas seleccionadas al azar del conjunto de datos junto a su correspondiente notación SMILES.

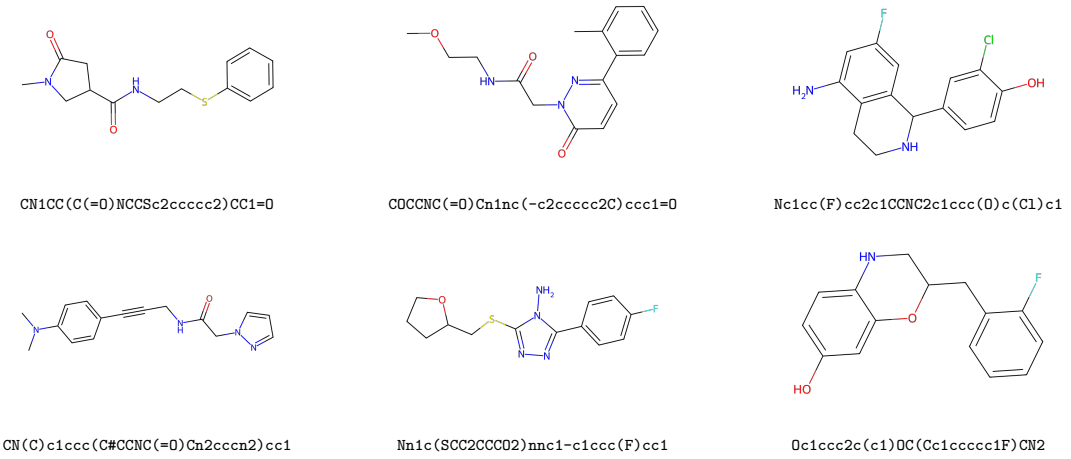


Figura 3.2: *Ejemplos de moléculas del conjunto de datos MOSES y su correspondiente representación lineal en formato SMILES.*

3.2.2. Representaciones Moleculares y Decodificación

En este trabajo se exploran y comparan dos representaciones lineales: SMILES y SELFIES. Se utiliza SMILES por ser el formato estándar del benchmark MOSES, mientras que SELFIES se incorpora para evitar la generación de estructuras sintéticamente inválidas. Comparar ambas permite evaluar el impacto de esta robustez sobre la calidad del espacio latente. En el caso de SMILES, las cadenas se tokenizan mediante la expresión regular propuesta por Cretu et al. [61], preservando átomos multicarácter (como Br y Cl), enlaces, ramas y ciclos como unidades individuales. Para SELFIES, la tokenización se realiza de forma nativa a partir de sus identificadores entre corchetes [24]. En ambas representaciones se incorporan los tokens de control de inicio (`[SOS]`), fin (`[EOS]`), símbolo desconocido (`[UNK]`) y relleno (`[PAD]`) para homogeneizar la longitud de las secuencias en los lotes de entrenamiento. La Figura 3.3 muestra un ejemplo de esta tokenización para una molécula en ambas representaciones.

Esta representación en secuencias de tokens sirve como base para el proceso de decodificación, mediante el cual el modelo reconstruye o genera nuevas moléculas a partir del espacio latente. Para ello, la red decodificadora toma un vector latente $\mathbf{z}$ muestrea-

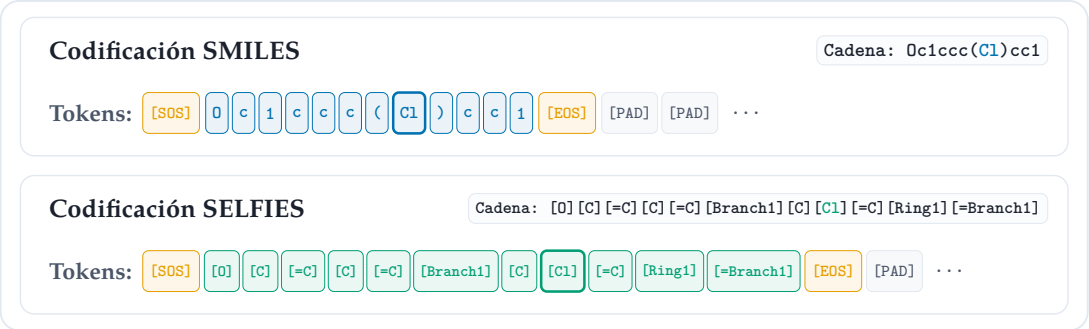


Figura 3.3: *Ejemplo de secuencia y tokenización para una molécula en formatos SMILES y SELFIES, incorporando los tokens especiales de inicio (`[SOS]`), fin (`[EOS]`) y relleno (`[PAD]`).*

do en el espacio continuo y genera de manera autorregresiva una nueva cadena token a token, iniciando con el delimitador `[SOS]` hasta emitir `[EOS]`. Finalmente, la secuencia obtenida se interpreta como una estructura molecular bajo las reglas de la representación empleada (SMILES o SELFIES).

3.3. FASE 1: Ajuste de Hiperparámetros y Evaluación en Fármacos Genéricos

En esta sección se describe la primera etapa metodológica, orientada a dos objetivos principales: seleccionar la mejor configuración del modelo generativo (VAE) a través de un espacio de búsqueda por fases, y calibrar los hiperparámetros de las metaheurísticas multiobjetivo al optimizar propiedades generales en su espacio latente.

3.3.1. Ajustes de Hiperparámetros del VAE

Con el fin de determinar la configuración con mejor desempeño del VAE, el espacio de búsqueda de hiperparámetros se estructuró en dos fases secuenciales, totalizando 72 entrenamientos independientes. Se optó por evaluar primero la estructura del autoencoder y posteriormente sus parámetros de optimización, evitando así escalar el tiempo de cómputo de forma desmedida. Así, la primera fase define la representación y la arquitectura base, y la segunda afina la tasa de aprendizaje y el tamaño de lote en las mejores configuraciones:

- **Fase 1 (Estructura base):** Se evaluaron 48 configuraciones combinando la representación molecular (SMILES y SELFIES), el tipo de celda recurrente (unidad recurrente con compuertas (*Gated Recurrent Unit*, GRU) y memoria de corto y largo plazo (*Long Short-Term Memory*, LSTM)), la cantidad de capas ocultas (1 y 2), la dimensión latente (64, 128 y 256) y las épocas de entrenamiento (100 y 300). La tasa de aprendizaje y el tamaño de lote se mantuvieron fijos en 1×10^{-3} y 128. Las dimensiones latentes se basan en trabajos previos de VAE moleculares [37] para

probar diferentes capacidades de representación, y las épocas buscan evaluar si un entrenamiento prolongado mejora los resultados.

- **Fase 2 (Optimización):** Sobre los cuatro modelos representativos con mejor balance de la fase previa, se exploraron dos tasas de aprendizaje (1×10^{-3} y 1×10^{-4}) y tres tamaños de lote (64, 128 y 192), sumando 24 ejecuciones adicionales. El objetivo fue comprobar si una tasa de aprendizaje más baja (1×10^{-4}) permitía un mejor ajuste y evaluar el efecto de variar el tamaño de lote en el entrenamiento.

El cuadro 3.1 resume las variables y los valores explorados en cada fase.

Tabla 3.1: *Espacio de búsqueda de hiperparámetros del VAE dividido por fases.*

Fase del Experimento	Variable	Valores Explorados	Total
Fase 1: Base (Fijos: LR 1×10^{-3}, Batch 128)	Representación	SMILES, SELFIES	48
	Arquitectura	GRU, LSTM	
	Capas ocultas	1, 2	
	Dimensión Latente	64, 128, 256	
	Épocas de Entrenamiento	100, 300	
Fase 2: Optimización (Mejores 4 Modelos de la Fase 1)	Tasa de Aprendizaje (LR)	1×10^{-3}, 1×10^{-4}	24
	Tamaño de Lote (Batch)	64, 128, 192	
		Total de ejecuciones:	**72**

Esquema de entrenamiento y regularización. Todos los modelos se entrenaron utilizando el optimizador Adam [62]. Para evitar el colapso del espacio latente, se aplicó un aumento gradual del peso de la divergencia KL, inspirado en la implementación *Chemical VAE* [37] y en el benchmark MOSES [60]. En este esquema, el parámetro β se incrementa linealmente desde 0 hasta un valor máximo de 0.3 durante el primer 25 % de las épocas de entrenamiento.

3.3.2. Ajuste de Hiperparámetros de las Metaheurísticas

Una vez determinado el modelo generativo base, esta subsección aborda la calibración de las metaheurísticas multiobjetivo en su espacio latente. Se presentan los cinco algoritmos evaluados, las funciones objetivo y restricciones químicas consideradas, y el diseño experimental adoptado para ajustar sus parámetros.

3.3.2.1. Metaheurísticas Consideradas

Se consideran cinco algoritmos metaheurísticos multiobjetivo para la experimentación, todos ellos operando sobre el espacio latente continuo del VAE:

NSGA-II (Non-dominated Sorting Genetic Algorithm II). Es el algoritmo evolutivo multiobjetivo de referencia y se apoya en la profundidad de dominancia. En cada generación ordena la población en frentes sucesivos de no dominancia mediante un procedimiento de ordenamiento rápido. Los empates dentro de un mismo frente se resuel-

ven con la *distancia de apiñamiento* (*crowding distance*), que mide qué tan poblado está el entorno de cada individuo y favorece a los que se encuentran en regiones menos densas. Estos dos mecanismos, junto con una estrategia elitista, le permiten mantener a la vez convergencia y diversidad [38].

NSGA-III (Non-dominated Sorting Genetic Algorithm III). Conserva el esquema anterior, pero reemplaza la distancia de apiñamiento por un mecanismo de nichos basado en puntos de referencia distribuidos sobre un hiperplano normalizado. Cada solución se asocia al punto de referencia más cercano y sobreviven primero las soluciones asociadas a los puntos con menos representantes. De esta forma se logra una cobertura uniforme del frente incluso cuando crece el número de objetivos [63].

MOEA/D (Multiobjective Evolutionary Algorithm Based on Decomposition). Descompone el problema multiobjetivo en un conjunto de subproblemas escalares, definidos por vectores de pesos, y los optimiza de forma simultánea. Cada subproblema se resuelve usando solo la información de sus subproblemas vecinos. La distribución de las soluciones sobre el frente depende de cómo se distribuyan los vectores de pesos, y no de un mecanismo explícito de preservación de la diversidad [64].

CMOPSO (Competitive Mechanism Based Multi-objective Particle Swarm Optimizer). Pertenece a la familia de la optimización por enjambre de partículas. El rendimiento de los optimizadores convencionales de esta familia depende en gran medida de las mejores soluciones globales y personales guardadas en un archivo externo. CMOPSO, en cambio, selecciona en cada generación un conjunto de partículas élite del propio enjambre, según el frente de no dominancia y la distancia de apiñamiento, y actualiza cada partícula mediante una competencia por pares entre dos élites elegidas al azar: gana la que forma el ángulo menor con la partícula [65].

AGE-MOEA (Adaptive Geometry Estimation Based MOEA). Parte de que el desempeño de los algoritmos multiobjetivo depende de la geometría del frente de Pareto, que puede ser una hipersuperficie euclídea, esférica o hiperbólica. Sobre el esquema de NSGA-II, reemplaza la distancia de apiñamiento por un puntaje de supervivencia que combina diversidad y proximidad mediante una norma L_p adaptativa. La estimación de dicha geometría se realiza mediante un procedimiento de complejidad $O(n \times N)$, donde n es el número de objetivos y N el tamaño de la población. De este modo mantiene un rendimiento competitivo ante frentes de geometrías diversas, donde los algoritmos que suponen una geometría fija tienden a degradarse [66].

3.3.2.2. Funciones Objetivo y Restricciones

En este apartado se describen las funciones objetivo y la restricción estructural empleadas para guiar la búsqueda de los algoritmos en el espacio latente continuo del VAE, todas ellas calculadas con RDKit [67], una librería de quimioinformática utilizada para el análisis y cálculo de descriptores moleculares:

- **QED (*Quantitative Estimate of Drug-likeness*) [26]:** [Problema de maximización] Cuantifica la probabilidad de que una molécula presente propiedades farmacológicas adecuadas. Asigna una puntuación continua entre 0 y 1 mediante funciones de deseabilidad derivadas de múltiples descriptores fisicoquímicos.
- **SAS (*Synthetic Accessibility Score*) [28]:** [Problema de minimización] Evalúa la dificultad teórica para sintetizar la molécula en un laboratorio químico. Asigna una puntuación continua en el rango $[1, 10]$, donde valores menores indican mayor accesibilidad sintética.

Para alejar la búsqueda de estructuras planas, se considera que una mayor proporción de carbonos saturados suele favorecer la solubilidad acuosa [29] y disminuir tanto la promiscuidad biológica como la inhibición de citocromos CYP450 [30].

Restricción de complejidad estructural. La fracción de carbonos con hibridación sp^3 (F_{sp3}) se define como:

$$F_{\text{sp3}} = \frac{\text{número de carbonos } sp^3}{\text{número total de carbonos}} \tag{3.1}$$

Esta propiedad se aplica como restricción de factibilidad ($F_{\text{sp3}} \geq 0.30$). Este límite coincide con los promedios observados en etapas iniciales de descubrimiento (~ 0.32–0.36), intervalo a partir del cual la promiscuidad comienza a descender de forma sostenida [30].

Para gestionar esta restricción, los algoritmos emplean el criterio de dominancia restringida [38], donde las soluciones factibles siempre dominan a las infactibles, y entre infactibles se prioriza la de menor violación. Asimismo, si un vector latente decodifica en una estructura químicamente inválida según RDKit, se le asigna la máxima penalización en ambos objetivos y en la violación de restricción, forzando a la búsqueda a mantenerse dentro de las regiones viables del espacio latente.

3.3.2.3. Protocolo Experimental del Ajuste

Para cada algoritmo se define un espacio de hiperparámetros que se explora mediante un barrido en grilla (*grid search*). Los hiperparámetros se organizan en tres niveles: el reparto del total de evaluaciones (común a todos los algoritmos), los operadores y probabilidades de los algoritmos genéticos, y los parámetros propios de CMOPSO.

Total de Evaluaciones y Tamaño de Población

Se fija un total de 100 000 evaluaciones por ejecución, repartido en tres combinaciones de tamaño de población y número de generaciones (Tabla 3.2). Esta elección permite evaluar el compromiso entre diversidad poblacional (más individuos) y profundidad de búsqueda (más generaciones) bajo un mismo costo computacional.

Tabla 3.2: *Combinaciones de tamaño de población y generaciones evaluadas. Todas mantienen un total fijo de 100 000 evaluaciones.*

Población	Generaciones	Evaluaciones
100	1 000	100 000
200	500	100 000
400	250	100 000

3.3.2.4. Operadores e Hiperparámetros de los Algoritmos Genéticos

Los cuatro algoritmos genéticos (NSGA-II, NSGA-III, MOEA/D y AGE-MOEA) comparten el mismo espacio de hiperparámetros, definido por el tipo de operador de cruce y mutación. Se evalúan los siguientes operadores:

- **Cruce Binario Simulado (SBX) [68]:** Genera dos hijos a partir de dos padres imitando el comportamiento del cruce de un punto en codificación binaria, pero adaptado a variables reales.
- **Cruce Centrado en Padres (PCX) [69]:** Genera cada hijo cerca del centroide de los padres seleccionados, desplazándolo ligeramente hacia uno de ellos y añadiendo una pequeña perturbación aleatoria en las demás direcciones.
- **Mutación Polinomial (PM) [70]:** Perturba cada variable del individuo a partir de una distribución polinomial.
- **Mutación Gaussiana [71]:** Añade a cada variable un ruido aleatorio extraído de una distribución normal.

La Tabla 3.3 resume el espacio de hiperparámetros barrido para los algoritmos genéticos.

Tabla 3.3: *Espacio de hiperparámetros para los algoritmos genéticos (NSGA-II, NSGA-III, MOEA/D, AGE-MOEA).*

Hiperparámetro	Valores evaluados
Tipo de cruce	SBX, PCX
Tipo de mutación	PM, Gaussiana
Probabilidad de cruce (p_c)	0.7, 0.9, 1.0
Probabilidad de mutación (p_m)	0.004, 0.012, 0.031

Para el cruce se evalúan valores de 0.7, 0.9 y 1.0, tomando como referencia el valor $p_c = 0.9$ propuesto en [38]. Las probabilidades de mutación parten de la regla $p_m = 1/n$ [38], que con $n = 256$ dimensiones da $p_m \approx 0.004$; los niveles 0.012 y 0.031 corresponden a perturbar unas 3 y 8 dimensiones por individuo.

3.3.2.5. Operadores e Hiperparámetros de CMOPSO

A diferencia de los algoritmos genéticos, CMOPSO no emplea operadores de cruce, sino una dinámica de enjambre de partículas donde la búsqueda se guía mediante competencias por pares entre partículas seleccionadas de un conjunto élite [65]. Sin embargo, para preservar la diversidad del enjambre y evitar el estancamiento en óptimos locales, el algoritmo sí aplica un operador de mutación polinomial tras la actualización de posiciones. La Tabla 3.4 muestra los hiperparámetros explorados.

Tabla 3.4: *Espacio de hiperparámetros para CMOPSO. Se evalúan todas las combinaciones del grid, resultando en* $3 \times 3 \times 3 = 27$ *configuraciones por tamaño de población, para un total de 81 configuraciones.*

Hiperparámetro	Valores evaluados
Tamaño del conjunto élite (γ)	5, 10, 25
Probabilidad de mutación polinomial (p_m)	0.004, 0.012, 0.031
Tasa de velocidad máxima ($v_{\max}$)	0.1, 0.2, 0.35

Aquí, γ fija la cantidad de partículas que compiten para orientar la búsqueda y $v_{\max}$ regula la velocidad máxima de desplazamiento.

3.3.2.6. Etapas del Protocolo Experimental

El estudio comprende cuatro etapas. Se utiliza el hipervolumen como criterio principal para elegir las mejores configuraciones porque evalúa a la vez la convergencia y la diversidad de las soluciones, sin requerir un frente de referencia previo:

1. **Estudio de hiperparámetros:** Se ejecutan 20 semillas independientes por configuración ($(108 \times 4 + 81) \times 20 = 10\,260$ ejecuciones en total). Para cada combinación de operadores (`pcx/pm`, `pcx/gauss`, `sbx/pm`, `sbx/gauss`) en los algoritmos genéticos y para CMOPSO, se selecciona la mejor configuración interna basándose en el menor rango medio de hipervolumen entre las 20 semillas.
2. **Comparativa de operadores genéticos:** Fijando la mejor configuración de cada combinación de operadores, se analizan las cuatro variantes por algoritmo para evaluar el impacto del cruce y la mutación mediante pruebas estadísticas sobre el hipervolumen e indicadores químicos.
3. **Comparación final frente a *baselines*:** Se toman las mejores configuraciones globales de los cinco algoritmos y se comparan entre sí y contra cuatro métodos de referencia (Aleatorio, Cribado MOSES, Escalador y GA de suma ponderada) sobre todos los indicadores multiobjetivo y químicos.
4. **Análisis del frente conjunto global y moléculas representativas:** Evaluación del frente no dominado conjunto obtenido a partir de las combinaciones de operadores (incorporando las familias de cruce PCX y SBX de todos los algoritmos genéticos y CMOPSO) y análisis de las moléculas representativas.

En total, el estudio comprende 10 260 ejecuciones independientes, cada una con un número fijo de 100 000 evaluaciones.

3.4. FASE 2: Diseño de Inhibidores de la Proteína MRP1

Una vez seleccionada la mejor configuración de las metaheurísticas, se aplica el esquema tomando como diana a MRP1, con el objetivo específico de inhibir la expulsión del irinotecán del espacio intracelular. En esta sección se describe la preparación de la proteína y la identificación de su sitio de unión, la formulación de las funciones objetivo junto con el acoplamiento molecular, y el protocolo de generación de los candidatos.

3.4.1. Preparación de la Proteína y Sitio de Unión

El procedimiento propuesto se organiza en una serie de etapas consecutivas que permiten definir las condiciones necesarias para evaluar las moléculas generadas. Como se muestra en la Figura 3.4, las primeras etapas se centran en la selección y preparación del receptor, seguidas por la identificación y caracterización del sitio de unión mediante simulaciones con un ligando de referencia. Esta información se utiliza posteriormente para delimitar la región de búsqueda que se empleará en los experimentos de docking. Por último, se preparan las estructuras tridimensionales de las moléculas candidatas para llevar a cabo dicha evaluación.

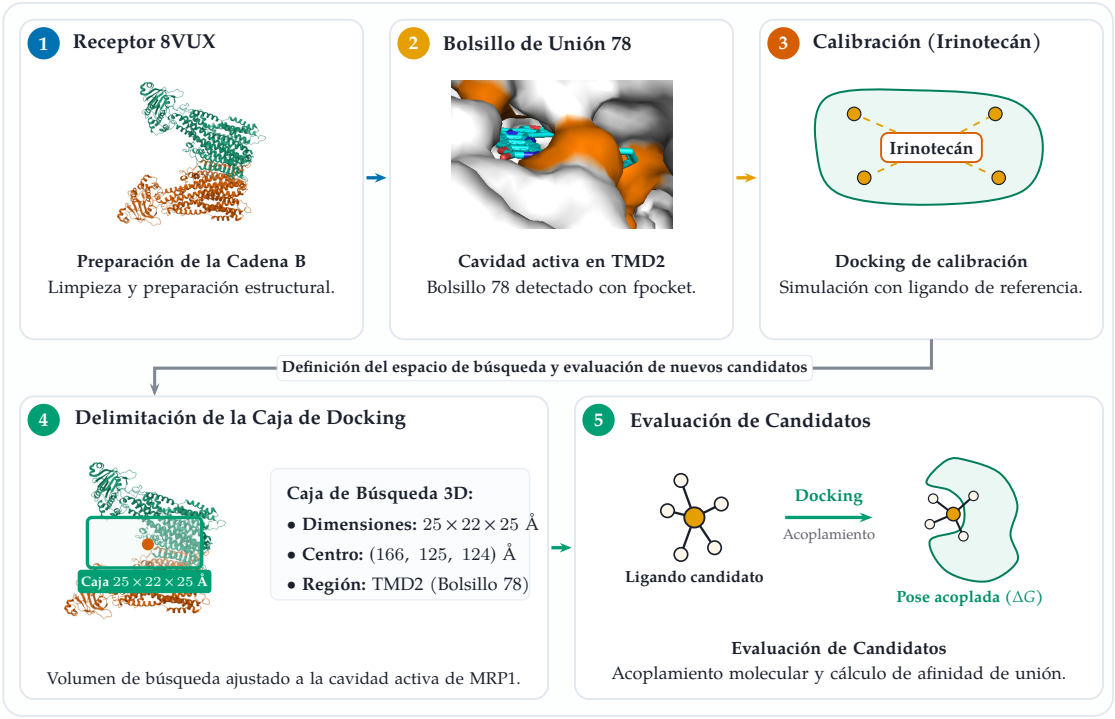


Figura 3.4: *Flujo metodológico en cinco etapas para el modelado de MRP1: preparación del receptor, identificación del bolsillo de unión, calibración con ligando de referencia, delimitación de la caja de docking sobre la cavidad y evaluación de las moléculas candidatas mediante docking.*

Estructura de referencia. Como no existen estructuras en el *Protein Data Bank* que contengan los quimioterápicos de interés unidos a MRP1, se recurre a la literatura. Se utiliza la estructura 8VUX, correspondiente a ABCC1 (MRP1) humano cocristalizado con monofosfato de guanosina-adenosina cíclico (*Cyclic GMP-AMP*, cGAMP) y determinada por microscopía crioelectrónica con una resolución de 3.54 Å (ángstroms, unidad de medida de distancias a escala atómica equivalente a 0.1 nm) [72]. El cGAMP es un nucleótido cíclico mensajero que desempeña un papel clave en la inmunidad innata y en la respuesta contra infecciones y tumores. Si bien el cGAMP no es un quimioterapéutico, los autores del trabajo que reporta la estructura señalan que el sitio donde se une es el sitio de unión del sustrato de MRP1, localizado en el dominio transmembrana TMD2 [72].

Preparación del receptor. Puesto que la proteína en la estructura 8VUX se encuentra como un homodímero, los experimentos de esta tesina se centran únicamente en la cadena B como receptor. Sobre esta se eliminan el cGAMP, el hemisuccinato de colesterol y las moléculas de agua. Posteriormente se añaden los átomos de hidrógeno, se asignan los estados de protonación estándar de cada residuo y las cargas parciales, y se genera el archivo en formato PDBQT con Meeko [73]. El receptor resultante comprende 1005 residuos y 9587 átomos, de los cuales 1658 son hidrógenos polares.

Identificación del sitio de unión. Se procede a identificar los sitios drogables de 8VUX posteriormente a la separación de la proteína del ligando, con énfasis en TMD2 por su asociación con el sitio de unión del sustrato. Para ello se utiliza FPocketWeb [74], que arrojó como resultado una cavidad drogable en TMD2, el bolsillo número 78, con una drogabilidad reportada de 0.738 (probabilidad de drogabilidad elevada), y que además coincide con el sitio de unión del cGAMP. Como resultado, se selecciona el bolsillo 78 como sitio de unión probable de los quimioterápicos. Los demás bolsillos con elevada drogabilidad no se consideran porque corresponden a las cavidades donde se une el ATP para accionar el mecanismo de extracción de MRP1.

Docking ciego y elección de los aminoácidos flexibles. Como no existe una estructura que cocristalice MRP1 con los quimioterápicos de interés, los aminoácidos relevantes se identifican de manera computacional. Para ello se utiliza AutoDock Vina [32, 75] en un docking ciego sobre el bolsillo 78, con el irinotecán como ligando de referencia (PubChem, CID 60838), con el objetivo de determinar las poses más probables y los aminoácidos con los que más interacciona. Vina se configuró con un centro en $(164.6835,\ 130.2140,\ 120.1165)$ Å y una caja de $29.2 \times 35.6 \times 35.0$ Å, una exhaustividad de 32 y la generación de 100 poses.

Para el irinotecán se obtuvo una puntuación de docking de -12.060 kcal/mol y 5 poses. Posteriormente se analizaron los aminoácidos situados a menos de 4 Å del ligando, con el fin de caracterizar las interacciones potenciales en la región de unión; los resultados se resumen en la Tabla 3.5.

Tabla 3.5: *Aminoácidos que con mayor frecuencia se ubicaron a menos de 4 Å del irinotecán en las poses generadas por Vina.*

Rank.	Aminoácido	Frecuencia
1	ASN590	5/5
2	TRP1246	5/5
3	VAL554	4/5
4	TYR1243	4/5
5	THR1242	4/5
6	MET1093	3/5
7	PRO557	3/5
8	ASN1100	3/5
9	ARG1249	3/5
10	PHE594	3/5

Como paso siguiente se realiza un docking sesgado, considerando como flexibles los cinco aminoácidos con mayor interacción (ASN590, TRP1246, VAL554, TYR1243 y THR1242). Se observa una reducción de la energía de unión del orden de -1.180 kcal/-mol, por lo que se infiere que la interacción ligando/proteína mejora al flexibilizar los aminoácidos seleccionados.

Caracterización de la interacción. La figura 3.5 muestra cómo el irinotecán se inserta en la cavidad de MRP1. El ligando se encuentra dentro de una cavidad delimitada por la superficie proteica, en lugar de estar expuesto al solvente, y la molécula parece extenderse a lo largo de un canal o surco. La figura 3.6 muestra el top 5 de aminoácidos que más frecuentemente interactúan con el irinotecán y otros aminoácidos cercanos, indicando cómo se posiciona el ligando con respecto a los aminoácidos de interés. Al calcular las distancias entre cada aminoácido y los átomos del ligando se obtienen los valores de la Tabla 3.6.

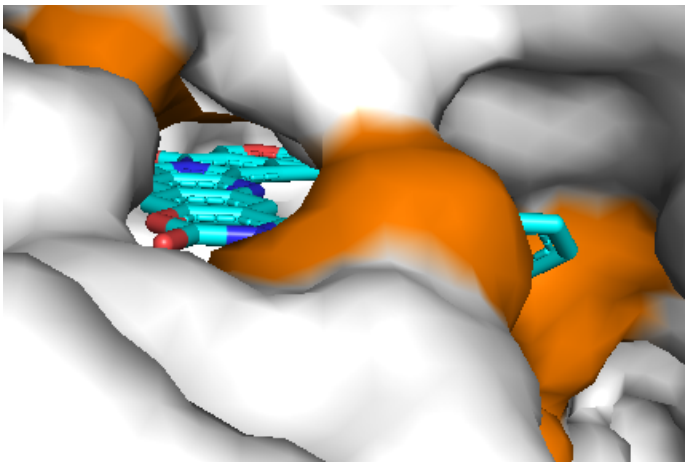


Figura 3.5: *Irinotecán dentro de la cavidad de MRP1. Las partes coloreadas en naranja corresponden a los residuos de interés.*

El TRP1246 presenta 11 pares de átomos con distancias de 2.98 a 3.87 Å en su anillo indólico, lo que es compatible con un contacto de tipo aromático. En la TYR1243, el grupo

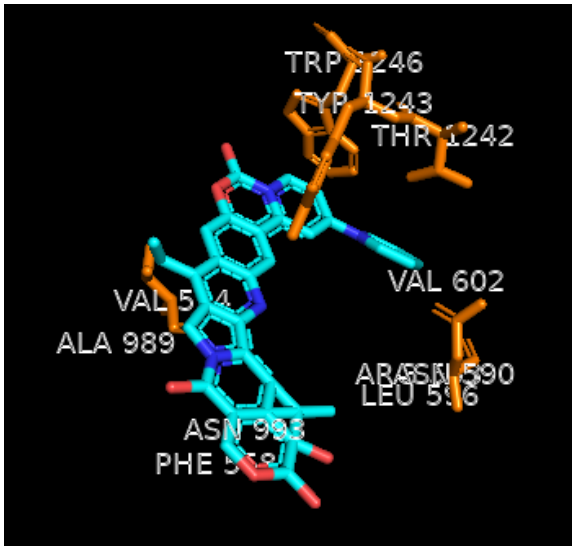


Figura 3.6: *Posición del irinotecán respecto de los cinco aminoácidos que más frecuentemente interactúan con él y de otros aminoácidos cercanos.*

Tabla 3.6: *Distancia entre los aminoácidos de interés y los átomos del irinotecán en la pose analizada.*

Residuo	Distancia mínima (Å)	Pares de átomos ≤ 4 Å
TYR1243	2.79	11
TRP1246	2.98	11
ASN590	3.15	2
VAL554	3.17	10
PHE558	3.51	3
ARG593	3.61	7
THR1242	3.63	1
LEU596	8.51	0

hidroxilo se ubica a 2.79 Å de un carbono del ligando y a 3.28 Å de un nitrógeno, lo que corresponde a un contacto muy cercano. La VAL554 presenta contactos con el carbono CG1 entre 3.17 y 3.51 Å, compatibles con un entorno hidrofóbico, y la ASN590 ubica su oxígeno OD1 a 3.15 Å de un carbono del ligando, lo que indica proximidad pero no demuestra un puente de hidrógeno. La LEU596 se encuentra a 8.51 Å y no participa directamente en esta pose. En consecuencia, se toman TYR1243, TRP1246 y VAL554 como núcleo de la región de interacción, manteniendo ASN590 y ARG593 como residuos de interés para el reconocimiento del ligando, mientras que THR1242 y PHE558 contribuyen a delimitar la geometría de la cavidad sin asumirlos como anclajes esenciales.

Caja de docking para la generación de candidatos. Para los experimentos de diseño se configura una caja de docking con centro en $(166,\ 125,\ 124)$ Å y dimensiones de $25 \times 22 \times 25$ Å, determinada a partir de los aminoácidos con mayor prevalencia en la interacción del irinotecán con el sitio de unión.

Preparación de las moléculas candidatas. Las secuencias lineales decodificadas por el VAE se convierten a su estructura tridimensional con RDKit [67] y se preparan con Meeko [73], que asigna los tipos de átomo, las cargas parciales y las torsiones activas.

3.4.2. Funciones Objetivo y Acoplamiento Molecular

Para el diseño dirigido hacia MRP1 se añade la energía de unión como tercer objetivo junto a QED y SAS, con el fin de guiar la búsqueda hacia la interacción con la diana objetivo. De este modo, se optimizan simultáneamente sobre el espacio latente del VAE:

- **Energía de unión:** [Minimizar] Energía libre de afinidad de unión de la molécula con MRP1, estimada mediante acoplamiento molecular con la función de puntuación de AutoDock Vina [32]. Se utiliza su implementación en GPU, Uni-Dock [33], que reproduce dicha función de puntuación y evalúa un lote de moléculas en paralelo.
- **QED:** [Maximizar] Definida en la sección 3.3.2.2.
- **SAS:** [Minimizar] Definida en la sección 3.3.2.2.

Cada molécula se acopla con el receptor rígido descrito en la subsección 3.4.1, dentro de la caja de docking de los experimentos de diseño, con un modo de búsqueda balanceado y una semilla fija, y se toma la energía de la mejor pose como valor del objetivo.

Se mantiene la restricción de complejidad estructural $F_{\mathrm{sp3}} \geq 0.30$ descrita en la sección 3.3.2.2, evaluada bajo el mismo criterio de dominancia restringida. Si una molécula no puede prepararse o el acoplamiento no produce una pose, se le asigna la máxima penalización en el objetivo de energía $(+1.0$ kcal/mol$)$. Para el cálculo del hipervolumen, la energía de unión se normaliza entre -15.0 y $+1.0$ kcal/mol.

3.4.3. Protocolo de Generación de Candidatos

Se ejecuta la búsqueda dirigida en el espacio latente con las mejores configuraciones seleccionadas en la sección 3.3, con el mismo total de 100 000 evaluaciones por ejecución y 20 semillas independientes. El acoplamiento se realiza con el receptor rígido, dentro de la caja de docking definida en la subsección 3.4.1.

Las moléculas generadas se evalúan en términos de QED, SAS, afinidad, F_{sp3} y características de unión. Adicionalmente, se evalúan la validez, la unicidad y la diversidad de las moléculas generadas.

3.5. Métricas de Evaluación del Rendimiento de los Modelos Considerados

En esta sección se describen las métricas empleadas para evaluar el rendimiento de la metodología. Se presentan las métricas del benchmark MOSES para medir la calidad química, validez y diversidad de las moléculas generadas por el VAE. Además, se detallan los indicadores multiobjetivo utilizados para comparar la convergencia y distribución de las soluciones obtenidas por las metaheurísticas en el espacio latente.

3.5.1. Métricas de Calidad de Generación

Para evaluar y comparar el desempeño de los modelos de VAE entrenados sobre el conjunto de datos MOSES [60], se emplean las métricas estandarizadas del benchmark:

Validez. Proporción de moléculas generadas que son químicamente viables, verificando que cada estructura respete las leyes de valencia y los criterios básicos de estabilidad química:

$$\text{Validez} = \frac{\#\text{moléculas válidas}}{\#\text{moléculas generadas}} \tag{3.2}$$

Unicidad. Evalúa la capacidad del modelo para generar estructuras distintas y evitar la repetición de moléculas:

$$\text{Unicidad} = \frac{\#\text{moléculas generadas únicas}}{\#\text{moléculas generadas}} \tag{3.3}$$

Novedad. Porcentaje de moléculas generadas que aparecen en el conjunto de entrenamiento, evaluando si el modelo generaliza o si memoriza las estructuras conocidas:

$$\text{Novedad} = 1 - \frac{\#\text{moléculas generadas} \cap \#\text{moléculas de entrenamiento}}{\#\text{moléculas generadas}} \tag{3.4}$$

Filtros (*Filters*). Fracción de moléculas generadas que logran superar los filtros aplicados en el conjunto original, evaluando el cumplimiento de PAINS (que descarta compuestos con falsos positivos por interferencia en ensayos biológicos) y MCF (que elimina fragmentos reactivos, inestables o farmacológicamente desfavorables).

Distancia Fréchet ChemNet (FCD). Compara la distribución estadística de las moléculas generadas frente a las de referencia utilizando las activaciones de la red neuronal *ChemNet*:

$$\mathrm{FCD}(G, R) = \|m_G - m_R\|^2 + \mathrm{Tr}\left(C_G + C_R - 2(C_G C_R)^{1/2}\right) \tag{3.5}$$

donde m representa el vector de medias y C la matriz de covarianza de las activaciones para los conjuntos generado (G) y real (R). Los autores de MOSES destacan a FCD como una de las métricas centrales del benchmark porque captura de forma conjunta la distribución de propiedades químicas y la relevancia biológica de los compuestos. Una puntuación cercana a cero indica que el modelo replica con precisión el perfil del conjunto de referencia.

Diversidad Interna (IntDiv). Cuantifica la variedad química dentro del conjunto generado para detectar colapso de modos (*mode collapse*):

$$\mathrm{IntDiv}_p(G) = 1 - \sqrt[p]{\frac{1}{|G^2|} \sum_{m_1, m_2 \in G} T(m_1, m_2)^p} \tag{3.6}$$

donde $T(m_1, m_2)$ evalúa la similitud de Tanimoto entre pares de moléculas generadas. Un resultado cercano a 1 indica alta diversidad estructural.

Distancias de Wasserstein-1 (QED y SAS). Cuantifica la diferencia entre las distribuciones de los datos reales y los generados para la SAS y la QED. Un valor cercano a cero indica que el modelo reproduce con precisión tanto los promedios como la dispersión de estas propiedades en el conjunto de referencia.

3.5.2. Indicadores de Rendimiento Multiobjetivo

La evaluación de metaheurísticas multiobjetivo representa un desafío particular ya que el resultado del proceso de optimización no es una única solución, sino un conjunto de soluciones no dominadas. Por lo tanto para evaluar el rendimiento de diferentes algoritmos es necesario comparar conjuntos enteros de soluciones. No existe un estándar único para evaluar estas soluciones los indicadores de calidad o métricas de desempeño se clasifican según sus propiedades y según el objetivo que evalúan [10]:

- **Indicadores de convergencia:** Evalúan la eficacia de las soluciones en términos de su cercanía al frente de Pareto óptimo. Ejemplos destacados incluyen la distancia generacional (*Generational Distance*, GD) y la distancia generacional invertida (*Inverted Generational Distance*, IGD), que calculan la distancia promedio entre el con-

junto aproximado y un conjunto de referencia, y el Indicador ϵ, que determina el factor mínimo de traslación necesario para que una aproximación domine a otra.

- **Indicadores de diversidad:** Miden la uniformidad y extensión de la distribución de las soluciones obtenidas a lo largo del frente. Indicadores como el Espaciado (*Spread*) o la Entropía penalizan los frentes donde las soluciones se agrupan excesivamente en una sola región del espacio de objetivos. Suelen tener un costo computacional mayor que los indicadores de convergencia.
- **Indicadores híbridos:** Evalúan tanto la convergencia como la diversidad del conjunto de soluciones. Tales como el hipervolumen (*Hypervolume*, HV), un indicador que calcula el volumen del espacio de objetivos que es débilmente dominado por el conjunto de aproximación respecto a un punto de referencia [10].

A partir de esta clasificación, los indicadores de rendimiento considerados en el marco metodologico son los siguientes:

Hipervolumen (HV). Mide el volumen de la región del espacio de objetivos que domina el conjunto de soluciones obtenido, acotada por un punto de referencia (Figura 3.7a). Cuanto mayor es ese volumen, mejor es el conjunto tanto en convergencia como en diversidad, de modo que resume ambos aspectos. Su ventaja práctica es que no exige conocer el frente de Pareto óptimo, sino únicamente el punto de referencia.

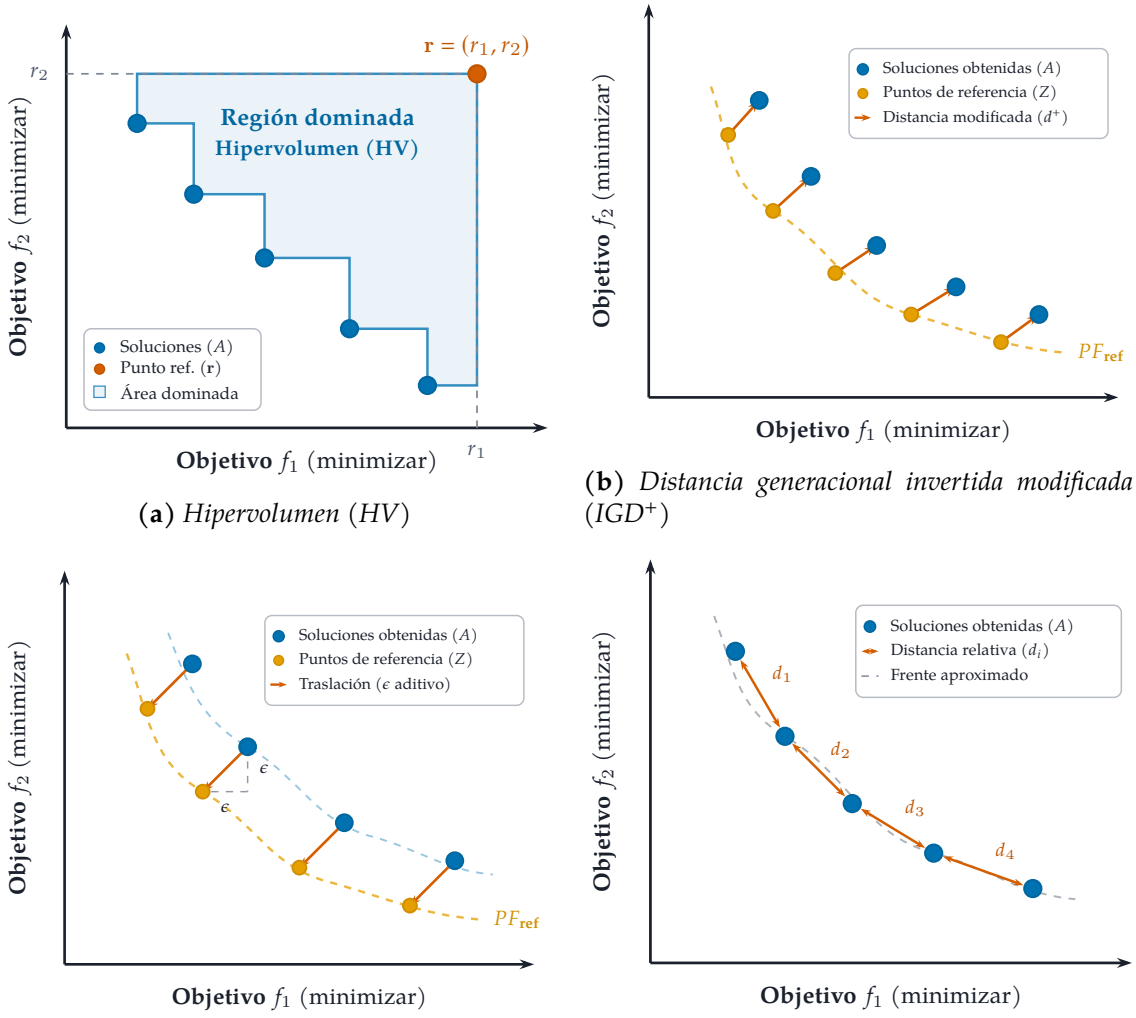
Distancia generacional invertida modificada ($\mathbf{IGD^+}$). Promedia la distancia que separa a cada punto de un conjunto de referencia de la solución más próxima del conjunto obtenido, contabilizando solo las componentes en las que esa solución es peor (Figura 3.7b). Valores bajos indican que el frente obtenido se aproxima al de referencia.

Indicador ϵ aditivo. Expresa cuánto habría que desplazar el conjunto obtenido para que llegue a dominar débilmente al de referencia (Figura 3.7c). Cuanto menor es ese desplazamiento, más próximos están ambos frentes, y un valor no positivo significa que el conjunto obtenido ya lo domina. A diferencia de la IGD^+, que evalúa la proximidad promedio, este indicador actúa como un criterio de peor caso determinado por la región más desfavorable del frente.

Espaciamiento (*Spacing*). Refleja con qué uniformidad se reparten las soluciones a lo largo del frente (Figura 3.7d), a partir de la dispersión de las distancias entre soluciones vecinas. Valores bajos corresponden a frentes donde las soluciones están espaciadas de manera regular, sin acumulaciones ni huecos.

Tamaño del frente de Pareto. Cuenta las soluciones no dominadas obtenidas, esto es, cuántas alternativas de compromiso distintas llega a ofrecer el algoritmo. Por sí solo no permite juzgar la calidad del frente.

Los dos indicadores basados en distancias, IGD^+ y el indicador ϵ aditivo, necesitan un conjunto de referencia que aproxime el frente de Pareto óptimo. Como en el diseño de moléculas ese frente no se conoce, dicho conjunto se construye de forma empírica [76].



(a) *Hipervolumen (HV)*

(b) *Distancia generacional invertida modificada (IGD^+)*

(c) *Indicador ϵ aditivo*

(d) *Espaciamiento (Spacing)*

Figura 3.7: *Interpretación geométrica de los principales indicadores de rendimiento multiobjetivo evaluados en un espacio bidimensional a minimizar: (a) región dominada acotada por el punto de referencia* $\mathbf{r}$ *(HV); (b) distancia mínima desde los puntos de referencia* Z *a las soluciones aproximadas* A *(IGD^+); (c) traslación requerida para dominar el frente de referencia (indicador* ϵ *aditivo); y (d) homogeneidad en la distribución espacial de las soluciones obtenidas (Spacing).*

3.6. Herramientas y Tecnologías de Implementación

En esta sección se describen las herramientas y tecnologías empleadas en el entrenamiento y evaluación del modelo generativo, la exploración del espacio latente mediante optimización multiobjetivo y el acoplamiento molecular sobre la proteína MRP1. Conda facilitó la gestión de dependencias y entornos virtuales de Python (Versión 3.12.3), utilizándose las siguientes herramientas y librerías principales:

- **PyTorch (Versión 2.12.1):** Utilizado para construir y entrenar las redes neuronales recurrentes (GRU y LSTM) del VAE.
- **pymoo (Versión 0.6.1.6):** Utilizado para ejecutar los algoritmos de optimización multiobjetivo, sus operadores y las métricas de rendimiento.
- **RDKit (Versión 2026.03.3):** Utilizado para validar estructuras químicas, calcular propiedades moleculares (QED, SAS, F_{sp3}) y generar conformaciones 3D.
- **SELFIES (Versión 2.2.0):** Representación molecular basada en cadenas válidas, empleada como alternativa a SMILES.
- **MOSES (Versión 0.3.1):** Benchmark para evaluar el modelo generativo y calcular métricas de distribución y calidad química.
- **Uni-Dock (Versión 1.2.0):** Motor de acoplamiento molecular en GPU, utilizado para evaluar la afinidad de unión contra MRP1.
- **AutoDock Vina (Versión 1.2.7):** Utilizado en el docking ciego y con residuos flexibles para caracterizar el sitio de unión de MRP1.
- **Meeko (Versión 0.8.0):** Utilizado para preparar receptores y ligandos en formato PDBQT para el acoplamiento molecular.
- **FPocket:** Utilizado para identificar y evaluar la drogabilidad de cavidades en la estructura de MRP1.

Además, para el desarrollo, redacción y diseño de esquemas se utilizaron Git para el control de versiones, LaTeX para la composición tipográfica de texto, fórmulas y bibliografía, Visual Studio Code como entorno integrado de desarrollo y TikZ para la creación de los diagramas y esquemas.

En cuanto a los recursos de hardware, los experimentos se llevaron a cabo en el Clúster Toko (FCEN-UNCuyo) sobre nodos con 16 vCPUs y 128 GB de memoria RAM: se empleó una GPU NVIDIA TITAN Xp para el entrenamiento del modelo generativo (VAE), y nodos equipados con GPU NVIDIA GeForce RTX 4080 para las tareas de optimización multiobjetivo y acoplamiento molecular.

4

Resultados y Discusión

En este capítulo se presentan los resultados obtenidos de las experimentaciones realizadas en este trabajo. En primer lugar, se examinan los resultados del ajuste de hiperparámetros del modelo generativo (VAE) a través de sus dos fases experimentales y se compara el desempeño de la mejor configuración frente al estado del arte en el benchmark MOSES. A continuación, se describen los resultados de la calibración de las metaheurísticas multiobjetivo en la generación de fármacos genéricos, analizando el impacto de los diferentes operadores. Finalmente, se evalúa la aplicación del enfoque propuesto en el diseño guiado de inhibidores de la proteína MRP1, analizando la afinidad de unión obtenida mediante acoplamiento molecular y las propiedades fisicoquímicas de las mejores moléculas candidatas.

4.1. Resultados del Modelo Generativo (VAE)

En esta sección se aborda la evaluación del modelo generativo sobre el conjunto de datos MOSES. Se presentan los resultados de las fases de ajuste de hiperparámetros y se examina el comportamiento del modelo seleccionado en dicho benchmark frente a otros enfoques de la literatura.

4.1.1. Ajuste de Hiperparámetros: Fase 1 (Arquitectura y Representación)

Cada configuración se identifica con la representación (SM para SMILES, SE para SELFIES), la arquitectura (L para LSTM, G para GRU), el número de capas y la dimensión latente. Por ejemplo, SM-L 2 256 corresponde a SMILES, LSTM, 2 capas y latente de 256.

La Tabla 4.1 muestra los resultados de la Fase 1 con 100 épocas de entrenamiento, y la Tabla 4.2 los de 300 épocas.

Tabla 4.1: *Fase 1: Resultados Experimentales de Generación Molecular (100 Épocas)*

ID	Val ↑	Uni ↑	Nov ↑	Filter ↑	FCD ↓	IntDiv ↑	SA ↓	QED ↓	Tiempo
SM-G 1 64	0.6048	0.9995	**0.9976**	0.9095	2.4573	0.8661	0.4919	0.0415	09:32:53
SM-G 1 128	0.8330	0.9999	0.9924	0.9441	1.3965	0.8600	0.3246	0.0273	02:34:12
SM-G 1 256	0.9145	**1.0000**	0.9811	0.9746	0.5655	0.8569	0.1594	**0.0126**	04:35:19
SM-G 2 64	0.7483	1.0000	0.9947	0.9486	1.5919	0.8616	0.3767	0.0316	04:46:52
SM-G 2 128	0.8931	**1.0000**	0.9830	0.9732	0.6699	0.8596	0.2336	0.0138	03:19:52
SM-G 2 256	**0.9449**	0.9998	0.9685	0.9821	0.4700	0.8586	**0.1150**	0.0053	08:19:48
SM-L 1 64	0.6317	**1.0000**	0.9966	0.9292	1.9910	**0.8663**	0.4769	0.0500	02:16:19
SM-L 1 128	0.8287	**1.0000**	0.9903	0.9573	1.2077	0.8631	0.3358	0.0211	02:50:02
SM-L 1 256	0.9224	**1.0000**	0.9769	0.9784	0.5341	0.8596	0.1834	0.0195	04:20:21
SM-L 2 64	0.8161	**1.0000**	0.9892	0.9640	0.9826	0.8640	0.3079	0.0326	02:41:42
SM-L 2 128	0.9082	0.9999	0.9840	0.9714	0.7658	0.8638	0.2393	0.0230	03:35:58
SM-L 2 256	0.9434	0.9999	0.9618	**0.9849**	**0.4125**	0.8587	0.1410	0.0130	08:05:22
SE-G 1 64	**1.0000**	0.9996	**0.9999**	0.5468	16.6096	0.8897	1.7459	0.1958	02:32:52
SE-G 1 128	**1.0000**	0.9997	0.9973	0.6921	9.0081	0.8812	1.1759	0.1030	02:36:18
SE-G 1 256	**1.0000**	**0.9999**	0.9879	0.8261	3.7491	0.8683	0.6360	0.0499	04:42:11
SE-G 2 64	**1.0000**	0.9998	0.9987	0.6582	10.5668	0.8826	1.2688	0.1278	03:08:15
SE-G 2 128	**1.0000**	**0.9999**	0.9906	0.8083	3.8895	0.8703	0.6685	0.0693	03:27:05
SE-G 2 256	**1.0000**	0.9997	0.9833	0.8517	2.9528	0.8663	0.5592	0.0510	08:51:40
SE-L 1 64	**1.0000**	0.9979	0.9991	0.5904	12.1475	**0.8831**	1.3856	0.1770	02:10:52
SE-L 1 128	**1.0000**	**0.9999**	0.9970	0.7151	8.0543	0.8799	1.0965	0.1100	02:53:50
SE-L 1 256	**1.0000**	**0.9999**	0.9880	0.8311	3.4543	0.8716	0.6284	0.0625	04:15:32
SE-L 2 64	**1.0000**	**0.9999**	0.9969	0.7140	7.6215	0.8817	1.0768	0.1182	02:43:37
SE-L 2 128	**1.0000**	**0.9999**	0.9894	0.8231	3.6458	0.8719	0.6502	0.0658	03:32:51
SE-L 2 256	**1.0000**	0.9997	0.8814	**0.9277**	**0.7642**	0.8609	**0.2007**	**0.0196**	08:59:13

Tabla 4.2: *Fase 1: Resultados Experimentales de Generación Molecular (300 Épocas)*

ID	Val ↑	Uni ↑	Nov ↑	Filter ↑	FCD ↓	IntDiv ↑	SA ↓	QED ↓	Tiempo
SM-G 1 64	0.5923	0.9999	0.9978	0.9040	2.5791	0.8661	0.5527	0.0430	10:53:24
SM-G 1 128	0.8126	**1.0000**	0.9925	0.9493	1.4190	0.8637	0.3731	0.0191	10:44:32
SM-G 1 256	0.2486	0.9998	0.9912	0.9170	5.5216	0.8603	0.5843	0.0340	17:20:11
SM-G 2 64	0.7617	**1.0000**	0.9939	0.9425	1.4415	0.8620	0.3546	0.0266	12:47:02
SM-G 2 128	0.0034	0.7857	**1.0000**	0.4167	35.7960	**0.9049**	0.8052	0.3806	12:32:25
SM-G 2 256	0.7879	0.9999	0.9844	0.9683	1.0484	0.8595	0.2054	0.0120	26:10:15
SM-L 1 64	0.6735	**1.0000**	0.9966	0.9301	2.1199	0.8657	0.4946	0.0426	04:37:36
SM-L 1 128	0.8544	**1.0000**	0.9887	0.9641	1.0559	0.8617	0.3053	0.0163	04:48:36
SM-L 1 256	0.9461	0.9999	0.9715	0.9807	0.4588	0.8593	0.1553	**0.0114**	07:30:22
SM-L 2 64	0.7832	**1.0000**	0.9938	0.9492	1.5143	0.8665	0.4109	0.0357	06:58:03

Continúa en la siguiente página...

Tabla 4.2 – Continuación de la página anterior

ID	Val ↑	Uni ↑	Nov ↑	Filter ↑	FCD ↓	IntDiv ↑	SA ↓	QED ↓	Tiempo
SM-L 2 128	0.9091	0.9999	0.9815	0.9744	0.6738	0.8642	0.2312	0.0233	07:35:45
SM-L 2 256	**0.9514**	1.0000	0.9559	**0.9864**	**0.3214**	0.8579	**0.1129**	0.0126	10:19:52
SE-G 1 64	**1.0000**	0.9899	0.9998	0.5650	16.4825	0.8928	1.7408	0.2109	10:48:12
SE-G 1 128	**1.0000**	0.7798	**1.0000**	0.5435	36.4865	0.9078	1.8901	0.5455	06:51:58
SE-G 1 256	**1.0000**	0.3196	**1.0000**	0.7144	42.3145	**0.9703**	2.9268	0.4431	12:33:11
SE-G 2 64	**1.0000**	0.9997	0.9981	0.7178	8.3782	0.8786	1.1093	0.1077	08:24:36
SE-G 2 128	**1.0000**	0.9961	**1.0000**	0.4366	34.5677	0.8805	2.6126	0.2739	09:57:54
SE-G 2 256	**1.0000**	**1.0000**	0.9887	0.8067	4.4307	0.8727	0.7486	0.0574	14:03:36
SE-L 1 64	**1.0000**	0.9994	0.9996	0.5598	14.2082	0.8887	1.5028	0.1909	10:01:24
SE-L 1 128	**1.0000**	0.9996	0.9961	0.7318	6.8969	0.8772	1.0110	0.0933	05:08:21
SE-L 1 256	**1.0000**	**1.0000**	0.9803	**0.8736**	**2.1698**	0.8651	**0.4525**	0.0455	09:43:56
SE-L 2 64	**1.0000**	0.9996	0.9976	0.7077	8.3676	0.8810	1.0930	0.1255	09:26:53
SE-L 2 128	**1.0000**	**1.0000**	0.9856	0.8269	3.3049	0.8712	0.6277	**0.0561**	05:20:24
SE-L 2 256	**1.0000**	0.9965	0.9986	0.4967	15.0077	0.8935	1.5616	0.1972	10:57:46

4.1.1.1. Análisis de la Fase 1

Al analizar las métricas obtenidas en los experimentos, surgen distintos patrones que nos permiten definir las mejores arquitecturas para balancear tanto la calidad del espacio químico que exploran como la validez de las moléculas generadas:

SMILES vs. SELFIES Si bien la representación de SELFIES cumple con su diseño, garantizando una validez perfecta en todas las ejecuciones, las redes entrenadas con SMILES logran capturar con mayor precisión la distribución estadística y las propiedades de las moléculas reales. Esto se refleja en puntuaciones de FCD y distancias de Wasserstein (SA y QED) notablemente inferiores a las de los modelos SELFIES.

Dimensionalidad El espacio latente de 256 es en general superior al de 64 y 128. El aumento de dimensionalidad permite al modelo representar en sus vectores latentes mayores características químicas y da como resultado un mejor FCD y una mayor validez general en los modelos SMILES.

LSTM vs. GRU Las redes LSTM demostraron ser más resilientes a entrenamientos prolongados. Al pasar de 100 a 300 épocas, las arquitecturas LSTM tendieron a mejorar sus métricas. Por el contrario, varios modelos GRU sufrieron un colapso o inestabilidad al pasar a las 300 épocas, reduciendo drásticamente la validez general de las moléculas generadas.

La mayor estabilidad de las redes LSTM en entrenamientos prolongados podría atribuirse a la presencia de una compuerta de salida, la cual permite controlar y atenuar la magnitud de su memoria antes de transmitirla a las siguientes capas. En contraste, la arquitectura GRU carece de este mecanismo [77]. Al exponer su memoria de forma directa, en épocas avanzadas se generaría un conflicto numérico con la regularización del VAE, lo que propiciaría el colapso del modelo.

4.1.1.2. Selección de modelos

La fase 2 de la optimización de hiperparámetros se centra en probar diferentes tasas de aprendizaje y tamaños de lote; por lo cual, se seleccionarán aquellas configuraciones que muestren tanto una generación estructural adecuada como un mejor balance en las métricas que miden la calidad de la generación molecular (FCD, SA, QED). Dado que todos los modelos seleccionados comparten un espacio latente de 256 dimensiones, este valor se omitirá en su nomenclatura.

SM-L 2 (300 épocas) Logró el FCD más bajo de todos los registros (0.3214), manteniendo una validez considerable (0.9514) y excelentes distancias para SA (0.1129) y QED (0.0126).

SM-G 2 (100 épocas) Aunque la arquitectura GRU se volvió inestable a las 300 épocas, su desempeño temprano fue sobresaliente. A las 100 épocas, este modelo obtuvo un notable FCD (0.4700) y una validez de 0.9449.

SE-L 2 (100 épocas) Si bien la representación SELFIES mostró consistentemente peores resultados que SMILES, el modelo seleccionado consiguió los mejores resultados frente a sus contrapartes que utilizan la misma representación, obteniendo el FCD más bajo (0.7642) y menores distancias de Wasserstein. En oposición, presenta una novedad pobre (0.8814), por lo cual es significativo observar si esta métrica mejora al explorar otras tasas de aprendizaje y tamaños de lote.

SM-L 1 (300 épocas) Representa una alternativa con menor profundidad de red, a las 300 épocas consiguió el segundo mejor FCD (0.4588), logrando una validez muy alta (0.9461). Se aspira a observar si el costo de añadir una segunda capa justifica la mejora en rendimiento que presenta el experimento SM-L 2 256.

4.1.2. Ajuste de Hiperparámetros: Fase 2 (Optimización de Entrenamiento)

La Tabla 4.3 muestra los resultados de la Fase 2 para los cuatro modelos seleccionados, evaluados con distintas combinaciones de tasa de aprendizaje y tamaño de lote.

Tabla 4.3: *Fase 2: Resultados de Optimización (Mejores 4 Modelos)*

LR	Batch	Val ↑	Uni ↑	Nov ↑	Filter ↑	FCD ↓	IntDiv ↑	SA ↓	QED ↓	Tiempo
Modelo: SM-L 2 (300 épocas)										
1×10^{-3}	64	0.9571	0.9999	0.9560	0.9867	0.2944	0.8573	0.1144	0.0147	19:53:13
1×10^{-3}	128	0.9514	**1.0000**	0.9559	0.9864	0.3214	0.8579	0.1129	0.0126	10:19:52
1×10^{-3}	192	0.9572	0.9999	0.9531	0.9863	0.2818	0.8589	0.1168	0.0095	07:15:25
1×10^{-4}	64	**0.9624**	0.9999	0.9434	**0.9884**	**0.1790**	0.8590	**0.0932**	0.0083	23:25:24
1×10^{-4}	128	0.9596	0.9999	0.9504	0.9876	0.2284	**0.8591**	0.1015	**0.0071**	13:45:28
1×10^{-4}	192	0.9567	**1.0000**	**0.9570**	0.9859	0.2570	0.8587	0.1251	0.0108	08:54:27
Modelo: SM-G 2 (100 épocas)										
1×10^{-3}	64	0.4590	**1.0000**	**0.9911**	**0.9386**	2.2125	0.8571	0.4210	0.0369	07:58:37
1×10^{-3}	128	0.9449	0.9998	0.9685	0.9821	0.4700	**0.8586**	0.1150	**0.0053**	08:19:48
1×10^{-3}	192	0.9425	**1.0000**	0.9682	0.9819	0.3598	0.8580	0.1347	0.0074	02:50:26
1×10^{-4}	64	**0.9500**	0.9999	0.9658	0.9835	**0.3014**	0.8580	**0.1114**	0.0064	08:10:05
1×10^{-4}	128	0.9357	0.9999	0.9706	0.9802	0.3460	0.8580	0.1288	0.0089	04:20:09
1×10^{-4}	192	0.9377	0.9999	0.9723	0.9768	0.4178	**0.8586**	0.1593	0.0055	02:53:20
Modelo: SE-L 2 (100 épocas)										
1×10^{-3}	64	**1.0000**	0.9996	0.9664	0.8151	3.6421	0.8705	0.5998	0.0632	06:34:09
1×10^{-3}	128	**1.0000**	0.9997	0.8814	0.9277	0.7642	0.8609	0.2007	0.0196	08:59:13
1×10^{-3}	192	**1.0000**	0.9992	0.8676	**0.9358**	**0.6751**	0.8615	**0.1853**	**0.0176**	02:26:16
1×10^{-4}	64	**1.0000**	**1.0000**	0.9762	0.8856	1.7909	0.8661	0.4262	0.0369	07:51:36
1×10^{-4}	128	**1.0000**	**1.0000**	0.9808	0.8732	2.0787	0.8669	0.4783	0.0417	03:29:25
1×10^{-4}	192	**1.0000**	**1.0000**	**0.9881**	0.8456	2.8927	**0.8713**	0.5756	0.0549	02:26:25
Modelo: SM-L 1 (300 épocas)										
1×10^{-3}	64	0.9420	**1.0000**	0.9696	**0.9815**	0.4488	0.8600	0.1596	0.0156	15:43:28
1×10^{-3}	128	**0.9461**	0.9999	0.9715	0.9807	0.4588	0.8593	**0.1553**	**0.0114**	07:30:22
1×10^{-3}	192	0.9211	**1.0000**	0.9783	0.9775	0.6037	0.8626	0.2421	0.0172	05:52:49
1×10^{-4}	64	0.9404	**1.0000**	0.9733	0.9797	**0.4242**	0.8588	0.1587	0.0129	19:07:21
1×10^{-4}	128	0.9047	0.9999	**0.9834**	0.9739	0.7291	**0.8633**	0.2673	0.0220	09:12:05
1×10^{-4}	192	0.9057	**1.0000**	0.9822	0.9762	0.6389	0.8622	0.2335	0.0207	05:03:35

4.1.2.1. Análisis de la Fase 2

Impacto de la Tasa de Aprendizaje (LR) La reducción de la tasa de aprendizaje de 1×10^{-3} a 1×10^{-4} muestra en general una mejora en las arquitecturas con representación SMILES en la calidad del espacio químico generado. Esta mejora se refleja en la obtención de mejores puntuaciones en las métricas de FCD y en las distancias de Wasserstein de estos modelos.

Por otro lado, la arquitectura SELFIES presentó en general mejores resultados con un learning rate de 1×10^{-3}, manteniendo la validez perfecta que le otorga esta representación, pero aun así mostrando peores métricas en cuanto a la calidad del espacio químico que sus contrapartes.

Impacto del tamaño de lote (Batch) De forma general, con excepción de los modelos SELFIES, configurar el entrenamiento con tamaños de lotes más pequeños, específicamente 64, en combinación con una tasa de aprendizaje de 1×10^{-4}, produce los mejores resultados, con el mejor FCD de cada modelo SMILES correspondiente a estos valores.

Tiempos de entrenamiento La tendencia de los datos nos muestra que existe un contraste entre la calidad del modelo y su costo computacional al modificar el tamaño de lote y los tiempos de entrenamiento, con los modelos de 300 épocas llegando a superar las 20 horas de entrenamiento con esos tamaños de lote. Sin embargo, asumir este gasto es necesario, ya que, como se mencionó previamente, a tamaños de lote más pequeños, se obtienen mejores resultados.

4.1.2.2. Análisis por Modelo

SM-L 2 (300 épocas) Esta arquitectura mostró los mejores resultados de toda la etapa experimental. Su configuración óptima (LR de 1×10^{-4} y Batch de 64) alcanzó conjuntamente la validez más alta de las arquitecturas SMILES y el FCD más bajo de todos los registros analizados (0.1790). De igual manera, el modelo alcanzó la menor distancia de Wasserstein para la distribución de Accesibilidad Sintética (SA) en todo el experimento (0.0932). En contraste, este modelo presentó una métrica de novedad levemente menor en comparación con las demás arquitecturas evaluadas (0.9434) y requirió el mayor tiempo de ejecución de todos los experimentos de la segunda fase.

SM-G 2 (100 épocas) Su mejor comportamiento se registró utilizando un LR de 1×10^{-4} y un Batch de 64, donde consiguió un FCD competitivo de 0.3014 y una validez de 0.9500. Además, presentó valores adecuados en las métricas de novedad (0.9658) y Filter (0.9835), logrando distancias de Wasserstein bajas para las distribuciones de SA (0.1114) y QED (0.0064). Esta arquitectura demuestra capacidad para generar un espacio químico de calidad con menos épocas de entrenamiento, aligerando la carga computacional.

SE-L 2 (100 épocas) Su principal ventaja sigue siendo la validez, al garantizar una puntuación perfecta (1.0000) en todas las pruebas gracias a la representación SELFIES. Pero, en términos generales, presenta resultados peores al compararlo con las arquitecturas basadas en SMILES. Mientras que los modelos SMILES alcanzan un FCD de hasta 0.1790, el SE-L 2 solo logra un FCD de 0.6751 en su mejor configuración y a costa de una nove-

dad baja (0.8676). Si se intenta mejorar esa novedad reduciendo la tasa de aprendizaje, el FCD empeora significativamente a 2.8927.

SM-L 1 (300 épocas) La variante de red menos profunda consiguió su punto de mayor eficacia con un LR de 1×10^{-4} y un Batch de 64, registrando un FCD de 0.4242 y una validez de 0.9404. Al comparar estos números con el modelo de dos capas (SM-L 2), podemos ver que si bien la arquitectura es más ligera y presenta menores tiempos de entrenamiento, el agregar una capa mejora sistemáticamente las métricas obtenidas.

4.1.3. Evaluación en el Benchmark MOSES

4.1.3.1. Modelo seleccionado

Se seleccionó SM-L 2 (300 épocas), con LR de 1×10^{-4} y batch de 64, por obtener el menor FCD de todos los experimentos (0.1790), la mayor validez entre los modelos SMILES (0.9624) y la menor distancia de Wasserstein para SA (0.0932). A cambio, presentó una novedad levemente menor (0.9434) y el mayor tiempo de entrenamiento de la segunda fase.

En la Figura 4.1 se muestran las distribuciones de QED y SA de las moléculas generadas por este modelo frente a las del conjunto de prueba de MOSES. Las curvas se superponen casi por completo, lo que concuerda con las distancias de Wasserstein obtenidas (0.0083 para QED y 0.0932 para SA).

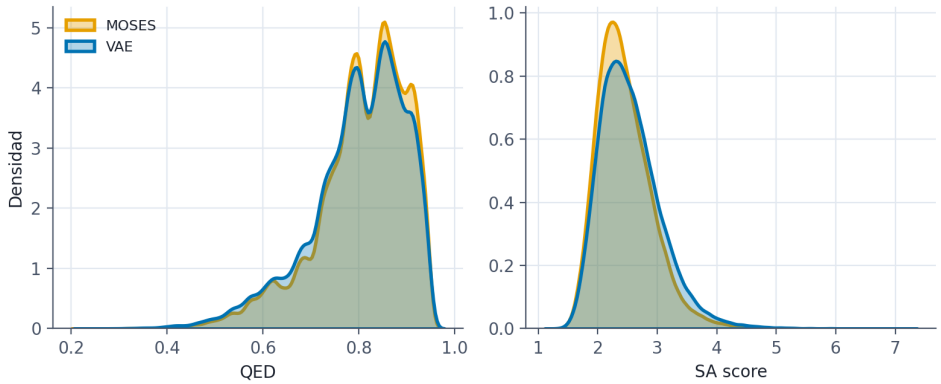


Figura 4.1: *Distribuciones de QED y SA de las moléculas válidas generadas por SM-L 2 frente al conjunto de prueba de MOSES.*

4.1.3.2. Comparación con el estado del arte

Los resultados indican que el modelo propuesto (SM-L VAE) ofrece un balance frente a otras arquitecturas recientes de espacio latente, como PCF-VAE y FRATTVAE. El modelo logra un FCD de 0.1790, manteniendo al mismo tiempo una alta tasa de novedad (0.9434) y diversidad interna (0.8590). Si bien enfoques autorregresivos como CharRNN

Tabla 4.4: *Comparación con el estado del arte utilizando el dataset MOSES*

Model	Valid (↑)	Unique (↑)	Novelty (↑)	Filters (↑)	FCD (↓)	IntDiv (↑)	SA (↓)	QED (↓)
Train	1.0000	1.0000	1.0000	1.0000	0.0080	0.8567	-	-
HMM	0.0760	0.5671	0.9994	0.9024	24.4661	0.8466	0.7416	0.2689
NGram	0.2376	0.9217	0.9694	0.9582	5.5069	0.8738	0.2312	0.0886
Combinatorial	1.0000	0.9909	0.9878	0.9557	4.2375	0.8732	0.2800	0.1514
CharRNN	0.9748	0.9994	0.8419	0.9943	0.0732	0.8562	0.0166	0.0026
AAE	0.9368	0.9973	0.7931	0.9960	0.5555	0.8557	0.0448	0.0038
LatentGAN	0.8966	0.9968	0.9498	0.9735	0.2968	0.8565	0.0883	0.0056
FRATTVAE	1.0000	0.9997	0.9742	N/R	0.8654	N/R	2.5910	0.0303
PCF-VAE	0.9801	1.0000	0.9377	0.9900	0.2962	0.8587	N/R	N/R
SM-L VAE	0.9624	0.9999	0.9434	0.9884	0.1790	0.8590	0.0932	0.0083

alcanzan un FCD numéricamente menor (0.0732), este comportamiento suele estar asociado a una caída en la novedad (0.8419), lo que sugiere una tendencia del modelo a replicar el conjunto de entrenamiento. La principal ventaja de los modelos VAE radica en su espacio latente continuo. A diferencia de las secuencias discretas de CharRNN, esta representación vectorial permite aplicar metaheurísticas multiobjetivo para buscar moléculas con propiedades específicas o afines a un target determinado.

4.2. Calibración de Metaheurísticas en Fármacos Genéricos

4.2.1. Ajuste de Hiperparámetros y Comparativa de Operadores

4.2.2. Análisis de Calidad de Generación de Moléculas

4.2.3. Comparación Contra Algoritmos del Estado del Arte

4.3. Generación de Inhibidores de la Proteína MRP1

4.3.1. Análisis de Calidad de Generación de Moléculas

4.3.2. Comparación Contra Algoritmos del Estado del Arte

4.3.3. Análisis Detallado de las Mejores Moléculas Candidatas

5

Conclusiones y Trabajo Futuro

5.1. Conclusiones

5.2. Trabajo Futuro

Apéndices

Anexos

L

Showcasing the First Annex

Writing Guidance

Annexes are supplementary sections in a dissertation that provide additional information or external documents not essential to the main arguments but that support or complement the research. Unlike appendices, **annexes generally contain material that was not developed by the author**, such as reports, legal documents, or published datasets from external sources. This information is placed separately to keep the main content concise, allowing readers access to relevant external references without disrupting the dissertation's flow.

Bibliografía

[1] American Cancer Society. *Breve historia del cáncer*. https://www.cancer.org/es/cancer/entendimiento-del-cancer/historia-del-cancer.html. Accedido: 2026. 2026.

[2] Hyuna Sung et al. «Global cancer statistics 2024: GLOBOCAN estimates of incidence and mortality worldwide for 34 cancers in 186 countries». En: *CA: A Cancer Journal for Clinicians* 76.4 (2026), e70090. DOI: 10.3322/caac.70090.

[3] Jose J. G. Marin et al. «Expression of Chemoresistance-Associated ABC Proteins in Hepatobiliary, Pancreatic and Gastrointestinal Cancers». En: *Cancers* 14.14 (2022), pág. 3524. DOI: 10.3390/cancers14143524.

[4] Emne Ali Abdallah et al. «MRP1 expression in CTCs confers resistance to irinotecan-based chemotherapy in metastatic colorectal cancer». En: *International Journal of Cancer* 139.4 (2016), págs. 890-898. DOI: 10.1002/ijc.30082.

[5] Fang-fang Qi et al. «Long non-coding RNAs: Key regulators in oxaliplatin resistance of colorectal cancer». En: *Biomedicine & Pharmacotherapy* 128 (2020), pág. 110329. DOI: 10.1016/j.biopha.2020.110329.

[6] Dongxing Cao et al. «The role of MRP1 in the multidrug resistance of colorectal cancer». En: *Oncology Letters* 13.4 (2017), págs. 2471-2476. ISSN: 1792-1074. DOI: 10.3892/ol.2017.5741.

[7] Uddalak Das. «Generative AI for drug discovery and protein design: the next frontier in AI-driven molecular science». En: *Medicine in Drug Discovery* 27 (2025), pág. 100213. DOI: 10.1016/j.medidd.2025.100213.

[8] Sohvi Luukkonen et al. «Artificial intelligence in multi-objective drug design». En: *Current Opinion in Structural Biology* 79 (2023), pág. 102537. DOI: 10.1016/j.sbi.2023.102537.

[9] Zijian Zhang et al. «Molecular Knowledge Representations in the Era of Artificial Intelligence». En: *ChemRxiv* (2026). DOI: 10.26434/chemrxiv.15002830/v1.

[10] El-Ghazali Talbi. *Metaheuristics: From Design to Implementation*. 1.ª ed. Hoboken, New Jersey: John Wiley & Sons, 2009. ISBN: 978-0-470-27858-1. DOI: 10.1002/9780470496916. URL: https://onlinelibrary.wiley.com/doi/book/10.1002/9780470496916.

[11] J. P. Hughes et al. «Principles of early drug discovery». En: *British Journal of Pharmacology* 162.6 (2011), págs. 1239-1249. DOI: 10.1111/j.1476-5381.2010.01127.x.

[12] Shujun Zhang et al. «The role and application of bioinformatics techniques and tools in drug discovery». En: *Frontiers in Pharmacology* 16 (2025), pág. 1547131. DOI: 10.3389/fphar.2025.1547131.

[13] Pooja A. Chawla et al., eds. *Computational Drug Discovery: Molecular Simulation for Medicinal Chemistry*. De Gruyter, 2024. ISBN: 978-3-11-120711-7. DOI: 10.1515/9783111207117.

[14] Grazyna Biala et al. «Research in the Field of Drug Design and Development». En: *Pharmaceuticals* 16.9 (2023), pág. 1283. DOI: 10.3390/ph16091283.

[15] Stephani Joy Y. Macalino et al. «Role of computer-aided drug design in modern drug discovery». En: *Archives of Pharmacal Research* 38.9 (2015), págs. 1686-1701. DOI: 10.1007/s12272-015-0640-5.

[16] John Jumper et al. «Highly accurate protein structure prediction with AlphaFold». En: *Nature* 596.7873 (2021), págs. 583-589. DOI: 10.1038/s41586-021-03819-2.

[17] David Weininger. «SMILES, a chemical language and information system. 1. Introduction to methodology and encoding rules». En: *Journal of Chemical Information and Computer Sciences* 28.1 (1988), págs. 31-36. DOI: 10.1021/ci00057a005.

[18] Evan E Bolton et al. «PubChem: Integrated Platform of Small Molecules and Biological Activities». En: *Annual Reports in Computational Chemistry* 4 (2008), págs. 217-241. DOI: 10.1016/S1574-1400(08)00012-1.

[19] David Mendez et al. «ChEMBL: towards direct deposition of bioassay data». En: *Nucleic Acids Research* 47.D1 (2019), págs. D930-D940. DOI: 10.1093/nar/gky1075.

[20] John J Irwin et al. «ZINC20—a free ultralarge-scale chemical database for ligand discovery». En: *Journal of Chemical Information and Modeling* 60.12 (2020), págs. 6065-6073. DOI: 10.1021/acs.jcim.0c00675.

[21] Weiya Kong et al. «Application of SMILES-based molecular generative model in new drug design». En: *Frontiers in Pharmacology* 13 (2022), pág. 1046524. DOI: 10.3389/fphar.2022.1046524.

[22] Marwin H. S. Segler et al. «Generating focused molecule libraries for drug discovery with recurrent neural networks». En: *ACS Central Science* 4.1 (2018), págs. 120-131. DOI: 10.1021/acscentsci.7b00512.

[23] Marcus Olivecrona et al. «Molecular de-novo design through deep reinforcement learning». En: *Journal of Cheminformatics* 9 (2017), pág. 48. DOI: 10.1186/s13321-017-0235-x.

[24] Mario Krenn et al. «SELFIES: a robust representation of semantically constrained graphs with an example application in chemistry». En: *Machine Learning: Science and Technology* 1.4 (2020), pág. 045024. DOI: 10.1088/2632-2153/aba947.

[25] Christopher A. Lipinski et al. «Experimental and computational approaches to estimate solubility and permeability in drug discovery and development settings». En: *Advanced Drug Delivery Reviews* 23.1–3 (1997), págs. 3-25. DOI: 10.1016/S0169-409X(96)00423-1.

[26] G. Richard Bickerton et al. «Quantifying the chemical beauty of drugs». En: *Nature Chemistry* 4.2 (2012), págs. 90-98. DOI: 10.1038/nchem.1243.

[27] Yuhang Xia et al. «A comprehensive review of molecular optimization in artificial intelligence-based drug discovery». En: *Quantitative Biology* 12.1 (2024), págs. 15-29. DOI: 10.1002/qub2.30.

[28] Peter Ertl et al. «Estimation of synthetic accessibility score of drug-like molecules based on molecular complexity and fragment contributions». En: *Journal of Cheminformatics* 1 (2009), pág. 8. DOI: 10.1186/1758-2946-1-8.

[29] Frank Lovering et al. «Escape from Flatland: Increasing Saturation as an Approach to Improving Clinical Success». En: *Journal of Medicinal Chemistry* 52.21 (2009), págs. 6752-6756. DOI: 10.1021/jm901241e.

[30] Frank Lovering. «Escape from Flatland 2: complexity and promiscuity». En: *MedChemComm* 4.3 (2013), págs. 515-519. DOI: 10.1039/C2MD20347B.

[31] Nataraj S. Pagadala et al. «Software for molecular docking: a review». En: *Biophysical Reviews* 9.2 (2017), págs. 91-102. DOI: 10.1007/s12551-016-0247-1. URL: https://doi.org/10.1007/s12551-016-0247-1.

[32] Oleg Trott et al. «AutoDock Vina: Improving the speed and accuracy of docking with a new scoring function, efficient optimization, and multithreading». En: *Journal of Computational Chemistry* 31.2 (2010), págs. 455-461. DOI: 10.1002/jcc.21334.

[33] Yuejiang Yu et al. «Uni-Dock: GPU-accelerated docking enables ultralarge virtual screening». En: *Journal of Chemical Theory and Computation* 19.11 (2023), págs. 3336-3345. DOI: 10.1021/acs.jctc.2c01145. URL: https://doi.org/10.1021/acs.jctc.2c01145.

[34] Diederik P. Kingma et al. «Auto-Encoding Variational Bayes». En: *arXiv preprint arXiv:1312.6114* (2013).

[35] Christopher M. Bishop et al. *Deep Learning: Foundations and Concepts*. Cham, Switzerland: Springer, 2024. DOI: 10.1007/978-3-031-45468-4.

[36] Joseph Taewoo Kim. *Exploring Effectiveness of Multimodal Variational Autoencoders on Text-Image Tasks*. Inf. téc. Stanford University, 2024. URL: https://github.com/josephtkim/Multimodal-VAE.

[37] Rafael Gómez-Bombarelli et al. «Automatic Chemical Design Using a Data-Driven Continuous Representation of Molecules». En: *ACS Central Science* 4.2 (2018), págs. 268-276.

DOI: 10.1021/acscentsci.7b00572. URL: https://doi.org/10.1021/acscentsci.7b00572.

[38] K. Deb et al. «A fast and elitist multiobjective genetic algorithm: NSGA-II». En: *IEEE Transactions on Evolutionary Computation* 6.2 (2002), págs. 182-197. DOI: 10.1109/4235.996017. URL: http://ieeexplore.ieee.org/document/996017/.

[39] Susan P. C. Cole. «Targeting Multidrug Resistance Protein 1 (MRP1, ABCC1): Past, Present, and Future». En: *Annual Review of Pharmacology and Toxicology* 54.1 (2014), págs. 95-117. ISSN: 0362-1642. DOI: 10.1146/annurev-pharmtox-011613-135959.

[40] Jamie F. Lu et al. «MRP1 and its role in anticancer drug resistance». En: *Drug Metabolism Reviews* 47.4 (2015), págs. 406-419. ISSN: 0360-2532. DOI: 10.3109/03602532.2015.1105253.

[41] Zachary Lee Johnson et al. «Structural Basis of Substrate Recognition by the Multidrug Resistance Protein MRP1». En: *Cell* 168.6 (2017), págs. 1075-1085. ISSN: 0092-8674. DOI: 10.1016/j.cell.2017.01.041.

[42] Sven Marcel Stefan et al. «Small-molecule inhibitors of multidrug resistance-associated protein 1 and related processes: A historic approach and recent advances». En: *Medicinal Research Reviews* 39 (2019), págs. 176-264. DOI: 10.1002/med.21510.

[43] Kanin Rungsardthong et al. «Virtual screening of ABCC1 transporter nucleotide-binding domains as a therapeutic target in multidrug resistant cancer». En: *Bioinformation* 8.19 (2012), págs. 907-911. DOI: 10.6026/97320630008907.

[44] Divya Dhasmana et al. «Targeting Nucleotide Binding Domain of Multidrug Resistance-associated Protein-1 (MRP1) for the Reversal of Multi Drug Resistance in Cancer». En: *Scientific Reports* 8 (2018), pág. 11973. DOI: 10.1038/s41598-018-30420-x.

[45] Zakia Belhadj et al. «Characterization of a deazaflavin analog as a potent inhibitor of multidrug resistance-associated protein 1». En: *Biomedicine & Pharmacotherapy* 178 (2024), pág. 117167. DOI: 10.1016/j.biopha.2024.117167.

[46] Nicola De Cao et al. *MolGAN: An implicit generative model for small molecular graphs*. Mayo de 2018. DOI: 10.48550/arXiv.1805.11973. URL: http://arxiv.org/abs/1805.11973.

[47] Tianfan Fu et al. «MOLER: Incorporate Molecule-Level Reward to Enhance Deep Generative Model for Molecule Optimization». en. En: *IEEE Transactions on Knowledge and Data Engineering* 34.11 (nov. de 2022), págs. 5459-5471. ISSN: 1041-4347, 1558-2191, 2326-3865. DOI: 10.1109/TKDE.2021.3052150. URL: https://ieeexplore.ieee.org/document/9330796/.

[48] Yuanqi Du et al. «Small molecule generation via disentangled representation learning». En: *Bioinformatics* 38.12 (jun. de 2022), págs. 3200-3208. ISSN: 1367-4803.

DOI: 10.1093/bioinformatics/btac296. URL: https://doi.org/10.1093/bioinformatics/btac296.

[49] Xiangzhe Kong et al. *Molecule Generation by Principal Subgraph Mining and Assembling*. 2022. URL: https://arxiv.org/abs/2106.15098.

[50] Arun Singh Bhadwal et al. «PCF-VAE: posterior collapse free variational autoencoder for de novo drug design». en. En: *Scientific Reports* 15.1 (oct. de 2025), pág. 34152. ISSN: 2045-2322. DOI: 10.1038/s41598-025-14285-5. URL: https://www.nature.com/articles/s41598-025-14285-5.

[51] Tensei Inukai et al. «Leveraging tree-transformer VAE with fragment tokenization for high-performance large chemical model generation». en. En: *Communications Chemistry* 8.1 (ago. de 2025), pág. 228. ISSN: 2399-3669. DOI: 10.1038/s42004-025-01640-w. URL: https://www.nature.com/articles/s42004-025-01640-w.

[52] Davide Rigoni et al. «RGCVAE: relational graph conditioned variational autoencoder for molecule design». en. En: *Machine Learning* 114.2 (ene. de 2025), pág. 47. ISSN: 1573-0565. DOI: 10.1007/s10994-024-06638-4. URL: https://doi.org/10.1007/s10994-024-06638-4.

[53] Robin Winter et al. «Efficient multi-objective molecular optimization in a continuous latent space». En: *Chemical Science* 10 (2019), págs. 8016-8024. DOI: 10.1039/c9sc01928f. URL: https://doi.org/10.1039/c9sc01928f.

[54] Sheriff Abouchekeir et al. «Adversarial deep evolutionary learning for drug design». En: *BioSystems* 222 (2022), pág. 104790. DOI: 10.1016/j.biosystems.2022.104790.

[55] Siddartha Reddy N et al. «Leveraging Latent Evolutionary Optimization for Targeted Molecule Generation». En: *2024 IEEE Congress on Evolutionary Computation (CEC)*. arXiv:2407.13779. 2024.

[56] Nicholas Aksamit et al. «Integrating transformers and many-objective optimization for drug design». En: *BMC Bioinformatics* 25.1 (2024), pág. 208. DOI: 10.1186/s12859-024-05822-6. URL: https://doi.org/10.1186/s12859-024-05822-6.

[57] Xin Xia et al. «Evolutionary Multiobjective Molecule Optimization in an Implicit Chemical Space». En: *Journal of Chemical Information and Modeling* 64 (2024), págs. 5161-5174. DOI: 10.1021/acs.jcim.4c00031. URL: https://doi.org/10.1021/acs.jcim.4c00031.

[58] AN M Nafiz Abeer et al. «Multi-Objective Latent Space Optimization of Generative Molecular Design Models». En: *arXiv preprint arXiv:2203.00526v3* (2024). URL: https://arxiv.org/abs/2203.00526v3.

[59] Armen G. Beck et al. «Paddy: an evolutionary optimization algorithm for chemical systems and spaces». En: *Digital Discovery* 4 (2025), págs. 1352-1371. DOI: 10.1039/d4dd00226a. URL: https://doi.org/10.1039/d4dd00226a.

[60] Daniil Polykovskiy et al. «Molecular Sets (MOSES): A Benchmarking Platform for Molecular Generation Models». En: *Frontiers in Pharmacology* 11 (2020), pág. 565644. DOI: 10.3389/fphar.2020.565644.

[61] Miruna T Cretu et al. «Standardizing chemical compounds with language models». En: *Machine Learning: Science and Technology* 4.3 (2023), pág. 035014. DOI: 10.1088/2632-2153/ace878.

[62] Diederik P. Kingma et al. «Adam: A Method for Stochastic Optimization». En: *3rd International Conference on Learning Representations (ICLR)*. 2015.

[63] Kalyanmoy Deb et al. «An Evolutionary Many-Objective Optimization Algorithm Using Reference-Point-Based Nondominated Sorting Approach, Part I: Solving Problems With Box Constraints». En: *IEEE Transactions on Evolutionary Computation* 18.4 (2014), págs. 577-601. DOI: 10.1109/TEVC.2013.2281535. URL: https://doi.org/10.1109/tevc.2013.2281535.

[64] Qingfu Zhang et al. «MOEA/D: A Multiobjective Evolutionary Algorithm Based on Decomposition». En: *IEEE Transactions on Evolutionary Computation* 11.6 (2007), págs. 712-731. DOI: 10.1109/TEVC.2007.892759. URL: http://ieeexplore.ieee.org/document/4358754/.

[65] Xingyi Zhang et al. «A competitive mechanism based multi-objective particle swarm optimizer with fast convergence». En: *Information Sciences* 427 (2018), págs. 63-76. DOI: 10.1016/j.ins.2017.10.037. URL: https://linkinghub.elsevier.com/retrieve/pii/S0020025517310344.

[66] Annibale Panichella. «An adaptive evolutionary algorithm based on non-euclidean geometry for many-objective optimization». En: *Proceedings of the Genetic and Evolutionary Computation Conference*. Prague, Czech Republic: ACM, 2019, págs. 595-603. ISBN: 978-1-4503-6111-8. DOI: 10.1145/3321707.3321839. URL: https://dl.acm.org/doi/10.1145/3321707.3321839.

[67] Greg Landrum et al. *RDKit: Open-Source Cheminformatics*. https://www.rdkit.org. Versión 2026.03.1. 2026. DOI: 10.5281/zenodo.591637.

[68] Kalyanmoy Deb et al. «Simulated Binary Crossover for Continuous Search Space». En: *Complex Systems* 9.2 (1995), págs. 115-148. URL: https://www.complex-systems.com/abstracts/v09_i02_a02/.

[69] Kalyanmoy Deb et al. «Real-coded evolutionary algorithms with parent-centric recombination». En: *Proceedings of the 2002 Congress on Evolutionary Computation (CEC '02)*. Vol. 1. IEEE, 2002, págs. 61-66. DOI: 10.1109/CEC.2002.1006210.

[70] Kalyanmoy Deb et al. «A Combined Genetic Adaptive Search (GeneAS) for Engineering Design». En: *Computer Science and Informatics* 26.4 (1996), págs. 30-45.

[71] Thomas Bäck et al. «An Overview of Evolutionary Algorithms for Parameter Optimization». En: *Evolutionary Computation* 1.1 (1993), págs. 1-23. DOI: 10.1162/evco.1993.1.1.1.

[72] Omkar Shinde et al. «Structures of ATP-binding cassette transporter ABCC1 reveal the molecular basis of cyclic dinucleotide cGAMP export». En: *Immunity* 58.1 (2025), 59-73.e5. DOI: 10.1016/j.immuni.2024.12.002.

[73] Diogo Santos-Martins et al. «Meeko: Molecule Parametrization and Software Interoperability for Docking and Beyond». En: *Journal of Chemical Information and Modeling* 65.24 (2025), págs. 13045-13050. DOI: 10.1021/acs.jcim.5c02271.

[74] Yuri Kochnev et al. «FPocketWeb: protein pocket hunting in a web browser». En: *Journal of Cheminformatics* 14.1 (2022), pág. 58. DOI: 10.1186/s13321-022-00637-0.

[75] Jerome Eberhardt et al. «AutoDock Vina 1.2.0: New Docking Methods, Expanded Force Field, and Python Bindings». En: *Journal of Chemical Information and Modeling* 61.8 (2021), págs. 3891-3898. DOI: 10.1021/acs.jcim.1c00203.

[76] Miqing Li et al. «Quality Evaluation of Solution Sets in Multiobjective Optimisation: A Survey». En: *ACM Computing Surveys* 52.2 (2019), 26:1-26:38. DOI: 10.1145/3300148. URL: https://doi.org/10.1145/3300148.

[77] Junyoung Chung et al. *Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling*. 2014. arXiv: 1412.3555 [cs.NE].

Siglas

5-FU 5-Fluorouracilo (*5-Fluorouracil*). (*p. 18, 69*)

ABC Transportadores de casete de unión a ATP (*ATP-Binding Cassette*). (*p. 3, 18, 69*)
ABCC1 Miembro 1 de la subfamilia C de casete de unión a ATP (*ATP-Binding Cassette Subfamily C Member 1*). (*p. 69*)
ADMET Absorción, distribución, metabolismo, excreción y toxicidad (*Absorption, Distribution, Metabolism, Excretion, and Toxicity*). (*p. 9, 69*)
AGE-MOEA Algoritmo evolutivo multiobjetivo basado en estimación adaptativa de geometría (*Adaptive Geometry Estimation Based MOEA*). (*p. 1, 34, 36, 69*)
ALERTS Alertas estructurales (*Structural Alerts*). (*p. 12, 69*)
ALOGP Coeficiente de partición octanol-agua basado en átomos (*Atom-based LogP*). (*p. 12, 69*)
AROM Anillos aromáticos (*Aromatic Rings*). (*p. 12, 69*)
ATP Trifosfato de adenosina (*Adenosine Triphosphate*). (*p. 18, 69*)

CADD Diseño de fármacos asistido por computadora (*Computer-Aided Drug Design*). (*p. 3, 5, 7, 8, 69*)
cGAMP Monofosfato de guanosina-adenosina cíclico (*Cyclic GMP-AMP*). (*p. 39, 69*)
CMOPSO Optimizador multiobjetivo por enjambre de partículas basado en mecanismo competitivo (*Competitive Mechanism Based Multi-objective Particle Swarm Optimizer*). (*p. 1, 34, 35, 37, 69*)
Cryo-EM Criomicroscopía electrónica (*Cryogenic Electron Microscopy*). (*p. 8, 20, 69*)

ELBO Cota inferior de la evidencia (*Evidence Lower Bound*). (*p. 16, 69*)

FCD Distancia Fréchet ChemNet (*Fréchet ChemNet Distance*). (*p. 44, 69*)
FDA Administración de Alimentos y Medicamentos (*Food and Drug Administration*). (*p. 20, 69*)

GD Distancia generacional (*Generational Distance*). (*p. 44, 69*)
GPU Unidad de procesamiento gráfico (*Graphics Processing Unit*). (*p. 14, 42, 47, 69*)
GRU Unidad recurrente con compuertas (*Gated Recurrent Unit*). (*p. 32, 69*)

HBA Aceptores de enlaces de hidrógeno (*Hydrogen Bond Acceptors*). (*p. 12, 69*)
HBD Donadores de enlaces de hidrógeno (*Hydrogen Bond Donors*). (*p. 12, 69*)

HV Hipervolumen (*Hypervolume*). (*p. xiv, 45, 46, 69*)

IGD Distancia generacional invertida (*Inverted Generational Distance*). (*p. xiv, 44–46, 69*)

LBDD Diseño de fármacos basado en el ligando (*Ligand-Based Drug Design*). (*p. 8, 9, 69*)

LSTM Memoria de corto y largo plazo (*Long Short-Term Memory*). (*p. 32, 69*)

MCF Filtros de química médica (*Medicinal Chemistry Filters*). (*p. 44, 69*)

MDR Resistencia a múltiples fármacos (*Multidrug Resistance*). (*p. 3, 18, 69*)

MOEA/D Algoritmo evolutivo multiobjetivo basado en descomposición (*Multiobjective Evolutionary Algorithm Based on Decomposition*). (*p. 1, 34, 36, 69*)

MOSES Conjuntos moleculares (*Molecular Sets*). (*p. 29–31, 33, 43, 44, 69*)

MRP1 Proteína 1 asociada a la resistencia a múltiples fármacos (*Multidrug Resistance-associated Protein 1*). (*p. xiv, 3–5, 7, 18–20, 28, 29, 38–40, 42, 47, 49, 69*)

MW Peso molecular (*Molecular Weight*). (*p. 12, 69*)

NSGA-II Algoritmo genético de ordenamiento no dominado II (*Non-dominated Sorting Genetic Algorithm II*). (*p. 1, 33, 34, 36, 69*)

NSGA-III Algoritmo genético de ordenamiento no dominado III (*Non-dominated Sorting Genetic Algorithm III*). (*p. 1, 34, 36, 69*)

PAINS Compuestos de interferencia en pan-ensayos (*Pan-Assay Interference Compounds*). (*p. 44, 69*)

PDB Banco de Datos de Proteínas (*Protein Data Bank*). (*p. 19, 69*)

PSA Área de superficie polar (*Polar Surface Area*). (*p. 12, 69*)

QED Estimación cuantitativa de la similitud a fármaco (*Quantitative Estimate of Drug-likeness*). (*p. 11, 12, 35, 42–44, 47, 69*)

QSAR Relación cuantitativa estructura-actividad (*Quantitative Structure–Activity Relationship*). (*p. 9, 69*)

RMN Resonancia magnética nuclear (*Nuclear Magnetic Resonance*). (*p. 8, 69*)

ROTB Enlaces rotables (*Rotatable Bonds*). (*p. 12, 69*)

SAS Puntuación de accesibilidad sintética (*Synthetic Accessibility Score*). (*p. 12, 35, 42–44, 47, 69*)

SBDD Diseño de fármacos basado en la estructura (*Structure-Based Drug Design*). (*p. 8, 9, 69*)

SELFIES Cadenas integradas autorreferenciadas (*Self-Referencing Embedded Strings*). (*p. 9, 10, 15, 31, 32, 69*)

SMILES Sistema simplificado de entrada de líneas moleculares (*Simplified Molecular Input Line Entry System*). (*p. 9, 10, 15, 30–32, 47, 69*)

VAE Autoencoder Variacional (*Variational Autoencoder*). (*p. 3–5, 14–16, 23, 29, 30, 32–34, 42, 43, 47, 49, 69*)