UNCUYO
UNIVERSIDAD NACIONAL DE CUYO

FACULTAD DE INGENIERÍA

TESINA FINAL DE GRADO

Licenciatura en Ciencias de la Computación

Diseño y evaluación de algoritmos metaheurísticos multiobjetivo y modelos generativos para el diseño de fármacos aplicados al cáncer colorrectal

---

Autor: Carlos Eduardo Perez Melendez

Tutor: Dr. Pablo Javier Vidal

Co-Tutor: Dr. Matías Gabriel Rojas

Noviembre 2026

AND TO ALL THE CHILDREN...
CONGRATULATIONS!

Hideaki Anno

Agradecimientos

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetuer id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Resumen

El diseño y descubrimiento de fármacos está condicionado por el tamaño del espacio químico estimado en más de 10^{60} moléculas posibles, esta escala resulta inviable de explorar mediante métodos experimentales tradicionales o de cribado virtual exhaustivo. Además, el explorar y diseñar compuestos con características de fármaco es un problema esencialmente multiobjetivo, ya que exige optimizar simultáneamente propiedades fisicoquímicas y farmacológicas frecuentemente en conflicto.

Frente a estas limitaciones, los modelos generativos permiten representar dicho espacio molecular en un espacio latente continuo, mientras que la aplicación de algoritmos de optimización multiobjetivo para guiar la búsqueda de nuevos compuestos en este espacio permite dirigir esta generación hacia candidatos con propiedades deseables.

Esta tesina de grado presenta la implementación y evaluación de un enfoque híbrido que combina autoencoders variacionales junto con algoritmos metaheurísticos multiobjetivo para optimizar la generación de nuevos compuestos explorando este espacio latente. Como caso de aplicación, este trabajo se orienta a la obtención de moléculas novedosas y viables para el tratamiento de la resistencia a fármacos en el cáncer colorrectal, relacionada con proteínas transportadoras de la familia ABC.

Abstract

Drug design and discovery is conditioned by the size of the chemical space, estimated at more than 10^{60} possible molecules, making exploration through traditional experimental methods or exhaustive virtual screening infeasible. Furthermore, exploring and designing drug-like compounds is essentially a multi-objective problem, as it requires simultaneously optimizing physicochemical and pharmacological properties that are frequently in conflict.

To address these limitations, generative models allow representing this molecular space in a continuous latent space, while the application of multi-objective optimization algorithms to guide the search for new compounds within this space allows steering this generation toward candidates with desirable properties.

This bachelor's thesis presents the implementation and evaluation of a hybrid approach combining variational autoencoders with multi-objective metaheuristic algorithms to optimize the generation of new compounds by exploring this latent space. As an application case, this work focuses on obtaining novel and viable molecules for the treatment of drug resistance in colorectal cancer, associated with ABC family transporter proteins.

Tabla de Contenidos

Índice de Figuras xiii

Índice de Tablas xvii

1. Introducción 3

1.1. Motivación . . . 3

1.2. Objetivos . . . 4

1.3. Organización del Documento . . . 5

2. Marco Teórico 7

2.1. Diseño de fármacos asistido por computadora (CADD) . . . 7

2.1.1. Representación de moléculas . . . 9

2.1.2. Métricas de evaluación química y propiedades moleculares . . . 10

2.1.2.1. Regla de Lipinski y propiedades fisicoquímicas . . . 11

2.1.2.2. Estimación cuantitativa de atributos de fármacos (QED) 11

2.1.2.3. Accesibilidad sintética . . . 12

2.1.2.4. Fracción de carbonos sp^3 . . . 12

2.1.2.5. Métodos de docking molecular y afinidad de unión . . . 13

2.1.3. Técnicas computacionales aplicadas al diseño de fármacos . . . 14

2.1.3.1. Autoencoders variacionales (VAE) . . . 14

2.1.3.2. Metaheurísticas multi-objetivo . . . 16

2.2. Caso de estudio: Proteína 1 de resistencia a múltiples fármacos (MRP1) . 18

2.3. Trabajos Relacionados . . . 20

2.3.1. Diseño de Fármacos Mediante Redes Generativas y VAEs . . . 20

2.3.2. Optimización del Espacio Latente Mediante Metaheurísticas . . . 24

3. Metodología **29**

3.1. Visión General de la Metodología 29

3.2. Datos de Entrada 30

3.2.1. Conjuntos de Datos y Preprocesamiento 30

3.2.2. Representaciones Moleculares y Decodificación 31

3.3. FASE 1: Ajuste de Hiperparámetros y Evaluación en Fármacos Genéricos 32

3.3.1. Ajustes de Hiperparámetros del VAE 32

3.3.2. Ajuste de Hiperparámetros de las Metaheurísticas 33

3.3.2.1. Metaheurísticas Consideradas 33

3.3.2.2. Funciones Objetivo y Restricciones 34

3.3.2.3. Protocolo Experimental del Ajuste 35

3.3.2.4. Operadores e Hiperparámetros de los Algoritmos Genéticos 36

3.3.2.5. Operadores e Hiperparámetros de CMOPSO 37

3.3.2.6. Etapas del Protocolo Experimental 37

3.4. FASE 2: Diseño de Inhibidores de la Proteína MRP1 38

3.4.1. Preparación de la Proteína y Sitio de Unión 38

3.4.2. Funciones Objetivo 42

3.4.3. Protocolo de Generación de Candidatos 43

3.5. Métricas de Evaluación del Rendimiento de los Modelos Considerados . 43

3.5.1. Métricas de Calidad de Generación 43

3.5.2. Indicadores de Rendimiento Multiobjetivo 44

3.5.3. Validación y Perfilado de las Moléculas Candidatas 46

3.6. Herramientas y Tecnologías de Implementación 47

4. Resultados y Discusión **49**

4.1. Evaluación y Selección del Modelo Generativo VAE 49

4.1.1. Evaluación de Arquitecturas y Selección de Configuraciones . . . 49

4.1.2. Optimización del Entrenamiento y Selección del Modelo Final . . 51

4.1.3. Evaluación en MOSES y Comparación con el Estado del Arte . . . 51
4.1.3.1. Modelo seleccionado . . . 52
4.1.3.2. Comparación con el estado del arte . . . 52
4.2. Optimización Multiobjetivo de Propiedades Moleculares sin Diana Específica . . . 53
4.2.1. Ajuste de Hiperparámetros . . . 53
4.2.1.1. Compromiso entre Hipervolumen y Validez Química . . . 54
4.2.2. Influencia de los Operadores de Cruce y Mutación . . . 55
4.2.3. Comparación Global de Metaheurísticas . . . 61
4.2.3.1. Indicadores Multiobjetivo y Químicos . . . 61
4.2.4. Convergencia, Cobertura y Diversidad de las Soluciones . . . 66
4.2.4.1. Frentes de Pareto . . . 68
4.2.5. Análisis del Frente no Dominado Conjunto y Moléculas Representativas . . . 69
4.2.5.1. Contribución al Frente Conjunto Global . . . 69
4.2.5.2. Moléculas Representativas . . . 70
4.2.6. Discusión y Limitaciones . . . 72
4.3. Generación de Inhibidores de la Proteína MRP1 . . . 72
4.3.1. Análisis de Calidad de Generación de Moléculas . . . 72
4.3.2. Comparación Contra Algoritmos del Estado del Arte . . . 72
4.3.3. Análisis Detallado de las Mejores Moléculas Candidatas . . . 72

5. Conclusiones y Trabajo Futuro **73**
5.1. Conclusiones . . . 73
5.2. Dificultades Encontradas . . . 74
5.3. Trabajo Futuro . . . 74
5.4. Conclusiones Finales . . . 75

Apéndices

A. Registro de Experimentos del Modelo VAE **77**

A.1. Exploración de Arquitecturas 77

A.2. Optimización de Hiperparámetros 79

B. Análisis Estadístico y Resultados Complementarios de las Metaheurísticas **81**

B.1. Configuraciones Seleccionadas del Ajuste de Hiperparámetros 81

B.2. Comparaciones Estadísticas por Pares (Test de Wilcoxon) 82

B.3. Frentes no Dominados por Frecuencia de Ejecución 84

B.4. Estructuras Químicas Obtenidas por Combinación de Operadores 88

B.5. Moléculas de Mayor QED por Algoritmo (Catálogo Completo) 90

Anexos

L. Showcasing the First Annex **93**

Bibliografía **95**

Siglas **101**

Índice de Figuras

2.1. Pipeline tradicional de diseño y desarrollo de fármacos 8

2.2. Bifurcación de las estrategias de diseño de fármacos asistido por computadora (CADD) en métodos basados en estructura (SBDD) y basados en ligando (LBDD), convergiendo en el cribado virtual. Adaptado de [13, 15]. 8

2.3. Representación de la molécula de aspirina en notación SMILES y correspondencia con su grafo 2D. 10

2.4. Representación de la molécula de aspirina en notación SELFIES y correspondencia con su grafo 2D. 11

2.5. Diagrama esquemático del proceso de docking molecular. 13

2.6. Diagrama esquemático del funcionamiento de un Autoencoder Variacional (VAE) 15

2.7. Frente de Pareto (soluciones no dominadas) y soluciones dominadas en el espacio de objetivos (f_1 y f_2 a minimizar). El frente delimita el límite óptimo de compromiso entre ambos criterios, adaptado de [10]. 18

2.8. Estructura tridimensional de la proteína MRP1 (código PDB: 8VUX). Obtenido de RCSB PDB. 19

3.1. Visión general de la metodología: arquitectura del VAE preentrenado con MOSES y ciclo iterativo de optimización multiobjetivo en el espacio latente para la generación de moléculas candidatas contra MRP1. 30

3.2. Ejemplos de moléculas del conjunto de datos MOSES y su correspondiente representación lineal en formato SMILES. 31

3.3. Ejemplo de secuencia y tokenización para una molécula en formatos SMILES y SELFIES, incorporando los tokens especiales de inicio (`[SOS]`), fin (`[EOS]`) y relleno (`[PAD]`). 32

3.4. Flujo metodológico en cinco etapas para el modelado de MRP1: preparación del receptor, identificación del bolsillo de unión, calibración con ligando de referencia, delimitación de la caja de docking sobre la cavidad y evaluación de las moléculas candidatas mediante docking. 38

3.5. Irinotecán dentro de la cavidad de proteína 1 asociada a la resistencia a múltiples fármacos (*Multidrug Resistance-associated Protein 1*, MRP1). Las partes coloreadas en naranja corresponden a los residuos de interés. 40

3.6. Posición del irinotecán respecto de los cinco aminoácidos que más frecuentemente interactúan con él y de otros aminoácidos cercanos. 41

3.7. Interpretación geométrica de los principales indicadores de rendimiento multiobjetivo evaluados en un espacio bidimensional a minimizar: (a) región dominada acotada por el punto de referencia $\mathbf{r}$ (HV); (b) distancia mínima desde los puntos de referencia Z a las soluciones aproximadas A (IGD^+); (c) traslación requerida para dominar el frente de referencia (indicador ϵ aditivo); y (d) homogeneidad en la distribución espacial de las soluciones obtenidas (*Spacing*). 46

4.1. Distribuciones de QED y SAS de las moléculas válidas generadas por SM-L 2 frente al conjunto de prueba de MOSES. 52

4.2. Muestras de moléculas generadas por el modelo seleccionado SM-L 2. 52

4.3. Relación de compromiso entre Hipervolumen y Validez Química para todas las configuraciones evaluadas (mediana de 20 semillas). Con borde negro, la configuración seleccionada para cada combinación de operadores. 54

4.4. Efecto de cada hiperparámetro sobre el hipervolumen dentro de cada combinación de operadores en los algoritmos genéticos y en CMOPSO. 55

4.5. Frente no dominado conjunto por familia de cruce (PCX vs. SBX) para cada metaheurística: (a) AGE-MOEA, (b) MOEA/D, (c) NSGA-II y (d) NSGA-III. 60

4.6. Distribución de los indicadores multiobjetivo de cada algoritmo sobre las veinte ejecuciones independientes. 64

4.7. Distribución de las propiedades químicas del frente de Pareto obtenido por cada algoritmo. 65

4.8. Convergencia de los indicadores multiobjetivo en función del número de evaluaciones para cada algoritmo, promediada sobre las veinte ejecuciones independientes. 66

4.9. Convergencia de los indicadores químicos en función del número de evaluaciones para cada algoritmo, promediada sobre las veinte ejecuciones independientes. 67

4.10. Frentes de Pareto superpuestos de las mejores configuraciones de los cinco algoritmos en el espacio QED–SA. 68

4.11. Frente no dominado conjunto global (32 soluciones) en el espacio QED–SA, coloreado según el algoritmo aportante. 70

4.12. Estructuras 2D de las moléculas representativas de cada algoritmo en tres puntos del frente de Pareto: extremo de menor SA, mayor QED y extremo de mayor SA. 71

B.1. Frentes no dominados acumulados sobre las veinte semillas en el espacio QED–SA para cada combinación de operadores en AGE-MOEA, coloreados por el número de semillas en que apareció cada molécula. 84

B.2. Frentes no dominados acumulados sobre las veinte semillas en el espacio QED–SA para cada combinación de operadores en MOEA/D, coloreados por el número de semillas en que apareció cada molécula. 85

B.3. Frentes no dominados acumulados sobre las veinte semillas en el espacio QED–SA para cada combinación de operadores en NSGA-II, coloreados por el número de semillas en que apareció cada molécula. 86

B.4. Frentes no dominados acumulados sobre las veinte semillas en el espacio QED–SA para cada combinación de operadores en NSGA-III, coloreados por el número de semillas en que apareció cada molécula. 87

B.5. Moléculas de mayor QED con SA < 3 seleccionadas del frente no dominado acumulado para cada combinación de operadores en AGE-MOEA. 88

B.6. Moléculas de mayor QED con SA < 3 seleccionadas del frente no dominado acumulado para cada combinación de operadores en MOEA/D. 88

B.7. Moléculas de mayor QED con SA < 3 seleccionadas del frente no dominado acumulado para cada combinación de operadores en NSGA-II. 89

B.8. Moléculas de mayor QED con SA < 3 seleccionadas del frente no dominado acumulado para cada combinación de operadores en NSGA-III. 89

Índice de Tablas

2.1. Modelos generativos para diseño molecular. 21

2.2. Métricas de evaluación de los modelos generativos. 21

2.3. Optimización del espacio latente mediante metaheurísticas en diseño de fármacos. 25

3.1. Espacio de búsqueda de hiperparámetros del autoencoder variacional (*Variational Autoencoder*, VAE). 33

3.2. Combinaciones de tamaño de población y generaciones evaluadas. Todas mantienen un total fijo de 100 000 evaluaciones. 36

3.3. Espacio de hiperparámetros para los algoritmos genéticos (NSGA-II, NSGA-III, MOEA/D, AGE-MOEA). 36

3.4. Espacio de hiperparámetros para CMOPSO. Se evalúan todas las combinaciones del grid, resultando en $3 \times 3 \times 3 = 27$ configuraciones por tamaño de población, para un total de 81 configuraciones. 37

3.5. Aminoácidos que con mayor frecuencia se ubicaron a menos de 4 Å del irinotecán en las poses generadas por Vina. 40

3.6. Distancia entre los aminoácidos de interés y los átomos del irinotecán en la pose analizada. 41

4.1. Configuraciones seleccionadas para la optimización del entrenamiento. . . . 50

4.2. Mejores configuraciones obtenidas en la optimización del entrenamiento. . . 51

4.3. Comparación con el estado del arte utilizando el dataset MOSES 53

4.4. Comparación de indicadores multiobjetivo para las distintas combinaciones de operadores de cruce y mutación (media ± desviación estándar sobre 20 semillas independientes). 56

4.5. Comparación de indicadores químicos para las distintas combinaciones de operadores de cruce y mutación (media ± desviación estándar sobre 20 semillas independientes). 57

4.6. Comparación de indicadores multiobjetivo - mejores configuraciones. 61

4.7. Comparación de indicadores químicos - mejores configuraciones. 62

4.8. Comparación entre algoritmos sobre hipervolumen. Grupos homogéneos: {NSGA-II} > {AGE-MOEA, NSGA-III} > {MOEA/D} > {CMOPSO}. 63

4.9. Contribución de cada algoritmo y combinación de operadores al frente no dominado conjunto global (32 soluciones). 69

4.10. Moléculas representativas de cada algoritmo en tres puntos del frente de Pareto: extremo de menor SA, mayor QED y extremo de mayor SA. 71

A.1. Resultados Experimentales de Generación Molecular (100 y 300 Épocas) . . 77

A.2. Resultados de Optimización de Hiperparámetros (Tasa de Aprendizaje y Tamaño de Lote) 79

B.1. Configuraciones seleccionadas: mejor configuración para cada combinación de operadores en los algoritmos genéticos y mejor configuración global en CMOPSO, determinadas por el menor rango medio de hipervolumen a lo largo de las 20 semillas independientes. 82

B.2. Comparación de operadores en AGE-MOEA sobre hipervolumen. Grupos homogéneos: {pcx_pm, pcx_gauss} > {sbx_gauss, sbx_pm}. 83

B.3. Comparación de operadores en MOEA/D sobre hipervolumen. Grupos homogéneos: {pcx_gauss, pcx_pm} > {sbx_gauss, sbx_pm}. 83

B.4. Comparación de operadores en NSGA-II sobre hipervolumen. Grupos homogéneos: {pcx_gauss, pcx_pm} > {sbx_gauss} > {sbx_pm}. 83

B.5. Comparación de operadores en NSGA-III sobre hipervolumen. Grupos homogéneos: {pcx_pm, pcx_gauss} > {sbx_gauss, sbx_pm}. 83

B.6. Las cinco moléculas con mayor QED del frente de Pareto de cada algoritmo que satisfacen el filtro de accesibilidad (SA < 3) y la restricción de tridimensionalidad ($F_{sp3} \geq 0{,}30$). 90

1

Introducción

1.1. Motivación

El cáncer es un conjunto de enfermedades de las que se tiene registro desde el antiguo Egipto y la Grecia clásica [1], pero que aun con los avances modernos continúa representando uno de los mayores desafíos sanitarios a nivel global, alcanzando más de 20 millones de nuevos diagnósticos anuales [2]. Dentro de este panorama, los cánceres del tracto gastrointestinal representan alrededor del 36 % de la mortalidad oncológica mundial [3]. En este grupo se encuentra el cáncer colorrectal, posicionado como el tercero de mayor incidencia y la segunda causa de muerte por cáncer en el mundo [2].

Si bien hoy en día existen tratamientos quimioterapéuticos estándar basados en fármacos como el 5-fluorouracilo, el oxaliplatino y el irinotecán, cerca del 50 % de los pacientes afectados por esta enfermedad en estadios avanzados desarrolla resistencia y sufre recaídas [3-5]. Estos fracasos en el tratamiento se han asociado con el desarrollo de resistencia a múltiples fármacos (*Multidrug Resistance*, MDR) adquirida, un proceso en el que cobran especial relevancia proteínas transportadoras de la familia de casetes de unión a ATP (*ATP-Binding Cassette*, ABC), las cuales expulsan los medicamentos fuera de la célula tumoral y reducen su concentración intracelular [3-5].

La MRP1, perteneciente a la familia de transportadores ABC, se ha asociado con la resistencia a distintos agentes quimioterapéuticos en cáncer colorrectal [4-6]. En este contexto, la inhibición de su actividad constituye una estrategia de interés para reducir el eflujo de fármacos y, potencialmente, mitigar la resistencia frente a los tratamientos convencionales [6].

El descubrimiento de fármacos mediante métodos tradicionales de laboratorio es un proceso lento y costoso, condicionado por el tamaño del espacio químico estimado en más de 10^{60} moléculas posibles [7, 8]. Además, el diseño de fármacos es un problema intrínsecamente multiobjetivo, ya que una molécula viable no solo debe ser capaz de interactuar con la proteína objetivo con alta afinidad, sino también cumplir con perfiles farmacológicos adecuados y una sintetizabilidad viable [8, 9].

Para abordar esta dificultad, el diseño de fármacos asistido por computadora (*Computer-Aided Drug Design*, CADD) y los modelos generativos, como los VAEs, permiten compri-

mir la información molecular en un espacio latente continuo desde el cual generar nuevas estructuras [7]. En este enfoque un codificador aprende a mapear representaciones moleculares discretas a vectores continuos, mientras que un decodificador realiza el proceso inverso, reconstruyendo o generando nuevas moléculas a partir de puntos de dicho espacio latente [7]. No obstante, muestrear este espacio de manera aleatoria no garantiza la obtención de compuestos con actividad biológica real ni con propiedades farmacológicas adecuadas [7], por lo que resulta necesario el diseño de métodos que permitan explorar el espacio latente de manera efectiva.

La exploración del espacio dirigida a moléculas con características de interés puede ser vista como un problema de optimización combinatoria. Entre los enfoques para abordarlo, las metaheurísticas han cobrado gran interés debido a que pueden encontrar soluciones destacadas en espacios de búsqueda de elevada complejidad y tamaño, sin incrementar la complejidad computacional considerablemente [10]. Específicamente, las metaheurísticas multiobjetivo permiten optimizar simultáneamente distintas metas que suelen entrar en conflicto entre sí, como lograr una alta afinidad con la proteína, asegurar que la molécula sea fácil de sintetizar y mantener un buen perfil farmacológico, ofreciendo un conjunto de soluciones compromiso [8, 10].

Esta tesina propone un esquema computacional de dos etapas. En la primera etapa, se entrena un modelo generativo VAE con bases de datos moleculares para crear un espacio latente continuo de compuestos químicos válidos. En la segunda etapa, se integran algoritmos metaheurísticos multiobjetivo para guiar la búsqueda dentro del espacio latente, evaluando iterativamente la aptitud de las moléculas generadas según su afinidad de unión y sus propiedades farmacológicas deseadas.

Bajo esta premisa, la presente tesina de grado se centra en el desarrollo y evaluación de un enfoque computacional que combina la capacidad generativa de los VAEs con la optimización guiada de algoritmos metaheurísticos multiobjetivo, con el propósito de descubrir moléculas candidatas viables y eficaces para inhibir la proteína MRP1.

1.2. Objetivos

El objetivo general de este trabajo final de grado consiste en desarrollar y evaluar un enfoque computacional híbrido que combine modelos generativos con algoritmos metaheurísticos multiobjetivo, con el fin de obtener moléculas capaces de inhibir la resistencia a quimioterápicos en cáncer colorrectal. A partir de este objetivo general, se plantean los siguientes objetivos específicos:

- Diseñar, implementar y evaluar modelos metaheurísticos multiobjetivo para optimizar moléculas generadas por un modelo generativo.
- Generar moléculas que tengan propiedades estables y que sean eficaces para inhibir la resistencia a quimioterápicos en cáncer colorrectal.

1.3. Organización del Documento

Esta tesina de grado se organiza en capítulos donde se establecen los fundamentos teóricos, se detallan los aspectos metodológicos y experimentales, y se presentan los resultados y las conclusiones alcanzadas. El contenido se estructura de la siguiente manera:

- **Capítulo 1 (Introducción):** Expone la motivación, el problema a abordar, los objetivos del trabajo y la estructura general de la tesina.
- **Capítulo 2 (Marco Teórico):** Brinda los fundamentos sobre CADD, representación molecular, métricas de evaluación, modelos generativos (VAE), optimización multiobjetivo y la proteína MRP1, junto con los trabajos relacionados en el área.
- **Capítulo 3 (Metodología):** Describe el enfoque propuesto, detallando el ajuste de hiperparámetros mediante fármacos genéricos, el diseño de inhibidores específicos contra MRP1 y la configuración experimental utilizada.
- **Capítulo 4 (Resultados y Discusión):** Presenta los resultados obtenidos, analizando la calidad de las moléculas generadas, la comparación con el estado del arte y el estudio de los mejores compuestos candidatos.
- **Capítulo 5 (Conclusiones y Trabajo Futuro):** Resume las principales conclusiones del trabajo, las dificultades encontradas y las líneas de trabajo futuro.

2

Marco Teórico

En este capítulo se hace una revisión de los conceptos teóricos que dan base a esta tesina de grado. Se abordan temas como el diseño de fármacos asistido por computadora, las formas de representar moléculas, las métricas de evaluación y el acoplamiento molecular. También se explica el funcionamiento de los autoencoders variacionales y los métodos de optimización multiobjetivo para buscar soluciones en espacios latentes. Finalmente, se describe el rol de la proteína MRP1 en el cáncer colorrectal y se resume el estado del arte en relación con el diseño computacional de fármacos.

2.1. Diseño de fármacos asistido por computadora (CADD)

El descubrimiento de nuevos fármacos es un proceso mediante el cual se buscan, identifican, diseñan y validan nuevas moléculas con el objetivo de tratar enfermedades mediante la inhibición o modulación de una proteína diana. Se trata de un proceso largo y costoso, que puede requerir entre 10 y 15 años de investigación y desarrollo, con una inversión que puede superar los 1.000 millones de dólares [11].

En la actualidad, es posible distinguir dos perspectivas complementarias dentro de este campo: por un lado, el pipeline tradicional, basado en etapas sucesivas de identificación y validación de blancos, ensayos y optimización de candidatos; por otro lado, el CADD, que incorpora técnicas y métodos computacionales y de tecnologías de la información para acelerar y optimizar el proceso [12].

Históricamente, el descubrimiento de fármacos tiene su origen en pruebas de ensayo y error sobre extractos naturales o compuestos aislados, evaluados directamente en células o animales, sin un blanco molecular específico previamente definido [13]. Tradicionalmente, este proceso sigue un flujo secuencial estructurado en tres fases principales: el descubrimiento temprano, el desarrollo preclínico y los ensayos clínicos en humanos, tal como se ilustra en la figura 2.1 [11, 14].

Este recorrido explica por qué el desarrollo de fármacos puede extenderse por más de una década y superar los 1.000 millones de dólares de inversión [11]. Miles de compuestos evaluados en las primeras etapas son rechazados posteriormente por distintos factores: falta de interacción con el objetivo, bajo perfil farmacológico, dificultad de sín-

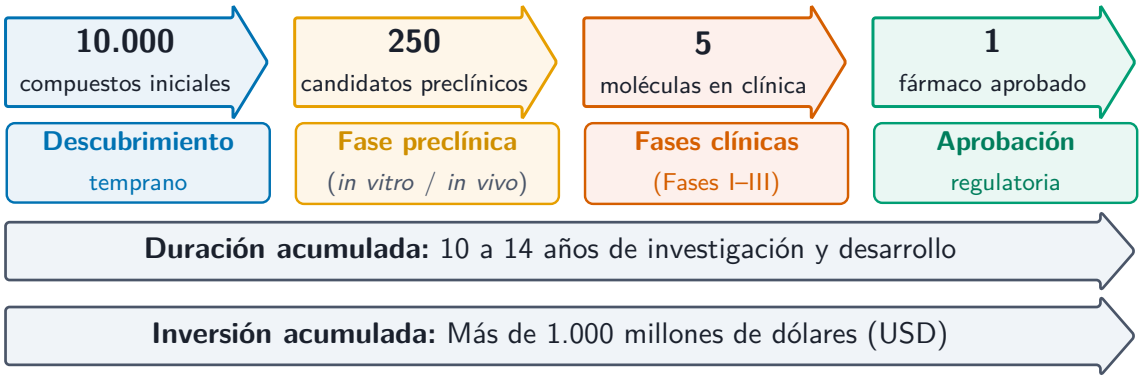


Figura 2.1: *Pipeline tradicional de descubrimiento y desarrollo de fármacos, ilustrando la reducción progresiva de candidatos, tiempos e inversión requerida hasta la aprobación regulatoria. Adaptado de* [11, 13].

tesis, entre otros. Solo un número reducido llega a fases preclínicas y de aprobación, lo que evidencia la enorme tasa de descarte de candidatos en cada etapa [13].

El CADD se originó en la década de 1960, cuando la capacidad de generar modelos moleculares tridimensionales por medios computacionales permitió superar las limitaciones de las representaciones bidimensionales de los compuestos. Desde entonces, evolucionó hasta dividirse en dos enfoques principales según la información disponible sobre el blanco terapéutico: el diseño de fármacos basado en la estructura (*Structure-Based Drug Design*, SBDD), que parte de la estructura tridimensional del blanco, y el diseño de fármacos basado en el ligando (*Ligand-Based Drug Design*, LBDD), que se basa en un conjunto de compuestos con actividad biológica ya conocida contra ese blanco [13].

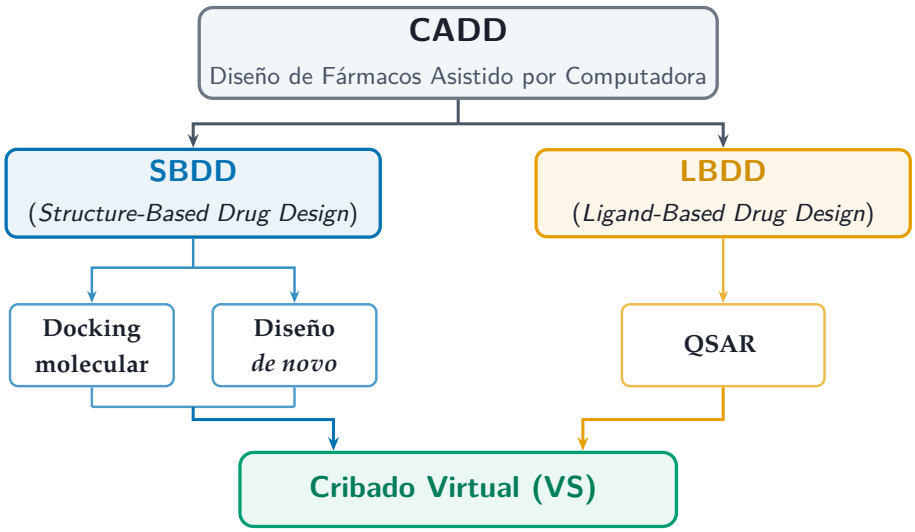


Figura 2.2: *Bifurcación de las estrategias de diseño de fármacos asistido por computadora (CADD) en métodos basados en estructura (SBDD) y basados en ligando (LBDD), convergiendo en el cribado virtual. Adaptado de* [13, 15].

En el diseño basado en la estructura, el blanco se obtiene experimentalmente mediante cristalografía de rayos X, resonancia magnética nuclear (*Nuclear Magnetic Resonance*, RMN) o criomicroscopía electrónica (*Cryogenic Electron Microscopy*, Cryo-EM), o bien por medios computacionales en ausencia de estructuras experimentales, ya sea

mediante modelado por homología o mediante modelos de inteligencia artificial como AlphaFold [16]. Este diseño presenta dos técnicas principales, el diseño de novo, que construye ligandos nuevos dentro de las restricciones del sitio de unión, y el acoplamiento molecular, que evalúa cómo encajan distintos compuestos en ese sitio y califica su afinidad mediante funciones de puntuación [15]. En el diseño basado en el ligando, se asume que las moléculas con estructuras semejantes tienden a exhibir actividades biológicas similares, su metodología más extendida es el modelado de relación cuantitativa estructura-actividad (*Quantitative Structure–Activity Relationship*, QSAR), el cual correlaciona variaciones estructurales con la actividad biológica observada [13].

Como se observa en la figura 2.2, el cribado virtual converge con ambos enfoques, ya que puede orientarse a partir de la estructura del blanco o de los ligandos de referencia. Asimismo, este proceso no se restringe a predecir afinidades de unión, sino que cumple un papel esencial al filtrar candidatos según su perfil de absorción, distribución, metabolismo, excreción y toxicidad (*Absorption, Distribution, Metabolism, Excretion, and Toxicity*, ADMET), descartando compuestos con baja viabilidad [15]. En años recientes, estas herramientas han incorporado distintas metodologías, tales como redes neuronales profundas para mejorar la capacidad predictiva, así como estrategias híbridas que integran SBDD y LBDD dentro de un mismo flujo de trabajo [13].

2.1.1. Representación de moléculas

El diseño de fármacos asistido por computadora requiere describir eficientemente la estructura de las moléculas para que los algoritmos puedan procesarlas y analizarlas. En este contexto, existen diversos formatos, que van desde conformaciones tridimensionales y grafos moleculares hasta secuencias lineales. Estas últimas describen la estructura del compuesto mediante una cadena de texto, lo cual facilita su almacenamiento, indexación y procesamiento. Entre las notaciones lineales más extendidas se destacan sistema simplificado de entrada de líneas moleculares (*Simplified Molecular Input Line Entry System*, SMILES) y cadenas integradas autorreferenciadas (*Self-Referencing Embedded Strings*, SELFIES), ambas abordadas en este trabajo.

La notación SMILES es una representación lineal ampliamente usada para describir la estructura bidimensional de las moléculas mediante cadenas de texto [17]. Cada átomo se representa por su símbolo químico y los enlaces por caracteres especiales. Su sintaxis captura la conectividad molecular, qué átomos están enlazados entre sí, utilizando paréntesis y dígitos para ciclos. Esta notación es concisa, legible y compatible con la mayoría de las bases de datos químicas (PubChem, ChEMBL, ZINC) [18-20], lo que facilita su integración en flujos de trabajo computacionales. SMILES se ha consolidado como la representación estándar en modelos generativos de moléculas basados en secuencias, análogos a los modelos de lenguaje. Arquitecturas basadas en redes neuronales pueden aprender las reglas químicas implícitas en las cadenas SMILES y generar nuevas estructuras válidas [21-23]. Sin embargo, SMILES presenta limitaciones. Su sintaxis es sensi-

ble a pequeños errores que pueden producir moléculas inválidas o distintas. Además, una misma molécula puede tener múltiples representaciones válidas, lo que complica su comparación directa.

Como se observa en la figura 2.3, la estructura de la aspirina se divide en tres partes dentro de la secuencia SMILES. A la izquierda se presenta el grafo bidimensional y a la derecha su correspondencia en texto, donde las ramificaciones se indican con paréntesis y el anillo aromático se delimita con números que abren y cierran el ciclo.

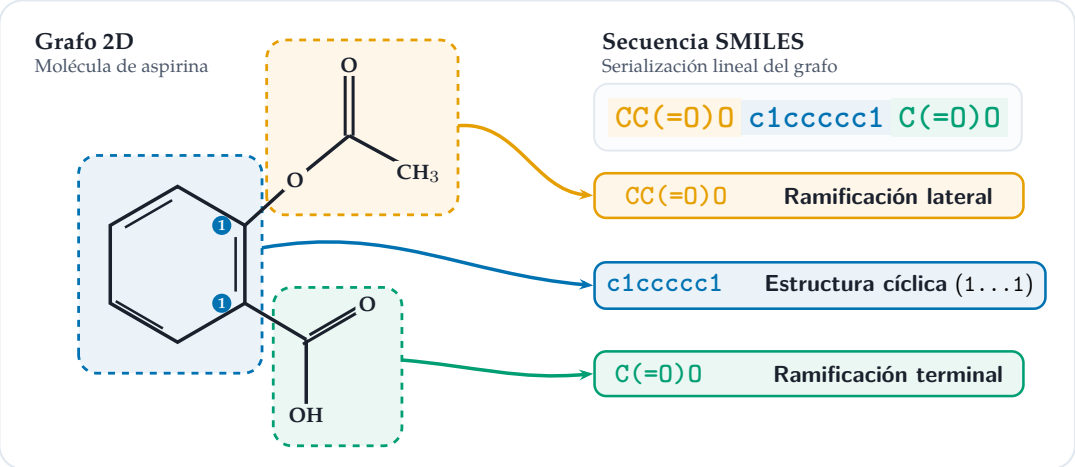


Figura 2.3: *Representación de la molécula de aspirina en notación SMILES y correspondencia con su grafo 2D.*

SELFIES es una representación lineal alternativa a SMILES, diseñada para ser robusta en términos de validez química. Introducida por Krenn et al. entre 2019 y 2020, su objetivo fue eliminar los errores sintácticos comunes de SMILES. En SELFIES, cada símbolo (token) de la cadena corresponde a un elemento químico o una relación estructural, y la gramática está restringida de manera que cualquier secuencia SELFIES decodifica una molécula válida. Es decir, no existen "SELFIES inválidos", y hasta una cadena aleatoria genera una estructura respetando las valencias permitidas [24]. La principal ventaja de SELFIES es esta robustez, que permite eliminar la necesidad de filtrar salidas inválidas de modelos generativos, como ocurre con SMILES [24]. Sin embargo, no está libre de limitaciones: las cadenas SELFIES pueden ser menos intuitivas, más largas que su SMILES equivalente y no reflejar de manera simple ciertas transformaciones moleculares.

La figura 2.4 ilustra cómo se representa la misma molécula en formato SELFIES mediante una secuencia de símbolos entre corchetes. Cada parte de la estructura se define con instrucciones directas, donde las ramas y el cierre del anillo indican de forma exacta los enlaces necesarios para mantener la validez molecular.

2.1.2. Métricas de evaluación química y propiedades moleculares

En el diseño de fármacos asistido por computadora, la calidad de las moléculas generadas no depende de una única característica, para que un compuesto sea viable como

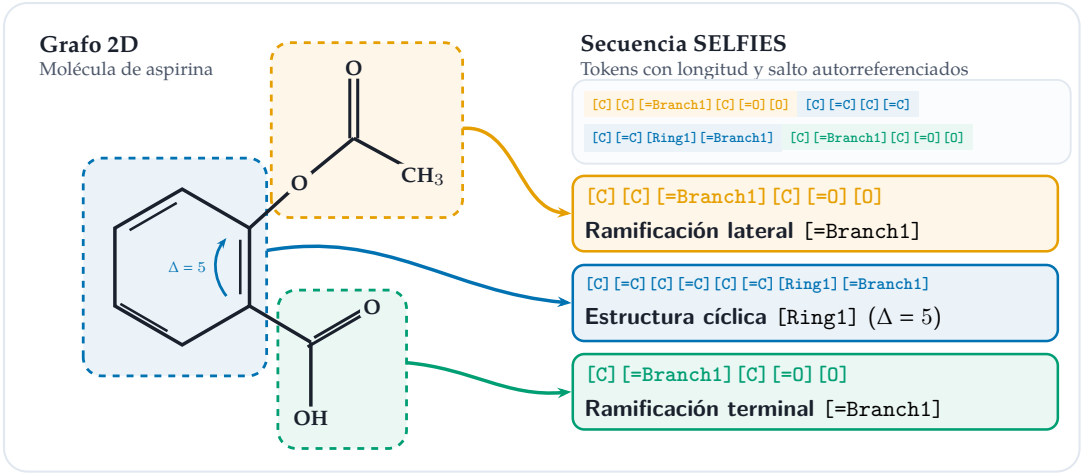


Figura 2.4: *Representación de la molécula de aspirina en notación SELFIES y correspondencia con su grafo 2D.*

candidato a fármaco, debe cumplir con una serie de propiedades para asegurar un perfil farmacológico adecuado. Estas propiedades abarcan desde características fisicoquímicas hasta su viabilidad de síntesis y afinidad de unión con el objetivo terapéutico.

2.1.2.1. Regla de Lipinski y propiedades fisicoquímicas

Uno de los primeros criterios para estimar si un compuesto químico puede cumplir alguna función farmacológica o actividad biológica es la Regla de los Cinco (*Rule of Five*) [25], propuesta en 1997 a partir de un análisis retrospectivo de las propiedades fisicoquímicas de fármacos que habían alcanzado con éxito ensayos clínicos de fase II. La regla establece que una molécula con buena biodisponibilidad oral debe cumplir con las siguientes condiciones:

- Peso Molecular ≤ 500 g/mol
- Coeficiente de partición octanol-agua (LogP) ≤ 5
- Número de aceptores de enlace de hidrógeno ≤ 10
- Número de donadores de enlace de hidrógeno ≤ 5

Esta regla se convirtió en un filtro en las primeras etapas del cribado virtual y diseño de fármacos, sin embargo, no es una regla absoluta, ya que existen fármacos que no cumplen con estas condiciones y son exitosos. Por ello, suele complementarse con métricas más detalladas para evaluar el perfil del compuesto.

2.1.2.2. Estimación cuantitativa de atributos de fármacos (QED)

La estimación cuantitativa de la similitud a fármaco (*Quantitative Estimate of Drug-likeness*, QED) es una métrica que permite evaluar la probabilidad de que una molécula sea un fármaco viable a partir del análisis de las propiedades fisicoquímicas de una co-

lección de fármacos aprobados [26]. El QED toma un valor entre 0 y 1, donde un valor cercano a 1 indica una mayor probabilidad de que la molécula sea un fármaco viable.

El QED se construye a partir de ocho propiedades moleculares relevantes en el diseño de fármacos:

- Peso molecular (*Molecular Weight*, MW)
- Coeficiente de partición octanol-agua basado en átomos (*Atom-based LogP*, ALOGP)
- Número de donadores de enlaces de hidrógeno (*Hydrogen Bond Donors*, HBD)
- Número de aceptores de enlaces de hidrógeno (*Hydrogen Bond Acceptors*, HBA)
- Área de superficie polar (*Polar Surface Area*, PSA)
- Número de enlaces rotables (*Rotatable Bonds*, ROTB)
- Número de anillos aromáticos (*Aromatic Rings*, AROM)
- Número de alertas estructurales (*Structural Alerts*, ALERTS)

Cada una de estas propiedades se transforma mediante una función de deseabilidad, derivada de la distribución de estas propiedades en fármacos aprobados, el QED final se calcula como la media geométrica ponderada de estas ocho funciones.

QED se ha convertido en una de las métricas más utilizadas en los pipelines de diseño de fármacos, debido a que, a diferencia de los filtros discretos como Lipinski, genera una puntuación suave y continua [27].

2.1.2.3. Accesibilidad sintética

La accesibilidad sintética es un criterio que evalúa la dificultad de síntesis de una molécula. Esta propiedad constituye un filtro común en el diseño de fármacos asistido por computadora, ya que permite que un compuesto prometedor pueda fabricarse de forma viable y eficiente, afectando directamente tanto la etapa de diseño y optimización de moléculas como la viabilidad de su posterior implementación experimental.

Para cuantificar la accesibilidad sintética se suele utilizar la puntuación de accesibilidad sintética (*Synthetic Accessibility Score*, SAS) [28]; esta métrica asigna a cada molécula un valor entre 1 (fácil de sintetizar) y 10 (difícil de sintetizar). Dicho valor se calcula a partir del número de fragmentos moleculares y la complejidad de las conexiones entre ellos. En la optimización molecular suele emplearse junto con el QED, donde el QED optimiza la deseabilidad farmacológica y la SAS la viabilidad práctica de obtenerla [27].

2.1.2.4. Fracción de carbonos sp^3

La fracción de carbonos F_{sp^3} es una métrica que evalúa la proporción de carbonos saturados respecto al número total de átomos de carbono:

$$F_{sp^3} = \frac{\text{Número de carbonos } sp^3}{\text{Número total de carbonos}} \tag{2.1}$$

Sus valores oscilan entre 0 para moléculas completamente planas y 1 para moléculas totalmente saturadas.

Esta métrica fue propuesta en el trabajo "Escape from Flatland" [29], donde se observó que las moléculas candidatas a fármacos que tendían a ser excesivamente planas mostraban tasas menores de éxito clínico. A través de un análisis de bases de datos de compuestos en distintas etapas se encontró una correlación positiva entre el grado de saturación Fsp3 y la probabilidad de que un compuesto avance a fases clínicas avanzadas. Asimismo, se encontró una correlación positiva entre el Fsp3 y la solubilidad acuosa. Un trabajo posterior [30] expandió este análisis, relacionando nuevamente la saturación sp3 con la promiscuidad farmacológica, es decir, la tendencia de una molécula a interactuar con dianas biológicas no deseadas, por lo que a mayor complejidad tridimensional, las moléculas tienden a reducir la promiscuidad y con ello el riesgo de efectos adversos fuera de la diana.

2.1.2.5. Métodos de docking molecular y afinidad de unión

El docking molecular es una técnica computacional que permite estimar la afinidad de una molécula pequeña hacia una diana, usualmente una proteína. Esta herramienta se utiliza para predecir la fuerza de dicha unión, conocida como afinidad de unión, y la orientación tridimensional de la molécula dentro del sitio de unión de la proteína.

En la figura 2.5 se muestra un diagrama esquemático con las etapas principales del proceso de docking molecular.

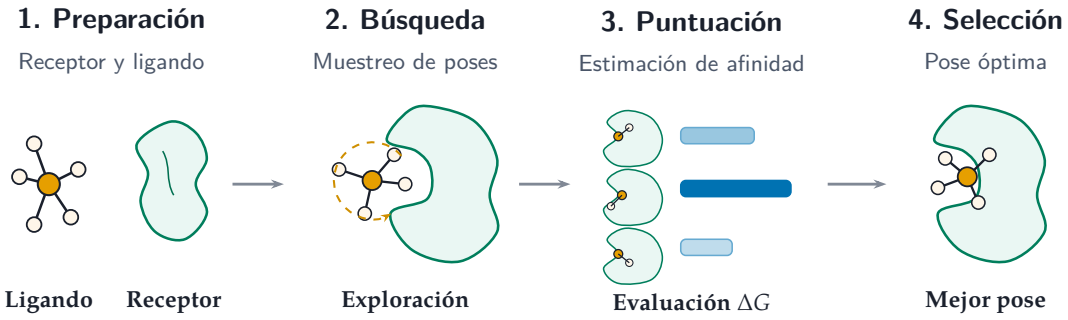


Figura 2.5: *Diagrama esquemático del proceso de docking molecular.*

Una herramienta de docking consiste en general de dos componentes, un algoritmo de búsqueda que explora el espacio de poses del ligando dentro del sitio de unión, y de una función de puntuación que evalúa cada pose y estima la energía de unión de cada pose y permite ordenarlas [31]. Existen distintas implementaciones que combinan estos componentes, cada una con su propia metodología de búsqueda y de puntuación.

Entre esas herramientas se encuentra AutoDock Vina [32], que combina un algoritmo de búsqueda local iterativo con una función de puntuación híbrida, usando información de estructuras de complejos proteína-ligando ya conocidos y de afinidades medidas en experimentos. El docking demanda recursos computacionales considerables cuando se tiene una gran cantidad de ligandos que evaluar, para reducir este costo existen implementaciones aceleradas por unidad de procesamiento gráfico (*Graphics Processing Unit*, GPU), entre ellas Uni-dock [33] que permite procesar moléculas en lotes. El resultado de la función de puntuación se da como una energía de unión estimada (ΔG) en kcal/mol [31] en la que un valor más negativo indica una unión más favorable.

2.1.3. Técnicas computacionales aplicadas al diseño de fármacos

Los métodos basados en inteligencia artificial pueden mejorar enormemente el proceso de diseño de fármacos, en especial los modelos generativos, los cuales son capaces de aprender representaciones del espacio químico para generar nuevos compuestos con propiedades deseadas. Al apoyarse en técnicas de aprendizaje profundo, estos modelos no evalúan únicamente las moléculas conocidas, sino que aprenden las reglas y patrones de la representación molecular para generar nuevos compuestos. Entre estos modelos, los Autoencoders Variacionales destacan por su capacidad de estructurar un espacio latente navegable.

Sin embargo, navegar este espacio latente para generar nuevos compuestos no es una tarea trivial, la optimización molecular requiere equilibrar propiedades que suelen competir entre sí, tales como maximizar la afinidad hacia una diana, mientras se preserva la facilidad de síntesis o la similitud a fármacos conocidos. Al no existir una solución que satisfaga todos estos criterios, la optimización multiobjetivo aborda este desafío identificando las mejores soluciones compromiso.

2.1.3.1. Autoencoders variacionales (VAE)

Los VAEs son una arquitectura de aprendizaje profundo de tipo generativo [34]. Su estructura se basa en dos redes neuronales conectadas: un codificador que procesa los datos y un decodificador que intenta reconstruirlos.

Para entender su funcionamiento, es necesario contrastarlos con los autoencoders tradicionales. Un autoencoder tradicional toma un dato de entrada y lo comprime en un vector fijo en el espacio latente. El problema de este enfoque es que, por sí solo, no puede generar directamente ejemplos nuevos a partir de la distribución de los datos [35].

El VAE trata con este problema modificando la naturaleza del espacio latente. En lugar de codificar la entrada como un punto fijo, la red predice una distribución estadística, definida por una media y una desviación estándar [34]. En la figura 2.6 se ilustra este flujo, desde la estimación de μ y σ hasta la reconstrucción de la entrada a partir de z.

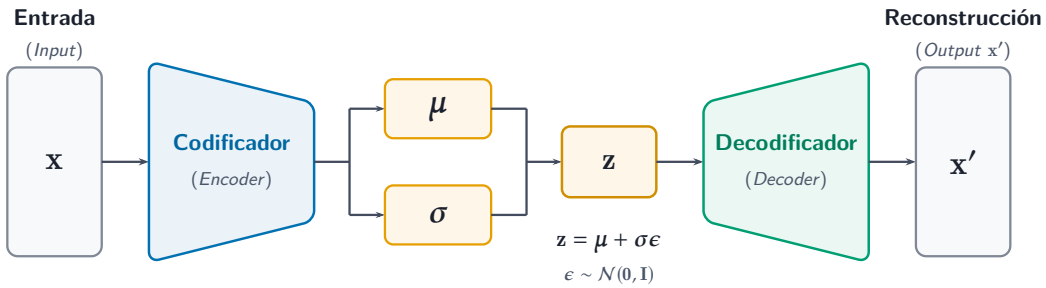


Figura 2.6: *Diagrama esquemático del funcionamiento de un Autoencoder Variacional (VAE). Adaptado de [36].*

En el diseño de fármacos, la entrada x es una molécula representada como una cadena de texto (SMILES o SELFIES). El codificador convierte esa cadena en una distribución sobre el espacio latente, de la que se toma una muestra z, y el decodificador convierte z de nuevo en una cadena. Como este espacio es continuo, se pueden generar moléculas nuevas decodificando vectores aleatorios, perturbando moléculas conocidas o interpolando entre ellas, y también aplicar métodos de optimización para buscar moléculas con mejores propiedades [37].

El entrenamiento de los VAEs presenta un desafío técnico, para generar datos el modelo necesita tomar una muestra aleatoria de esa distribución estadística, pero fijar el vector latente a un valor muestreado bloquea la propagación del error hacia el codificador, por lo que sus pesos no se pueden actualizar [35]. Para solucionarlo se emplea el «truco de reparametrización» [34], que obtiene el vector latente z mediante una ecuación que separa la aleatoriedad de los parámetros aprendibles:

$$z = \mu + \sigma \odot \epsilon \tag{2.2}$$

Donde μ y σ son la media y la desviación estándar que predice el codificador, $\odot$ es el producto elemento a elemento y ϵ es un ruido aleatorio externo que debe seguir una distribución normal estándar. De esta forma, la red puede usar la aleatoriedad para generar variedad, pero mantiene una conexión matemática directa que le permite propagar los gradientes hacia el codificador.

Función de pérdida. Para que el modelo generativo aprenda correctamente, no basta con medir la precisión con la que reconstruye los datos de entrada. Es fundamental asegurar también que el espacio latente posea una estructura estadística coherente que permita la generación de nuevas muestras. Para lograr esto, se utiliza una función de pérdida con dos términos:

$$\mathcal{L} = \mathcal{L}_{recon} + \beta \cdot \mathcal{D}_{KL}\left(q_\phi(z|x) \,\|\, p(z)\right) \tag{2.3}$$

Donde $q_\phi(z|x)$ es la distribución que predice el codificador y $p(z)$ es una distribución normal estándar $\mathcal{N}(0, I)$ [34]. Cuando $\beta = 1$, esta función corresponde al negativo de la cota inferior de la evidencia (*Evidence Lower Bound*, ELBO), la cota inferior que el VAE busca maximizar [34, 35]; el coeficiente β permite ponderar la divergencia KL. En la práctica, este peso puede variar durante el entrenamiento: en *Chemical VAE*, por ejemplo, la pérdida variacional se introduce con un calendario sigmoide (*annealing*) [37].

Esta ecuación actúa como un mecanismo de balance entre dos objetivos contrapuestos durante el entrenamiento:

- **Pérdida de reconstrucción ($\mathcal{L}_{recon}$):** Es el primer término de la ecuación. Su función es comparar el dato generado por el decodificador con el dato original de entrada. Cuanto mayor sea la diferencia o el error en la recuperación de la información, mayor será este valor. Su objetivo es forzar a la red a mantener la fidelidad respecto a los datos reales.
- **Divergencia de Kullback-Leibler ($\mathcal{D}_{KL}$):** Es el segundo término y actúa como un regularizador [34] ponderado por el coeficiente β. Mide la discrepancia entre la distribución aprendida por el codificador y la distribución a priori. Este término funciona como un componente variacional que organiza el espacio latente. Su objetivo principal es forzar a que la distribución que aprende el modelo se parezca lo más posible a la distribución normal estándar, creando un espacio continuo y ordenado.

El objetivo final de esta función es encontrar un equilibrio óptimo: reconstruir los datos con alta precisión sin perder la capacidad de generar nuevas muestras válidas al interpolar en el espacio latente.

2.1.3.2. Metaheurísticas multi-objetivo

La optimización de soluciones en la naturaleza frecuentemente requiere explorar espacios de búsqueda vastos y de alta dimensionalidad, donde los métodos exactos resultan inviables. Estos problemas raramente se pueden reducir a un único objetivo a optimizar, sino que presentan múltiples metas u objetivos en conflicto.

En estos problemas la solución óptima no es única, sino que es un conjunto de soluciones definidas como soluciones óptimas de Pareto, donde no es posible mejorar un objetivo específico sin que ello conlleve al deterioro de otro. Es decir, estas soluciones representan un compromiso entre diferentes objetivos en conflicto por lo que la finalidad es encontrar este conjunto óptimo, y consecuentemente la Frontera de Pareto [10].

Problema de optimización multiobjetivo. Un problema de optimización multiobjetivo puede definirse como [10]:

$$\begin{cases} \text{Min } F(x) = (f_1(x), f_2(x), \ldots, f_n(x)) \\ \text{s.c. } x \in S \end{cases} \tag{2.4}$$

Donde $F(x)$ es el vector de los n objetivos a optimizar $(n \geq 2)$, mientras que x y S mantienen las definiciones de variables de decisión y espacio factible ya establecidas. En este contexto, la búsqueda se orienta a encontrar un equilibrio entre los distintos criterios de aptitud en conflicto.

Los objetivos a maximizar se transforman en problemas de minimización invirtiendo su signo, por lo que la formulación (2.4) abarca ambos sentidos de optimización [10].

Dominancia de Pareto. Un vector objetivo $u = (u_1, \ldots, u_n)$ domina a $v = (v_1, \ldots, v_n)$ $(u \prec v)$ si ninguna componente de v es menor que la correspondiente de u y al menos una es estrictamente menor [10]:

$$\forall i \in \{1, \ldots, n\} : u_i \leq v_i \wedge \exists i \in \{1, \ldots, n\} : u_i < v_i \tag{2.5}$$

Dominancia Débil $(u \preceq v)$. u domina débilmente a v si [10]:

$$\forall i \in \{1, \ldots, n\}, \quad u_i \leq v_i \tag{2.6}$$

Dominancia restringida. Cuando el problema de optimización multiobjetivo incorpora restricciones, la comparación entre soluciones debe contemplar además su factibilidad. Bajo el principio de *dominancia restringida*, una solución x_i domina a una solución x_j si se verifica alguna de las siguientes condiciones [38]:

1. x_i es factible y x_j no lo es.
2. Ambas soluciones son infactibles, pero x_i presenta una menor violación de restricciones.
3. Ambas soluciones son factibles y x_i domina a x_j en el sentido de la ecuación (2.5).

Este criterio permite incorporar restricciones sin recurrir a funciones de penalización, que exigirían el ajuste de parámetros adicionales [38].

Optimalidad de Pareto. Una solución $x^* \in S$ es *Pareto óptima* si para cada $x \in S$, $F(x)$ no domina a $F(x^*)$, es decir, $F(x) \not\prec F(x^*)$ [10].

En general, la búsqueda en un problema mono-objetivo conduce al hallazgo de una única solución óptima global. Un problema de optimización multiobjetivo puede tener un conjunto de soluciones conocido como el *conjunto Pareto óptimo*. La imagen de este conjunto en el espacio de objetivos se denomina el frente de Pareto [10].

Frente de Pareto. Para un problema de optimización multiobjetivo (F, S) dado y su conjunto óptimo de Pareto P^*, el **frente de Pareto** se define como [10]:

$$PF^* = \{F(x) \mid x \in P^*\} \tag{2.7}$$

El frente de Pareto es la imagen del conjunto óptimo de Pareto en el espacio de los objetivos, y su obtención constituye el propósito central de la optimización multiobjetivo. Dado que este frente puede ser sumamente extenso, se busca una aproximación finita que garantice tanto la convergencia hacia la frontera teórica como una distribución uniforme de las soluciones sobre la misma [10].

En la figura 2.7 se ilustra la representación de soluciones dominadas y soluciones pertenecientes al frente de Pareto en un espacio bidimensional.

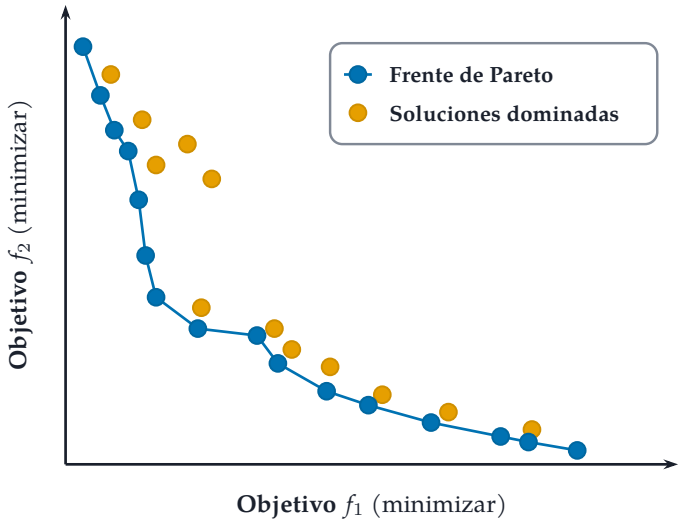


Figura 2.7: *Frente de Pareto (soluciones no dominadas) y soluciones dominadas en el espacio de objetivos (f_1 y f_2 a minimizar). El frente delimita el límite óptimo de compromiso entre ambos criterios, adaptado de [10].*

2.2. Caso de estudio: Proteína 1 de resistencia a múltiples fármacos (MRP1)

El tratamiento del cáncer colorrectal avanzado se maneja principalmente con regímenes de quimioterapia basados en fármacos citotóxicos como el 5-fluorouracilo (*5-Fluorouracil*, 5-FU), el oxaliplatino y el irinotecán. Sin embargo, la efectividad de estos fármacos se ve comprometida debido al desarrollo de MDR, lo cual provoca recaídas en una elevada proporción de pacientes [3, 4].

MRP1 es una proteína transportadora de la familia ABC que usa energía del trifosfato de adenosina (*Adenosine Triphosphate*, ATP) para expulsar moléculas desde el interior

de las células hacia el exterior [39, 40]. Entre estas moléculas se encuentran diversos fármacos quimioterápicos; al ser expulsados, se reduce su concentración intracelular y la célula tumoral adquiere resistencia a los mismos. Esta capacidad de reconocer y transportar activamente un amplio conjunto de quimioterápicos explica la resistencia farmacológica asociada a su sobreexpresión [39, 40].

En el cáncer colorrectal existe evidencia experimental sobre el papel de MRP1 en la resistencia a los fármacos mencionados [6], además de que MRP1 funciona como biomarcador de resistencia al irinotecán [3]. Se encontró que al reducir su producción en células tumorales resistentes, la sensibilidad a dichos fármacos se restablece y la muerte celular de las mismas vuelve a activarse. MRP1 contribuye entonces a la resistencia del cáncer colorrectal, lo que la convierte en un blanco terapéutico de interés [6].

Si bien MRP1 cumple funciones fisiológicas en tejidos sanos, su sobreexpresión en tumores colorrectales representa una barrera terapéutica, por lo que diseñar inhibidores que reduzcan su actividad en células tumorales es un desafío significativo.

Se conoce la estructura tridimensional de MRP1 y el sitio donde se aloja el sustrato que transporta [41]. En la Figura 2.8 se observa la conformación tridimensional de esta proteína (código Banco de Datos de Proteínas (*Protein Data Bank*, PDB): 8VUX). Dicho sitio de unión está dividido en dos partes, una con carga positiva y otra hidrofóbica (que repele el agua), y varios de sus aminoácidos cambian de posición cuando una molécula se une. Esa flexibilidad explica por qué la proteína reconoce ligandos tan distintos entre sí, y a la vez ofrece un blanco delimitado contra el cual evaluar moléculas candidatas mediante acoplamiento molecular [41].

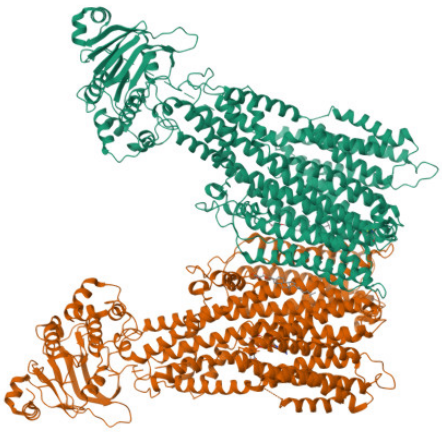


Figura 2.8: *Estructura tridimensional de la proteína MRP1 (código PDB: 8VUX). Obtenido de RCSB PDB.*

El diseño de inhibidores de MRP1 se basó durante décadas en probar, mediante campañas de cribado masivo de la industria farmacéutica, compuestos ya conocidos por

otras propiedades (como el verapamilo o la ciclosporina A) y una amplia variedad de productos naturales. Ninguno de estos compuestos llegó a aprobarse como fármaco [42]. En paralelo, desde que se resolvió por cristalografía de rayos X una parte de MRP1 en 2006, varios trabajos computacionales combinaron esa estructura parcial con modelos por homología del resto de la proteína para buscar inhibidores mediante virtual screening y acoplamiento molecular. Rungsardthong et al. [43] identificaron 20 compuestos candidatos dirigidos a esa parte, y Dhasmana et al. [44] propusieron el citrato de potasio como el mejor candidato de una biblioteca de fármacos aprobados por la Administración de Alimentos y Medicamentos (*Food and Drug Administration*, FDA).

La estructura completa de MRP1, resuelta por Cryo-EM en 2017, reveló por primera vez otra parte de la proteína: la zona donde se une a los fármacos que va a expulsar, distinta de la que usaron los trabajos anteriores. Belhadj et al. [45] utilizan esa estructura para caracterizar ZW-1226, un compuesto que mediante acoplamiento molecular ocupa esa zona de enganche, y que en líneas celulares revierte la resistencia mediada por MRP1 a dos fármacos de quimioterapia.

2.3. Trabajos Relacionados

En este trabajo se propone un enfoque híbrido, en el que mediante un modelo generativo y metaheurísticas multiobjetivo se busca, en una primera instancia, optimizar el diseño y búsqueda de moléculas con propiedades farmacológicas para, posteriormente, enfocarse en candidatos capaces de unirse a la proteína MRP1. Por lo tanto, esta sección revisa los antecedentes de modelos generativos para el diseño molecular y la optimización del espacio latente mediante metaheurísticas.

2.3.1. Diseño de Fármacos Mediante Redes Generativas y VAEs

En esta subsección se revisan los principales modelos generativos aplicados al diseño de moléculas. La Tabla 2.1 resume las características de cada uno: el conjunto de datos con el que fue entrenado, la arquitectura sobre la que se construye, la representación molecular que emplea y el año de publicación. La Tabla 2.2 reúne, para esos mismos modelos, las métricas de calidad de generación que reporta cada trabajo, es decir, la validez, la unicidad y la novedad de las moléculas producidas.

En [37], Gómez-Bombarelli et al. presentan el *Chemical Variational Autoencoder* (Chemical VAE), uno de los primeros modelos en mapear representaciones moleculares discretas (SMILES) a un espacio latente continuo. Entrenado con los conjuntos QM9 y ZINC, permitió explorar y optimizar moléculas mediante operaciones continuas en dicho espacio. Aunque introdujo una base sólida para modelos generativos posteriores, su principal limitación radica en la generación de moléculas inválidas debido a la rigidez sintáctica de

Tabla 2.1: *Modelos generativos para diseño molecular.*

Modelo	Dataset	Arquitectura	Representación molecular	Año
Chemical VAE	QM9 / ZINC	VAE (CNN Enc / GRU Dec)	SMILES	2018
MolGAN	QM9	Implicit GAN (Relational GCN + RL)	Grafo molecular	2018
MOLER	ZINC	Reward shaping sobre JTVAE	Grafo molecular	2022
D-MolVAE	QM9 / ZINC	Graph-based VAE	Grafo molecular	2022
PS-VAE	ZINC250K / QM9	Junction Tree VAE	Subgrafos (Grafos)	2022
PCF-VAE	MOSES	VAE (RNN)	GenSMILES	2025
FRATTVAE	MOSES	Graph Transformer VAE	Grafo molecular	2025
RGCVAE	QM9 / ZINC	Relational Graph VAE	Grafo molecular	2025

Tabla 2.2: *Métricas de evaluación de los modelos generativos.*

Modelo	Dataset	Validez (%)	Unicidad (%)	Novedad (%)
Chemical VAE	ZINC	73.00–79.00	–	–
MolGAN	QM9	98.10	10.40	94.20
MOLER	ZINC	–	–	–
D-MolVAE	QM9	100.00	98.66	95.85
PS-VAE	ZINC250K	100.00	99.70	99.70
PCF-VAE	MOSES	98.01	100.00	93.77
FRATTVAE	MOSES	100.00	99.97	97.42
RGCVAE	QM9	99.90	94.00	96.40

Nota: el guion (–) indica que el trabajo original no reporta dicha métrica.

SMILES. En sus experimentos, el modelo alcanzó una validez del 73–79 % al decodificar puntos cercanos a moléculas reales.

En [46], De Cao y Kipf presentan MolGAN, un modelo generativo adversario que opera directamente sobre grafos moleculares pequeños. El modelo genera de manera simultánea los átomos y los enlaces e incorpora, junto con el entrenamiento adversario, una red de recompensa basada en aprendizaje por refuerzo para guiar la generación hacia mejores propiedades químicas (p. ej., QED, $\log P$ y sintetizabilidad). Está orientado a moléculas de tamaño reducido (entrenado en QM9). Sus principales limitaciones radican en una baja unicidad debido al colapso de modos y dificultades de escalabilidad a grafos mayores. En QM9 reporta una validez del 98.10 %, una unicidad del 10.40 % y una novedad del 94.20 %.

Fu et al. [47] proponen MOLER, un esquema de optimización condicionada que incorpora recompensas a nivel molecular para guiar modelos generativos basados en grafos (acoplable a arquitecturas como JTVAE, VJTNN y CORE). El método añade términos de recompensa y penalización orientados a maximizar la similitud con el compuesto de partida y penalizar la desviación de tamaño, manteniendo así la proximidad estructural mientras se optimiza una propiedad objetivo (QED, afinidad DRD2 o $\log P$). En sus evaluaciones, MOLER incrementa consistentemente la tasa de éxito y la mejora de propiedades respecto de las líneas base (hasta ∼20 %) con bajo costo computacional y alta novedad. Como limitaciones, está concebido para optimización local en lugar de generación totalmente *de novo*, no reporta validez ni unicidad bajo protocolos estandarizados (como MOSES o GuacaMol) y su desempeño depende de la calibración de los pesos de similitud y tamaño.

Du et al. [48] introducen *D-MolVAE*, un autoencoder variacional sobre grafos moleculares enfocado en el aprendizaje de representaciones desentrelazadas (*disentangled representation learning*). Esta arquitectura permite aislar factores latentes asociados a distintas propiedades químicas, generando moléculas válidas, únicas y novedosas con una mayor interpretabilidad del espacio latente. Como limitación, el modelo se enfoca en propiedades globales y el desacoplamiento latente se realiza de manera no supervisada, lo que restringe el control determinista sobre propiedades dirigidas específicas.

Kong et al. [49] proponen *PS-VAE* (*Principal Subgraph Variational Auto-Encoder*), un marco generativo que introduce el concepto de «subgrafos principales»: motivos estructurales recurrentes extraídos automáticamente del conjunto de datos mediante un algoritmo de minería *merge-and-update*, prescindiendo de vocabularios predefinidos manualmente. El modelo sigue un procedimiento en dos etapas: primero emplea un VAE con decodificador autorregresivo (unidad recurrente con compuertas (*Gated Recurrent Unit*, GRU)) para generar una secuencia de subgrafos y, posteriormente, ensambla dichos fragmentos prediciendo las conexiones interfragmentarias mediante una red neuronal de grafos (GNN). Este enfoque preserva la valencia química y reduce la dependencia del orden de permutación. En el benchmark GuacaMol sobre ZINC250K, PS-VAE alcan-

za una validez del 100 % (respaldada por verificación de valencias en inferencia), con 99.70 % de unicidad y 99.70 % de novedad. Como contrapartida, la granularidad a nivel de subgrafos dificulta modificaciones atómicas mínimas en tareas de optimización molecular altamente restringidas.

Bhadwal et al. [50] desarrollan *PCF-VAE* (*Posterior Collapse-Free Variational Autoencoder*), una arquitectura condicional orientada a mitigar el problema del colapso del espacio latente (*posterior collapse*). El modelo utiliza la representación *GenSMILES*, la cual simplifica las reglas sintácticas de SMILES e incrementa la tasa de estructuras químicamente viables. Adicionalmente, implementa una función de pérdida con ponderación dinámica y una capa de control de diversidad estructural. En el benchmark conjuntos moleculares (*Molecular Sets*, MOSES), reporta una validez del 98.01 %, una unicidad del 100.00 % y una novedad del 93.77 %. No obstante, niveles elevados de diversidad inducen estructuras químicamente inestables, y el desempeño global permanece condicionado a los hiperparámetros de regularización y al preprocesamiento de GenSMILES.

Inukai et al. [51] presentan *FRATTVAE* (*Fragment Tree-Transformer based VAE*), un modelo generativo que representa cada molécula como una estructura de árbol en la que los nodos corresponden a fragmentos moleculares. Sobre dicha representación, se aplica una codificación posicional en árbol que preserva las relaciones jerárquicas y un mecanismo de autoatención tipo Transformer para capturar dependencias de largo alcance entre fragmentos. Este diseño busca resolver las limitaciones de los modelos basados en cadenas lineales ante compuestos de alta complejidad topológica. Evaluado en el benchmark MOSES, reporta una validez del 100.00 %, una unicidad del 99.97 % y una novedad del 97.42 %. Entre sus limitaciones, el espacio de generación depende estrechamente de las reglas de fragmentación adoptadas y el costo computacional de la atención en árbol es considerable frente a modelos recurrentes tradicionales.

Rigoni et al. [52] proponen *RGCVAE* (*Relational Graph Conditioned Variational Autoencoder*), un modelo generativo para grafos moleculares que incorpora en su codificador una red *Relational Graph Isomorphism Network* (RGIN). Esta red es capaz de capturar atributos relacionales complejos, tales como órdenes de enlace y estereoquímica tridimensional. La decodificación se ejecuta en dos pasos paralelizables: primero se seleccionan los tipos atómicos conforme a restricciones de valencia y luego se predicen simultáneamente las conexiones entre ellos. Este esquema agiliza los tiempos de convergencia y asegura una alta precisión de reconstrucción. No obstante, el modelo muestra sensibilidad al equilibrio de hiperparámetros: priorizar la exactitud de reconstrucción reduce la diversidad y unicidad de las moléculas generadas en conjuntos complejos como ZINC.

En resumen, los antecedentes recopilados muestran que los modelos generativos presentan distintas limitaciones según la representación y la arquitectura empleada, existiendo un balance entre la complejidad computacional y la validez química. Modelos generativos basados en representaciones tridimensionales conllevan una mayor carga de procesamiento, muchas veces requiriendo datasets reducidos debido a esta limitación. Esto motiva en este trabajo el desarrollo de un VAE sobre representaciones lineales, explorando distintas configuraciones con un benchmark común con el fin de evaluar la

configuración que mejor favorezca la generación de candidatos a fármacos para su posterior optimización.

2.3.2. Optimización del Espacio Latente Mediante Metaheurísticas

En esta subsección se revisan los principales métodos metaheurísticos que operan sobre el espacio latente de modelos generativos moleculares. La Tabla 2.3 resume las características de cada uno: la descripción del método y el modelo generativo sobre el que actúa, la configuración experimental empleada, las métricas de evaluación reportadas y el blanco terapéutico u objetivo de optimización abordado.

Winter et al. [53] proponen *Molecule Swarm Optimization* (MSO), un método que combina una representación continua del espacio químico con el algoritmo metaheurístico de optimización por enjambre de partículas (PSO). El modelo utiliza un espacio latente preentrenado mediante una arquitectura codificador-decodificador que procesa representaciones SMILES, lo que permite desacoplar la generación de moléculas del proceso de optimización multiobjetivo. Su principal innovación radica en el empleo de PSO para explorar dicho espacio latente, lo que reduce drásticamente el costo computacional y permite manejar con eficiencia la alta dimensionalidad del espacio de búsqueda. MSO logró generar moléculas con alta afinidad predicha hacia los blancos biológicos EGFR y BACE1. Como limitaciones, los autores señalan que al depender de modelos predictivos de relación estructura-actividad cuantitativa (QSAR) para evaluar la función objetivo, el algoritmo puede ser conducido hacia regiones fuera del dominio de aplicabilidad o generar moléculas con artefactos estructurales si no se imponen restricciones adecuadas durante la optimización.

Abouchekeir et al. [54] presentan *ADEL* (*Adversarial Deep Evolutionary Learning*), un marco que combina autoencoders adversariales (AAE) y algoritmos evolutivos para el diseño de fármacos. A diferencia de enfoques previos, emplea redes recurrentes (memoria de corto y largo plazo (*Long Short-Term Memory*, LSTM)) junto con un discriminador para estructurar de forma más regular el espacio latente de cadenas SMILES. Posteriormente, aplica el algoritmo genético multiobjetivo algoritmo genético de ordenamiento no dominado II (*Non-dominated Sorting Genetic Algorithm II*, NSGA-II) para operar mediante cruce y mutación sobre los vectores latentes, refinando el modelo de manera iterativa al incorporar las nuevas soluciones generadas a la población de entrenamiento. En sus evaluaciones, ADEL generó compuestos que optimizan simultáneamente múltiples propiedades fisicoquímicas (QED, $\log P$ y accesibilidad sintética), identificando moléculas con favorable energía de unión en simulaciones de acoplamiento molecular contra el biomarcador tumoral CA9. Como limitación metodológica, la optimización evolutiva se restringe a descriptores generales, delegando la selectividad hacia el blanco a una etapa posterior de filtrado sobre la última población.

Tabla 2.3: *Optimización del espacio latente mediante metaheurísticas en diseño de fármacos.*

Método (Año)	Descripción	Configuraciones	Métricas	Target / Objetivo
MSO (2019)	*Particle Swarm Optimization* (PSO) sobre un espacio latente continuo construido a partir de representaciones SMILES.	50 o 200 partículas; 100 o 200 iteraciones. Puntos de inicio: benceno o ChEMBL.	Continuas: afinidad a blanco, QED, $\log P$ penalizado, SA y solubilidad. Binarias: filtros de toxicidad y peso molecular.	Optimización mono y multiobjetivo para compuestos contra los blancos EGFR y BACE1.
ADEL (2022)	*Deep Evolutionary Learning* (DEL) sobre el espacio latente continuo de un autoencoder adversarial (AAE) entrenado con secuencias SMILES, con reentrenamiento iterativo incorporando nuevas moléculas generadas.	Población de 20 000 individuos, 10 generaciones.	Continuas: QED, $\log P$, SAS y afinidad de unión (*docking*). Binarias: validez, novedad y unicidad.	Optimización multiobjetivo (QED, $\log P$ y SAS). Filtrado de la última población para cribado virtual contra CA9.
LEOMol (2024)	Algoritmos evolutivos (GA y evolución diferencial) en el espacio latente continuo de un VAE que utiliza representación SELFIES.	Población de 20 individuos, 20 generaciones, tasa de cruce de 0.8 y mutación de 0.4.	Continuas: $\log P$, QED, peso molecular y similitud de Tanimoto. Binarias: restricción de toxicidad.	Optimización maximizando propiedades fisicoquímicas ($\log P$, QED).
Transformer + MO (2024)	MOEA/DD, GrEA, HypE, KnEA, A-NSGA-III y NMPSO sobre un espacio latente continuo basado en SELFIES.	Predicción ADMET con MTL-BERT y *docking* con QuickVina2-GPU.	Continuas: afinidad, SA, $\log P$ y toxicidad aguda (LD_{50}). Binarias: validez, unicidad, novedad y filtros de toxicidad (ClinTox).	Optimización de solubilidad y biodisponibilidad minimizando toxicidad, SAS y afinidad al receptor LPA1.

Continúa en la siguiente página...

Tabla 2.3 – *Continuación*

Método (Año)	**Descripción**	**Configuraciones**	**Métricas**	**Target / Objetivo**
MOMO (2024)	Marco de optimización multiobjetivo basado en dominancia de Pareto para guiar la búsqueda evolutiva en el espacio latente de un modelo codificador-decodificador entrenado con secuencias SMILES.	Población inicial perturbada con ruido gaussiano. Operadores: selección por torneo binario, cruce lineal combinado y mutación ($p = 0.5$).	Continuas: QED, similitud de Tanimoto, eficiencia del ligando (LE), puntuación de *docking*, actividad DRD2, inhibición de GSK3β y SA.	Optimización simultánea multiobjetivo (de 2 a 4 propiedades). Evaluación contra blancos biológicos 1SYH y 4LDE.
MO-LSO (2024)	Optimización multiobjetivo en el espacio latente continuo de un JT-VAE mediante reentrenamiento iterativo ponderado por eficiencia de Pareto.	Entrenamiento inicial con ZINC. Reentrenamiento iterativo ajustado por parámetro de peso (k). Exploración latente por muestreo aleatorio.	Continuas: $\log P$, SAS, similitud a productos naturales (NP score) y probabilidad de inhibición de DRD2 mediante aprendizaje automático.	Optimización multiobjetivo simultánea (hasta 3 propiedades) para maximizar $\log P$, NP score e inhibición de DRD2, y minimizar SAS.
Paddy (2025)	Algoritmo evolutivo basado en el *Paddy field algorithm*, aplicado sobre el espacio latente continuo de un JT-VAE.	Operadores evolutivos inspirados en la dispersión de plantas de arrozal, con tasa de dispersión adaptativa que regula la proximidad y número de nuevas soluciones.	Continuas: $\log P$, SA, número de ciclos con más de 6 átomos y similitud de Tversky.	Optimización de múltiples parámetros integrados en una función objetivo.

El modelo *LEOMol*, introducido por Siddartha Reddy et al. [55], aborda el diseño de fármacos integrando un autoencoder variacional con algoritmos genéticos y evolución diferencial. Al adoptar la representación robusta SELFIES, el sistema garantiza un 100 % de validez química. Su principal ventaja radica en explorar el espacio latente mediante operadores estocásticos poblacionales en lugar de métodos basados en gradientes continuos, lo que facilita optimizar funciones de aptitud complejas evaluadas con herramientas quimioinformáticas estándar. En sus experimentos, demostró alta eficacia para generar compuestos que satisfacen múltiples criterios concurrentes, destacando la generación de moléculas exentas de toxicidad. No obstante, el algoritmo presenta dificultades para converger hacia soluciones viables cuando se le exige preservar una elevada similitud estructural con respecto a un compuesto de partida.

Aksamit et al. [56] proponen un marco de trabajo que integra la arquitectura Transformer con algoritmos metaheurísticos de muchos objetivos (*many-objective optimization*) para el diseño molecular. Este enfoque busca optimizar simultáneamente perfiles farmacocinéticos ADMET y la afinidad de unión estimada mediante acoplamiento molecular. Empleando el modelo ReLSO para proyectar las moléculas en un espacio latente continuo basado en SELFIES, el estudio evalúa y compara el desempeño de diversas metaheurísticas (tales como MOEA/DD, GrEA, HypE, KnEA, A-NSGA-III y NMPSO) en la búsqueda de ligandos dirigidos al receptor LPA1. Como principal limitación, los autores destacan el elevado costo computacional derivado de evaluar el acoplamiento molecular en cada evaluación de aptitud, lo que restringe la sintonización exhaustiva de los hiperparámetros del optimizador.

Xia et al. [57] desarrollan *MOMO* (*Multiobjective Molecule Optimization*), un marco metodológico que guía la búsqueda evolutiva en el espacio químico fundamentándose en el principio de dominancia de Pareto. El método utiliza un codificador-decodificador preentrenado sobre secuencias SMILES para mapear las estructuras moleculares a vectores continuos, sobre los cuales aplica selección por torneo binario, cruce lineal combinado y perturbaciones de mutación. Su fortaleza radica en superar el rendimiento de algoritmos convencionales del estado del arte, reportando mejoras notables en tasa de éxito, novedad e hipervolumen en problemas de optimización de dos a cuatro propiedades simultáneas (incluyendo afinidad contra dianas 1SYH y 4LDE). Como debilidad, el modelo manifiesta susceptibilidad a producir ciertas estructuras químicamente poco realistas si no se imponen restricciones de valencia y filtros estructurales rigurosos durante la fase de decodificación.

Abeer et al. [58] introducen *MO-LSO* (*Multi-Objective Latent Space Optimization*), un método que optimiza el espacio latente de modelos preentrenados tipo JT-VAE a través de un esquema de reentrenamiento iterativo ponderado por la eficiencia de Pareto de las moléculas muestreadas. Esta estrategia permite equilibrar compromisos entre propiedades fisicoquímicas contrapuestas, generando moléculas de alta calidad (como potenciales inhibidores del receptor DRD2) incluso a partir de conjuntos de datos iniciales

desprovistos de ligandos activos. Como contrapartida, el procedimiento iterativo tiende a concentrar las soluciones en regiones localizadas del espacio químico, reduciendo la diversidad estructural de los compuestos finales, a lo que se suma el incremento del costo computacional derivado de los ciclos sucesivos de reentrenamiento.

Beck et al. [59] presentan *Paddy*, un algoritmo de optimización evolutiva inspirado en la dispersión reproductiva de las plantas de arrozal (*paddy field algorithm*), diseñado para explorar sistemas y espacios químicos complejos. A diferencia de los algoritmos genéticos convencionales que dependen de operadores de recombinación cromosómica, Paddy propaga soluciones en el espacio latente de un modelo JT-VAE mediante mutaciones gaussianas reguladas por la densidad local de las soluciones y su aptitud. Esto proporciona una exploración rápida y flexible del espacio paramétrico continuo. Sin embargo, en su formulación para optimización molecular monoproyectada sobre una única función escalar agregada, el método tiende a simplificar las relaciones de compromiso no lineales inherentes a la optimización multiobjetivo de propiedades farmacológicas.

En general, los trabajos revisados muestran la capacidad de las metaheurísticas para navegar espacios latentes, aunque en muchos casos la afinidad a una diana terapéutica se evalúa como un filtrado posterior y no como una función objetivo. De igual manera, son escasos los antecedentes que integran directamente el acoplamiento molecular en una optimización multiobjetivo frente a proteínas transportadoras como MRP1. Asimismo, la mayoría de los estudios se limita a evaluar uno o dos algoritmos aislados, sin realizar una comparación sistemática entre ellos. Esto motiva en este trabajo de grado a evaluar la búsqueda en el espacio latente mediante un enfoque multiobjetivo, contrastando diferentes algoritmos representativos para optimizar simultáneamente la afinidad hacia MRP1 y propiedades farmacológicas deseadas.

3

Metodología

En este capítulo se describe la metodología empleada en esta tesina de grado. Se explica el proceso de ajuste de hiperparámetros y evaluación de metaheurísticas multiobjetivo en el reccorido del espacio latente del modelo generativo, seguido por la formulación del problema de diseño de inhibidores dirigidos a la inhibición de la extracción de quimioterapeúticos del interior de la célula tumoral por parte de MRP1.

3.1. Visión General de la Metodología

Se propone un esquema estructurado en dos etapas. La primera abarca el desarrollo, ajuste y evaluación comparativa de un VAE. La segunda consiste en la exploración de su espacio latente mediante metaheurísticas multiobjetivo para la generación de moléculas. El objetivo de la primera etapa es determinar la configuración con mejor desempeño en la generación molecular y utilizar dicha configuración como base para la posterior búsqueda y optimización de compuestos dirigidos a la diana MRP1.

En la primera etapa se entrena un VAE sobre el benchmark MOSES [60]. El propósito del modelo es comprimir la estructura química de los compuestos en un espacio latente continuo. Su evaluación se realiza bajo el protocolo y las métricas estándar de MOSES para seleccionar la mejor combinación de representación molecular, arquitectura e hiperparámetros.

En la segunda etapa se emplean algoritmos metaheurísticos multiobjetivo para explorar el espacio latente continuo del VAE. Este proceso se divide en dos fases:

1. **Ajuste de hiperparámetros y evaluación en fármacos genéricos:** Se optimizan simultáneamente propiedades fisicoquímicas para comparar el desempeño de los algoritmos y calibrar sus hiperparámetros mediante indicadores químicos y multiobjetivo.
2. **Diseño de inhibidores de MRP1:** Primero se identifica el sitio de unión del sustrato. Con base en esto, se emplean las mejores configuraciones de los algoritmos para optimizar la afinidad hacia la diana, dirigiendo la búsqueda hacia moléculas con interacciones en ese sitio.

La Figura 3.1 resume este flujo de trabajo, combinando el VAE con las metaheurísticas para la búsqueda de moléculas candidatas.

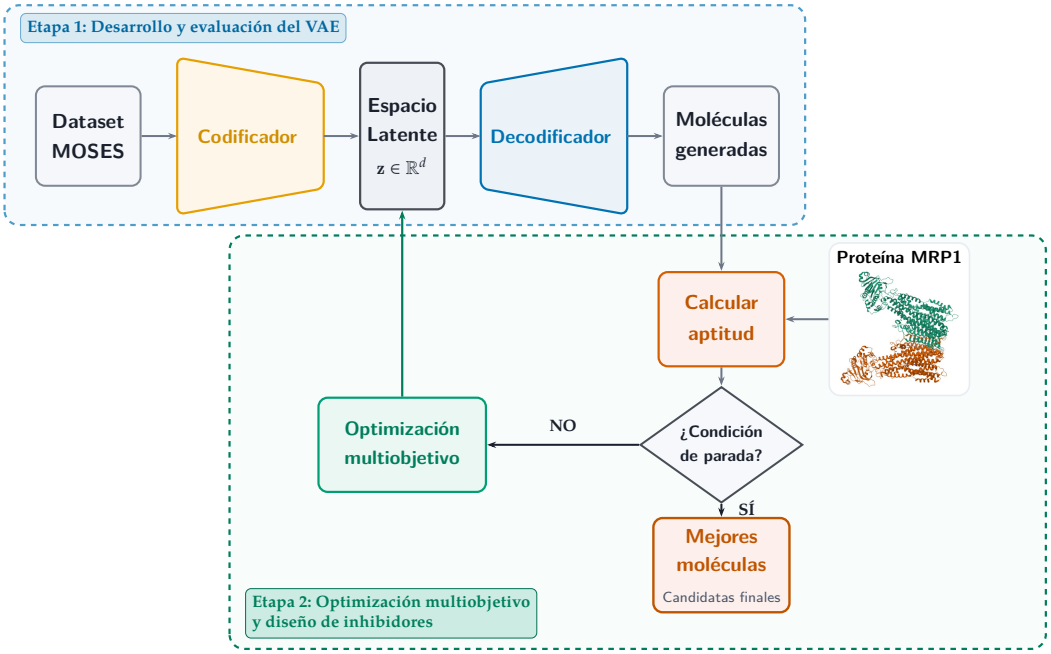


Figura 3.1: *Visión general de la metodología: arquitectura del VAE preentrenado con MOSES y ciclo iterativo de optimización multiobjetivo en el espacio latente para la generación de moléculas candidatas contra MRP1.*

A partir de este esquema se analiza el rendimiento de los algoritmos y la calidad de las moléculas generadas, comparando además los frentes de Pareto obtenidos. Posteriormente en los experimentos dirigidos hacia la diana, se evalúa su afinidad de unión y la formación de interacciones en el sitio de interés. En las siguientes secciones se explica cada uno de estos pasos con mayor detalle.

3.2. Datos de Entrada

En esta sección se presentan los datos y las codificaciones utilizadas para el entrenamiento del modelo generativo. Se detalla el conjunto de datos químicos empleado, sus características y las particiones adoptadas. Se describen ademas las representaciones moleculares evaluadas, sus esquemas de tokenización y los mecanismos de decodificación a partir del espacio latente.

3.2.1. Conjuntos de Datos y Preprocesamiento

Para el entrenamiento del modelo generativo se utiliza el conjunto de datos MOSES [60], obtenido a partir de la colección *Clean Leads* de la base de datos pública ZINC [20]. Este conjunto reúne aproximadamente 1.93 millones de moléculas en formato SMILES con propiedades de compuestos tipo fármaco, previamente filtradas para descartar estructuras inestables, reactivas o con propiedades farmacológicas desfavorables. Estas

moléculas son genéricas y no están dirigidas a ninguna diana biológica en particular. Cuentan con un peso molecular de entre 250 y 350 Da, $\log P \leq 3.5$, hasta 7 enlaces rotables, ciclos de no más de 8 átomos y están formadas únicamente por átomos de C, N, O, S, F, Cl, Br e H.

Para los experimentos se utilizan las particiones oficiales del conjunto de datos, utilizando el conjunto de entrenamiento (~1.58 millones de moléculas) para ajustar el modelo y el conjunto de prueba (~176 mil moléculas) para evaluar su desempeño.

La Figura 3.2 muestra seis moléculas seleccionadas al azar del conjunto de datos junto a su correspondiente notación SMILES.

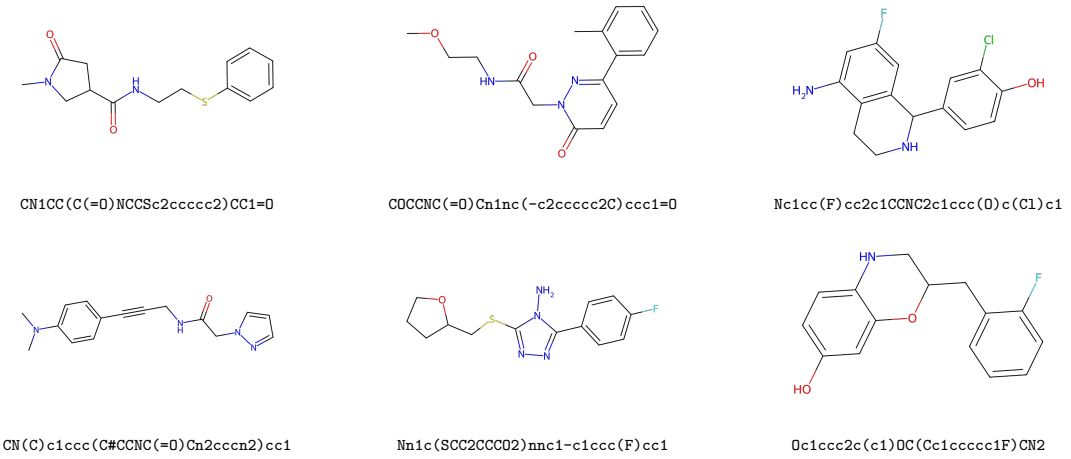


Figura 3.2: *Ejemplos de moléculas del conjunto de datos MOSES y su correspondiente representación lineal en formato SMILES.*

3.2.2. Representaciones Moleculares y Decodificación

En este trabajo se exploran y comparan dos representaciones lineales: SMILES y SELFIES. Se utiliza SMILES por ser el formato estándar del benchmark MOSES, mientras que SELFIES se incorpora para evitar la generación de estructuras sintéticamente inválidas. Comparar ambas permite evaluar el impacto de esta robustez sobre la calidad del espacio latente. En el caso de SMILES, las cadenas se tokenizan mediante la expresión regular propuesta por Cretu et al. [61], preservando átomos multicarácter (como Br y Cl), enlaces, ramas y ciclos como unidades individuales. Para SELFIES, la tokenización se realiza de forma nativa a partir de sus identificadores entre corchetes [24]. En ambas representaciones se incorporan los tokens de control de inicio (`[SOS]`), fin (`[EOS]`), símbolo desconocido (`[UNK]`) y relleno (`[PAD]`) para homogeneizar la longitud de las secuencias en los lotes de entrenamiento. La Figura 3.3 muestra un ejemplo de esta tokenización para una molécula en ambas representaciones.

Esta representación en secuencias de tokens sirve como base para el proceso de decodificación, mediante el cual el modelo reconstruye o genera nuevas moléculas a partir del espacio latente. Para ello, la red decodificadora toma un vector latente $\mathbf{z}$ muestrea-

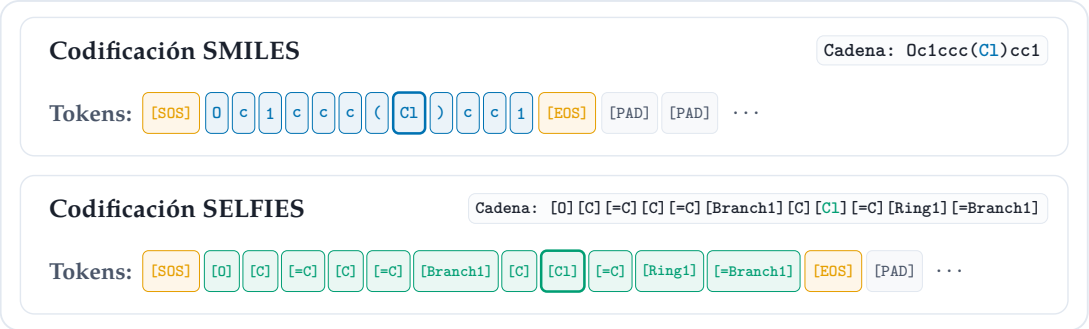


Figura 3.3: *Ejemplo de secuencia y tokenización para una molécula en formatos SMILES y SELFIES, incorporando los tokens especiales de inicio (`[SOS]`), fin (`[EOS]`) y relleno (`[PAD]`).*

do en el espacio continuo y genera de manera autorregresiva una nueva cadena token a token, iniciando con el delimitador `[SOS]` hasta emitir `[EOS]`. Finalmente, la secuencia obtenida se interpreta como una estructura molecular bajo las reglas de la representación empleada (SMILES o SELFIES).

3.3. FASE 1: Ajuste de Hiperparámetros y Evaluación en Fármacos Genéricos

En esta sección se describe la primera etapa metodológica, orientada a dos objetivos principales: seleccionar la mejor configuración del modelo generativo (VAE) a través de un espacio de búsqueda estructurado, y calibrar los hiperparámetros de las metaheurísticas multiobjetivo al optimizar propiedades generales en su espacio latente.

3.3.1. Ajustes de Hiperparámetros del VAE

Con el fin de determinar la configuración con mejor desempeño del VAE, el espacio de búsqueda de hiperparámetros se dividió en dos partes, totalizando 72 entrenamientos independientes. Se optó por evaluar primero la estructura del autoencoder y posteriormente sus parámetros de optimización, evitando así escalar el tiempo de cómputo de forma desmedida. Así, la exploración inicial define la representación y la arquitectura base, y la optimización posterior afina la tasa de aprendizaje y el tamaño de lote en las mejores configuraciones:

- **Exploración de la estructura base:** Se evaluaron 48 configuraciones combinando la representación molecular (SMILES y SELFIES), el tipo de celda recurrente (GRU y LSTM), la cantidad de capas ocultas (1 y 2), la dimensión latente (64, 128 y 256) y las épocas de entrenamiento (100 y 300). La tasa de aprendizaje y el tamaño de lote se mantuvieron fijos en 1×10^{-3} y 128. Las dimensiones latentes se basan en trabajos previos de VAEs moleculares [37] para probar diferentes capacidades de representación, y las épocas buscan evaluar si un entrenamiento prolongado mejora los resultados.

- **Optimización del entrenamiento:** Sobre los cuatro modelos representativos con mejor balance del análisis previo, se exploraron dos tasas de aprendizaje (1×10^{-3} y 1×10^{-4}) y tres tamaños de lote (64, 128 y 192), sumando 24 ejecuciones adicionales. El objetivo fue comprobar si una tasa de aprendizaje más baja (1×10^{-4}) permitía un mejor ajuste y evaluar el efecto de variar el tamaño de lote en el entrenamiento.

El cuadro 3.1 resume las variables y los valores explorados en cada parte del análisis.

Tabla 3.1: *Espacio de búsqueda de hiperparámetros del VAE.*

Configuración	Variable	Valores Explorados	Total
Estructura base (Fijos: LR 1×10^{-3}, Batch 128)	Representación	SMILES, SELFIES	48
	Arquitectura	GRU, LSTM	
	Capas ocultas	1, 2	
	Dimensión Latente	64, 128, 256	
	Épocas de Entrenamiento	100, 300	
Optimización de entrenamiento (Mejores 4 Modelos seleccionados)	Tasa de Aprendizaje (LR)	1×10^{-3}, 1×10^{-4}	24
	Tamaño de Lote (Batch)	64, 128, 192	
		Total de ejecuciones:	**72**

Esquema de entrenamiento y regularización. Todos los modelos se entrenaron utilizando el optimizador Adam [62]. Para evitar el colapso del espacio latente, se aplicó un aumento gradual del peso de la divergencia KL, inspirado en la implementación *Chemical VAE* [37] y en el benchmark MOSES [60]. En este esquema, el parámetro β se incrementa linealmente desde 0 hasta un valor máximo de 0.3 durante el primer 25 % de las épocas de entrenamiento.

3.3.2. Ajuste de Hiperparámetros de las Metaheurísticas

Una vez determinado el modelo generativo base, esta subsección aborda la calibración de las metaheurísticas multiobjetivo en su espacio latente. Se presentan los cinco algoritmos evaluados, las funciones objetivo y restricciones químicas consideradas, y el diseño experimental adoptado para ajustar sus parámetros.

3.3.2.1. Metaheurísticas Consideradas

Se consideran cinco algoritmos metaheurísticos multiobjetivo para la experimentación, todos ellos operando sobre el espacio latente continuo del VAE:

NSGA-II (Non-dominated Sorting Genetic Algorithm II). Es el algoritmo evolutivo multiobjetivo de referencia y se apoya en la profundidad de dominancia. En cada generación ordena la población en frentes sucesivos de no dominancia mediante un procedimiento de ordenamiento rápido. Los empates dentro de un mismo frente se resuelven con la *distancia de apiñamiento* (*crowding distance*), que mide qué tan poblado está el

entorno de cada individuo y favorece a los que se encuentran en regiones menos densas. Estos dos mecanismos, junto con una estrategia elitista, le permiten mantener a la vez convergencia y diversidad [38].

NSGA-III (Non-dominated Sorting Genetic Algorithm III). Conserva el esquema anterior, pero reemplaza la distancia de apiñamiento por un mecanismo de nichos basado en puntos de referencia distribuidos sobre un hiperplano normalizado. Cada solución se asocia al punto de referencia más cercano y sobreviven primero las soluciones asociadas a los puntos con menos representantes. De esta forma se logra una cobertura uniforme del frente incluso cuando crece el número de objetivos [63].

MOEA/D (Multiobjective Evolutionary Algorithm Based on Decomposition). Descompone el problema multiobjetivo en un conjunto de subproblemas escalares, definidos por vectores de pesos, y los optimiza de forma simultánea. Cada subproblema se resuelve usando solo la información de sus subproblemas vecinos. La distribución de las soluciones sobre el frente depende de cómo se distribuyan los vectores de pesos, y no de un mecanismo explícito de preservación de la diversidad [64].

CMOPSO (Competitive Mechanism Based Multi-objective Particle Swarm Optimizer). Pertenece a la familia de la optimización por enjambre de partículas. El rendimiento de los optimizadores convencionales de esta familia depende en gran medida de las mejores soluciones globales y personales guardadas en un archivo externo. CMOPSO, en cambio, selecciona en cada generación un conjunto de partículas élite del propio enjambre, según el frente de no dominancia y la distancia de apiñamiento, y actualiza cada partícula mediante una competencia por pares entre dos élites elegidas al azar: gana la que forma el ángulo menor con la partícula [65].

AGE-MOEA (Adaptive Geometry Estimation Based MOEA). Parte de que el desempeño de los algoritmos multiobjetivo depende de la geometría del frente de Pareto, que puede ser una hipersuperficie euclídea, esférica o hiperbólica. Sobre el esquema de NSGA-II, reemplaza la distancia de apiñamiento por un puntaje de supervivencia que combina diversidad y proximidad mediante una norma L_p adaptativa. La estimación de dicha geometría se realiza mediante un procedimiento de complejidad $O(n \times N)$, donde n es el número de objetivos y N el tamaño de la población. De este modo mantiene un rendimiento competitivo ante frentes de geometrías diversas, donde los algoritmos que suponen una geometría fija tienden a degradarse [66].

3.3.2.2. Funciones Objetivo y Restricciones

En este apartado se describen las funciones objetivo y la restricción estructural empleadas para guiar la búsqueda de los algoritmos en el espacio latente continuo del VAE, todas ellas calculadas con RDKit [67], una librería de quimioinformática utilizada para el análisis y cálculo de descriptores moleculares:

- **QED (*Quantitative Estimate of Drug-likeness*) [26]:** [Problema de maximización] Cuantifica la probabilidad de que una molécula presente propiedades farmacológicas adecuadas. Asigna una puntuación continua entre 0 y 1 mediante funciones de deseabilidad derivadas de múltiples descriptores fisicoquímicos.
- **SAS (*Synthetic Accessibility Score*) [28]:** [Problema de minimización] Evalúa la dificultad teórica para sintetizar la molécula en un laboratorio químico. Asigna una puntuación continua en el rango $[1, 10]$, donde valores menores indican mayor accesibilidad sintética.

Para alejar la búsqueda de estructuras planas, se considera que una mayor proporción de carbonos saturados suele favorecer la solubilidad acuosa [29] y disminuir tanto la promiscuidad biológica como la inhibición de citocromos CYP450 [30].

Restricción de complejidad estructural. La fracción de carbonos con hibridación sp^3 (F_{sp3}) se define como:

$$F_{\text{sp3}} = \frac{\text{número de carbonos } sp^3}{\text{número total de carbonos}} \tag{3.1}$$

Esta propiedad se aplica como restricción de factibilidad ($F_{\text{sp3}} \geq 0.30$). Este límite coincide con los promedios observados en etapas iniciales de descubrimiento (~ 0.32–0.36), intervalo a partir del cual la promiscuidad comienza a descender de forma sostenida [30].

Para gestionar esta restricción, los algoritmos emplean el criterio de dominancia restringida [38], donde las soluciones factibles siempre dominan a las infactibles, y entre infactibles se prioriza la de menor violación. Asimismo, si un vector latente decodifica en una estructura químicamente inválida según RDKit, se le asigna la máxima penalización en ambos objetivos y en la violación de restricción, forzando a la búsqueda a mantenerse dentro de las regiones viables del espacio latente.

3.3.2.3. Protocolo Experimental del Ajuste

Para cada algoritmo se define un espacio de hiperparámetros que se explora mediante un barrido en grilla (*grid search*). Los hiperparámetros se organizan en tres niveles: el reparto del total de evaluaciones (común a todos los algoritmos), los operadores y probabilidades de los algoritmos genéticos, y los parámetros propios de CMOPSO.

Total de Evaluaciones y Tamaño de Población

Se fija un total de 100 000 evaluaciones por ejecución, repartido en tres combinaciones de tamaño de población y número de generaciones (Tabla 3.2). Esta elección permite evaluar el compromiso entre diversidad poblacional (más individuos) y profundidad de búsqueda (más generaciones) bajo un mismo costo computacional.

Tabla 3.2: *Combinaciones de tamaño de población y generaciones evaluadas. Todas mantienen un total fijo de 100 000 evaluaciones.*

Población	Generaciones	Evaluaciones
100	1 000	100 000
200	500	100 000
400	250	100 000

3.3.2.4. Operadores e Hiperparámetros de los Algoritmos Genéticos

Los cuatro algoritmos genéticos (NSGA-II, NSGA-III, MOEA/D y AGE-MOEA) comparten el mismo espacio de hiperparámetros, definido por el tipo de operador de cruce y mutación. Se evalúan los siguientes operadores:

- **Cruce Binario Simulado (SBX) [68]:** Genera dos hijos a partir de dos padres imitando el comportamiento del cruce de un punto en codificación binaria, pero adaptado a variables reales.
- **Cruce Centrado en Padres (PCX) [69]:** Genera cada hijo cerca del centroide de los padres seleccionados, desplazándolo ligeramente hacia uno de ellos y añadiendo una pequeña perturbación aleatoria en las demás direcciones.
- **Mutación Polinomial (PM) [70]:** Perturba cada variable del individuo a partir de una distribución polinomial.
- **Mutación Gaussiana [71]:** Añade a cada variable un ruido aleatorio extraído de una distribución normal.

La Tabla 3.3 resume el espacio de hiperparámetros barrido para los algoritmos genéticos.

Tabla 3.3: *Espacio de hiperparámetros para los algoritmos genéticos (NSGA-II, NSGA-III, MOEA/D, AGE-MOEA).*

Hiperparámetro	Valores evaluados
Tipo de cruce	SBX, PCX
Tipo de mutación	PM, Gaussiana
Probabilidad de cruce (p_c)	0.7, 0.9, 1.0
Probabilidad de mutación (p_m)	0.004, 0.012, 0.031

Para el cruce se evalúan valores de 0.7, 0.9 y 1.0, tomando como referencia el valor $p_c = 0.9$ propuesto en [38]. Las probabilidades de mutación parten de la regla $p_m = 1/n$ [38], que con $n = 256$ dimensiones da $p_m \approx 0.004$; los niveles 0.012 y 0.031 corresponden a perturbar unas 3 y 8 dimensiones por individuo.

3.3.2.5. Operadores e Hiperparámetros de CMOPSO

A diferencia de los algoritmos genéticos, CMOPSO no emplea operadores de cruce, sino una dinámica de enjambre de partículas donde la búsqueda se guía mediante competencias por pares entre partículas seleccionadas de un conjunto élite [65]. Sin embargo, para preservar la diversidad del enjambre y evitar el estancamiento en óptimos locales, el algoritmo sí aplica un operador de mutación polinomial tras la actualización de posiciones. La Tabla 3.4 muestra los hiperparámetros explorados.

Tabla 3.4: *Espacio de hiperparámetros para CMOPSO. Se evalúan todas las combinaciones del grid, resultando en* $3 \times 3 \times 3 = 27$ *configuraciones por tamaño de población, para un total de 81 configuraciones.*

Hiperparámetro	Valores evaluados
Tamaño del conjunto élite (γ)	5, 10, 25
Probabilidad de mutación polinomial (p_m)	0.004, 0.012, 0.031
Tasa de velocidad máxima ($v_{\max}$)	0.1, 0.2, 0.35

Aquí, γ fija la cantidad de partículas que compiten para orientar la búsqueda y $v_{\max}$ regula la velocidad máxima de desplazamiento.

3.3.2.6. Etapas del Protocolo Experimental

El estudio comprende cuatro etapas. Se utiliza el hipervolumen como criterio principal para elegir las mejores configuraciones porque evalúa a la vez la convergencia y la diversidad de las soluciones, sin requerir un frente de referencia previo:

1. **Estudio de hiperparámetros:** Se ejecutan 20 semillas independientes por configuración ($(108 \times 4 + 81) \times 20 = 10\,260$ ejecuciones en total). Para cada combinación de operadores (`pcx/pm`, `pcx/gauss`, `sbx/pm`, `sbx/gauss`) en los algoritmos genéticos y para CMOPSO, se selecciona la mejor configuración interna basándose en el menor rango medio de hipervolumen entre las 20 semillas.
2. **Comparativa de operadores genéticos:** Fijando la mejor configuración de cada combinación de operadores, se analizan las cuatro variantes por algoritmo para evaluar el impacto del cruce y la mutación mediante pruebas estadísticas sobre el hipervolumen e indicadores químicos.
3. **Comparación global entre metaheurísticas multiobjetivo:** Se seleccionan las configuraciones con mejor desempeño de los cinco algoritmos y se comparan exhaustivamente entre sí sobre todos los indicadores multiobjetivo y químicos, analizando además sus dinámicas de convergencia y la distribución de sus frentes de Pareto.
4. **Análisis del frente conjunto global y moléculas representativas:** Evaluación del frente no dominado conjunto obtenido a partir de las combinaciones de operadores (incorporando las familias de cruce PCX y SBX de todos los algoritmos genéticos y CMOPSO) y análisis de las moléculas representativas.

En total, el estudio comprende 10 260 ejecuciones independientes, cada una con un número fijo de 100 000 evaluaciones.

3.4. FASE 2: Diseño de Inhibidores de la Proteína MRP1

Una vez seleccionada la mejor configuración de las metaheurísticas, se aplica el esquema tomando como diana a MRP1, con el objetivo específico de inhibir la expulsión del irinotecán del espacio intracelular. En esta sección se describe la preparación de la proteína y la identificación de su sitio de unión, la formulación de las funciones objetivo junto con el acoplamiento molecular, y el protocolo de generación de los candidatos.

3.4.1. Preparación de la Proteína y Sitio de Unión

El procedimiento propuesto se organiza en una serie de etapas consecutivas que permiten definir las condiciones necesarias para evaluar las moléculas generadas. Como se muestra en la Figura 3.4, las primeras etapas se centran en la selección y preparación del receptor, seguidas por la identificación y caracterización del sitio de unión mediante simulaciones con un ligando de referencia. Esta información se utiliza posteriormente para delimitar la región de búsqueda que se empleará en los experimentos de docking. Por último, se preparan las estructuras tridimensionales de las moléculas candidatas para llevar a cabo dicha evaluación.

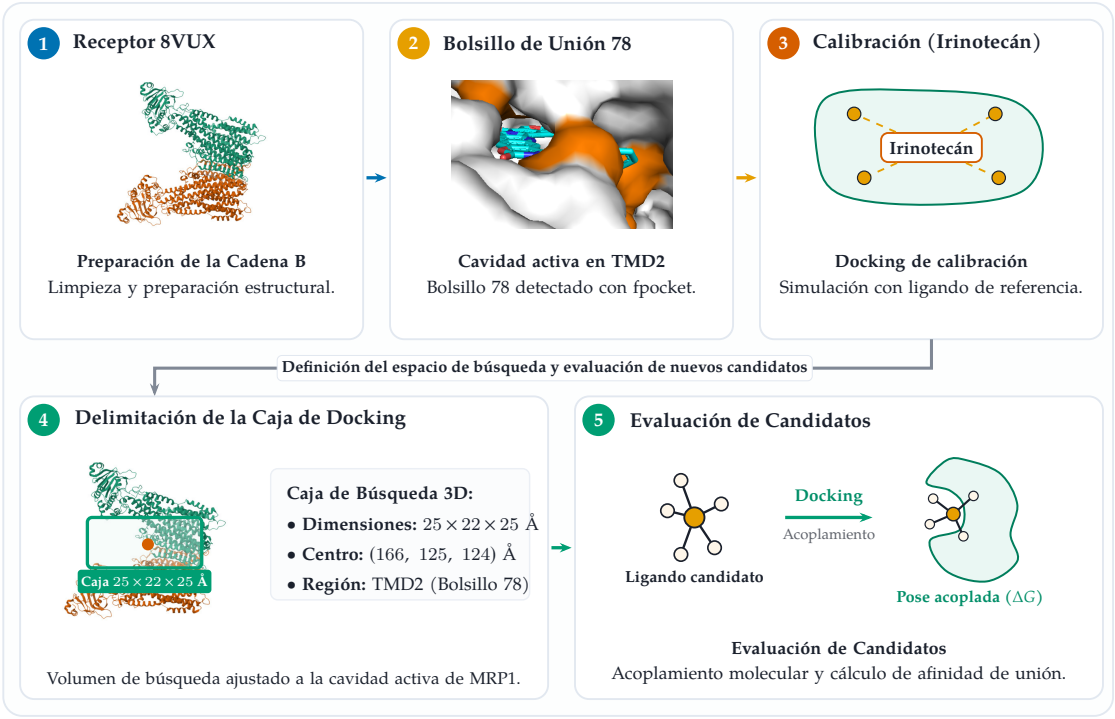


Figura 3.4: *Flujo metodológico en cinco etapas para el modelado de MRP1: preparación del receptor, identificación del bolsillo de unión, calibración con ligando de referencia, delimitación de la caja de docking sobre la cavidad y evaluación de las moléculas candidatas mediante docking.*

Estructura de referencia. Como no existen estructuras en el *Protein Data Bank* que contengan los quimioterápicos de interés unidos a MRP1, se recurre a la literatura. Se utiliza la estructura 8VUX, correspondiente a miembro 1 de la subfamilia C de casete de unión a ATP (*ATP-Binding Cassette Subfamily C Member 1*, ABCC1) (MRP1) humano cocristalizado con monofosfato de guanosina-adenosina cíclico (*Cyclic GMP-AMP*, cGAMP) y determinada por microscopía crioelectrónica con una resolución de 3.54 Å (ángstroms, unidad de medida de distancias a escala atómica equivalente a 0.1 nm) [72]. El cGAMP es un nucleótido cíclico mensajero que desempeña un papel clave en la inmunidad innata y en la respuesta contra infecciones y tumores. Si bien el cGAMP no es un quimioterapéutico, los autores del trabajo que reporta la estructura señalan que el sitio donde se une es el sitio de unión del sustrato de MRP1, localizado en el dominio transmembrana TMD2 [72].

Preparación del receptor. Puesto que la proteína en la estructura 8VUX se encuentra como un homodímero, los experimentos de esta tesina se centran únicamente en la cadena B como receptor. Sobre esta se eliminan el cGAMP, el hemisuccinato de colesterol y las moléculas de agua. Posteriormente se añaden los átomos de hidrógeno, se asignan los estados de protonación estándar de cada residuo y las cargas parciales, y se genera el archivo en formato PDBQT con Meeko [73]. El receptor resultante comprende 1005 residuos y 9587 átomos, de los cuales 1658 son hidrógenos polares.

Identificación del sitio de unión. Se procede a identificar los sitios drogables de 8VUX posteriormente a la separación de la proteína del ligando, con énfasis en TMD2 por su asociación con el sitio de unión del sustrato. Para ello se utiliza FPocketWeb [74], que arrojó como resultado una cavidad drogable en TMD2, el bolsillo número 78, con una drogabilidad reportada de 0.738 (probabilidad de drogabilidad elevada), y que además coincide con el sitio de unión del cGAMP. Como resultado, se selecciona el bolsillo 78 como sitio de unión probable de los quimioterápicos. Los demás bolsillos con elevada drogabilidad no se consideran porque corresponden a las cavidades donde se une el ATP para accionar el mecanismo de extracción de MRP1.

Docking ciego y elección de los aminoácidos flexibles. Como no existe una estructura que cocristalice MRP1 con los quimioterápicos de interés, los aminoácidos relevantes se identifican de manera computacional. Para ello se utiliza AutoDock Vina [32, 75] en un docking ciego sobre el bolsillo 78, con el irinotecán como ligando de referencia (PubChem, CID 60838), con el objetivo de determinar las poses más probables y los aminoácidos con los que más interacciona. Vina se configuró con un centro en $(164.6835,\ 130.2140,\ 120.1165)$ Å y una caja de $29.2 \times 35.6 \times 35.0$ Å, una exhaustividad de 32 y la generación de 100 poses.

Para el irinotecán se obtuvo una puntuación de docking de -12.060 kcal/mol y 5 poses. Posteriormente se analizaron los aminoácidos situados a menos de 4 Å del ligando, con el fin de caracterizar las interacciones potenciales en la región de unión; los resultados se resumen en la Tabla 3.5.

Tabla 3.5: *Aminoácidos que con mayor frecuencia se ubicaron a menos de 4 Å del irinotecán en las poses generadas por Vina.*

Rank.	Aminoácido	Frecuencia
1	ASN590	5/5
2	TRP1246	5/5
3	VAL554	4/5
4	TYR1243	4/5
5	THR1242	4/5
6	MET1093	3/5
7	PRO557	3/5
8	ASN1100	3/5
9	ARG1249	3/5
10	PHE594	3/5

Como paso siguiente se realiza un docking sesgado, considerando como flexibles los cinco aminoácidos con mayor interacción (ASN590, TRP1246, VAL554, TYR1243 y THR1242). Se observa una reducción de la energía de unión del orden de -1.180 kcal/-mol, por lo que se infiere que la interacción ligando/proteína mejora al flexibilizar los aminoácidos seleccionados.

Caracterización de la interacción. La figura 3.5 muestra cómo el irinotecán se inserta en la cavidad de MRP1. El ligando se encuentra dentro de una cavidad delimitada por la superficie proteica, en lugar de estar expuesto al solvente, y la molécula parece extenderse a lo largo de un canal o surco. La figura 3.6 muestra el top 5 de aminoácidos que más frecuentemente interactúan con el irinotecán y otros aminoácidos cercanos, indicando cómo se posiciona el ligando con respecto a los aminoácidos de interés. Al calcular las distancias entre cada aminoácido y los átomos del ligando se obtienen los valores de la Tabla 3.6.

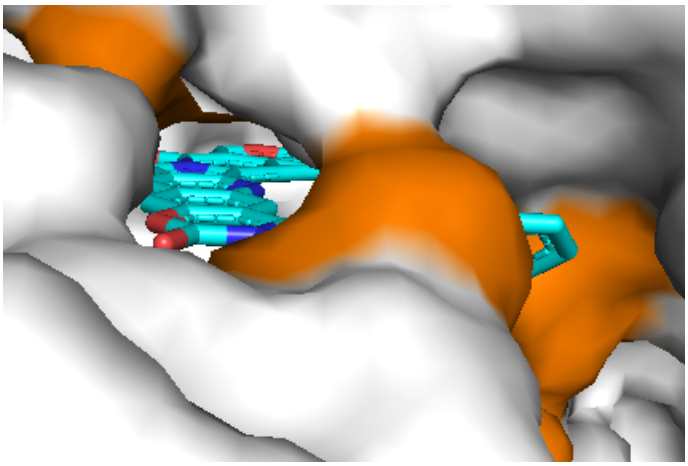


Figura 3.5: *Irinotecán dentro de la cavidad de MRP1. Las partes coloreadas en naranja corresponden a los residuos de interés.*

El TRP1246 presenta 11 pares de átomos con distancias de 2.98 a 3.87 Å en su anillo indólico, lo que es compatible con un contacto de tipo aromático. En la TYR1243, el grupo

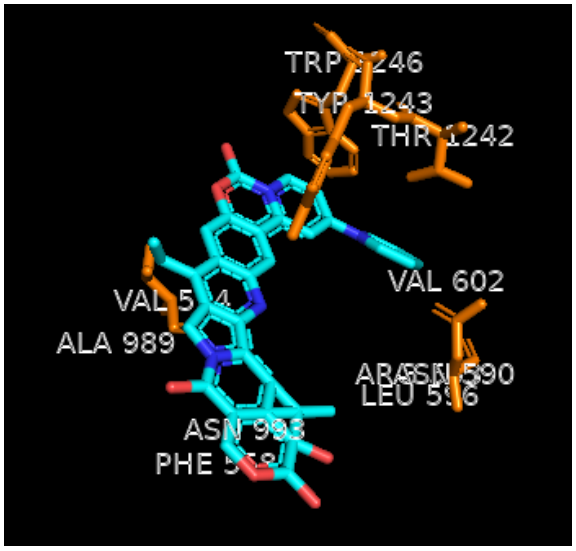


Figura 3.6: *Posición del irinotecán respecto de los cinco aminoácidos que más frecuentemente interactúan con él y de otros aminoácidos cercanos.*

Tabla 3.6: *Distancia entre los aminoácidos de interés y los átomos del irinotecán en la pose analizada.*

Residuo	Distancia mínima (Å)	Pares de átomos ≤ 4 Å
TYR1243	2.79	11
TRP1246	2.98	11
ASN590	3.15	2
VAL554	3.17	10
PHE558	3.51	3
ARG593	3.61	7
THR1242	3.63	1
LEU596	8.51	0

hidroxilo se ubica a 2.79 Å de un carbono del ligando y a 3.28 Å de un nitrógeno, lo que corresponde a un contacto muy cercano. La VAL554 presenta contactos con el carbono CG1 entre 3.17 y 3.51 Å, compatibles con un entorno hidrofóbico, y la ASN590 ubica su oxígeno OD1 a 3.15 Å de un carbono del ligando, lo que indica proximidad pero no demuestra un puente de hidrógeno. La LEU596 se encuentra a 8.51 Å y no participa directamente en esta pose. En consecuencia, se toman TYR1243, TRP1246 y VAL554 como núcleo de la región de interacción, manteniendo ASN590 y ARG593 como residuos de interés para el reconocimiento del ligando, mientras que THR1242 y PHE558 contribuyen a delimitar la geometría de la cavidad sin asumirlos como anclajes esenciales.

Caja de docking para la generación de candidatos. Para los experimentos de diseño se configura una caja de docking con centro en $(166,\ 125,\ 124)$ Å y dimensiones de $25 \times 22 \times 25$ Å, determinada a partir de los aminoácidos con mayor prevalencia en la interacción del irinotecán con el sitio de unión.

Preparación de las moléculas candidatas. Las secuencias lineales decodificadas por el VAE se convierten a su estructura tridimensional con RDKit [67] y se preparan con Meeko [73], que asigna los tipos de átomo, las cargas parciales y las torsiones activas.

3.4.2. Funciones Objetivo

Para el diseño dirigido hacia MRP1 se añaden la energía de unión y el pChEMBL predicho junto a QED y SAS, con el fin de guiar la búsqueda hacia la interacción con la diana objetivo. De este modo, se optimizan simultáneamente sobre el espacio latente del VAE:

- **Energía de unión:** [Minimizar] Energía libre de afinidad de unión de la molécula con MRP1, estimada mediante acoplamiento molecular con la función de puntuación de AutoDock Vina [32]. Se utiliza su implementación en GPU, Uni-Dock [33], que reproduce dicha función de puntuación y evalúa un lote de moléculas en paralelo.
- **pChEMBL predicho:** [Maximizar] Busca maximizar la potencia inhibitoria esperada de cada molécula frente a MRP1. El pChEMBL expresa el IC_{50} en escala logarítmica, de modo que un valor mayor corresponde a una mayor potencia. Dado que no es posible determinar experimentalmente el IC_{50} de moléculas recién generadas, este valor se estima con un modelo Random Forest entrenado con compuestos de MRP1 cuyo IC_{50} está reportado en ChEMBL [19].
- **QED:** [Maximizar] Definida en la sección 3.3.2.2.
- **SAS:** [Minimizar] Definida en la sección 3.3.2.2.

Cada molécula se acopla con el receptor rígido descrito en la subsección 3.4.1, dentro de la caja de docking de los experimentos de diseño, con un modo de búsqueda balanceado y una semilla fija, y se toma la energía de la mejor pose como valor del objetivo.

Se mantiene la restricción de complejidad estructural $F_{sp3} \geq 0.30$ descrita en la sección 3.3.2.2, evaluada bajo el mismo criterio de dominancia restringida. Si una molécula no puede prepararse o el acoplamiento no produce una pose, se le asigna la máxima penalización en el objetivo de energía $(+1.0$ kcal/mol$)$. Para el cálculo del hipervolumen, la energía de unión se normaliza entre -15.0 y $+1.0$ kcal/mol.

3.4.3. Protocolo de Generación de Candidatos

Se ejecuta la búsqueda dirigida en el espacio latente con las mejores configuraciones seleccionadas en la sección 3.3, con el mismo total de 100 000 evaluaciones por ejecución y 20 semillas independientes. El acoplamiento se realiza con el receptor rígido, dentro de la caja de docking definida en la subsección 3.4.1.

Las moléculas generadas se evalúan en términos de QED, SAS, afinidad, potencia predicha, F_{sp3} y características de unión. Adicionalmente, se evalúan la validez, la unicidad y la diversidad de las moléculas generadas.

3.5. Métricas de Evaluación del Rendimiento de los Modelos Considerados

En esta sección se describen las métricas empleadas para evaluar el rendimiento de la metodología. Se presentan las métricas del benchmark MOSES para medir la calidad química, validez y diversidad de las moléculas generadas por el VAE. Además, se detallan los indicadores multiobjetivo utilizados para comparar la convergencia y distribución de las soluciones obtenidas por las metaheurísticas en el espacio latente.

3.5.1. Métricas de Calidad de Generación

Para evaluar y comparar el desempeño de los modelos de VAE entrenados sobre el conjunto de datos MOSES [60], se emplean las métricas estandarizadas del benchmark:

Validez. Proporción de moléculas generadas que son químicamente viables, verificando que cada estructura respete las leyes de valencia y los criterios básicos de estabilidad química:

$$\text{Validez} = \frac{\#\text{moléculas válidas}}{\#\text{moléculas generadas}} \tag{3.2}$$

Unicidad. Evalúa la capacidad del modelo para generar estructuras distintas y evitar la repetición de moléculas:

$$\text{Unicidad} = \frac{\#\text{moléculas generadas únicas}}{\#\text{moléculas generadas}} \tag{3.3}$$

Novedad. Porcentaje de moléculas generadas que aparecen en el conjunto de entrenamiento, evaluando si el modelo generaliza o si memoriza las estructuras conocidas:

$$\text{Novedad} = 1 - \frac{\#\text{moléculas generadas} \cap \#\text{moléculas de entrenamiento}}{\#\text{moléculas generadas}} \tag{3.4}$$

Filtros (*Filters*). Fracción de moléculas generadas que logran superar los filtros aplicados en el conjunto original, evaluando el cumplimiento de PAINS (que descarta compuestos con falsos positivos por interferencia en ensayos biológicos) y MCF (que elimina fragmentos reactivos, inestables o farmacológicamente desfavorables).

Distancia Fréchet ChemNet (FCD). Compara la distribución estadística de las moléculas generadas frente a las de referencia utilizando las activaciones de la red neuronal *ChemNet*:

$$\text{FCD}(G, R) = \|m_G - m_R\|^2 + \text{Tr}\left(C_G + C_R - 2(C_G C_R)^{1/2}\right) \tag{3.5}$$

donde m representa el vector de medias y C la matriz de covarianza de las activaciones para los conjuntos generado (G) y real (R). Los autores de MOSES destacan a FCD como una de las métricas centrales del benchmark porque captura de forma conjunta la distribución de propiedades químicas y la relevancia biológica de los compuestos. Una puntuación cercana a cero indica que el modelo replica con precisión el perfil del conjunto de referencia.

Diversidad Interna (IntDiv). Cuantifica la variedad química dentro del conjunto generado para detectar colapso de modos (*mode collapse*):

$$\text{IntDiv}_p(G) = 1 - \sqrt[p]{\frac{1}{|G^2|} \sum_{m_1, m_2 \in G} T(m_1, m_2)^p} \tag{3.6}$$

donde $T(m_1, m_2)$ evalúa la similitud de Tanimoto entre pares de moléculas generadas. Un resultado cercano a 1 indica alta diversidad estructural.

Distancias de Wasserstein-1 (QED y SAS). Cuantifica la diferencia entre las distribuciones de los datos reales y los generados para la SAS y la QED. Un valor cercano a cero indica que el modelo reproduce con precisión tanto los promedios como la dispersión de estas propiedades en el conjunto de referencia.

3.5.2. Indicadores de Rendimiento Multiobjetivo

La evaluación de metaheurísticas multiobjetivo representa un desafío particular ya que el resultado del proceso de optimización no es una única solución, sino un conjunto de soluciones no dominadas. Por lo tanto para evaluar el rendimiento de diferentes algoritmos es necesario comparar conjuntos enteros de soluciones. No existe un estándar único para evaluar estas soluciones los indicadores de calidad o métricas de desempeño se clasifican según sus propiedades y según el objetivo que evalúan [10]:

- **Indicadores de convergencia:** Evalúan la eficacia de las soluciones en términos de su cercanía al frente de Pareto óptimo. Ejemplos destacados incluyen la distancia generacional (*Generational Distance*, GD) y la distancia generacional invertida (*Inverted Generational Distance*, IGD), que calculan la distancia promedio entre el conjunto aproximado y un conjunto de referencia, y el Indicador ϵ, que determina el factor mínimo de traslación necesario para que una aproximación domine a otra.
- **Indicadores de diversidad:** Miden la uniformidad y extensión de la distribución de las soluciones obtenidas a lo largo del frente. Indicadores como el Espaciado (*Spread*) o la Entropía penalizan los frentes donde las soluciones se agrupan excesivamente en una sola región del espacio de objetivos. Suelen tener un costo computacional mayor que los indicadores de convergencia.
- **Indicadores híbridos:** Evalúan tanto la convergencia como la diversidad del conjunto de soluciones. Tales como el hipervolumen (*Hypervolume*, HV), un indicador que calcula el volumen del espacio de objetivos que es débilmente dominado por el conjunto de aproximación respecto a un punto de referencia [10].

A partir de esta clasificación, los indicadores de rendimiento considerados en el marco metodologico son los siguientes:

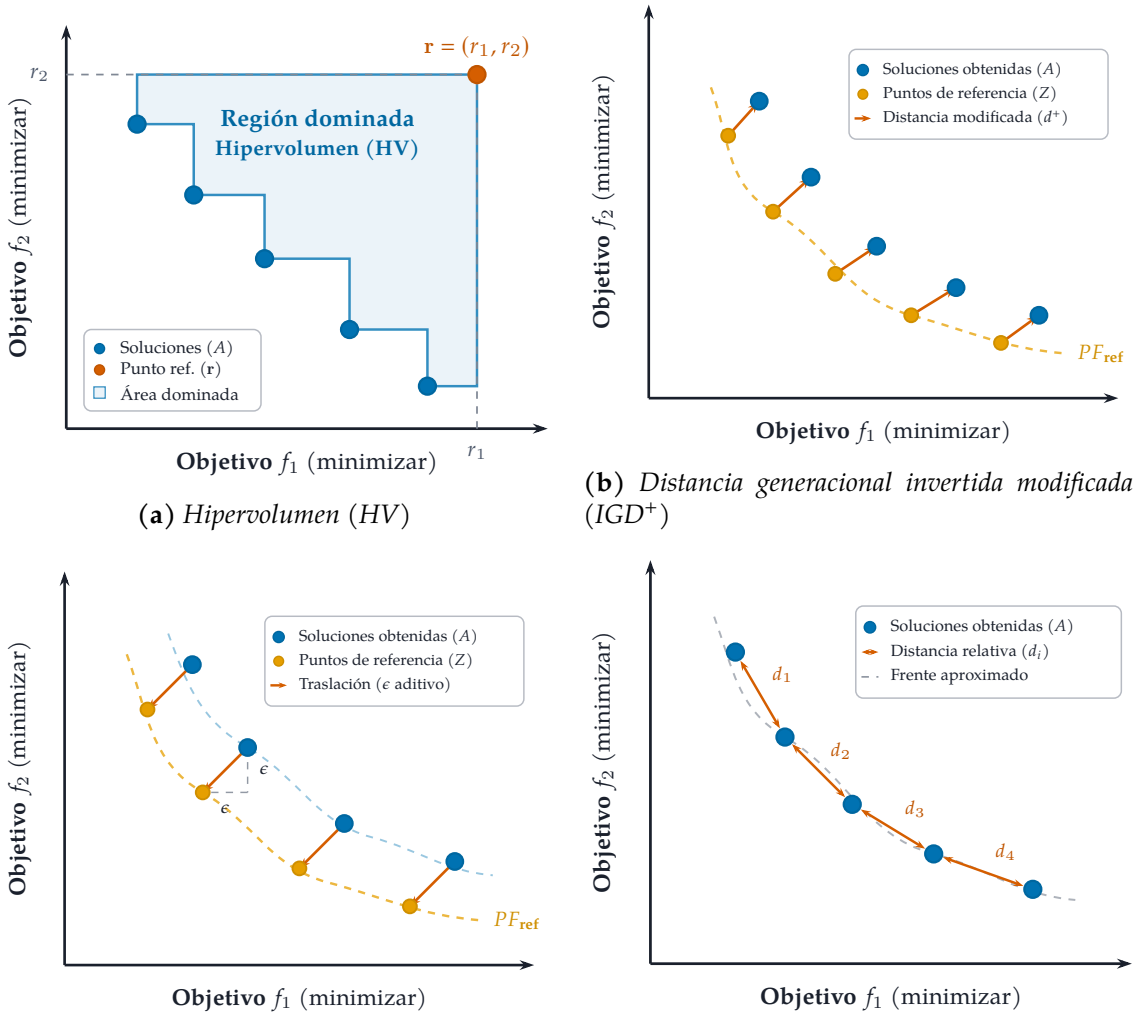
Hipervolumen (HV). Mide el volumen de la región del espacio de objetivos que domina el conjunto de soluciones obtenido, acotada por un punto de referencia (Figura 3.7a). Cuanto mayor es ese volumen, mejor es el conjunto tanto en convergencia como en diversidad, de modo que resume ambos aspectos. Su ventaja práctica es que no exige conocer el frente de Pareto óptimo, sino únicamente el punto de referencia.

Distancia generacional invertida modificada ($\mathbf{IGD^+}$). Promedia la distancia que separa a cada punto de un conjunto de referencia de la solución más próxima del conjunto obtenido, contabilizando solo las componentes en las que esa solución es peor (Figura 3.7b). Valores bajos indican que el frente obtenido se aproxima al de referencia.

Indicador ϵ aditivo. Expresa cuánto habría que desplazar el conjunto obtenido para que llegue a dominar débilmente al de referencia (Figura 3.7c). Cuanto menor es ese desplazamiento, más próximos están ambos frentes, y un valor no positivo significa que el conjunto obtenido ya lo domina. A diferencia de la IGD^+, que evalúa la proximidad promedio, este indicador actúa como un criterio de peor caso determinado por la región más desfavorable del frente.

Espaciamiento (*Spacing*). Refleja con qué uniformidad se reparten las soluciones a lo largo del frente (Figura 3.7d), a partir de la dispersión de las distancias entre soluciones vecinas. Valores bajos corresponden a frentes donde las soluciones están espaciadas de manera regular, sin acumulaciones ni huecos.

Tamaño del frente de Pareto. Cuenta las soluciones no dominadas obtenidas, esto es, cuántas alternativas de compromiso distintas llega a ofrecer el algoritmo. Por sí solo no permite juzgar la calidad del frente.



(a) *Hipervolumen (HV)*

(b) *Distancia generacional invertida modificada (IGD^+)*

(c) *Indicador ϵ aditivo*

(d) *Espaciamiento (Spacing)*

Figura 3.7: *Interpretación geométrica de los principales indicadores de rendimiento multiobjetivo evaluados en un espacio bidimensional a minimizar: (a) región dominada acotada por el punto de referencia* $\mathbf{r}$ *(HV); (b) distancia mínima desde los puntos de referencia Z a las soluciones aproximadas A (IGD^+); (c) traslación requerida para dominar el frente de referencia (indicador ϵ aditivo); y (d) homogeneidad en la distribución espacial de las soluciones obtenidas (Spacing).*

Los dos indicadores basados en distancias, IGD^+ y el indicador ϵ aditivo, necesitan un conjunto de referencia que aproxime el frente de Pareto óptimo. Como en el diseño de moléculas ese frente no se conoce, dicho conjunto se construye de forma empírica [76].

3.5.3. Validación y Perfilado de las Moléculas Candidatas

Con el fin de evaluar y caracterizar las moléculas candidatas obtenidas para MRP1, se realiza un análisis sobre sus soluciones del frente de pareto. En esta sección se describen los criterios empleados para evaluar la calidad física de las poses de acoplamiento,

la estimación de su potencia inhibitoria y el perfil farmacocinético, fisicoquímico y toxicológico (ADMET).

Validación de poses de acoplamiento. Para evaluar las moléculas obtenidas del frente de Pareto, se utiliza PoseBusters [77], que permite verificar si las conformaciones generadas son físicamente viables. La métrica corresponde al porcentaje de moléculas que supera las 20 pruebas de la herramienta.

Predicción de potencia y bioactividad inhibitoria. Se entrenó un modelo de *Random Forest* con inhibidores conocidos de MRP1 extraídos de ChEMBL [19] para predecir la bioactividad de las moléculas. Como métrica se utiliza el valor pChEMBL predicho, fijando un umbral de 5.0 para considerar activo al compuesto.

Perfil farmacocinético, fisicoquímico y toxicológico. Se utilizó ADMET-AI [78] para predecir las propiedades de los candidatos a partir de modelos de *Therapeutics Data Commons*. Se analizaron descriptores de absorción y permeabilidad intestinal (HIA, Caco-2, PAMPA y biodisponibilidad oral), propiedades fisicoquímicas de solubilidad y lipofilicidad ($\log P$), y el perfil de toxicidad clínica y aguda (ClinTox y LD_{50}).

3.6. Herramientas y Tecnologías de Implementación

En esta sección se describen las herramientas y tecnologías empleadas en el entrenamiento y evaluación del modelo generativo, la exploración del espacio latente mediante optimización multiobjetivo y el acoplamiento molecular sobre la proteína MRP1. Conda facilitó la gestión de dependencias y entornos virtuales de Python (Versión 3.12.3), utilizándose las siguientes herramientas y librerías principales:

- **PyTorch (Versión 2.12.1):** Utilizado para construir y entrenar las redes neuronales recurrentes (GRU y LSTM) del VAE.
- **pymoo (Versión 0.6.1.6):** Utilizado para ejecutar los algoritmos de optimización multiobjetivo, sus operadores y las métricas de rendimiento.
- **RDKit (Versión 2026.03.3):** Utilizado para validar estructuras químicas, calcular propiedades moleculares (QED, SAS, F_{sp3}) y generar conformaciones 3D.
- **SELFIES (Versión 2.2.0):** Representación molecular basada en cadenas válidas, empleada como alternativa a SMILES.
- **MOSES (Versión 0.3.1):** Benchmark para evaluar el modelo generativo y calcular métricas de distribución y calidad química.
- **Uni-Dock (Versión 1.2.0):** Motor de acoplamiento molecular en GPU, utilizado para evaluar la afinidad de unión contra MRP1.
- **AutoDock Vina (Versión 1.2.7):** Utilizado en el docking ciego y con residuos flexibles para caracterizar el sitio de unión de MRP1.
- **Meeko (Versión 0.8.0):** Utilizado para preparar receptores y ligandos en formato PDBQT para el acoplamiento molecular.

- **FPocket:** Utilizado para identificar y evaluar la drogabilidad de cavidades en la estructura de MRP1.
- **PoseBusters:** Utilizado para evaluar la validez química y la plausibilidad física de las poses de acoplamiento.
- **Scikit-learn:** Empleado para el entrenamiento y evaluación del modelo Random Forest de bioactividad.
- **ADMET-AI:** Utilizado para predecir perfiles farmacocinéticos y de toxicidad sobre los candidatos.

Además, para el desarrollo, redacción y diseño de esquemas se utilizaron Git para el control de versiones, LaTeX para la composición tipográfica de texto, fórmulas y bibliografía, Visual Studio Code como entorno integrado de desarrollo y TikZ para la creación de los diagramas y esquemas.

En cuanto a los recursos de hardware, los experimentos se llevaron a cabo en el Clúster Toko (FCEN-UNCuyo) sobre nodos con 16 vCPUs y 64 GB de memoria RAM: se empleó una GPU NVIDIA TITAN Xp para el entrenamiento del modelo generativo (VAE), y nodos equipados con GPU NVIDIA GeForce RTX 4080 para las tareas de optimización multiobjetivo y acoplamiento molecular.

4

Resultados y Discusión

En este capítulo se presentan los resultados obtenidos de las experimentaciones realizadas en este trabajo. En primer lugar, se examinan los resultados del ajuste de hiperparámetros del modelo generativo (VAE) a través de sus dos fases experimentales y se compara el desempeño de la mejor configuración frente al estado del arte en el benchmark MOSES. A continuación, se describen los resultados de la generación de fármacos genéricos y la evaluación de las metaheurísticas multiobjetivo, analizando el impacto de los diferentes operadores. Finalmente, se evalúa la aplicación del enfoque propuesto en el diseño guiado de inhibidores de la proteína MRP1, analizando la afinidad de unión obtenida mediante acoplamiento molecular y las propiedades fisicoquímicas de las mejores moléculas candidatas.

4.1. Evaluación y Selección del Modelo Generativo VAE

En esta sección se aborda la evaluación del modelo generativo sobre el conjunto de datos MOSES. Se presentan los resultados de las fases de ajuste de hiperparámetros y se examina el comportamiento del modelo seleccionado en dicho benchmark frente a otros enfoques de la literatura.

4.1.1. Evaluación de Arquitecturas y Selección de Configuraciones

En esta etapa se evaluaron diversas configuraciones del modelo generativo VAE con 100 y 300 épocas de entrenamiento, cuyos resultados completos se presentan detalladamente en el Apéndice A (Tabla A.1). Cada configuración se identifica con la representación (SM para SMILES, SE para SELFIES), la arquitectura (L para LSTM, G para GRU), el número de capas y la dimensión latente. Por ejemplo, SM-L 2 256 corresponde a SMILES, LSTM, 2 capas y latente de 256. A partir de estos resultados, surgen distintos patrones respecto a cada componente:

En primer lugar, si bien la representación de SELFIES cumple con su diseño garantizando una validez perfecta en todas las ejecuciones, las redes entrenadas con SMILES logran capturar con mayor precisión la distribución estadística y las propiedades de las moléculas reales, lo cual se refleja en puntuaciones de distancia Fréchet ChemNet (*Fré-*

chet ChemNet Distance, FCD) y distancias de Wasserstein (SAS y QED) notablemente inferiores a las de los modelos SELFIES. Asimismo, el espacio latente de 256 dimensiones superó a las configuraciones de 64 y 128 en todas las arquitecturas evaluadas. Al incrementar la dimensión a 256 se observa una reducción constante en el FCD (por ejemplo, descendiendo de 0.983 a 0.412 en SM-L 2), junto con un incremento sostenido en la validez de los modelos SMILES (que en dicha configuración pasa de 0.816 a 0.943) y menores distancias de Wasserstein.

En cuanto a la arquitectura, las redes LSTM demostraron ser más resilientes a entrenamientos prolongados: al pasar de 100 a 300 épocas, tendieron a mejorar sus métricas. Por el contrario, varios modelos GRU sufrieron un colapso o inestabilidad al alcanzar las 300 épocas, reduciendo drásticamente la validez general de las moléculas generadas. Esta mayor estabilidad de las redes LSTM podría deberse, a modo de hipótesis, a la presencia de una compuerta de salida que permite regular la magnitud de su memoria antes de transmitirla. En contraste, al carecer GRU de este mecanismo [79], es posible que en épocas avanzadas se produzca un conflicto numérico con la regularización del VAE que favorezca el colapso del modelo. Cabe destacar que las ejecuciones evaluadas corresponden a configuraciones experimentales individuales y no a repeticiones de cada una, por lo que la variabilidad entre entrenamientos no queda caracterizada.

La etapa de optimización del entrenamiento se centra en probar diferentes tasas de aprendizaje y tamaños de lote. Por esta razón, se seleccionaron aquellas configuraciones que mostraron tanto una generación estructural adecuada como un mejor balance en las métricas de calidad molecular (FCD, SAS, QED). Dado que todos los modelos seleccionados comparten un espacio latente de 256 dimensiones, este valor se omitirá en su nomenclatura. La Tabla 4.1 resume las configuraciones elegidas.

Tabla 4.1: *Configuraciones seleccionadas para la optimización del entrenamiento.*

ID	Épocas	Val ↑	Uni ↑	Nov ↑	Filter ↑	FCD ↓	IntDiv ↑	SA ↓	QED ↓
SM-G 2	100	0.945	1.000	0.969	0.982	0.470	0.859	0.115	0.005
SE-L 2	100	1.000	1.000	0.881	0.928	0.764	0.861	0.201	0.020
SM-L 1	300	0.946	1.000	0.972	0.981	0.459	0.859	0.155	0.011
SM-L 2	300	0.951	1.000	0.956	0.986	0.321	0.858	0.113	0.013

A partir de los entrenamientos de 100 épocas se eligió **SM-G 2**, que a pesar de la inestabilidad de GRU a 300 épocas tuvo un desempeño temprano sobresaliente con un FCD de 0.470 y validez de 0.945, y **SE-L 2**, que obtuvo los mejores resultados dentro de la representación SELFIES con el menor FCD (0.764), siendo de interés evaluar si su novedad (0.881) mejora al ajustar los hiperparámetros.

En cuanto a las 300 épocas, se seleccionó **SM-L 1**, una opción con menor profundidad de red que alcanzó el segundo mejor FCD (0.459) con una validez de 0.946, y **SM-L 2**, que logró el FCD más bajo de todos los registros (0.321) manteniendo una alta validez (0.951) y excelentes distancias para SAS (0.113) y QED (0.013).

4.1.2. Optimización del Entrenamiento y Selección del Modelo Final

Los resultados completos de la optimización con todas las combinaciones de tasa de aprendizaje y tamaño de lote para los cuatro modelos seleccionados se detallan en el Apéndice A (Tabla A.2). La Tabla 4.2 resume la mejor configuración alcanzada para cada una de las arquitecturas evaluadas.

Tabla 4.2: *Mejores configuraciones obtenidas en la optimización del entrenamiento.*

Modelo	Épocas	LR	Batch	Val ↑	Uni ↑	Nov ↑	Filter ↑	FCD ↓	IntDiv ↑	SA ↓	QED ↓
SM-G 2	100	1×10^{-4}	64	0.950	1.000	0.966	0.984	0.301	0.858	0.111	0.006
SE-L 2	100	1×10^{-3}	192	1.000	0.999	0.868	0.936	0.675	0.861	0.185	0.018
SM-L 1	300	1×10^{-4}	64	0.940	1.000	0.973	0.980	0.424	0.859	0.159	0.013
SM-L 2	300	1×10^{-4}	64	**0.962**	1.000	0.943	**0.988**	**0.179**	0.859	**0.093**	0.008

Al optimizar el entrenamiento, la reducción de la tasa de aprendizaje de 1×10^{-3} a 1×10^{-4} y el uso de lotes más pequeños de 64 produjo una mejora consistente en las arquitecturas con representación SMILES, alcanzando las mejores puntuaciones de FCD y menores distancias de Wasserstein. Aunque esta configuración elevó los tiempos de cómputo por encima de las 20 horas en los modelos de 300 épocas, asumir este costo fue necesario para conseguir los mejores resultados.

En los entrenamientos de 100 épocas, **SM-G 2** registró su mejor comportamiento con este LR de 1×10^{-4} y Batch de 64, donde consiguió un FCD competitivo de 0.301, una validez de 0.950 y distancias de Wasserstein bajas (SAS de 0.111 y QED de 0.006), demostrando capacidad para generar un espacio químico de calidad en menos épocas de entrenamiento y aligerando la carga computacional. En contraste, la representación SELFIES en **SE-L 2** requirió una tasa de 1×10^{-3} y un lote de 192 para lograr su mejor FCD (0.675) a costa de una novedad baja (0.868). Si bien mantiene una validez perfecta (1.000), si se intenta mejorar esa novedad reduciendo la tasa de aprendizaje a 1×10^{-4}, el FCD empeora significativamente a 2.893.

A las 300 épocas, la variante de red menos profunda, **SM-L 1**, consiguió su mayor eficacia también con LR de 1×10^{-4} y Batch de 64, registrando un FCD de 0.424 y una validez de 0.940. Al comparar estos números con el modelo de dos capas (**SM-L 2**), se observa que si bien la arquitectura de una capa es más ligera, agregar una segunda capa mejora sistemáticamente las métricas. **SM-L 2** mostró los mejores resultados de toda la etapa experimental con dicha configuración, ya que alcanzó conjuntamente la validez más alta de las arquitecturas SMILES (0.962), el FCD más bajo de todos los registros analizados (0.179) y la menor distancia de Wasserstein para SAS (0.093), con una novedad de 0.943.

4.1.3. Evaluación en MOSES y Comparación con el Estado del Arte

4.1.3.1. Modelo seleccionado

Se seleccionó SM-L 2 (300 épocas), con LR de 1×10^{-4} y batch de 64, por obtener el menor FCD de todos los experimentos (0.179), la mayor validez entre los modelos SMILES (0.962) y la menor distancia de Wasserstein para SAS (0.093). A cambio, presentó una novedad levemente menor (0.943) y el mayor tiempo de entrenamiento en esta etapa.

En la Figura 4.1 se muestran las distribuciones de QED y SAS de las moléculas generadas por este modelo frente a las del conjunto de prueba de MOSES. Las curvas se superponen casi por completo, lo que concuerda con las distancias de Wasserstein obtenidas (0.008 para QED y 0.093 para SAS).

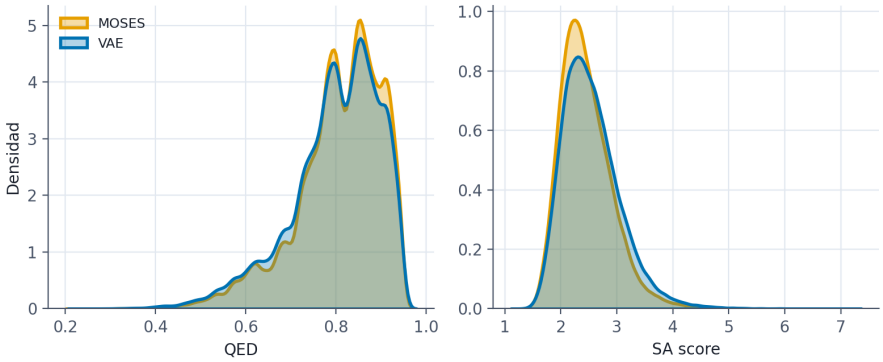


Figura 4.1: *Distribuciones de QED y SAS de las moléculas válidas generadas por SM-L 2 frente al conjunto de prueba de MOSES.*

[Placeholder: Figura 4.2 – Muestras de moléculas generadas por el modelo SM-L 2]

Figura 4.2: *Muestras de moléculas generadas por el modelo seleccionado SM-L 2.*

4.1.3.2. Comparación con el estado del arte

Los resultados indican que el modelo propuesto (SM-L VAE) ofrece un balance competitivo frente a otras arquitecturas recientes de espacio latente, como PCF-VAE y FRATTVAE. El modelo logra un FCD de 0.179, manteniendo al mismo tiempo una alta

Tabla 4.3: *Comparación con el estado del arte utilizando el dataset MOSES*

Model	Valid (↑)	Unique (↑)	Novelty (↑)	Filters (↑)	FCD (↓)	IntDiv (↑)	SA (↓)	QED (↓)
Train	1.000	1.000	1.000	1.000	0.008	0.857	-	-
HMM	0.076	0.567	0.999	0.902	24.466	0.847	0.742	0.269
NGram	0.238	0.922	0.969	0.958	5.507	0.874	0.231	0.089
Combinatorial	1.000	0.991	0.988	0.956	4.238	0.873	0.280	0.151
CharRNN	0.975	0.999	0.842	0.994	0.073	0.856	0.017	0.003
AAE	0.937	0.997	0.793	0.996	0.556	0.856	0.045	0.004
LatentGAN	0.897	0.997	0.950	0.974	0.297	0.857	0.088	0.006
FRATTVAE	1.000	1.000	0.974	N/R	0.865	N/R	2.591	0.030
PCF-VAE	0.980	1.000	0.938	0.990	0.296	0.859	N/R	N/R
SM-L VAE	0.962	1.000	0.943	0.988	0.179	0.859	0.093	0.008

tasa de novedad (0.943) y diversidad interna (0.859). Si bien enfoques autorregresivos como CharRNN alcanzan un FCD numéricamente menor (0.073), este comportamiento suele estar asociado a una caída en la novedad (0.842), lo que sugiere una tendencia del modelo a replicar el conjunto de entrenamiento. La principal ventaja de los modelos VAE radica en su espacio latente continuo. A diferencia de las secuencias discretas de CharRNN, esta representación vectorial permite aplicar metaheurísticas multiobjetivo para buscar moléculas con propiedades específicas o afines a un target determinado.

4.2. Optimización Multiobjetivo de Propiedades Moleculares sin Diana Específica

En esta sección se aborda la optimización multiobjetivo de propiedades moleculares sin diana específica mediante metaheurísticas en el espacio latente del VAE. Se describen los resultados del ajuste de hiperparámetros y la influencia de los operadores de cruce y mutación, para luego contrastar el desempeño global de los cinco algoritmos y caracterizar las moléculas candidatas obtenidas en el frente de Pareto conjunto.

4.2.1. Ajuste de Hiperparámetros

Siguiendo el protocolo experimental establecido en la Sección 3.3.2.3, la exploración de hiperparámetros se evaluó utilizando el hipervolumen (HV) como métrica principal sobre 20 semillas independientes. La mejor configuración obtenida para cada algoritmo y combinación de operadores se detalla en el Apéndice B.1 (Tabla B.1).

En términos generales, al evaluar los objetivos QED y SA bajo la restricción de factibilidad ($F_{\text{sp3}} \geq 0.30$), los valores de hipervolumen se sitúan en el rango de ~ 1.10–1.12. Asimismo, la mayoría de las configuraciones seleccionadas favorece esquemas con mayor número de generaciones (100×1000 y 200×500), lo cual permite una explotación más prolongada en el espacio latente frente a particiones de población más amplia (400×250). En CMOPSO, la configuración seleccionada (100×1000, archivo élite de 10, velocidad $v_{\max} = 0.1$ y mutación 0.031) alcanza un hipervolumen medio de 1.1092.

4.2.1.1. Compromiso entre Hipervolumen y Validez Química

La Figura 4.3 muestra el compromiso entre hipervolumen y validez química en todas las configuraciones evaluadas (mediana de 20 semillas).

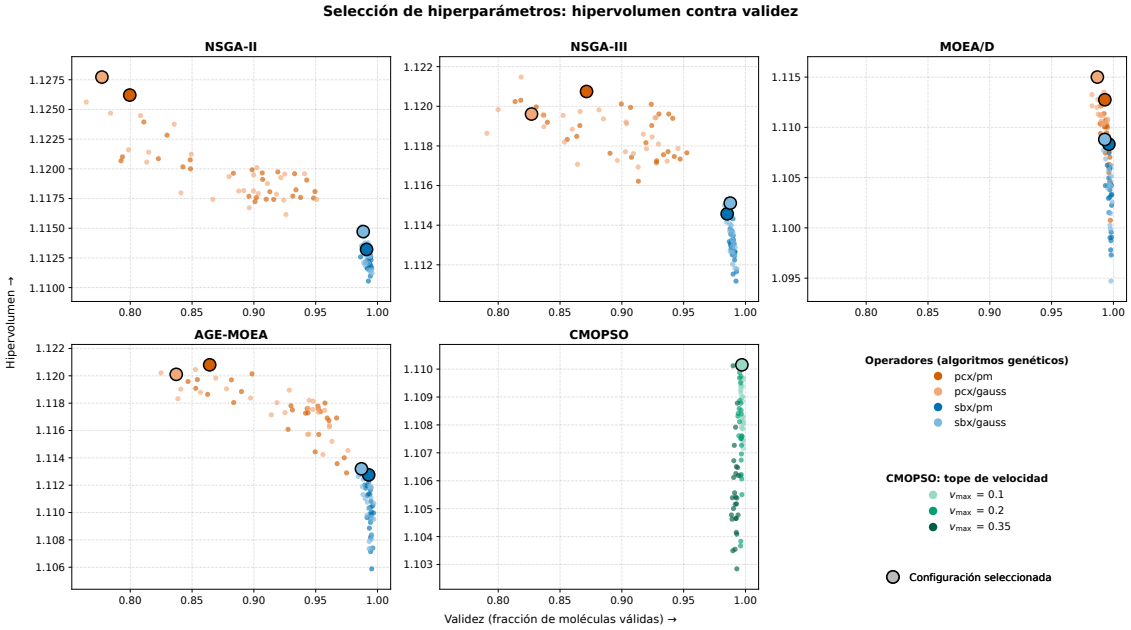


Figura 4.3: *Relación de compromiso entre Hipervolumen y Validez Química para todas las configuraciones evaluadas (mediana de 20 semillas). Con borde negro, la configuración seleccionada para cada combinación de operadores.*

Este análisis muestra los siguientes comportamientos:

- **Separación por operador de cruce:** En los algoritmos genéticos se aprecia una clara diferenciación según el operador de cruce. Las variantes con PCX logran los mayores valores de hipervolumen, a costa de una validez química moderada (entre $80\,\%$ y $95\,\%$). En contraposición, las variantes con SBX preservan una validez casi completa (entre $98\,\%$ y $100\,\%$), aunque con un hipervolumen inferior.
- **Alta validez en MOEA/D:** MOEA/D mantiene una validez química superior al $98\,\%$ en la totalidad de sus configuraciones, independientemente de los operadores empleados.
- **Comportamiento en CMOPSO:** CMOPSO presenta una validez superior al $99\,\%$ en prácticamente todas sus configuraciones. Su hipervolumen se encuentra fuertemente condicionado por el tope de velocidad: los valores bajos ($v_{\max} = 0.1$) permiten alcanzar los mayores hipervolúmenes, mientras que un aumento en la velocidad ($v_{\max} = 0.35$) produce un descenso apreciable del hipervolumen.

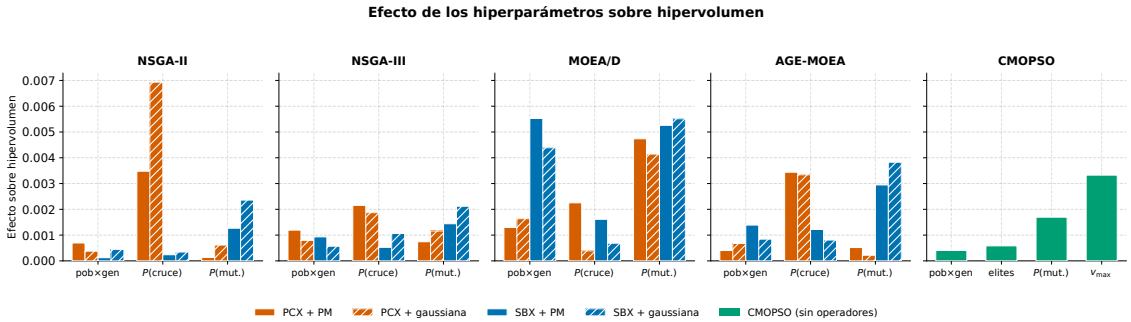


Figura 4.4: *Efecto de cada hiperparámetro sobre el hipervolumen dentro de cada combinación de operadores en los algoritmos genéticos y en CMOPSO.*

La Figura 4.4 resume la magnitud del efecto de cada hiperparámetro sobre el hipervolumen. En los algoritmos genéticos, las variantes con PCX son predominantemente sensibles a la probabilidad de cruce $P(\text{cruce})$ (con un efecto especialmente marcado en NSGA-II), mientras que las variantes con SBX responden principalmente a la probabilidad de mutación $P(\text{mut.})$. MOEA/D exhibe una marcada sensibilidad tanto a la mutación como al reparto de población y generaciones. En CMOPSO, el parámetro de mayor impacto es el tope de velocidad ($v_{\max}$), seguido por la probabilidad de mutación, mientras que el tamaño del archivo de élites y la partición del presupuesto presentan una influencia secundaria.

4.2.2. Influencia de los Operadores de Cruce y Mutación

Se evalúa el impacto de los operadores de cruce (SBX, PCX) y mutación (Polinomial, Gaussiana) en AGE-MOEA, MOEA/D, NSGA-II y NSGA-III sobre distintos indicadores multiobjetivo y químicos.

La comparación estadística se realiza sobre el hipervolumen: test de Friedman con las 20 semillas ($p < 0.001$), seguido de comparaciones por pares con Wilcoxon de rangos con signo y corrección de Holm ($\alpha = 0.05$). Para cada par se reporta el valor p ajustado y la correlación rango-biserial de pares emparejados (r_{rb}), con signo positivo cuando la primera combinación aventaja a la segunda; un valor próximo al máximo (± 1.0) indica unanimidad en las 20 semillas.

Tabla 4.4: *Comparación de indicadores multiobjetivo para las distintas combinaciones de operadores de cruce y mutación (media ± desviación estándar sobre 20 semillas independientes).*

Algoritmo	Operadores	Hipervolumen ↑	Espaciamiento ↓	IGD$^+$ ↓	ϵ^+ ↓	Tamaño de Pareto ↑	Tiempo (s) ↓
AGE-MOEA	pcx_pm	1.121 ± 0.003	1.169 ± 0.352	0.040 ± 0.005	**0.118 ± 0.020**	**24.1 ± 4.4**	110.7 ± 5.1
	pcx_gauss	**1.122 ± 0.004**	1.019 ± 0.357	**0.037 ± 0.007**	0.119 ± 0.029	22.9 ± 4.1	120.2 ± 4.5
	sbx_pm	1.113 ± 0.002	**0.903 ± 0.306**	0.053 ± 0.006	0.180 ± 0.022	19.4 ± 2.4	229.6 ± 19.6
	sbx_gauss	1.114 ± 0.003	1.025 ± 0.314	0.052 ± 0.009	0.178 ± 0.024	18.2 ± 3.9	**97.0 ± 3.6**
MOEA/D	pcx_pm	1.113 ± 0.004	1.042 ± 0.272	0.057 ± 0.011	**0.173 ± 0.032**	19.9 ± 3.5	43.9 ± 2.4
	pcx_gauss	**1.114 ± 0.003**	1.112 ± 0.383	**0.053 ± 0.009**	0.173 ± 0.025	**19.9 ± 4.1**	52.2 ± 3.0
	sbx_pm	1.107 ± 0.005	1.112 ± 0.308	0.068 ± 0.014	0.199 ± 0.029	17.9 ± 3.7	**38.5 ± 1.5**
	sbx_gauss	1.108 ± 0.006	**1.033 ± 0.370**	0.069 ± 0.013	0.199 ± 0.024	17.4 ± 3.7	41.4 ± 2.5
NSGA-II	pcx_pm	1.125 ± 0.004	1.228 ± 0.446	0.038 ± 0.006	0.101 ± 0.023	**29.4 ± 4.7**	99.0 ± 4.1
	pcx_gauss	**1.126 ± 0.005**	1.264 ± 0.502	**0.034 ± 0.008**	**0.094 ± 0.031**	26.1 ± 5.7	102.2 ± 4.7
	sbx_pm	1.114 ± 0.002	1.132 ± 0.362	0.051 ± 0.005	0.181 ± 0.011	24.0 ± 3.9	**56.5 ± 5.7**
	sbx_gauss	1.116 ± 0.003	**1.086 ± 0.324**	0.046 ± 0.008	0.167 ± 0.023	21.9 ± 4.2	59.4 ± 4.4
NSGA-III	pcx_pm	**1.121 ± 0.003**	1.171 ± 0.390	**0.036 ± 0.006**	**0.121 ± 0.021**	22.7 ± 5.1	108.3 ± 3.7
	pcx_gauss	1.121 ± 0.004	1.221 ± 0.322	0.038 ± 0.005	0.124 ± 0.025	23.8 ± 4.2	106.0 ± 4.4
	sbx_pm	1.115 ± 0.002	**1.130 ± 0.314**	0.048 ± 0.005	0.171 ± 0.016	**24.8 ± 3.4**	**60.5 ± 4.0**
	sbx_gauss	1.116 ± 0.003	1.137 ± 0.467	0.045 ± 0.007	0.163 ± 0.024	22.9 ± 3.5	64.8 ± 6.1

La Tabla 4.4 compara las configuraciones de AGE-MOEA, MOEA/D, NSGA-II y NSGA-III frente a las distintas combinaciones de operadores de cruce y mutación sobre indicadores de convergencia (HV, IGD$^+$), cobertura (ϵ^+), distribución (espaciamiento), tamaño del frente y costo computacional.

A nivel general, el factor determinante en el desempeño multiobjetivo es el operador de cruce, mientras que el impacto de la mutación (polinomial vs. gaussiana) resulta secundario. Las combinaciones basadas en PCX superan de forma sistemática a las de SBX en todos los algoritmos, alcanzando hipervolúmenes superiores (HV $\approx$ 1.113–1.126 frente a 1.107–1.116 en SBX) y una aproximación sustancialmente más cercana al frente de referencia (reducciones notorias en IGD$^+$ y ϵ^+). Esta superioridad responde a la dinámica de exploración en el espacio latente continuo del VAE: mientras que SBX recombina únicamente dos progenitores coordenada a coordenada atrapando a la población en regiones intermedias conocidas, PCX proyecta descendientes a partir de una nube de múltiples padres, favoreciendo la dispersión hacia regiones extremas no exploradas. La contrapartida de esta búsqueda más amplia es un incremento en el tiempo de cómputo (por la mayor complejidad del muestreo) y un espaciamiento numéricamente superior, derivado de extender soluciones hacia los bordes del frente en lugar de concentrarlas densamente en el centro.

En NSGA-II, la combinación con PCX alcanza el mejor desempeño global de la comparativa (HV = 1.126, $\epsilon^+ = 0.094$). Este algoritmo es el que mayor provecho obtiene de la dispersión de PCX, reflejado en el frente no dominado más numeroso (29.4 soluciones en promedio frente a 21.9–24.0 en SBX). Esto se debe a su mecanismo de selección basado en la distancia de apiñamiento (*crowding distance*), el cual recompensa a las soluciones aisladas generadas en los bordes y permite retener un abanico continuo de alternativas

que abarca desde compuestos de máxima facilidad de síntesis hasta moléculas de alto QED.

En NSGA-III, las variantes con PCX logran una convergencia sobresaliente ($IGD^+ = 0.036$, el valor más bajo de la comparativa) y un HV de 1.121. A diferencia de NSGA-II, el tamaño del frente se mantiene prácticamente invariable entre configuraciones (22.7–24.8 soluciones). Este comportamiento responde a la sustitución de la distancia de apiñamiento por puntos de referencia estructurados en un hiperplano, lo que acota la acumulación de soluciones en los extremos y preserva una distribución espacial uniforme a lo largo del frente independientemente de la agresividad del operador de cruce.

En AGE-MOEA, el uso de PCX consolida un frente competitivo ($HV = 1.122$ e $IGD^+ = 0.037$ en pcx_gauss) con un conjunto amplio de soluciones (24.1 en pcx_pm). No obstante, el algoritmo acusa una marcada sensibilidad computacional según el operador empleado: la variante `sbx_pm` eleva el tiempo a 229.6 s frente a los $\approx$ 97–120 s de las restantes configuraciones. Esta sobrecarga sugiere que la combinación de un cruce concentrador con mutación polinomial dificulta el ajuste adaptativo de la geometría del frente que realiza AGE-MOEA, requiriendo mayor iteración en el cálculo de distancias extremas de supervivencia.

Por último, MOEA/D presenta la menor brecha relativa entre familias de cruce y registra los menores tiempos de ejecución (38.5–52.2 s) y espaciamientos más reducidos (1.033–1.042). Al descomponer la búsqueda en subproblemas escalares acotados a vecindarios locales fijos, la capacidad de dispersión de PCX queda parcialmente restringida al entorno de soluciones vecinas muy similares entre sí. En consecuencia, aunque PCX mejora la cobertura frente a SBX, la dinámica de vecindad de MOEA/D prioriza la explotación local, evitando que el frente se expanda hacia los extremos del espacio de propiedades.

Tabla 4.5: *Comparación de indicadores químicos para las distintas combinaciones de operadores de cruce y mutación (media ± desviación estándar sobre 20 semillas independientes).*

Algoritmo	Operadores	QED ↑	SA ↓	Factibilidad ↑	F_{sp3}	Validez ↑	Unicidad ↑	Novedad ↑
AGE-MOEA	pcx_pm	0.848 ± 0.040	1.620 ± 0.090	0.746 ± 0.038	0.413 ± 0.041	0.864 ± 0.026	0.986 ± 0.022	0.974 ± 0.007
	pcx_gauss	0.848 ± 0.054	1.620 ± 0.080	0.736 ± 0.035	0.408 ± 0.058	0.831 ± 0.038	**0.998 ± 0.005**	**0.977 ± 0.006**
	sbx_pm	**0.884 ± 0.010**	**1.610 ± 0.060**	**0.859 ± 0.044**	0.390 ± 0.017	**0.990 ± 0.010**	0.323 ± 0.033	0.624 ± 0.208
	sbx_gauss	0.884 ± 0.013	1.630 ± 0.080	0.856 ± 0.052	0.384 ± 0.026	0.984 ± 0.011	0.483 ± 0.067	0.696 ± 0.167
MOEA/D	pcx_pm	0.877 ± 0.017	1.660 ± 0.070	0.882 ± 0.050	0.388 ± 0.020	0.991 ± 0.005	0.445 ± 0.070	0.745 ± 0.091
	pcx_gauss	0.882 ± 0.015	**1.650 ± 0.080**	0.875 ± 0.044	0.387 ± 0.032	0.985 ± 0.009	**0.545 ± 0.060**	**0.793 ± 0.066**
	sbx_pm	**0.889 ± 0.012**	1.700 ± 0.050	**0.930 ± 0.030**	0.391 ± 0.024	**0.997 ± 0.001**	0.255 ± 0.048	0.700 ± 0.104
	sbx_gauss	0.884 ± 0.017	1.690 ± 0.090	0.923 ± 0.031	0.407 ± 0.033	0.990 ± 0.009	0.380 ± 0.060	0.740 ± 0.181
NSGA-II	pcx_pm	0.803 ± 0.058	1.620 ± 0.080	0.735 ± 0.023	0.464 ± 0.064	0.798 ± 0.036	0.991 ± 0.010	0.983 ± 0.003
	pcx_gauss	0.805 ± 0.067	**1.580 ± 0.080**	0.746 ± 0.036	0.458 ± 0.076	0.786 ± 0.033	**0.996 ± 0.008**	**0.983 ± 0.005**
	sbx_pm	**0.889 ± 0.014**	1.650 ± 0.080	**0.867 ± 0.029**	0.397 ± 0.032	**0.989 ± 0.006**	0.833 ± 0.048	0.804 ± 0.045
	sbx_gauss	0.884 ± 0.014	1.630 ± 0.100	0.857 ± 0.037	0.389 ± 0.031	0.988 ± 0.006	0.761 ± 0.077	0.847 ± 0.043
NSGA-III	pcx_pm	0.854 ± 0.044	**1.600 ± 0.090**	0.744 ± 0.042	0.408 ± 0.049	0.863 ± 0.036	**0.999 ± 0.003**	0.973 ± 0.007
	pcx_gauss	0.851 ± 0.060	1.650 ± 0.090	0.747 ± 0.038	0.415 ± 0.072	0.826 ± 0.041	0.998 ± 0.005	**0.980 ± 0.005**
	sbx_pm	**0.885 ± 0.008**	1.610 ± 0.060	0.819 ± 0.025	0.408 ± 0.021	**0.985 ± 0.004**	0.756 ± 0.044	0.824 ± 0.034
	sbx_gauss	0.881 ± 0.011	1.620 ± 0.080	**0.841 ± 0.030**	0.392 ± 0.027	0.985 ± 0.008	0.853 ± 0.057	0.843 ± 0.028

La Tabla 4.5 resume las propiedades químicas obtenidas para los cuatro algoritmos, donde QED y SA se promedian sobre el frente no dominado acumulado, la validez, factibilidad y novedad sobre el total de evaluaciones de la ejecución, la unicidad sobre la población final, y F_{sp3} como nivel medio de saturación alcanzado bajo la restricción.

A nivel general, las propiedades químicas exhiben un compromiso directo condicionado por el operador de cruce. Las variantes con SBX generan descendientes en la vecindad inmediata de los progenitores, manteniéndose en regiones densas y confiables del modelo generativo; esto asegura una validez química sobresaliente ($> 98\,\%$) y una alta tasa de factibilidad ($82\,\%$–$93\,\%$), pero a costa de una pérdida apreciable de diversidad estructural, reflejada en menores niveles de unicidad y novedad por la reiteración de análogos ya conocidos en el entrenamiento. En contraposición, PCX aplica perturbaciones direccionales basadas en múltiples progenitores hacia zonas menos densas del espacio latente, lo que permite preservar una elevada unicidad y novedad ($> 97\,\%$ en la mayoría de los métodos) junto con una mayor tridimensionalidad ($F_{sp3} \geq 0.38$), asumiendo una reducción moderada en la validez ($78\,\%$–$86\,\%$). Cabe destacar que en todas las variantes evaluadas la accesibilidad sintética media se mantiene en rangos favorables (SA ≈ 1.58–1.70), confirmando que la mayor exploración de PCX no degrada la viabilidad sintética de los candidatos generados.

En NSGA-II, las combinaciones con PCX destacan por alcanzar la mayor diferenciación química, registrando una novedad superior al $98\,\%$ frente a los compuestos de entrenamiento y un F_{sp3} medio de 0.46, el más elevado entre todos los algoritmos evaluados, lo que asegura un marcado carácter tridimensional bajo la restricción impuesta ($F_{sp3} \geq 0.30$) junto con un SA favorable de 1.58–1.62. Su validez química desciende a $78.6\,\%$–$79.8\,\%$, con una factibilidad del $73.5\,\%$–$74.6\,\%$. Si bien las variantes con SBX obtienen mayor validez ($> 98.7\,\%$) y un QED promedio superior (0.884–0.889 frente a 0.803–0.805 en PCX), esto se debe a que concentran su búsqueda en un tramo acotado de alta similitud, mientras que PCX expande el espacio explorado hacia candidatos con andamiajes no reportados. En cuanto a la mutación, su efecto resulta secundario frente al cruce, aunque la mutación gaussiana en SBX aporta una novedad algo superior ($84.7\,\%$ frente a $80.4\,\%$ con polinomial).

En NSGA-III, las combinaciones con PCX preservan la mayor diversidad en la población final, alcanzando una unicidad prácticamente perfecta ($\geq 99.8\,\%$) y una novedad de $97.3\,\%$–$98.0\,\%$, junto con un F_{sp3} medio de 0.41 y un SA favorable de 1.60–1.65. Su validez química se sitúa entre $82.6\,\%$ y $86.3\,\%$, con una factibilidad del $74.4\,\%$–$74.7\,\%$. En cambio, SBX obtiene un QED promedio superior (0.881–0.885 frente a 0.851–0.854 en PCX), mayor validez ($> 98.4\,\%$) y mayor factibilidad ($81.9\,\%$–$84.1\,\%$), pero su menor dispersión reduce la unicidad ($75.6\,\%$ en `sbx_pm` y $85.3\,\%$ en `sbx_gauss`) y la novedad ($82.4\,\%$–$84.3\,\%$), mostrando mayor repetición de estructuras. La mutación muestra un efecto secundario frente al cruce, registrando una validez algo mayor con mutación polinomial en PCX ($86.3\,\%$ frente a $82.6\,\%$ con gaussiana).

En AGE-MOEA, se observa la caída más marcada de diversidad bajo SBX, donde la unicidad de la población final se reduce al $32.3\,\%$–$48.3\,\%$ y la novedad desciende a $62.4\,\%$–$69.6\,\%$, lo que en la práctica representa una desventaja al generar estructuras repetidas. En contraste, las combinaciones con PCX restablecen la variedad estructural, manteniendo una unicidad y novedad elevadas ($> 97\,\%$), con un nivel de factibilidad en torno al $74\,\%$, una validez moderada ($83.1\,\%$–$86.4\,\%$) y un F_{sp3} medio de 0.41. Esto evidencia que la selección por geometría adaptativa de AGE-MOEA requiere la diversidad que aporta PCX para no concentrarse prematuramente en familias moleculares análogas.

Por último, todas las configuraciones de MOEA/D destacan por sostener una validez química alta ($> 98.4\,\%$) y una factibilidad de $87.5\,\%$–$93.0\,\%$, con valores de SA favorables (1.65–1.70) y un F_{sp3} medio de 0.39–0.41. No obstante, a diferencia de los otros métodos, en MOEA/D la descomposición en subproblemas escalares y el cruce acotado a vecinos locales restringe la dispersión de PCX; en consecuencia, aun con este operador, la unicidad ($44.5\,\%$–$54.5\,\%$) y la novedad ($74.5\,\%$–$79.3\,\%$) resultan inferiores a las de los restantes algoritmos genéticos, concentrando la exploración en análogos moleculares conocidos.

Las pruebas de Wilcoxon de rangos con signo con corrección de Holm (detalladas en las Tablas B.2, B.3, B.4 y B.5 del Apéndice B) confirman que las combinaciones basadas en PCX superan a las de SBX en hipervolumen con significancia estadística en los cuatro algoritmos. Dentro de cada familia de cruce, el tipo de mutación (polinomial o gaussiana) no produce diferencias significativas en AGE-MOEA, MOEA/D ni NSGA-III, definiendo. La única excepción se presenta en NSGA-II bajo SBX, donde la mutación gaussiana supera de forma estadísticamente significativa a la polinomial.

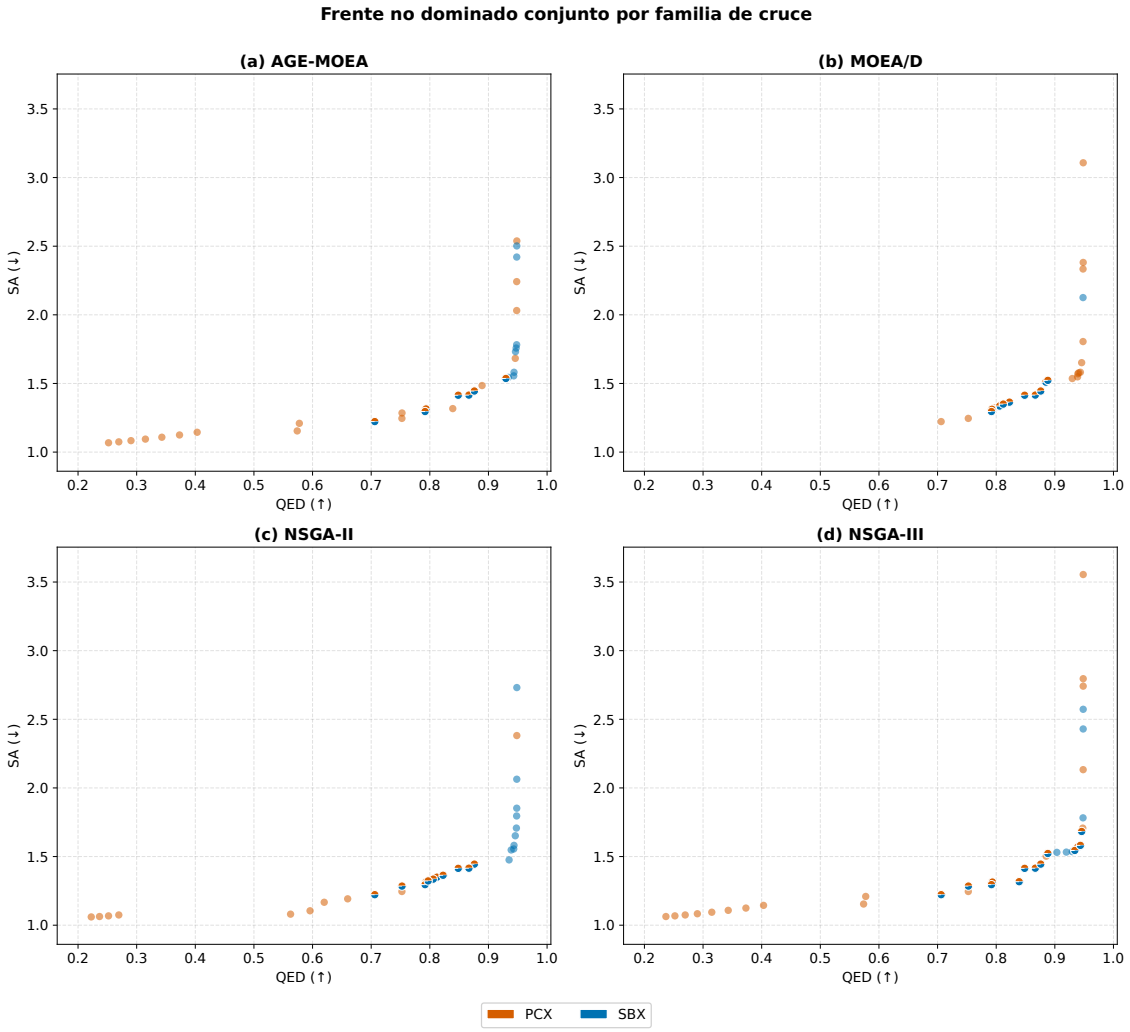


Figura 4.5: *Frente no dominado conjunto por familia de cruce (PCX vs. SBX) para cada metaheurística: (a) AGE-MOEA, (b) MOEA/D, (c) NSGA-II y (d) NSGA-III.*

La Figura 4.5 muestra los frentes no dominados combinados de ambas familias de cruce en el espacio QED–SA. Se observa una complementariedad clara entre los operadores: en la zona intermedia (QED entre 0.80 y 0.88), donde coinciden la mayoría de las corridas (véanse las distribuciones por semilla en las Figuras B.1–B.4 del Apéndice B.3), ambos operadores encuentran soluciones similares. La diferencia aparece en los extremos: PCX cubre en solitario la zona de menor SA (SA $\approx$ 1.06–1.20), mientras que SBX aporta más soluciones en el tramo de alto QED (≈ 0.948), donde la complejidad de las moléculas aumenta (SA > 2.5).

Entre los algoritmos, NSGA-II y NSGA-III logran los frentes más amplios, cubriendo tanto valores bajos de SA como altos de QED. En AGE-MOEA, PCX permite alcanzar la zona de bajo SA que SBX no logra explorar. En cambio, en MOEA/D ambos operadores se quedan en valores de QED > 0.70 debido a la búsqueda por vecindarios, sin llegar al extremo de bajo SA.

En cuanto a las moléculas obtenidas (que se muestran en detalle en las Figuras B.5–B.8 del Apéndice B.4), todas las configuraciones alcanzan valores de QED cercanos a 0.948 con SA < 3. Con SBX predominan estructuras planas y sencillas, mientras que PCX incorpora más anillos no aromáticos, lo que aumenta la tridimensionalidad (F_{sp3} de hasta 0.50) manteniendo una adecuada facilidad de síntesis.

4.2.3. Comparación Global de Metaheurísticas

En esta sección se comparan los cinco algoritmos (NSGA-II, NSGA-III, MOEA/D, AGE-MOEA y CMOPSO) seleccionando la mejor configuración de cada uno a partir del estudio de hiperparámetros y operadores presentado anteriormente. Los cuatro algoritmos genéticos (NSGA-II, NSGA-III, MOEA/D y AGE-MOEA) emplean la combinación pcx_pm, acorde a las comparaciones de la Sección 4.2.2. CMOPSO usa su configuración de hiperparámetros ganadora (100×1000, élite = 10, $p_m = 0.031$, $v_{\max} = 0.1$).

4.2.3.1. Indicadores Multiobjetivo y Químicos

Tabla 4.6: *Comparación de indicadores multiobjetivo - mejores configuraciones.*

Algoritmo	Hipervolumen ↑	Espaciamiento ↓	IGD$^+$ ↓	ϵ^+ ↓	Tamaño de Pareto ↑	Tiempo (s) ↓
NSGA-II (PCX+PM)	$\mathbf{1.125 \pm 0.004}$	1.228 ± 0.446	0.038 ± 0.006	$\mathbf{0.101 \pm 0.023}$	$\mathbf{29.4 \pm 4.7}$	99.0 ± 4.1
NSGA-III (PCX+PM)	1.121 ± 0.003	1.171 ± 0.390	$\mathbf{0.036 \pm 0.006}$	0.121 ± 0.021	22.7 ± 5.1	108.3 ± 3.7
MOEA/D (PCX+PM)	1.113 ± 0.004	$\mathbf{1.042 \pm 0.272}$	0.057 ± 0.011	0.173 ± 0.032	19.9 ± 3.5	$\mathbf{43.9 \pm 2.4}$
AGE-MOEA (PCX+PM)	1.121 ± 0.003	1.170 ± 0.352	0.040 ± 0.005	0.118 ± 0.020	24.1 ± 4.4	110.7 ± 5.1
CMOPSO ($v_{\max} = 0.1$)	1.109 ± 0.004	1.053 ± 0.380	0.059 ± 0.003	0.191 ± 0.011	17.8 ± 3.4	50.2 ± 1.9

La Tabla 4.6 presenta la comparación de las mejores configuraciones de los cinco algoritmos en el espacio multiobjetivo. Se evalúan indicadores de convergencia y proximidad al frente de referencia (hipervolumen, IGD$^+$ y ϵ^+), junto con la distribución (espaciamiento), el número de soluciones no dominadas factibles y el tiempo de ejecución.

Los resultados muestran que NSGA-II alcanza el mayor hipervolumen promedio (1.125), el menor ϵ^+ (0.101) y el frente más numeroso (29.4 soluciones factibles), y NSGA-III el menor IGD$^+$ (0.036). NSGA-III (1.121) y AGE-MOEA (1.121) se ubican en un segundo nivel muy cercano en convergencia, con valores de IGD$^+$ de 0.036 y 0.040, ϵ^+ de 0.121 y 0.118, y tamaños de frente de 22.7 y 24.1 soluciones, respectivamente. Por su parte, MOEA/D (1.113) y CMOPSO (1.109) obtienen hipervolúmenes menores y valores más altos en IGD$^+$ (0.057 y 0.059) y ϵ^+ (0.173 y 0.191), lo que refleja que dejan segmentos del frente de referencia sin cubrir. No obstante, ambos destacan por una ejecución más rápida (43.9 s y 50.2 s frente a 99.0–110.7 s en los demás métodos) y por un espaciamiento menor (1.042 y 1.053) al concentrar sus soluciones en la región de alto QED.

Estas diferencias podrían deberse a cómo busca y selecciona cada algoritmo. En NSGA-II, la distancia de apiñamiento permite que las soluciones se expandan libremen-

te hacia los extremos del frente, lo que junto con PCX facilita descubrir moléculas tanto de bajo SA como de alto QED y acumular más soluciones no dominadas. En cambio, CMOPSO mueve sus partículas hacia las mejores soluciones encontradas, las cuales suelen concentrarse en la zona de alto QED, lo que reduce la exploración hacia otras regiones. En MOEA/D, cruzar únicamente entre vecinos cercanos favorece la búsqueda local pero limita la dispersión. Finalmente, NSGA-III y AGE-MOEA reparten las soluciones de forma más uniforme a lo largo del frente, logrando una buena convergencia sin acumular tantas moléculas como NSGA-II.

Tabla 4.7: *Comparación de indicadores químicos - mejores configuraciones.*

Algoritmo	QED ↑	SA ↓	Factibilidad ↑	F_{sp3}	Validez ↑	Unicidad ↑	Novedad ↑
NSGA-II (PCX+PM)	0.803 ± 0.058	1.620 ± 0.080	0.735 ± 0.023	0.464 ± 0.064	0.798 ± 0.036	0.991 ± 0.010	$\mathbf{0.983 \pm 0.003}$
NSGA-III (PCX+PM)	0.854 ± 0.044	$\mathbf{1.600 \pm 0.090}$	0.744 ± 0.042	0.408 ± 0.049	0.863 ± 0.036	$\mathbf{0.999 \pm 0.003}$	0.973 ± 0.007
MOEA/D (PCX+PM)	0.877 ± 0.017	1.660 ± 0.070	0.882 ± 0.050	0.388 ± 0.020	0.991 ± 0.005	0.445 ± 0.070	0.745 ± 0.091
AGE-MOEA (PCX+PM)	0.848 ± 0.040	1.620 ± 0.090	0.746 ± 0.038	0.413 ± 0.041	0.864 ± 0.026	0.986 ± 0.022	0.974 ± 0.007
CMOPSO ($v_{max} = 0.1$)	$\mathbf{0.887 \pm 0.009}$	1.650 ± 0.080	$\mathbf{0.930 \pm 0.025}$	0.407 ± 0.030	$\mathbf{0.996 \pm 0.005}$	0.320 ± 0.064	0.665 ± 0.211

La Tabla 4.7 presenta la comparación de las propiedades químicas entre los cinco algoritmos. QED y SA se promedian sobre el frente no dominado acumulado, mientras que validez, factibilidad, unicidad, novedad y F_{sp3} describen el comportamiento de la búsqueda sobre el espacio químico.

Los resultados dividen a los algoritmos en dos grupos definidos. Por un lado, CMOPSO y MOEA/D obtienen los valores promedio más altos de QED (0.887 y 0.877), junto con una validez química cercana al $100\,\%$. Sin embargo, este comportamiento reduce la diversidad de la población final, registrando una unicidad baja ($32.0\,\%$ en CMOPSO y $44.5\,\%$ en MOEA/D) y menor novedad frente a los compuestos de entrenamiento ($66.5\,\%$ y $74.5\,\%$).

Por otro lado, NSGA-II, NSGA-III y AGE-MOEA mantienen una unicidad superior al $98.6\,\%$ (0.999 en NSGA-III y 0.991 en NSGA-II) y una novedad superior al $97\,\%$ (0.983 en NSGA-II), con una factibilidad del $73.5\,\%$–$74.6\,\%$ y una validez entre $79.8\,\%$ y $86.4\,\%$. Su menor QED promedio en el frente (0.803–0.854) responde a que estos algoritmos incorporan soluciones a lo largo de todo el frente, incluyendo el extremo de bajo SA (1.600 en NSGA-III y 1.620 en NSGA-II y AGE-MOEA), cubriendo un conjunto más amplio de compromisos. Todos los métodos cumplen la restricción de tridimensionalidad ($F_{sp3} \geq 0.30$), destacando NSGA-II con un promedio de 0.464.

Estas diferencias en la diversidad química podrían explicarse por la dinámica de búsqueda en el espacio latente. CMOPSO y MOEA/D tienden a concentrar a sus individuos en zonas densas del modelo generativo, lo que asegura que casi todas las moléculas decodificadas sean válidas pero a costa de repetir estructuras conocidas. En cambio, los algoritmos genéticos combinados con PCX exploran regiones más diversas del espacio latente, lo que genera compuestos estructuralmente únicos y novedosos, aunque con una leve disminución en la tasa de validez.

Tabla 4.8: *Comparación entre algoritmos sobre hipervolumen. Grupos homogéneos: {NSGA-II} > {AGE-MOEA, NSGA-III} > {MOEA/D} > {CMOPSO}.*

Par	p (Holm)	r_{rb}	Mejor
NSGA-II vs NSGA-III	0.005	+0.762	NSGA-II
NSGA-II vs MOEA/D	<0.001	+1.000	NSGA-II
NSGA-II vs AGE-MOEA	0.004	+0.790	NSGA-II
NSGA-II vs CMOPSO	<0.001	+1.000	NSGA-II
NSGA-III vs MOEA/D	<0.001	+1.000	NSGA-III
NSGA-III vs AGE-MOEA	0.571	+0.152	-
NSGA-III vs CMOPSO	<0.001	+1.000	NSGA-III
MOEA/D vs AGE-MOEA	<0.001	−0.990	AGE-MOEA
MOEA/D vs CMOPSO	0.008	+0.705	MOEA/D
AGE-MOEA vs CMOPSO	<0.001	+1.000	AGE-MOEA

La Tabla 4.8 confirma diferencias significativas entre los algoritmos sobre el hipervolumen ($p < 0.001$ en el test de Friedman). NSGA-II se posiciona como el algoritmo con mejor desempeño global, superando a todos los demás de forma estadísticamente significativa ($p \leq 0.005, r_{\text{rb}} \geq +0.762$). En el segundo escalón homogéneo se ubican AGE-MOEA y NSGA-III sin diferencias significativas entre sí ($p = 0.571$), seguidos por MOEA/D en tercer lugar ($p = 0.008$ frente a CMOPSO) y finalmente CMOPSO.

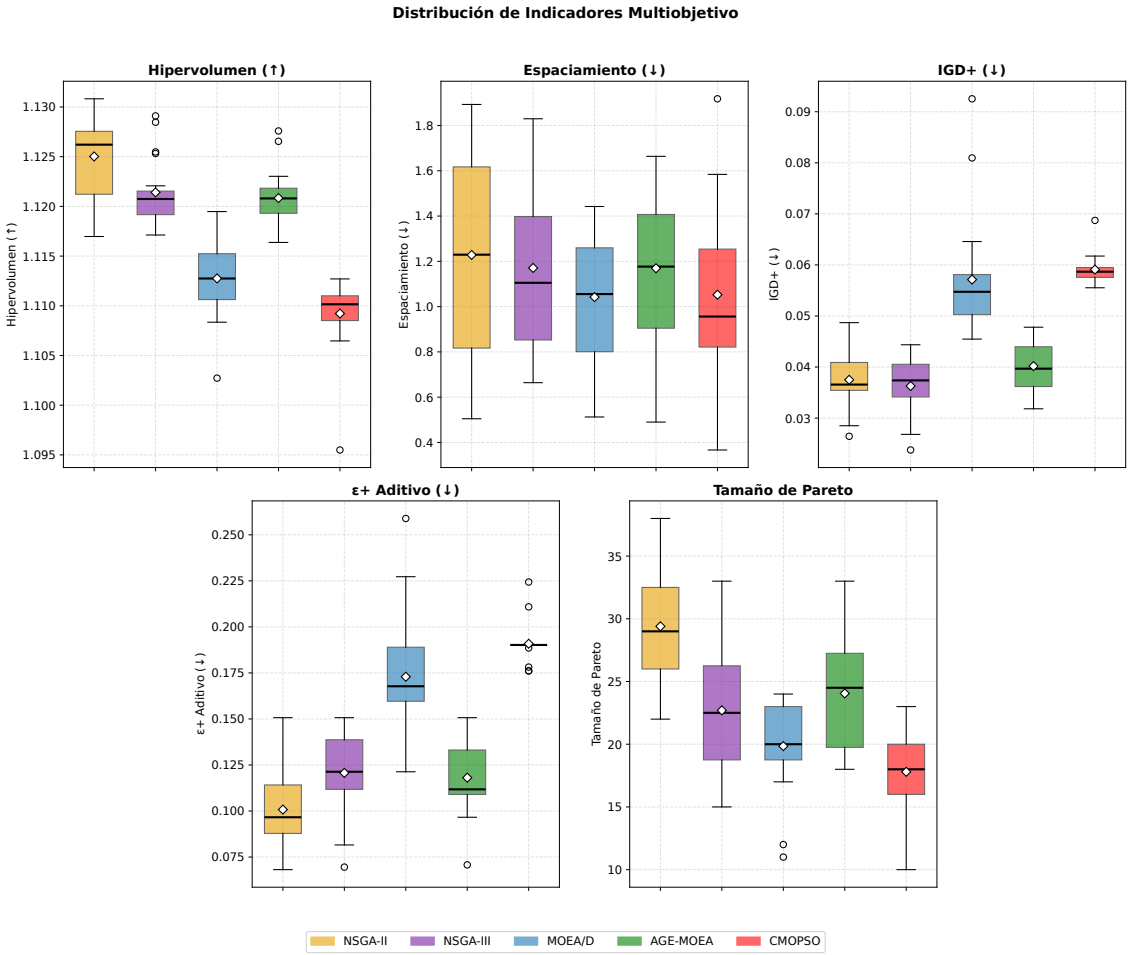


Figura 4.6: *Distribución de los indicadores multiobjetivo de cada algoritmo sobre las veinte ejecuciones independientes.*

La Figura 4.6 ilustra la distribución de los indicadores multiobjetivo de la Tabla 4.6 mediante diagramas de caja. NSGA-II obtiene las medianas más favorables en hipervolumen (≈ 1.126), IGD$^+$ y ϵ^+, junto con el mayor número de soluciones no dominadas (mediana de 29). AGE-MOEA y NSGA-III muestran distribuciones similares entre sí en todas las métricas, manteniendo una buena aproximación y cobertura del frente de referencia.

Por su parte, MOEA/D y CMOPSO presentan medianas menores de espaciamiento (1.05 y 0.95) debido a que sus soluciones se concentran en el tramo de alto QED. Sin embargo, al no explorar la rama de bajo SA, registran valores peores en IGD$^+$ y ϵ^+, ya que dejar ese sector sin cubrir aumenta la distancia respecto al frente de referencia. Además, al enfocarse en una zona más acotada, obtienen menos soluciones no dominadas (medianas de 20 y 18 moléculas, respectivamente).

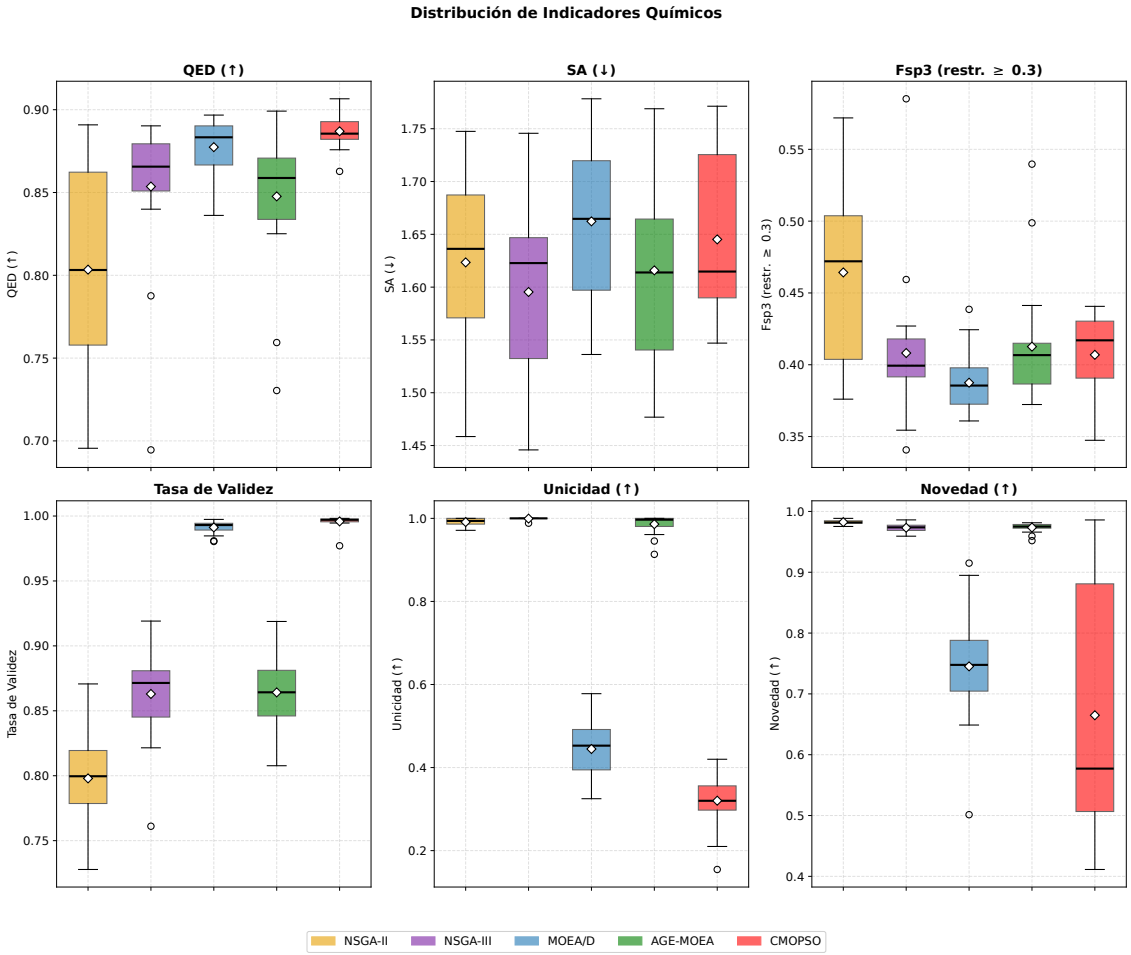


Figura 4.7: *Distribución de las propiedades químicas del frente de Pareto obtenido por cada algoritmo.*

La Figura 4.7 ilustra mediante diagramas de caja las distribuciones de la Tabla 4.7 a lo largo de las veinte ejecuciones. En ella, QED, SA y F_{sp3} se evalúan sobre las moléculas del frente no dominado, mientras que la validez, unicidad y novedad describen la generación global de cada ejecución.

En los objetivos, CMOPSO y MOEA/D concentran sus resultados de QED en torno a 0.88, mientras que NSGA-II presenta mayor dispersión con valores entre 0.70 y 0.88, reflejando su cobertura sobre el frente. En accesibilidad sintética, todos los métodos obtienen valores favorables con medianas entre 1.60 y 1.66. Respecto a la restricción $F_{\text{sp3}} \geq 0.30$, todos los algoritmos la cumplen, alcanzando NSGA-II los valores más altos cerca de 0.47.

En las métricas de generación, MOEA/D y CMOPSO alcanzan una validez próxima al $99\,\%$, pero su unicidad desciende a medianas de 0.45 y 0.32, y su novedad resulta menor y dispersa en CMOPSO. En contraste, NSGA-II, NSGA-III y AGE-MOEA mantienen unicidad y novedad cercanas a 1.0 y 0.98, con una validez situada entre el $80\,\%$ y el $86\,\%$.

4.2.4. Convergencia, Cobertura y Diversidad de las Soluciones

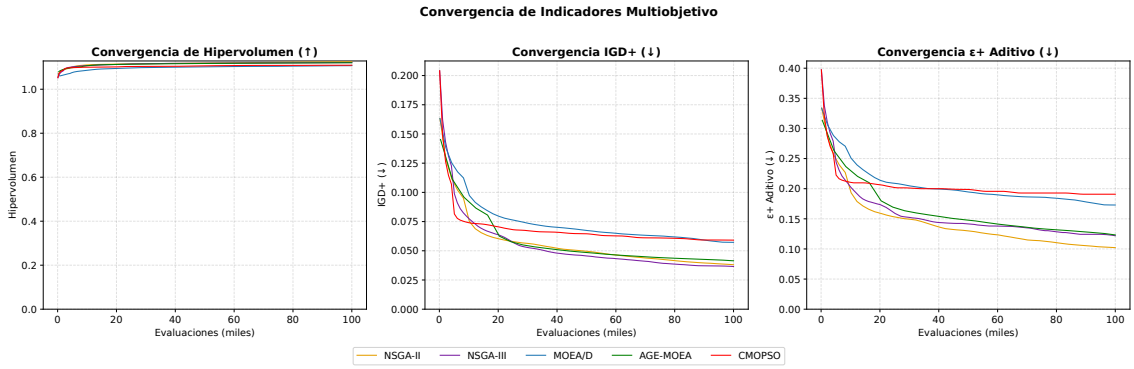


Figura 4.8: *Convergencia de los indicadores multiobjetivo en función del número de evaluaciones para cada algoritmo, promediada sobre las veinte ejecuciones independientes.*

La Figura 4.8 presenta la convergencia de los indicadores multiobjetivo en función del número de evaluaciones, promediada sobre las veinte ejecuciones independientes. Estas curvas muestran el progreso del frente no dominado a lo largo del presupuesto y convergen hacia los valores reportados en la Tabla 4.6.

En hipervolumen, todos los algoritmos experimentan un avance rápido durante las primeras $20{,}000$ evaluaciones, superando valores de 1.10, para luego ingresar en una fase de refinamiento gradual. NSGA-II consolida la cota más alta a lo largo de todo el proceso (1.125), seguido por NSGA-III (1.121) y AGE-MOEA (1.121), mientras que CMOPSO (1.109) y MOEA/D (1.107) se estabilizan en niveles inferiores desde etapas tempranas, ratificando la jerarquía obtenida en los tests estadísticos.

En IGD$^+$ y ϵ^+, las trayectorias evidencian diferencias en la dinámica de exploración. CMOPSO desciende durante las primeras $10{,}000$ evaluaciones al concentrar sus partículas en la zona de alto QED, alcanzando IGD$^+ \approx 0.073$ y $\epsilon^+ \approx 0.210$. Sin embargo, su progreso se detiene a partir de las $40{,}000$ evaluaciones y finaliza con los valores más desfavorables (0.059 y 0.191). MOEA/D muestra un descenso más progresivo pero igualmente limitado, concluyendo en 0.057 y 0.173. Este comportamiento confirma que ambos métodos dejan sectores periféricos del frente de referencia sin cubrir.

Por el contrario, los algoritmos NSGA-II, NSGA-III y AGE-MOEA logran una mejora sostenida a lo largo de todo el presupuesto. NSGA-II registra el menor ϵ^+ desde las $10{,}000$ evaluaciones y concluye en 0.101, mientras que el menor IGD$^+$ lo alcanza NSGA-III (0.036), seguido de NSGA-II (0.038) y AGE-MOEA (0.040). La capacidad de estos algoritmos para extender soluciones hacia el extremo de bajo SA explica que continúen descubriendo nuevas alternativas no dominadas a lo largo de la optimización.

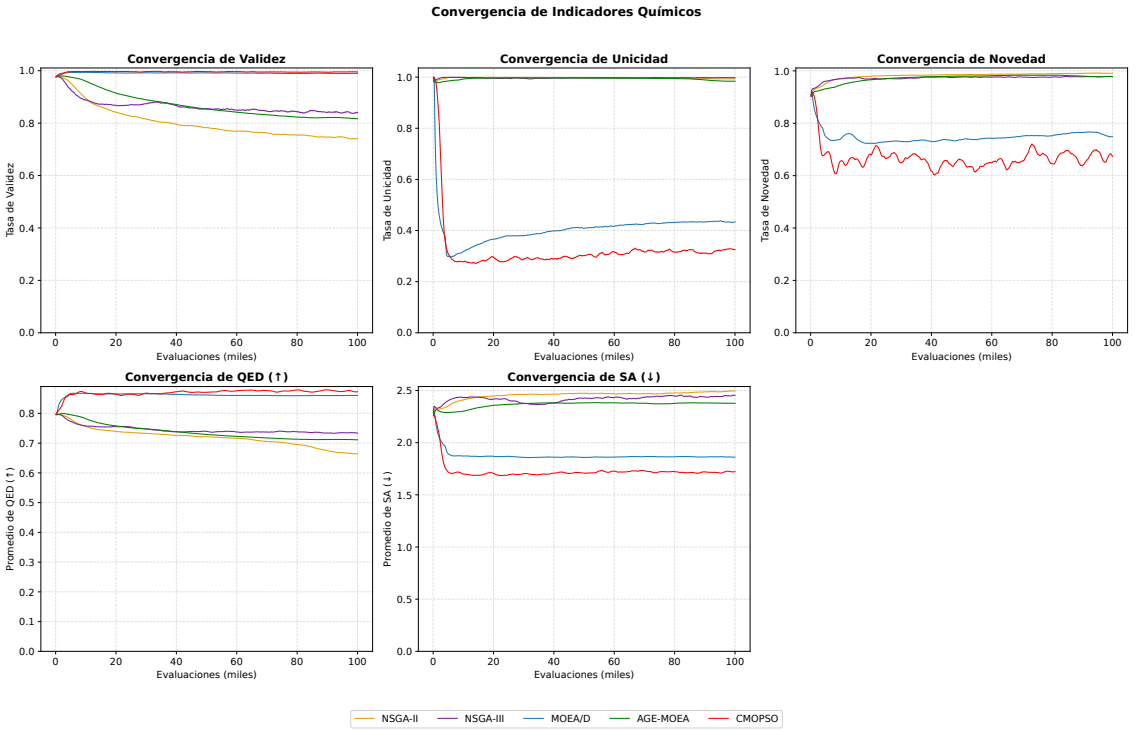


Figura 4.9: *Convergencia de los indicadores químicos en función del número de evaluaciones para cada algoritmo, promediada sobre las veinte ejecuciones independientes.*

La Figura 4.9 muestra la dinámica de las propiedades químicas en la población activa a lo largo de las evaluaciones. MOEA/D y CMOPSO sostienen una validez cercana al $99\,\%$ durante toda la optimización, pero su unicidad desciende durante las primeras $5{,}000$ evaluaciones y se estabiliza entre el $30\,\%$ y el $44\,\%$. En cuanto a la novedad frente a los compuestos de entrenamiento, MOEA/D se sitúa en torno al $75\,\%$ y CMOPSO alrededor del $66\,\%$. Por el contrario, NSGA-II, NSGA-III y AGE-MOEA conservan una unicidad y novedad próximas al $98\,\%$ y $100\,\%$, con una validez que se sitúa entre el $75\,\%$ y el $84\,\%$. En el espacio de objetivos de la población activa, CMOPSO y MOEA/D concentran sus soluciones en valores promedio de QED cercanos a 0.88 y SA inferior a 1.86, mientras que los algoritmos genéticos registran un QED promedio en torno a 0.66–0.73 y un SA superior a 2.37, reflejando la presencia continua de individuos en diversas regiones del frente.

4.2.4.1. Frentes de Pareto

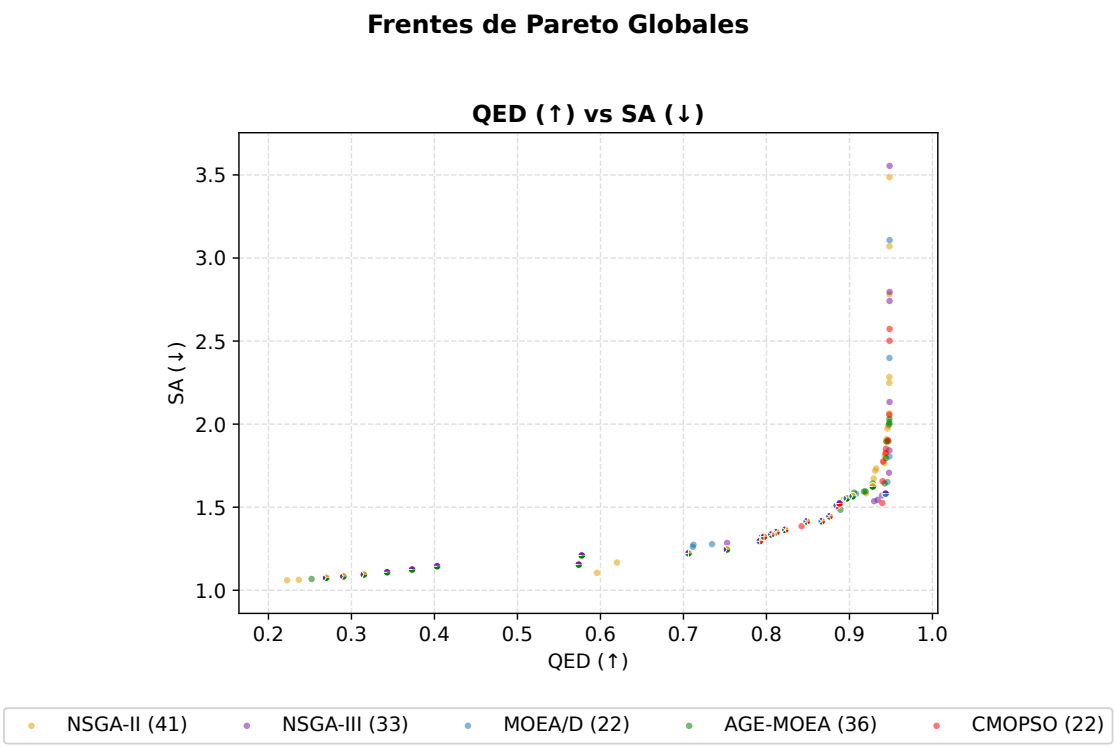


Figura 4.10: *Frentes de Pareto superpuestos de las mejores configuraciones de los cinco algoritmos en el espacio QED–SA.*

La Figura 4.10 muestra los frentes de Pareto acumulados de los cinco algoritmos en el espacio QED–SA sobre las veinte ejecuciones. Todos los métodos comparten el frente general, aunque con diferencias en la cantidad y distribución de las soluciones. NSGA-II acumula el mayor número de moléculas no dominadas (41), seguido por AGE-MOEA (36) y NSGA-III (33), mientras que CMOPSO y MOEA/D obtienen solo 22 cada uno, en línea con el tamaño de frente reportado en la Tabla 4.6.

En la región de bajo SA, los algoritmos genéticos son los únicos que encuentran soluciones, alcanzando NSGA-II los compuestos de menor SA (≈ 1.06). En cambio, CMOPSO y MOEA/D no exploran esta zona y limitan su búsqueda a valores de QED superiores a 0.70. Hacia el centro del frente, los cinco métodos coinciden y comparten soluciones con un equilibrio adecuado entre ambas propiedades.

En el extremo de alto QED, el frente forma una rama vertical donde los valores se saturan cerca de 0.948. En este tramo, mejoras mínimas en QED exigen estructuras más complejas y elevan el SA por encima de 3.0, donde NSGA-II y NSGA-III alcanzan las soluciones más altas. Esta distribución explica por qué CMOPSO y MOEA/D obtienen un QED promedio superior en la Tabla 4.7, ya que concentran sus soluciones en la derecha, mientras que los algoritmos genéticos reducen su promedio al incluir también alternativas de fácil síntesis.

4.2.5. Análisis del Frente no Dominado Conjunto y Moléculas Representativas

Para evaluar la capacidad exploratoria conjunta y caracterizar el espacio químico accesible, se combinan las soluciones obtenidas por las ramas de cruce PCX y SBX en los cuatro algoritmos genéticos (empleando en cada caso el operador de mutación con mejor desempeño en la comparación estadística), junto con CMOPSO, a lo largo de las veinte ejecuciones independientes. Tras deduplicar por estructura química (SMILES), se recalcula la no dominancia global, conformando un frente no dominado conjunto de 32 moléculas únicas.

4.2.5.1. Contribución al Frente Conjunto Global

La Tabla 4.9 presenta la contribución de cada algoritmo y combinación de operadores al frente no dominado conjunto global, indicando el número de moléculas aportadas, las exclusivas, el porcentaje sobre el total y los promedios de los objetivos en las soluciones aportadas.

Tabla 4.9: *Contribución de cada algoritmo y combinación de operadores al frente no dominado conjunto global (32 soluciones).*

Configuración	Operadores	Aporta	Exclusivas	%	QED ↑	SA ↓	F_{sp3}
NSGA-II	pcx_pm	15	4	46.9	0.598	1.220	0.570
	sbx_gauss	16	6	50.0	0.874	1.590	0.338
NSGA-III	pcx_pm	15	2	46.9	0.726	1.470	0.475
	sbx_pm	9	1	28.1	0.829	1.480	0.347
MOEA/D	pcx_pm	9	0	28.1	0.841	1.410	0.343
	sbx_pm	6	0	18.8	0.828	1.370	0.359
AGE-MOEA	pcx_pm	11	1	34.4	0.615	1.240	0.587
	sbx_pm	7	0	21.9	0.811	1.350	0.350
CMOPSO	-	10	3	31.2	0.865	1.620	0.360

En la Tabla 4.9 se observa que NSGA-II lidera la contribución al frente global, aportando el $50.0\,\%$ de las soluciones mediante sbx_gauss (16 moléculas, 6 exclusivas) y el $46.9\,\%$ mediante pcx_pm (15 moléculas, 4 exclusivas). NSGA-III y AGE-MOEA también realizan aportes importantes, mientras que CMOPSO suma 10 soluciones (3 de ellas exclusivas, representando el $31.2\,\%$). Por su parte, las soluciones de MOEA/D resultan compartidas con las aportadas por los demás algoritmos.

Nuevamente se comprueba la complementariedad entre familias de operadores: las combinaciones con PCX aportan las moléculas con mayor grado de saturación (F_{sp3} medio de 0.48–0.59) y menor dificultad sintética (SA ≈ 1.220–1.470, aunque con menor

QED), mientras que las variantes con SBX y CMOPSO consolidan la zona de alto QED (> 0.81–0.87) con valores de F_{sp3} en torno a 0.34–0.36.

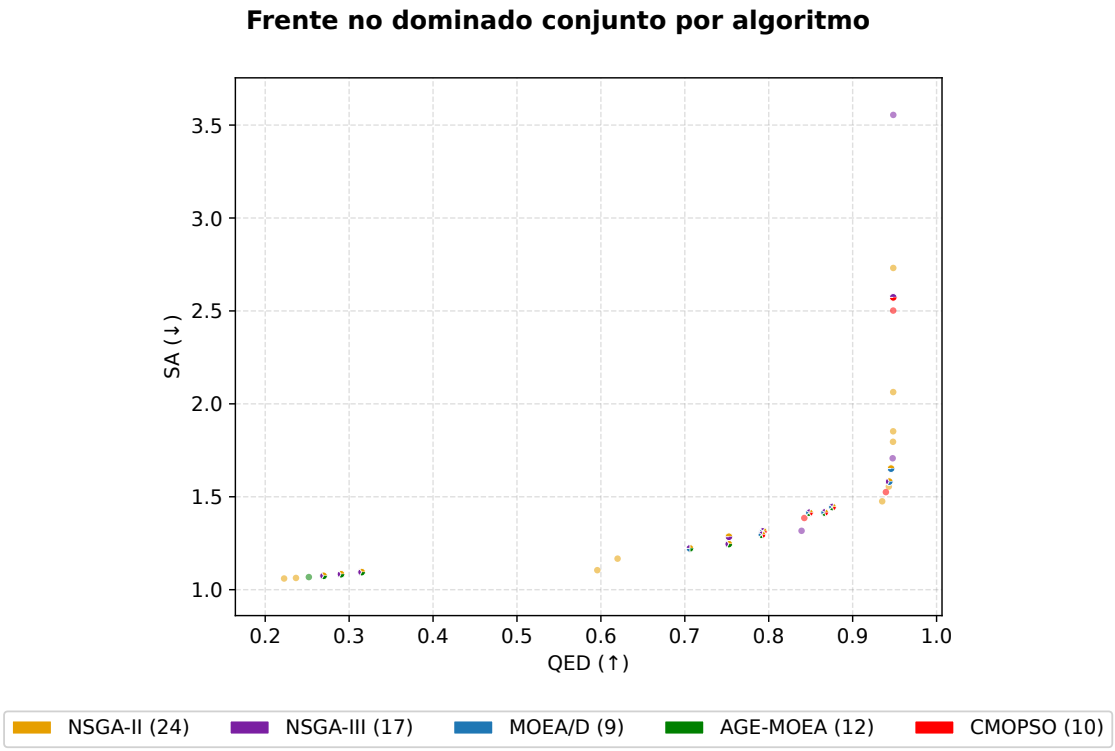


Figura 4.11: *Frente no dominado conjunto global (32 soluciones) en el espacio QED–SA, coloreado según el algoritmo aportante.*

La Figura 4.11 presenta la distribución de las 32 soluciones del frente no dominado conjunto en el espacio QED–SA. Los círculos de un solo color representan aportes exclusivos de un algoritmo, mientras que las divisiones multicolores indican moléculas descubiertas por más de un método.

NSGA-II muestra la mayor cobertura al participar en 24 de las 32 soluciones y aportar 10 de forma exclusiva, abarcando los compuestos de menor SA en solitario y compartiendo la zona intermedia de esa cola con AGE-MOEA y NSGA-III. En el centro del frente, la presencia de puntos multicolores refleja convergencia hacia las mismas estructuras de compromiso, mientras que en la rama vertical de alto QED destacan aportes de CMOPSO, NSGA-II y la molécula de mayor SA descubierta por NSGA-III.

4.2.5.2. Moléculas Representativas

Para analizar la calidad de las moléculas generadas y comparar cómo explora cada metaheurística las distintas regiones del frente de Pareto, se seleccionan tres soluciones representativas por algoritmo: la de menor dificultad sintética (menor SA), la de mayor valor de QED, y la del extremo de mayor SA dentro del frente no dominado. La Tabla 4.10 y la Figura 4.12 presentan sus propiedades fisicoquímicas y estructuras 2D. El catálogo

completo de las cinco moléculas de mayor QED por algoritmo se encuentra disponible en el Apéndice B.5 (Tabla B.6).

Tabla 4.10: *Moléculas representativas de cada algoritmo en tres puntos del frente de Pareto: extremo de menor SA, mayor QED y extremo de mayor SA.*

Algoritmo	Punto del Frente	QED ↑	SA ↓	F_{sp3}	SMILES
NSGA-II	Extremo de menor SA	0.223	1.060	1.000	CCCCCCCCCCCCCCCCCCCC
	Mayor QED	0.948	1.800	0.333	Cc1ccc(NC(=O)N2CCN(Cc3ccccn3)CC2)cc1
	Extremo de mayor SA	0.948	2.730	0.333	Cn1cc(NC(=O)C2CCCO2)c(-c2ccccc2Cl)n1
NSGA-III	Extremo de menor SA	0.270	1.070	1.000	CCCCCCCCCCCCCCCCCC
	Mayor QED	0.948	1.710	0.316	Cc1cc(C(=O)N2CCN(Cc3ccccc3)CC2)ccc1O
	Extremo de mayor SA	0.948	3.550	0.312	Cc1cc(CO)c(Cl)c(-c2cccn2C2COCC2=O)c1
MOEA/D	Extremo de menor SA	0.706	1.220	0.300	O=C(Nc1ccccc1)C1CC1
	Mayor QED	0.948	1.810	0.333	Cc1ccc(CN2CCN(C(=O)Nc3cccnc3)CC2)cc1
	Extremo de mayor SA	0.948	3.110	0.333	Cc1nc(C(O)c2ccccc2Cl)n(CC(F)(F)F)n1
AGE-MOEA	Extremo de menor SA	0.252	1.070	1.000	CCCCCCCCCCCCCCCCCCC
	Mayor QED	0.948	1.810	0.333	Cc1ccc(NC(=O)N2CCN(Cc3ccccc3)CC2)cn1
	Extremo de mayor SA	0.948	2.030	0.375	O=C(c1csc(-c2cccc(CO)c2)n1)N1CCCCC1
CMOPSO	Extremo de menor SA	0.792	1.300	0.364	CCCNC(=O)c1ccc(OC)cc1
	Mayor QED	0.948	2.060	0.333	O=C(NC1CCN(c2nccs2)CC1)c1ccccc1F
	Extremo de mayor SA	0.948	2.570	0.333	O=C(NC1(c2nccs2)CCOCC1)c1ccccc1F

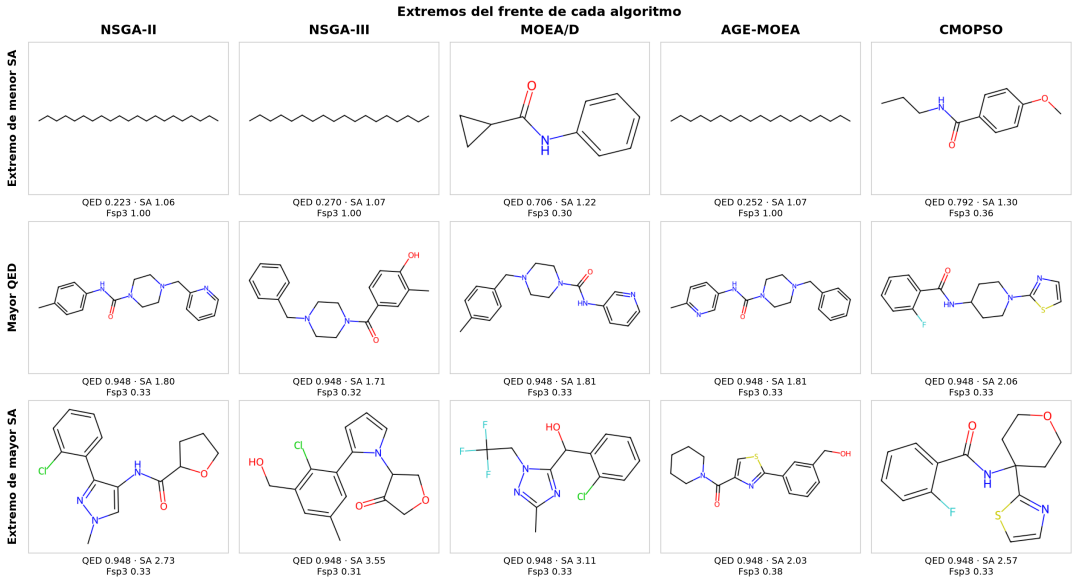


Figura 4.12: *Estructuras 2D de las moléculas representativas de cada algoritmo en tres puntos del frente de Pareto: extremo de menor SA, mayor QED y extremo de mayor SA.*

La Tabla 4.10 y la Figura 4.12 muestran las moléculas generadas a lo largo del frente de Pareto. En la zona de menor SA, NSGA-II, NSGA-III y AGE-MOEA exploran el extremo del espacio generando cadenas lineales de carbono saturadas con bajo QED. Aunque estas cadenas no presentan interés como fármacos, la capacidad de estos algoritmos para

explorar los extremos del frente puede resultar útil al incorporar otros objetivos a optimizar. Por el contrario, MOEA/D y CMOPSO son más conservadores en esta región y generan moléculas pequeñas con mejor perfil farmacológico.

En la zona de mayor QED, todos los métodos convergen alrededor de 0.948 y producen estructuras similares basadas en anillos aromáticos combinados con piperazina o piperidina. En este punto, NSGA-III destaca al obtener la molécula de mayor QED con la menor dificultad sintética entre todos los algoritmos. Finalmente, en el extremo de mayor SA, el QED se satura mientras el SA aumenta debido a la incorporación de más anillos y sustituyentes. Esto explica por qué el frente de Pareto se vuelve casi vertical en esa zona, ya que agregar más complejidad estructural no produce mejoras en el QED.

4.2.6. Discusión y Limitaciones

La incorporación de $F_{\text{sp3}} \geq 0.30$ como restricción de factibilidad fuerza al modelo a evitar estructuras predominantemente planas, asociadas a baja solubilidad y promiscuidad biológica [29, 30]. Los resultados muestran que existe complementariedad de los operadores, donde PCX actúa como motor de dispersión y novedad, extendiendo el frente hacia regiones de bajo SA y alta saturación, mientras que SBX y CMOPSO concentran la búsqueda en regiones de alto QED manteniendo una alta validez química.

En conjunto, estos resultados sugieren que formular la tridimensionalidad como una restricción ayuda a orientar la búsqueda sin sobrecargar la optimización. La combinación de operadores con dinámicas distintas permite explorar diferentes zonas del frente, aportando soluciones factibles que concilian de manera razonable la accesibilidad sintética y las propiedades tipo fármaco evaluadas.

Al no existir un frente de Pareto teórico conocido para este espacio químico, la comparación entre algoritmos esta basada en un frente de referencia empírico construido a partir de las soluciones no dominadas factibles obtenidas.

Por último, las funciones objetivo optimizadas (QED y SA) y la restricción impuesta ($F_{\text{sp3}} \geq 0.30$) evalúan propiedades fisicoquímicas generales estimadas computacionalmente, sin medir la afinidad frente a una diana terapéutica particular, aspecto que se aborda en una etapa posterior incorporando acoplamiento molecular.

4.3. Generación de Inhibidores de la Proteína MRP1

4.3.1. Análisis de Calidad de Generación de Moléculas

4.3.2. Comparación Contra Algoritmos del Estado del Arte

4.3.3. Análisis Detallado de las Mejores Moléculas Candidatas

5

Conclusiones y Trabajo Futuro

Este capítulo contiene las conclusiones generales del desarrollo y los resultados obtenidos en esta tesina final de grado. Se repasan los principales hallazgos alcanzados, se presentan las dificultades y desafíos que surgieron a lo largo de la investigación, tanto a nivel metodológico como computacional y se plantean posibles líneas de trabajo futuro.

5.1. Conclusiones

En este trabajo se presentó la implementación de un enfoque híbrido, mediante el cual, a través de un modelo generativo y la aplicación de metaheurísticas multiobjetivo, se evaluó la generación y optimización dirigida de nuevos compuestos químicos para la inhibición de la proteína MRP1.

En relación con los objetivos específicos planteados al inicio de esta tesina (Sección 1.2), se destacan los siguientes logros y conclusiones:

- En primer lugar, se diseñó, entrenó y evaluó mediante *benchmarks* estandarizados un modelo generativo de tipo autoencoder variacional (VAE), logrando una alta tasa de validez química, novedad y diversidad en la reconstrucción y decodificación del espacio molecular.
- En segundo lugar, las metaheurísticas multiobjetivo demostraron ser eficaces para explorar el espacio latente continuo del modelo, resolviendo el compromiso entre múltiples métricas en conflicto y permitiendo encontrar moléculas candidatas con perfiles fisicoquímicos estables y potencial inhibitorio frente a MRP1.

En resumen, la integración propuesta valida que la combinación de modelos generativos continuos y metaheurísticas multiobjetivo constituye una herramienta computacional sólida para el diseño dirigido de moléculas, dando cumplimiento satisfactorio a los propósitos planteados para este trabajo de grado.

5.2. Dificultades Encontradas

Durante el desarrollo de esta tesina de grado surgió un conjunto de dificultades relevantes, relacionadas tanto al campo de estudio del proyecto como a las particularidades del contexto computacional que requirió la implementación. Algunas de estas son:

- En primer lugar, la naturaleza interdisciplinaria del proyecto representó una curva de aprendizaje exigente, siendo necesario adquirir conocimientos fundamentales del campo farmacológico para poder afrontar este trabajo. Aspectos que abarcan desde representaciones moleculares, métricas de acoplamiento molecular y de caracterización de compuestos, hasta nociones sobre el funcionamiento de las proteínas y su interacción con ligandos, fueron imprescindibles para abordar el problema y definir los objetivos a optimizar.
- En segundo lugar, la selección y formulación de los objetivos a optimizar se presentó como una dificultad importante. Caracterizar correctamente las moléculas candidatas exigió contemplar propiedades fisicoquímicas, métricas de acoplamiento y predictores de bioactividad para obtener candidatos viables.
- Por último, los requerimientos de cómputo representaron una dificultad importante, tanto para el entrenamiento de los modelos generativos como para la posterior optimización metaheurística. En particular, la necesidad de evaluar el acoplamiento de las moléculas generadas en cada iteración de los algoritmos supuso un cuello de botella temporal significativo. Frente a este desafío, la aceleración por GPU provista por el clúster TOKO de la UNCUYO fue fundamental para hacer viable la experimentación en tiempos de ejecución razonables.

Superar estas dificultades hizo posible la obtención de los resultados presentados y dejó aprendizajes metodológicos, los cuales dan pie a las distintas líneas de trabajo futuro que se detallan a continuación.

5.3. Trabajo Futuro

Los resultados y metodologías desarrolladas en esta tesina sientan las bases para diversas líneas de investigación a futuro:

- En primer lugar, se plantea la exploración de otras técnicas de representación molecular, en especial representaciones tridimensionales que permitan incorporar información geométrica de las moléculas directamente.
- En segundo lugar, se propone ampliar el conjunto de entrenamiento mediante la integración de librerías químicas de mayor escala y diversidad estructural, permitiendo al modelo aprender una distribución más amplia y representativa del espacio químico.

- Por último, se plantea la extensión de la metodología hacia otras dianas biológicas. El enfoque híbrido desarrollado en este trabajo no está restringido exclusivamente a MRP1, por lo que una línea prometedora consiste en aplicar este mismo esquema al diseño de candidatos dirigidos contra otras proteínas de relevancia terapéutica en el tratamiento del cáncer.

De este modo, las líneas propuestas abren un camino claro para continuar evolucionando esta metodología, ampliando su capacidad de exploración en el diseño computacional de nuevos compuestos.

5.4. Conclusiones Finales

Desde una perspectiva personal, el desarrollo de esta tesina final de grado representó una experiencia fructifera. Abordar un desafío interdisciplinario como el diseño de fármacos no solo demandó poner en práctica conceptos de las ciencias de la computación, sino también aplicarlos a un campo complejo, demostrando la capacidad de la disciplina para aportar soluciones a problemas de otras áreas.

Apéndices

A

Registro de Experimentos del Modelo VAE

En este apéndice se presentan los resultados detallados de todas las configuraciones evaluadas durante las etapas de exploración y optimización del modelo generativo VAE.

A.1. Exploración de Arquitecturas

En la Tabla A.1 se presentan los resultados de las 48 configuraciones evaluadas a 100 y 300 épocas de entrenamiento.

Tabla A.1: *Resultados Experimentales de Generación Molecular (100 y 300 Épocas)*

ID	Val ↑	Uni ↑	Nov ↑	Filter ↑	FCD ↓	IntDiv ↑	SA ↓	QED ↓	Tiempo
Modelos entrenados a 100 épocas									
SM-G 1 64	0.605	1.000	**0.998**	0.909	2.457	0.866	0.492	0.042	09:32:53
SM-G 1 128	0.833	1.000	0.992	0.944	1.397	0.860	0.325	0.027	02:34:12
SM-G 1 256	0.914	**1.000**	0.981	0.975	0.566	0.857	0.159	**0.013**	04:35:19
SM-G 2 64	0.748	1.000	0.995	0.949	1.592	0.862	0.377	0.032	04:46:52
SM-G 2 128	0.893	**1.000**	0.983	0.973	0.670	0.860	0.234	0.014	03:19:52
SM-G 2 256	**0.945**	1.000	0.969	0.982	0.470	0.859	**0.115**	0.005	08:19:48
SM-L 1 64	0.632	**1.000**	0.997	0.929	1.991	**0.866**	0.477	0.050	02:16:19
SM-L 1 128	0.829	**1.000**	0.990	0.957	1.208	0.863	0.336	0.021	02:50:02
SM-L 1 256	0.922	**1.000**	0.977	0.978	0.534	0.860	0.183	0.019	04:20:21
SM-L 2 64	0.816	**1.000**	0.989	0.964	0.983	0.864	0.308	0.033	02:41:42
SM-L 2 128	0.908	1.000	0.984	0.971	0.766	0.864	0.239	0.023	03:35:58
SM-L 2 256	0.943	1.000	0.962	**0.985**	**0.412**	0.859	0.141	0.013	08:05:22
SE-G 1 64	**1.000**	1.000	**1.000**	0.547	16.610	0.890	1.746	0.196	02:32:52
SE-G 1 128	**1.000**	1.000	0.997	0.692	9.008	0.881	1.176	0.103	02:36:18
SE-G 1 256	**1.000**	**1.000**	0.988	0.826	3.749	0.868	0.636	0.050	04:42:11

Continúa en la siguiente página...

Tabla A.1 – Continuación de la página anterior

ID	Val ↑	Uni ↑	Nov ↑	Filter ↑	FCD ↓	IntDiv ↑	SA ↓	QED ↓	Tiempo
SE-G 2 64	**1.000**	1.000	0.999	0.658	10.567	0.883	1.269	0.128	03:08:15
SE-G 2 128	**1.000**	**1.000**	0.991	0.808	3.889	0.870	0.668	0.069	03:27:05
SE-G 2 256	**1.000**	1.000	0.983	0.852	2.953	0.866	0.559	0.051	08:51:40
SE-L 1 64	**1.000**	0.998	0.999	0.590	12.148	**0.883**	1.386	0.177	02:10:52
SE-L 1 128	**1.000**	**1.000**	0.997	0.715	8.054	0.880	1.097	0.110	02:53:50
SE-L 1 256	**1.000**	**1.000**	0.988	0.831	3.454	0.872	0.628	0.062	04:15:32
SE-L 2 64	**1.000**	**1.000**	0.997	0.714	7.622	0.882	1.077	0.118	02:43:37
SE-L 2 128	**1.000**	**1.000**	0.989	0.823	3.646	0.872	0.650	0.066	03:32:51
SE-L 2 256	**1.000**	1.000	0.881	**0.928**	**0.764**	0.861	**0.201**	**0.020**	08:59:13
Modelos entrenados a 300 épocas									
SM-G 1 64	0.592	1.000	0.998	0.904	2.579	0.866	0.553	0.043	10:53:24
SM-G 1 128	0.813	**1.000**	0.993	0.949	1.419	0.864	0.373	0.019	10:44:32
SM-G 1 256	0.249	1.000	0.991	0.917	5.522	0.860	0.584	0.034	17:20:11
SM-G 2 64	0.762	**1.000**	0.994	0.943	1.442	0.862	0.355	0.027	12:47:02
SM-G 2 128	0.003	0.786	**1.000**	0.417	35.796	**0.905**	0.805	0.381	12:32:25
SM-G 2 256	0.788	1.000	0.984	0.968	1.048	0.860	0.205	0.012	26:10:15
SM-L 1 64	0.673	**1.000**	0.997	0.930	2.120	0.866	0.495	0.043	04:37:36
SM-L 1 128	0.854	**1.000**	0.989	0.964	1.056	0.862	0.305	0.016	04:48:36
SM-L 1 256	0.946	1.000	0.972	0.981	0.459	0.859	0.155	**0.011**	07:30:22
SM-L 2 64	0.783	**1.000**	0.994	0.949	1.514	0.867	0.411	0.036	06:58:03
SM-L 2 128	0.909	1.000	0.982	0.974	0.674	0.864	0.231	0.023	07:35:45
SM-L 2 256	**0.951**	1.000	0.956	**0.986**	**0.321**	0.858	**0.113**	0.013	10:19:52
SE-G 1 64	**1.000**	0.990	1.000	0.565	16.483	0.893	1.741	0.211	10:48:12
SE-G 1 128	**1.000**	0.780	**1.000**	0.543	36.486	0.908	1.890	0.545	06:51:58
SE-G 1 256	**1.000**	0.320	**1.000**	0.714	42.315	**0.970**	2.927	0.443	12:33:11
SE-G 2 64	**1.000**	1.000	0.998	0.718	8.378	0.879	1.109	0.108	08:24:36
SE-G 2 128	**1.000**	0.996	**1.000**	0.437	34.568	0.880	2.613	0.274	09:57:54
SE-G 2 256	**1.000**	**1.000**	0.989	0.807	4.431	0.873	0.749	0.057	14:03:36
SE-L 1 64	**1.000**	0.999	1.000	0.560	14.208	0.889	1.503	0.191	10:01:24
SE-L 1 128	**1.000**	1.000	0.996	0.732	6.897	0.877	1.011	0.093	05:08:21
SE-L 1 256	**1.000**	**1.000**	0.980	**0.874**	**2.170**	0.865	**0.453**	0.045	09:43:56
SE-L 2 64	**1.000**	1.000	0.998	0.708	8.368	0.881	1.093	0.126	09:26:53
SE-L 2 128	**1.000**	**1.000**	0.986	0.827	3.305	0.871	0.628	**0.056**	05:20:24
SE-L 2 256	**1.000**	0.997	0.999	0.497	15.008	0.893	1.562	0.197	10:57:46

A.2. Optimización de Hiperparámetros

En la Tabla A.2 se detallan los resultados obtenidos al variar la tasa de aprendizaje y el tamaño de lote para los cuatro modelos seleccionados.

Tabla A.2: *Resultados de Optimización de Hiperparámetros* (*Tasa de Aprendizaje y Tamaño de Lote*)

LR	Batch	Val ↑	Uni ↑	Nov ↑	Filter ↑	FCD ↓	IntDiv ↑	SA ↓	QED ↓	Tiempo
Modelo: SM-G 2 (100 épocas)										
1×10^{-3}	64	0.459	**1.000**	**0.991**	0.939	2.212	0.857	0.421	0.037	07:58:37
1×10^{-3}	128	0.945	1.000	0.969	0.982	0.470	**0.859**	0.115	**0.005**	08:19:48
1×10^{-3}	192	0.943	**1.000**	0.968	0.982	0.360	0.858	0.135	0.007	02:50:26
1×10^{-4}	64	**0.950**	1.000	0.966	**0.984**	**0.301**	0.858	**0.111**	0.006	08:10:05
1×10^{-4}	128	0.936	1.000	0.971	0.980	0.346	0.858	0.129	0.009	04:20:09
1×10^{-4}	192	0.938	1.000	0.972	0.977	0.418	**0.859**	0.159	0.006	02:53:20
Modelo: SE-L 2 (100 épocas)										
1×10^{-3}	64	**1.000**	1.000	0.966	0.815	3.642	0.871	0.600	0.063	06:34:09
1×10^{-3}	128	**1.000**	1.000	0.881	0.928	0.764	0.861	0.201	0.020	08:59:13
1×10^{-3}	192	**1.000**	0.999	0.868	**0.936**	**0.675**	0.861	**0.185**	**0.018**	02:26:16
1×10^{-4}	64	**1.000**	**1.000**	0.976	0.886	1.791	0.866	0.426	0.037	07:51:36
1×10^{-4}	128	**1.000**	**1.000**	0.981	0.873	2.079	0.867	0.478	0.042	03:29:25
1×10^{-4}	192	**1.000**	**1.000**	**0.988**	0.846	2.893	**0.871**	0.576	0.055	02:26:25
Modelo: SM-L 1 (300 épocas)										
1×10^{-3}	64	0.942	**1.000**	0.970	**0.982**	0.449	0.860	0.160	0.016	15:43:28
1×10^{-3}	128	**0.946**	1.000	0.971	0.981	0.459	0.859	**0.155**	**0.011**	07:30:22
1×10^{-3}	192	0.921	**1.000**	0.978	0.978	0.604	0.863	0.242	0.017	05:52:49
1×10^{-4}	64	0.940	**1.000**	0.973	0.980	**0.424**	0.859	0.159	0.013	19:07:21
1×10^{-4}	128	0.905	1.000	**0.983**	0.974	0.729	**0.863**	0.267	0.022	09:12:05
1×10^{-4}	192	0.906	**1.000**	0.982	0.976	0.639	0.862	0.234	0.021	05:03:35
Modelo: SM-L 2 (300 épocas)										
1×10^{-3}	64	0.957	1.000	0.956	0.987	0.294	0.857	0.114	0.015	19:53:13
1×10^{-3}	128	0.951	**1.000**	0.956	0.986	0.321	0.858	0.113	0.013	10:19:52
1×10^{-3}	192	0.957	1.000	0.953	0.986	0.282	0.859	0.117	0.010	07:15:25
1×10^{-4}	64	**0.962**	1.000	0.943	**0.988**	**0.179**	0.859	**0.093**	0.008	23:25:24
1×10^{-4}	128	0.960	1.000	0.950	0.988	0.228	**0.859**	0.102	**0.007**	13:45:28
1×10^{-4}	192	0.957	**1.000**	**0.957**	0.986	0.257	0.859	0.125	0.011	08:54:27

B

Análisis Estadístico y Resultados Complementarios de las Metaheurísticas

En este apéndice se presentan las configuraciones seleccionadas del ajuste de hiperparámetros, los contrastes estadísticos detallados correspondientes a las comparaciones por pares de operadores de cruce y mutación evaluados en la Sección 4.2.2, así como los frentes no dominados desagregados por frecuencia de aparición entre semillas y las estructuras químicas obtenidas.

B.1. Configuraciones Seleccionadas del Ajuste de Hiperparámetros

A partir de la exploración de hiperparámetros definida en la Sección 3.3.2.3, la Tabla B.1 presenta las configuraciones seleccionadas para cada algoritmo y combinación de operadores, determinadas por el menor rango medio de hipervolumen a lo largo de las 20 semillas independientes.

Tabla B.1: *Configuraciones seleccionadas: mejor configuración para cada combinación de operadores en los algoritmos genéticos y mejor configuración global en CMOPSO, determinadas por el menor rango medio de hipervolumen a lo largo de las 20 semillas independientes.*

Algoritmo	Operadores	Configuración	Rango medio	$\mu \pm \sigma$
NSGA-II	pcx/pm	200×500 cx=1 mut=0.012	5.20	1.1250 ± 0.0039
	pcx/gauss	100×1000 cx=1 mut=0.012	5.55	1.1258 ± 0.0046
	sbx/pm	100×1000 cx=0.9 mut=0.031	9.35	1.1137 ± 0.0016
	sbx/gauss	100×1000 cx=0.7 mut=0.031	6.70	1.1158 ± 0.0029
NSGA-III	pcx/pm	100×1000 cx=1 mut=0.004	8.65	1.1214 ± 0.0032
	pcx/gauss	100×1000 cx=1 mut=0.012	9.35	1.1213 ± 0.0036
	sbx/pm	400×250 cx=1 mut=0.031	7.00	1.1151 ± 0.0022
	sbx/gauss	100×1000 cx=0.9 mut=0.031	7.65	1.1163 ± 0.0029
MOEA/D	pcx/pm	200×500 cx=0.9 mut=0.031	7.20	1.1128 ± 0.0039
	pcx/gauss	200×500 cx=1 mut=0.031	7.70	1.1138 ± 0.0033
	sbx/pm	400×250 cx=1 mut=0.031	7.60	1.1073 ± 0.0050
	sbx/gauss	200×500 cx=1 mut=0.031	8.25	1.1079 ± 0.0055
AGE-MOEA	pcx/pm	400×250 cx=1 mut=0.004	6.35	1.1208 ± 0.0028
	pcx/gauss	100×1000 cx=1 mut=0.031	6.25	1.1216 ± 0.0037
	sbx/pm	400×250 cx=1 mut=0.031	6.30	1.1132 ± 0.0024
	sbx/gauss	200×500 cx=0.9 mut=0.031	6.75	1.1137 ± 0.0031
CMOPSO	-	100×1000 elite=10 mut=0.031 vel=0.1	26.00	1.1092 ± 0.0037

B.2. Comparaciones Estadísticas por Pares (Test de Wilcoxon)

Para cada metaheurística basada en operadores genéticos (AGE-MOEA, MOEA/D, NSGA-II y NSGA-III), se evaluó la significancia estadística sobre el hipervolumen a lo largo de las 20 semillas independientes mediante la prueba de rangos con signo de Wilcoxon con corrección de Holm para comparaciones múltiples ($\alpha = 0.05$). En cada par se reporta el valor p ajustado, el estimador del tamaño del efecto mediante la correlación rango-biserial (r_{rb}) y el operador dominante.

Tabla B.2: *Comparación de operadores en AGE-MOEA sobre hipervolumen. Grupos homogéneos: {pcx_pm, pcx_gauss} > {sbx_gauss, sbx_pm}.*

Par	p (Holm)	r_{rb}	Mejor
pcx_pm vs pcx_gauss	0.818	−0.219	-
pcx_pm vs sbx_pm	<0.001	+0.971	pcx_pm
pcx_pm vs sbx_gauss	<0.001	+0.962	pcx_pm
pcx_gauss vs sbx_pm	<0.001	+1.000	pcx_gauss
pcx_gauss vs sbx_gauss	<0.001	+1.000	pcx_gauss
sbx_pm vs sbx_gauss	0.818	−0.190	-

Tabla B.3: *Comparación de operadores en MOEA/D sobre hipervolumen. Grupos homogéneos: {pcx_gauss, pcx_pm} > {sbx_gauss, sbx_pm}.*

Par	p (Holm)	r_{rb}	Mejor
pcx_pm vs pcx_gauss	0.624	−0.200	-
pcx_pm vs sbx_pm	<0.001	+0.933	pcx_pm
pcx_pm vs sbx_gauss	0.011	+0.714	pcx_pm
pcx_gauss vs sbx_pm	<0.001	+0.886	pcx_gauss
pcx_gauss vs sbx_gauss	0.001	+0.848	pcx_gauss
sbx_pm vs sbx_gauss	0.624	−0.267	-

Tabla B.4: *Comparación de operadores en NSGA-II sobre hipervolumen. Grupos homogéneos: {pcx_gauss, pcx_pm} > {sbx_gauss} > {sbx_pm}.*

Par	p (Holm)	r_{rb}	Mejor
pcx_pm vs pcx_gauss	0.388	−0.229	-
pcx_pm vs sbx_pm	<0.001	+1.000	pcx_pm
pcx_pm vs sbx_gauss	<0.001	+1.000	pcx_pm
pcx_gauss vs sbx_pm	<0.001	+1.000	pcx_gauss
pcx_gauss vs sbx_gauss	<0.001	+0.981	pcx_gauss
sbx_pm vs sbx_gauss	0.002	−0.800	sbx_gauss

Tabla B.5: *Comparación de operadores en NSGA-III sobre hipervolumen. Grupos homogéneos: {pcx_pm, pcx_gauss} > {sbx_gauss, sbx_pm}.*

Par	p (Holm)	r_{rb}	Mejor
pcx_pm vs pcx_gauss	0.729	+0.095	-
pcx_pm vs sbx_pm	<0.001	+0.971	pcx_pm
pcx_pm vs sbx_gauss	<0.001	+0.914	pcx_pm
pcx_gauss vs sbx_pm	<0.001	+1.000	pcx_gauss
pcx_gauss vs sbx_gauss	<0.001	+0.943	pcx_gauss
sbx_pm vs sbx_gauss	0.286	−0.381	-

B.3. Frentes no Dominados por Frecuencia de Ejecución

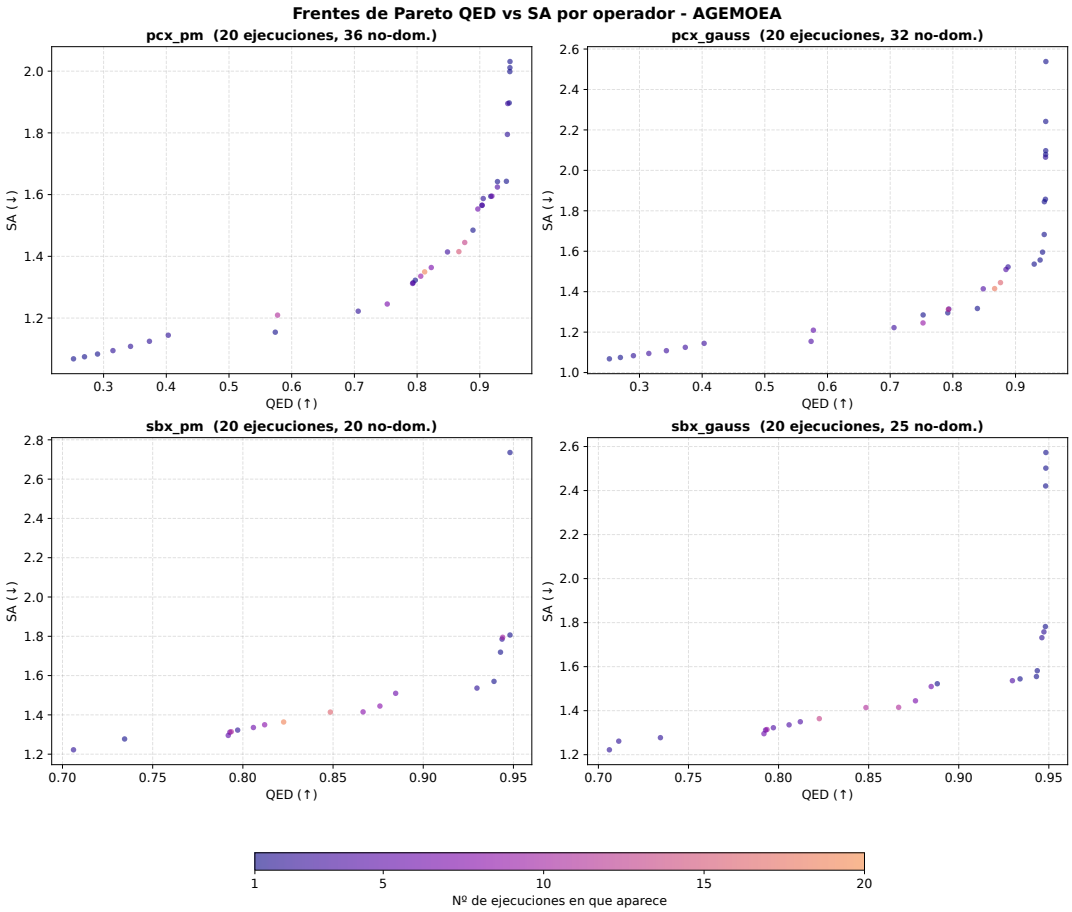


Figura B.1: *Frentes no dominados acumulados sobre las veinte semillas en el espacio QED–SA para cada combinación de operadores en AGE-MOEA, coloreados por el número de semillas en que apareció cada molécula.*

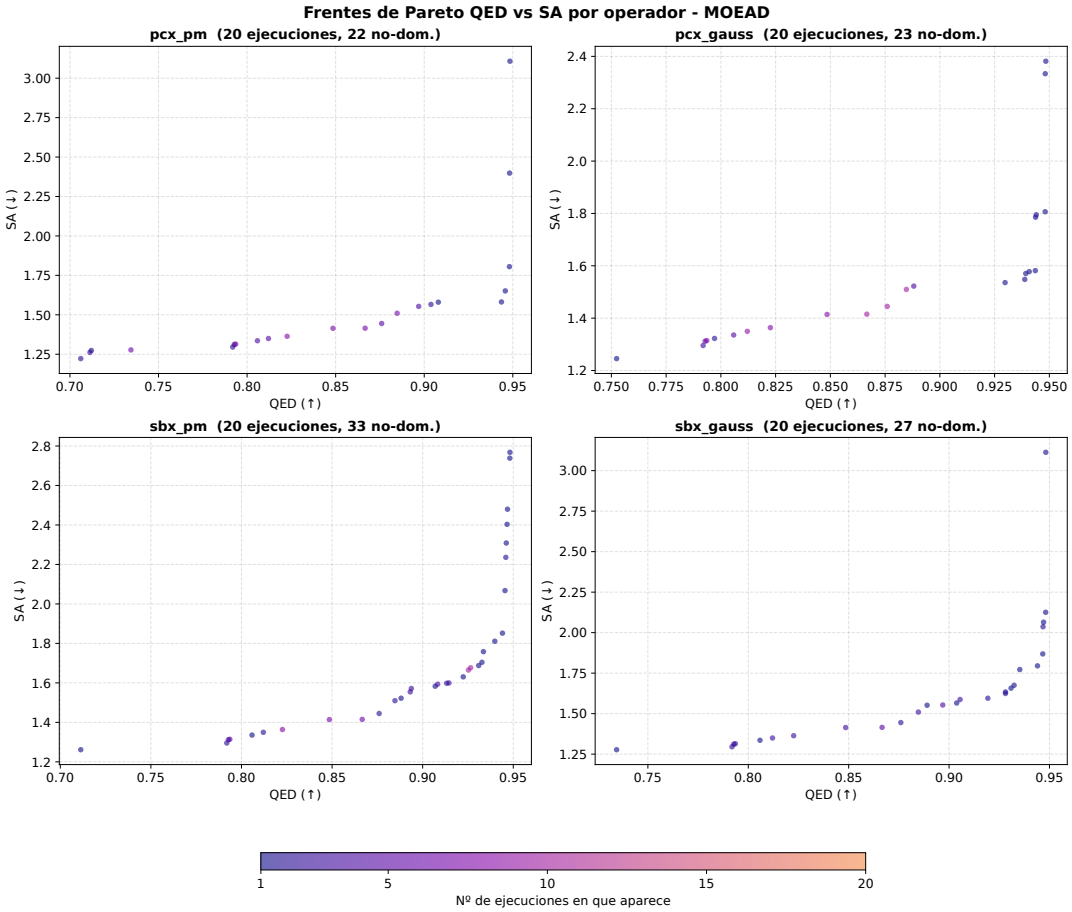


Figura B.2: *Frentes no dominados acumulados sobre las veinte semillas en el espacio QED–SA para cada combinación de operadores en MOEA/D, coloreados por el número de semillas en que apareció cada molécula.*

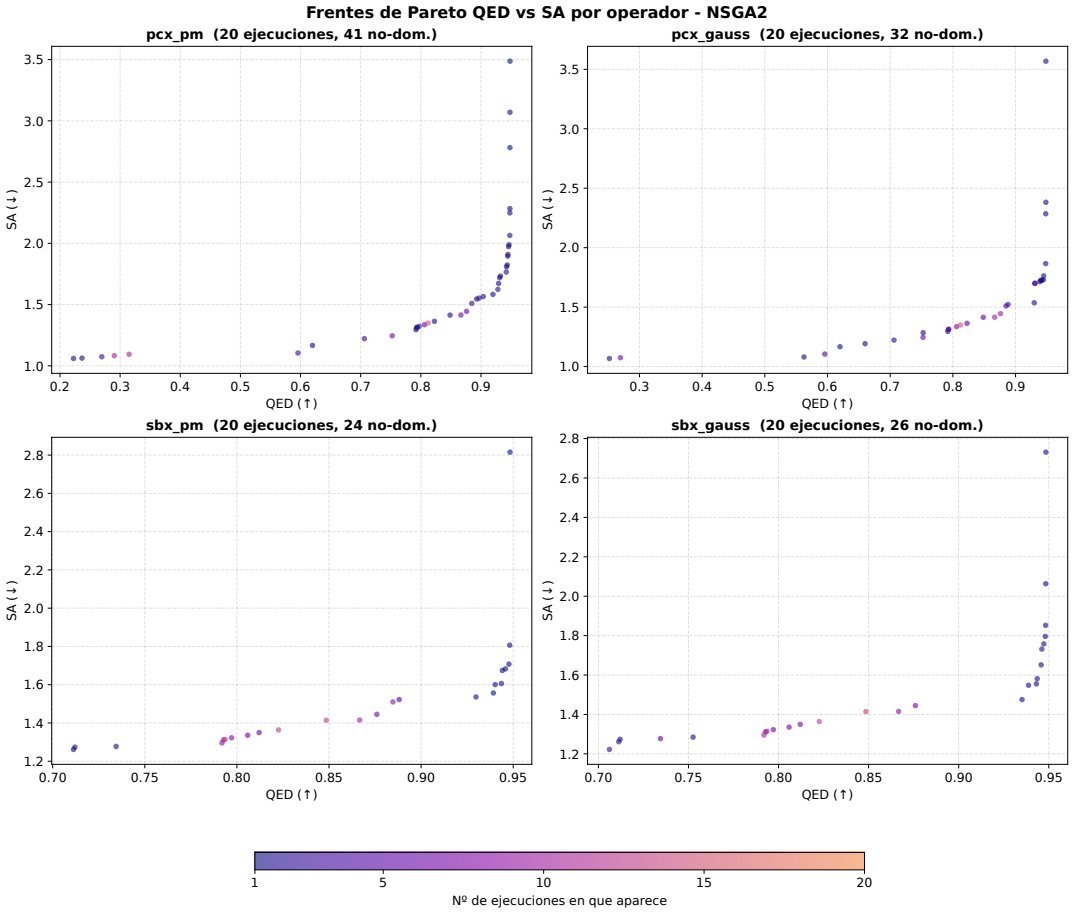


Figura B.3: *Frentes no dominados acumulados sobre las veinte semillas en el espacio QED–SA para cada combinación de operadores en NSGA-II, coloreados por el número de semillas en que apareció cada molécula.*

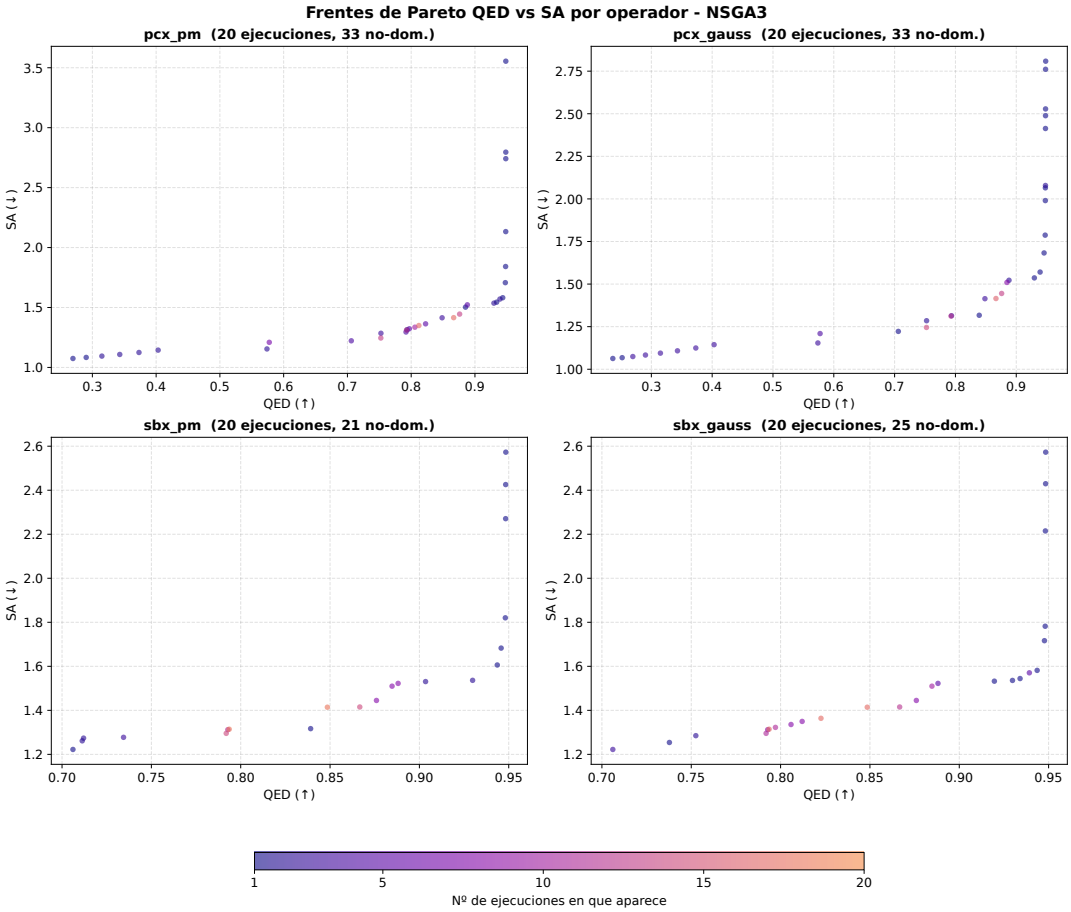


Figura B.4: *Frentes no dominados acumulados sobre las veinte semillas en el espacio QED–SA para cada combinación de operadores en NSGA-III, coloreados por el número de semillas en que apareció cada molécula.*

B.4. Estructuras Químicas Obtenidas por Combinación de Operadores

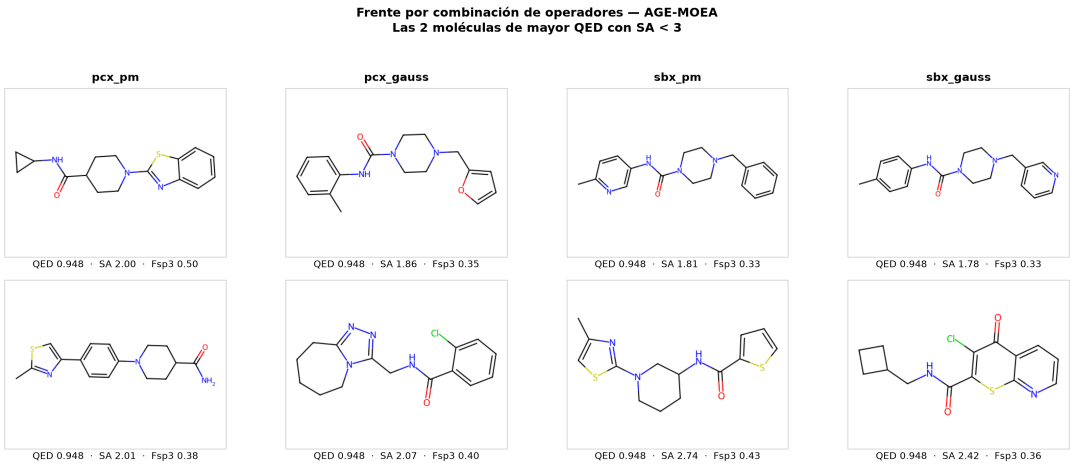


Figura B.5: *Moléculas de mayor QED con SA < 3 seleccionadas del frente no dominado acumulado para cada combinación de operadores en AGE-MOEA.*

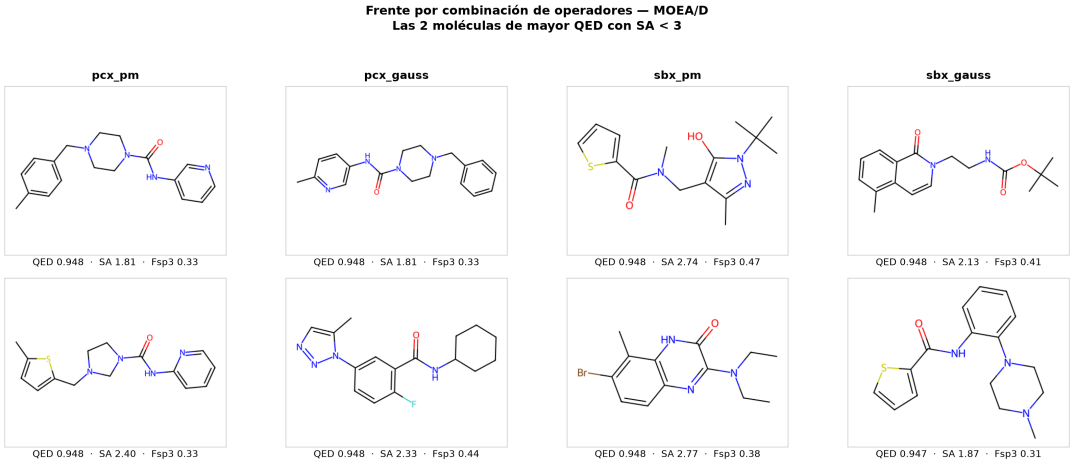


Figura B.6: *Moléculas de mayor QED con SA < 3 seleccionadas del frente no dominado acumulado para cada combinación de operadores en MOEA/D.*

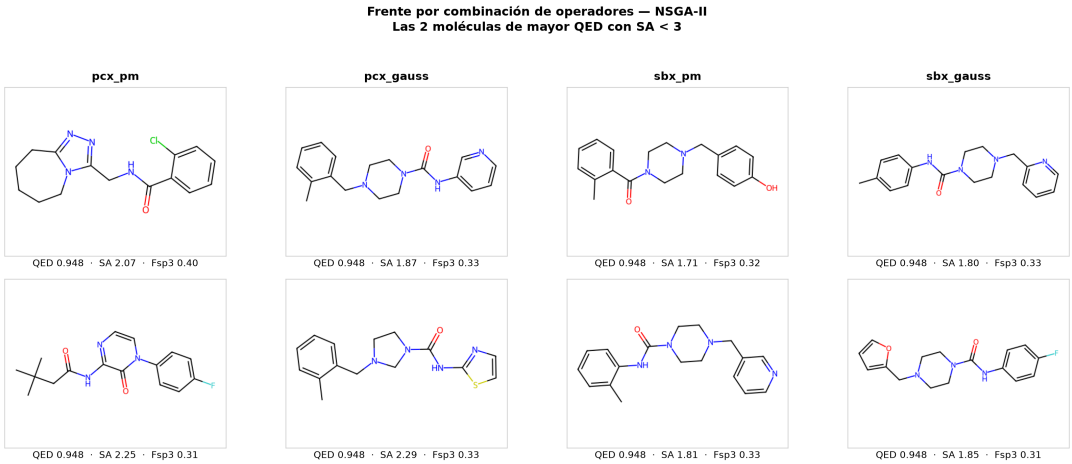


Figura B.7: *Moléculas de mayor QED con SA < 3 seleccionadas del frente no dominado acumulado para cada combinación de operadores en NSGA-II.*

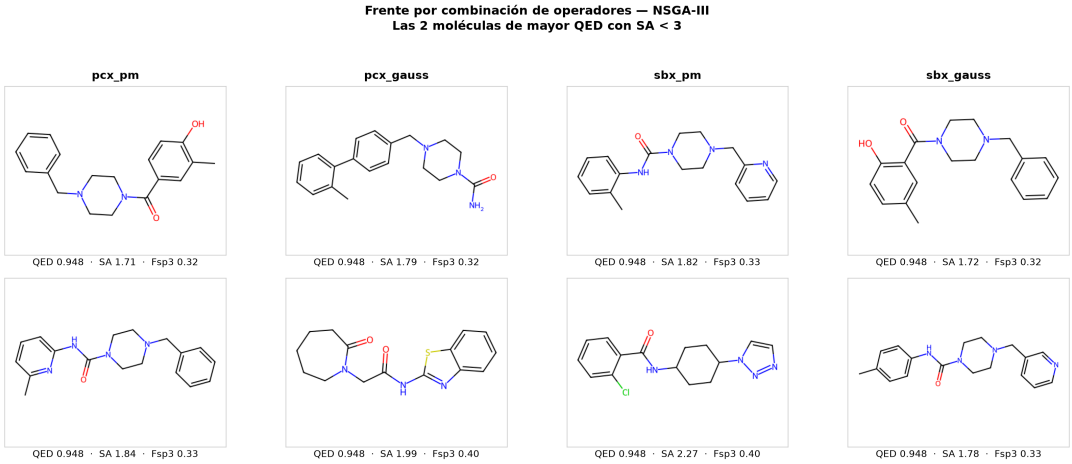


Figura B.8: *Moléculas de mayor QED con SA < 3 seleccionadas del frente no dominado acumulado para cada combinación de operadores en NSGA-III.*

B.5. Moléculas de Mayor QED por Algoritmo (Catálogo Completo)

En la Tabla B.6 se detallan las cinco moléculas de mayor QED obtenidas a partir del frente no dominado acumulado de cada algoritmo que satisfacen el filtro de accesibilidad sintética ($\mathrm{SA} < 3$) y la restricción de tridimensionalidad ($F_{\mathrm{sp3}} \geq 0.30$).

Tabla B.6: *Las cinco moléculas con mayor QED del frente de Pareto de cada algoritmo que satisfacen el filtro de accesibilidad ($SA < 3$) y la restricción de tridimensionalidad ($F_{sp3} \geq 0.30$).*

Algoritmo	Puesto	QED ↑	SA ↓	F_{sp3}	SMILES
NSGA-II	1	0.948	2.730	0.333	`Cn1cc(NC(=O)C2CCCO2)c(-c2ccccc2Cl)n1`
	2	0.948	2.060	0.357	`O=C(Nc1nnc(Cc2ccc(F)cc2)s1)N1CCCC1`
	3	0.948	1.850	0.312	`O=C(Nc1ccc(F)cc1)N1CCN(Cc2ccco2)CC1`
	4	0.948	1.800	0.333	`Cc1ccc(NC(=O)N2CCN(Cc3ccccn3)CC2)cc1`
	5	0.947	1.760	0.368	`O=C(NCC(=O)N1CCCCCC1)c1ccc2ccccc2c1`
NSGA-III	1	0.948	2.800	0.333	`Cn1nc(NC(=O)C2CCCO2)cc1-c1ccccc1Cl`
	2	0.948	2.740	0.308	`Nc1cc(Br)n(COc2ccc3c(c2)CCC3)n1`
	3	0.948	2.570	0.333	`O=C(NC1(c2nccs2)CCOCC1)c1ccccc1F`
	4	0.948	2.130	0.357	`O=C(Nc1nnc(Cc2ccccc2F)s1)N1CCCC1`
	5	0.948	1.820	0.333	`Cc1ccccc1NC(=O)N1CCN(Cc2ccccn2)CC1`
MOEA/D	1	0.948	2.400	0.333	`Cc1ccc(CN2CCN(C(=O)Nc3ccccn3)C2)s1`
	2	0.948	1.810	0.333	`Cc1ccc(CN2CCN(C(=O)Nc3cccnc3)CC2)cc1`
	3	0.946	1.650	0.316	`Cc1ccc(N2CCN(C(=O)NCc3ccccc3)CC2)cc1`
	4	0.944	1.580	0.316	`Cc1ccc(NC(=O)N2CCN(Cc3ccccc3)CC2)cc1`
	5	0.908	1.580	0.467	`CCC(=O)Nc1ccc(C(=O)N2CCCCC2)cc1`
AGE-MOEA	1	0.948	2.030	0.375	`O=C(c1csc(-c2cccc(CO)c2)n1)N1CCCCC1`
	2	0.948	1.810	0.333	`Cc1ccc(NC(=O)N2CCN(Cc3ccccc3)CC2)cn1`
	3	0.944	1.800	0.312	`O=C(Nc1ccc(CN2CCOCC2)cc1)c1cccs1`
	4	0.944	1.790	0.300	`O=C(Nc1ccc(C(=O)N2CCc3ccccc3C2)cc1)C1CC1`
	5	0.943	1.720	0.333	`O=C(NCc1ccc(N2CCCCC2)nc1)c1ccccc1`
CMOPSO	1	0.948	2.570	0.333	`O=C(NC1(c2nccs2)CCOCC1)c1ccccc1F`
	2	0.948	2.500	0.333	`O=C(c1cc[nH]n1)N1CCC(Oc2ccccc2Cl)CC1`
	3	0.948	2.060	0.333	`O=C(NC1CCN(c2nccs2)CC1)c1ccccc1F`
	4	0.946	1.900	0.389	`O=C(Nc1ccc2c(N3CCOCC3)cccc2c1)C1CC1`
	5	0.944	1.850	0.312	`O=C(Nc1cccc(CN2CCOCC2)c1)c1cccs1`

Anexos

L

Showcasing the First Annex

Writing Guidance

Annexes are supplementary sections in a dissertation that provide additional information or external documents not essential to the main arguments but that support or complement the research. Unlike appendices, **annexes generally contain material that was not developed by the author**, such as reports, legal documents, or published datasets from external sources. This information is placed separately to keep the main content concise, allowing readers access to relevant external references without disrupting the dissertation's flow.

Bibliografía

[1] American Cancer Society. *Breve historia del cáncer*. https://www.cancer.org/es/cancer/entendimiento-del-cancer/historia-del-cancer.html. Accedido: 2026. 2026.

[2] Hyuna Sung et al. «Global cancer statistics 2024: GLOBOCAN estimates of incidence and mortality worldwide for 34 cancers in 186 countries». En: *CA: A Cancer Journal for Clinicians* 76.4 (2026), e70090. DOI: 10.3322/caac.70090.

[3] Jose J. G. Marin et al. «Expression of Chemoresistance-Associated ABC Proteins in Hepatobiliary, Pancreatic and Gastrointestinal Cancers». En: *Cancers* 14.14 (2022), pág. 3524. DOI: 10.3390/cancers14143524.

[4] Emne Ali Abdallah et al. «MRP1 expression in CTCs confers resistance to irinotecan-based chemotherapy in metastatic colorectal cancer». En: *International Journal of Cancer* 139.4 (2016), págs. 890-898. DOI: 10.1002/ijc.30082.

[5] Fang-fang Qi et al. «Long non-coding RNAs: Key regulators in oxaliplatin resistance of colorectal cancer». En: *Biomedicine & Pharmacotherapy* 128 (2020), pág. 110329. DOI: 10.1016/j.biopha.2020.110329.

[6] Dongxing Cao et al. «The role of MRP1 in the multidrug resistance of colorectal cancer». En: *Oncology Letters* 13.4 (2017), págs. 2471-2476. ISSN: 1792-1074. DOI: 10.3892/ol.2017.5741.

[7] Uddalak Das. «Generative AI for drug discovery and protein design: the next frontier in AI-driven molecular science». En: *Medicine in Drug Discovery* 27 (2025), pág. 100213. DOI: 10.1016/j.medidd.2025.100213.

[8] Sohvi Luukkonen et al. «Artificial intelligence in multi-objective drug design». En: *Current Opinion in Structural Biology* 79 (2023), pág. 102537. DOI: 10.1016/j.sbi.2023.102537.

[9] Zijian Zhang et al. «Molecular Knowledge Representations in the Era of Artificial Intelligence». En: *ChemRxiv* (2026). DOI: 10.26434/chemrxiv.15002830/v1.

[10] El-Ghazali Talbi. *Metaheuristics: From Design to Implementation*. 1.ª ed. Hoboken, New Jersey: John Wiley & Sons, 2009. ISBN: 978-0-470-27858-1. DOI: 10.1002/9780470496916. URL: https://onlinelibrary.wiley.com/doi/book/10.1002/9780470496916.

[11] J. P. Hughes et al. «Principles of early drug discovery». En: *British Journal of Pharmacology* 162.6 (2011), págs. 1239-1249. DOI: 10.1111/j.1476-5381.2010.01127.x.

[12] Shujun Zhang et al. «The role and application of bioinformatics techniques and tools in drug discovery». En: *Frontiers in Pharmacology* 16 (2025), pág. 1547131. DOI: 10.3389/fphar.2025.1547131.

[13] Pooja A. Chawla et al., eds. *Computational Drug Discovery: Molecular Simulation for Medicinal Chemistry*. De Gruyter, 2024. ISBN: 978-3-11-120711-7. DOI: 10.1515/9783111207117.

[14] Grazyna Biala et al. «Research in the Field of Drug Design and Development». En: *Pharmaceuticals* 16.9 (2023), pág. 1283. DOI: 10.3390/ph16091283.

[15] Stephani Joy Y. Macalino et al. «Role of computer-aided drug design in modern drug discovery». En: *Archives of Pharmacal Research* 38.9 (2015), págs. 1686-1701. DOI: 10.1007/s12272-015-0640-5.

[16] John Jumper et al. «Highly accurate protein structure prediction with AlphaFold». En: *Nature* 596.7873 (2021), págs. 583-589. DOI: 10.1038/s41586-021-03819-2.

[17] David Weininger. «SMILES, a chemical language and information system. 1. Introduction to methodology and encoding rules». En: *Journal of Chemical Information and Computer Sciences* 28.1 (1988), págs. 31-36. DOI: 10.1021/ci00057a005.

[18] Evan E Bolton et al. «PubChem: Integrated Platform of Small Molecules and Biological Activities». En: *Annual Reports in Computational Chemistry* 4 (2008), págs. 217-241. DOI: 10.1016/S1574-1400(08)00012-1.

[19] David Mendez et al. «ChEMBL: towards direct deposition of bioassay data». En: *Nucleic Acids Research* 47.D1 (2019), págs. D930-D940. DOI: 10.1093/nar/gky1075.

[20] John J Irwin et al. «ZINC20—a free ultralarge-scale chemical database for ligand discovery». En: *Journal of Chemical Information and Modeling* 60.12 (2020), págs. 6065-6073. DOI: 10.1021/acs.jcim.0c00675.

[21] Weiya Kong et al. «Application of SMILES-based molecular generative model in new drug design». En: *Frontiers in Pharmacology* 13 (2022), pág. 1046524. DOI: 10.3389/fphar.2022.1046524.

[22] Marwin H. S. Segler et al. «Generating focused molecule libraries for drug discovery with recurrent neural networks». En: *ACS Central Science* 4.1 (2018), págs. 120-131. DOI: 10.1021/acscentsci.7b00512.

[23] Marcus Olivecrona et al. «Molecular de-novo design through deep reinforcement learning». En: *Journal of Cheminformatics* 9 (2017), pág. 48. DOI: 10.1186/s13321-017-0235-x.

[24] Mario Krenn et al. «SELFIES: a robust representation of semantically constrained graphs with an example application in chemistry». En: *Machine Learning: Science and Technology* 1.4 (2020), pág. 045024. DOI: 10.1088/2632-2153/aba947.

[25] Christopher A. Lipinski et al. «Experimental and computational approaches to estimate solubility and permeability in drug discovery and development settings». En: *Advanced Drug Delivery Reviews* 23.1–3 (1997), págs. 3-25. DOI: 10.1016/S0169-409X(96)00423-1.

[26] G. Richard Bickerton et al. «Quantifying the chemical beauty of drugs». En: *Nature Chemistry* 4.2 (2012), págs. 90-98. DOI: 10.1038/nchem.1243.

[27] Yuhang Xia et al. «A comprehensive review of molecular optimization in artificial intelligence-based drug discovery». En: *Quantitative Biology* 12.1 (2024), págs. 15-29. DOI: 10.1002/qub2.30.

[28] Peter Ertl et al. «Estimation of synthetic accessibility score of drug-like molecules based on molecular complexity and fragment contributions». En: *Journal of Cheminformatics* 1 (2009), pág. 8. DOI: 10.1186/1758-2946-1-8.

[29] Frank Lovering et al. «Escape from Flatland: Increasing Saturation as an Approach to Improving Clinical Success». En: *Journal of Medicinal Chemistry* 52.21 (2009), págs. 6752-6756. DOI: 10.1021/jm901241e.

[30] Frank Lovering. «Escape from Flatland 2: complexity and promiscuity». En: *MedChemComm* 4.3 (2013), págs. 515-519. DOI: 10.1039/C2MD20347B.

[31] Nataraj S. Pagadala et al. «Software for molecular docking: a review». En: *Biophysical Reviews* 9.2 (2017), págs. 91-102. DOI: 10.1007/s12551-016-0247-1. URL: https://doi.org/10.1007/s12551-016-0247-1.

[32] Oleg Trott et al. «AutoDock Vina: Improving the speed and accuracy of docking with a new scoring function, efficient optimization, and multithreading». En: *Journal of Computational Chemistry* 31.2 (2010), págs. 455-461. DOI: 10.1002/jcc.21334.

[33] Yuejiang Yu et al. «Uni-Dock: GPU-accelerated docking enables ultralarge virtual screening». En: *Journal of Chemical Theory and Computation* 19.11 (2023), págs. 3336-3345. DOI: 10.1021/acs.jctc.2c01145. URL: https://doi.org/10.1021/acs.jctc.2c01145.

[34] Diederik P. Kingma et al. «Auto-Encoding Variational Bayes». En: *arXiv preprint arXiv:1312.6114* (2013).

[35] Christopher M. Bishop et al. *Deep Learning: Foundations and Concepts*. Cham, Switzerland: Springer, 2024. DOI: 10.1007/978-3-031-45468-4.

[36] Joseph Taewoo Kim. *Exploring Effectiveness of Multimodal Variational Autoencoders on Text-Image Tasks*. Inf. téc. Stanford University, 2024. URL: https://github.com/josephtkim/Multimodal-VAE.

[37] Rafael Gómez-Bombarelli et al. «Automatic Chemical Design Using a Data-Driven Continuous Representation of Molecules». En: *ACS Central Science* 4.2 (2018), págs. 268-276.

DOI: 10.1021/acscentsci.7b00572. URL: https://doi.org/10.1021/acscentsci.7b00572.

[38] K. Deb et al. «A fast and elitist multiobjective genetic algorithm: NSGA-II». En: *IEEE Transactions on Evolutionary Computation* 6.2 (2002), págs. 182-197. DOI: 10.1109/4235.996017. URL: http://ieeexplore.ieee.org/document/996017/.

[39] Susan P. C. Cole. «Targeting Multidrug Resistance Protein 1 (MRP1, ABCC1): Past, Present, and Future». En: *Annual Review of Pharmacology and Toxicology* 54.1 (2014), págs. 95-117. ISSN: 0362-1642. DOI: 10.1146/annurev-pharmtox-011613-135959.

[40] Jamie F. Lu et al. «MRP1 and its role in anticancer drug resistance». En: *Drug Metabolism Reviews* 47.4 (2015), págs. 406-419. ISSN: 0360-2532. DOI: 10.3109/03602532.2015.1105253.

[41] Zachary Lee Johnson et al. «Structural Basis of Substrate Recognition by the Multidrug Resistance Protein MRP1». En: *Cell* 168.6 (2017), págs. 1075-1085. ISSN: 0092-8674. DOI: 10.1016/j.cell.2017.01.041.

[42] Sven Marcel Stefan et al. «Small-molecule inhibitors of multidrug resistance-associated protein 1 and related processes: A historic approach and recent advances». En: *Medicinal Research Reviews* 39 (2019), págs. 176-264. DOI: 10.1002/med.21510.

[43] Kanin Rungsardthong et al. «Virtual screening of ABCC1 transporter nucleotide-binding domains as a therapeutic target in multidrug resistant cancer». En: *Bioinformation* 8.19 (2012), págs. 907-911. DOI: 10.6026/97320630008907.

[44] Divya Dhasmana et al. «Targeting Nucleotide Binding Domain of Multidrug Resistance-associated Protein-1 (MRP1) for the Reversal of Multi Drug Resistance in Cancer». En: *Scientific Reports* 8 (2018), pág. 11973. DOI: 10.1038/s41598-018-30420-x.

[45] Zakia Belhadj et al. «Characterization of a deazaflavin analog as a potent inhibitor of multidrug resistance-associated protein 1». En: *Biomedicine & Pharmacotherapy* 178 (2024), pág. 117167. DOI: 10.1016/j.biopha.2024.117167.

[46] Nicola De Cao et al. *MolGAN: An implicit generative model for small molecular graphs*. Mayo de 2018. DOI: 10.48550/arXiv.1805.11973. URL: http://arxiv.org/abs/1805.11973.

[47] Tianfan Fu et al. «MOLER: Incorporate Molecule-Level Reward to Enhance Deep Generative Model for Molecule Optimization». en. En: *IEEE Transactions on Knowledge and Data Engineering* 34.11 (nov. de 2022), págs. 5459-5471. ISSN: 1041-4347, 1558-2191, 2326-3865. DOI: 10.1109/TKDE.2021.3052150. URL: https://ieeexplore.ieee.org/document/9330796/.

[48] Yuanqi Du et al. «Small molecule generation via disentangled representation learning». En: *Bioinformatics* 38.12 (jun. de 2022), págs. 3200-3208. ISSN: 1367-4803.

DOI: 10.1093/bioinformatics/btac296. URL: https://doi.org/10.1093/bioinformatics/btac296.

[49] Xiangzhe Kong et al. *Molecule Generation by Principal Subgraph Mining and Assembling*. 2022. URL: https://arxiv.org/abs/2106.15098.

[50] Arun Singh Bhadwal et al. «PCF-VAE: posterior collapse free variational autoencoder for de novo drug design». en. En: *Scientific Reports* 15.1 (oct. de 2025), pág. 34152. ISSN: 2045-2322. DOI: 10.1038/s41598-025-14285-5. URL: https://www.nature.com/articles/s41598-025-14285-5.

[51] Tensei Inukai et al. «Leveraging tree-transformer VAE with fragment tokenization for high-performance large chemical model generation». en. En: *Communications Chemistry* 8.1 (ago. de 2025), pág. 228. ISSN: 2399-3669. DOI: 10.1038/s42004-025-01640-w. URL: https://www.nature.com/articles/s42004-025-01640-w.

[52] Davide Rigoni et al. «RGCVAE: relational graph conditioned variational autoencoder for molecule design». en. En: *Machine Learning* 114.2 (ene. de 2025), pág. 47. ISSN: 1573-0565. DOI: 10.1007/s10994-024-06638-4. URL: https://doi.org/10.1007/s10994-024-06638-4.

[53] Robin Winter et al. «Efficient multi-objective molecular optimization in a continuous latent space». En: *Chemical Science* 10 (2019), págs. 8016-8024. DOI: 10.1039/c9sc01928f. URL: https://doi.org/10.1039/c9sc01928f.

[54] Sheriff Abouchekeir et al. «Adversarial deep evolutionary learning for drug design». En: *BioSystems* 222 (2022), pág. 104790. DOI: 10.1016/j.biosystems.2022.104790.

[55] Siddartha Reddy N et al. «Leveraging Latent Evolutionary Optimization for Targeted Molecule Generation». En: *2024 IEEE Congress on Evolutionary Computation (CEC)*. arXiv:2407.13779. 2024.

[56] Nicholas Aksamit et al. «Integrating transformers and many-objective optimization for drug design». En: *BMC Bioinformatics* 25.1 (2024), pág. 208. DOI: 10.1186/s12859-024-05822-6. URL: https://doi.org/10.1186/s12859-024-05822-6.

[57] Xin Xia et al. «Evolutionary Multiobjective Molecule Optimization in an Implicit Chemical Space». En: *Journal of Chemical Information and Modeling* 64 (2024), págs. 5161-5174. DOI: 10.1021/acs.jcim.4c00031. URL: https://doi.org/10.1021/acs.jcim.4c00031.

[58] AN M Nafiz Abeer et al. «Multi-Objective Latent Space Optimization of Generative Molecular Design Models». En: *arXiv preprint arXiv:2203.00526v3* (2024). URL: https://arxiv.org/abs/2203.00526v3.

[59] Armen G. Beck et al. «Paddy: an evolutionary optimization algorithm for chemical systems and spaces». En: *Digital Discovery* 4 (2025), págs. 1352-1371. DOI: 10.1039/d4dd00226a. URL: https://doi.org/10.1039/d4dd00226a.

[60] Daniil Polykovskiy et al. «Molecular Sets (MOSES): A Benchmarking Platform for Molecular Generation Models». En: *Frontiers in Pharmacology* 11 (2020), pág. 565644. DOI: 10.3389/fphar.2020.565644.

[61] Miruna T Cretu et al. «Standardizing chemical compounds with language models». En: *Machine Learning: Science and Technology* 4.3 (2023), pág. 035014. DOI: 10.1088/2632-2153/ace878.

[62] Diederik P. Kingma et al. «Adam: A Method for Stochastic Optimization». En: *3rd International Conference on Learning Representations (ICLR)*. 2015.

[63] Kalyanmoy Deb et al. «An Evolutionary Many-Objective Optimization Algorithm Using Reference-Point-Based Nondominated Sorting Approach, Part I: Solving Problems With Box Constraints». En: *IEEE Transactions on Evolutionary Computation* 18.4 (2014), págs. 577-601. DOI: 10.1109/TEVC.2013.2281535. URL: https://doi.org/10.1109/tevc.2013.2281535.

[64] Qingfu Zhang et al. «MOEA/D: A Multiobjective Evolutionary Algorithm Based on Decomposition». En: *IEEE Transactions on Evolutionary Computation* 11.6 (2007), págs. 712-731. DOI: 10.1109/TEVC.2007.892759. URL: http://ieeexplore.ieee.org/document/4358754/.

[65] Xingyi Zhang et al. «A competitive mechanism based multi-objective particle swarm optimizer with fast convergence». En: *Information Sciences* 427 (2018), págs. 63-76. DOI: 10.1016/j.ins.2017.10.037. URL: https://linkinghub.elsevier.com/retrieve/pii/S0020025517310344.

[66] Annibale Panichella. «An adaptive evolutionary algorithm based on non-euclidean geometry for many-objective optimization». En: *Proceedings of the Genetic and Evolutionary Computation Conference*. Prague, Czech Republic: ACM, 2019, págs. 595-603. ISBN: 978-1-4503-6111-8. DOI: 10.1145/3321707.3321839. URL: https://dl.acm.org/doi/10.1145/3321707.3321839.

[67] Greg Landrum et al. *RDKit: Open-Source Cheminformatics*. https://www.rdkit.org. Versión 2026.03.1. 2026. DOI: 10.5281/zenodo.591637.

[68] Kalyanmoy Deb et al. «Simulated Binary Crossover for Continuous Search Space». En: *Complex Systems* 9.2 (1995), págs. 115-148. URL: https://www.complex-systems.com/abstracts/v09_i02_a02/.

[69] Kalyanmoy Deb et al. «Real-coded evolutionary algorithms with parent-centric recombination». En: *Proceedings of the 2002 Congress on Evolutionary Computation (CEC '02)*. Vol. 1. IEEE, 2002, págs. 61-66. DOI: 10.1109/CEC.2002.1006210.

[70] Kalyanmoy Deb et al. «A Combined Genetic Adaptive Search (GeneAS) for Engineering Design». En: *Computer Science and Informatics* 26.4 (1996), págs. 30-45.

[71] Thomas Bäck et al. «An Overview of Evolutionary Algorithms for Parameter Optimization». En: *Evolutionary Computation* 1.1 (1993), págs. 1-23. DOI: 10.1162/evco.1993.1.1.1.

[72] Omkar Shinde et al. «Structures of ATP-binding cassette transporter ABCC1 reveal the molecular basis of cyclic dinucleotide cGAMP export». En: *Immunity* 58.1 (2025), 59-73.e5. DOI: 10.1016/j.immuni.2024.12.002.

[73] Diogo Santos-Martins et al. «Meeko: Molecule Parametrization and Software Interoperability for Docking and Beyond». En: *Journal of Chemical Information and Modeling* 65.24 (2025), págs. 13045-13050. DOI: 10.1021/acs.jcim.5c02271.

[74] Yuri Kochnev et al. «FPocketWeb: protein pocket hunting in a web browser». En: *Journal of Cheminformatics* 14.1 (2022), pág. 58. DOI: 10.1186/s13321-022-00637-0.

[75] Jerome Eberhardt et al. «AutoDock Vina 1.2.0: New Docking Methods, Expanded Force Field, and Python Bindings». En: *Journal of Chemical Information and Modeling* 61.8 (2021), págs. 3891-3898. DOI: 10.1021/acs.jcim.1c00203.

[76] Miqing Li et al. «Quality Evaluation of Solution Sets in Multiobjective Optimisation: A Survey». En: *ACM Computing Surveys* 52.2 (2019), 26:1-26:38. DOI: 10.1145/3300148. URL: https://doi.org/10.1145/3300148.

[77] Martin Buttenschoen et al. «PoseBusters: AI-based docking methods fail to generate physically valid poses or accurately predict binding modes». En: *Chemical Science* 15.9 (2024), págs. 3130-3139. DOI: 10.1039/D3SC04185A.

[78] Kyle Swanson et al. «ADMET-AI: a machine learning platform for the rapid and accurate prediction of ADMET properties». En: *Bioinformatics* 40.6 (2024), btae366. DOI: 10.1093/bioinformatics/btae366.

[79] Junyoung Chung et al. *Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling*. 2014. arXiv: 1412.3555 [cs.NE].

Siglas

5-FU 5-Fluorouracilo (*5-Fluorouracil*). (*p. 18, 101*)

ABC Transportadores de casete de unión a ATP (*ATP-Binding Cassette*). (*p. 3, 18, 101*)

ABCC1 Miembro 1 de la subfamilia C de casete de unión a ATP (*ATP-Binding Cassette Subfamily C Member 1*). (*p. 39, 101*)

ADMET Absorción, distribución, metabolismo, excreción y toxicidad (*Absorption, Distribution, Metabolism, Excretion, and Toxicity*). (*p. 9, 27, 47, 101*)

AGE-MOEA Algoritmo evolutivo multiobjetivo basado en estimación adaptativa de geometría (*Adaptive Geometry Estimation Based MOEA*). (*p. xiv, xv, xvii, 1, 34, 36, 55–57, 59–71, 82–84, 88, 90, 101*)

ALERTS Alertas estructurales (*Structural Alerts*). (*p. 12, 101*)

ALOGP Coeficiente de partición octanol-agua basado en átomos (*Atom-based LogP*). (*p. 12, 101*)

AROM Anillos aromáticos (*Aromatic Rings*). (*p. 12, 101*)

ATP Trifosfato de adenosina (*Adenosine Triphosphate*). (*p. 18, 39, 101*)

CADD Diseño de fármacos asistido por computadora (*Computer-Aided Drug Design*). (*p. 3, 5, 7, 8, 101*)

cGAMP Monofosfato de guanosina-adenosina cíclico (*Cyclic GMP-AMP*). (*p. 39, 101*)

CMOPSO Optimizador multiobjetivo por enjambre de partículas basado en mecanismo competitivo (*Competitive Mechanism Based Multi-objective Particle Swarm Optimizer*). (*p. xiv, xvii, 1, 34, 35, 37, 53–55, 61–72, 82, 90, 101*)

Cryo-EM Criomicroscopía electrónica (*Cryogenic Electron Microscopy*). (*p. 8, 20, 101*)

ELBO Cota inferior de la evidencia (*Evidence Lower Bound*). (*p. 16, 101*)

FCD Distancia Fréchet ChemNet (*Fréchet ChemNet Distance*). (*p. 44, 49–53, 101*)

FDA Administración de Alimentos y Medicamentos (*Food and Drug Administration*). (*p. 20, 101*)

GD Distancia generacional (*Generational Distance*). (*p. 45, 101*)

GPU Unidad de procesamiento gráfico (*Graphics Processing Unit*). (*p. 14, 42, 47, 48, 74, 101*)

GRU Unidad recurrente con compuertas (*Gated Recurrent Unit*). (*p. 22, 32, 47, 49, 50, 101*)

HBA Aceptores de enlaces de hidrógeno (*Hydrogen Bond Acceptors*). (*p. 12, 101*)
HBD Donadores de enlaces de hidrógeno (*Hydrogen Bond Donors*). (*p. 12, 101*)
HV Hipervolumen (*Hypervolume*). (*p. xiv, 45, 46, 53, 56, 57, 101*)

IGD Distancia generacional invertida (*Inverted Generational Distance*). (*p. xiv, 45, 46, 101*)

LBDD Diseño de fármacos basado en el ligando (*Ligand-Based Drug Design*). (*p. 8, 9, 101*)
LSTM Memoria de corto y largo plazo (*Long Short-Term Memory*). (*p. 24, 32, 47, 49, 50, 101*)

MCF Filtros de química médica (*Medicinal Chemistry Filters*). (*p. 44, 101*)
MDR Resistencia a múltiples fármacos (*Multidrug Resistance*). (*p. 3, 18, 101*)
MOEA/D Algoritmo evolutivo multiobjetivo basado en descomposición (*Multiobjective Evolutionary Algorithm Based on Decomposition*). (*p. xiv, xv, xvii, 1, 34, 36, 54–57, 59–69, 71, 72, 82, 83, 85, 88, 90, 101*)
MOSES Conjuntos moleculares (*Molecular Sets*). (*p. 23, 29–31, 33, 43, 44, 49, 52, 101*)
MRP1 Proteína 1 asociada a la resistencia a múltiples fármacos (*Multidrug Resistance-associated Protein 1*). (*p. xiv, 3–5, 7, 18–20, 28, 29, 38–40, 42, 46–49, 73, 75, 101*)
MW Peso molecular (*Molecular Weight*). (*p. 12, 101*)

NSGA-II Algoritmo genético de ordenamiento no dominado II (*Non-dominated Sorting Genetic Algorithm II*). (*p. xiv, xv, xvii, 1, 24, 33, 34, 36, 55–71, 82, 83, 86, 89, 90, 101*)
NSGA-III Algoritmo genético de ordenamiento no dominado III (*Non-dominated Sorting Genetic Algorithm III*). (*p. xiv, xv, xvii, 1, 27, 34, 36, 55–72, 82, 83, 87, 89, 90, 101*)

PAINS Compuestos de interferencia en pan-ensayos (*Pan-Assay Interference Compounds*). (*p. 44, 101*)
PCX Cruce centrado en los padres (*Parent-Centric Crossover*). (*p. 36, 37, 101*)
PDB Banco de Datos de Proteínas (*Protein Data Bank*). (*p. 19, 101*)
PM Mutación polinomial (*Polynomial Mutation*). (*p. 36, 101*)
PSA Área de superficie polar (*Polar Surface Area*). (*p. 12, 101*)

QED Estimación cuantitativa de la similitud a fármaco (*Quantitative Estimate of Drug-likeness*). (*p. 11, 12, 35, 42–44, 47, 50–53, 57, 58, 60–62, 64–68, 70–72, 90, 101*)
QSAR Relación cuantitativa estructura-actividad (*Quantitative Structure–Activity Relationship*). (*p. 9, 24, 101*)

RMN Resonancia magnética nuclear (*Nuclear Magnetic Resonance*). (*p. 8, 101*)
ROTB Enlaces rotables (*Rotatable Bonds*). (*p. 12, 101*)

SAS Puntuación de accesibilidad sintética (*Synthetic Accessibility Score*). (*p. 12, 35, 42–44, 47, 50–52, 101*)

SBDD Diseño de fármacos basado en la estructura (*Structure-Based Drug Design*). (*p. 8, 9, 101*)

SBX Cruce binario simulado (*Simulated Binary Crossover*). (*p. 36, 37, 101*)

SELFIES Cadenas integradas autorreferenciadas (*Self-Referencing Embedded Strings*). (*p. 9, 10, 15, 27, 31, 32, 49–51, 101*)

SMILES Sistema simplificado de entrada de líneas moleculares (*Simplified Molecular Input Line Entry System*). (*p. 9, 10, 15, 20, 22–24, 27, 30–32, 47, 49–52, 69, 101*)

VAE Autoencoder Variacional (*Variational Autoencoder*). (*p. xvii, 3–5, 14–16, 22, 23, 29, 30, 32–34, 42, 43, 47–50, 53, 56, 73, 77, 101*)