

UNCUYO | FACULTAD DE INGENIERÍA

UNIVERSIDAD NACIONAL DE CUYO

TESINA FINAL DE GRADO

Licenciatura en Ciencias de la Computación

Diseño y Evaluación de algoritmos metaheurísticos multiobjetivo y modelos generativos para el diseño de fármacos aplicados al cáncer colorrectal

Autor: Carlos Eduardo Perez Melendez

Tutor: Dr. Pablo Javier Vidal

Co-Tutor: Dr. Matías Gabriel Rojas

Septiembre 2026

A quien le dedicas la tesis.

A tus padres o al profesor ese que nunca confió en ti.

*La tolerancia llegará a tal nivel
que las personas inteligentes
tendrán prohibido pensar
para no ofender a los imbéciles.*

Fiódor Dostoyevski

AGRADECIMIENTOS

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

RESUMEN

ABSTRACT

TABLA DE CONTENIDOS

Índice de Figuras

Índice de Tablas	1
------------------	---

1. Introducción	3
-----------------	---

1.1. Motivación	3
-----------------	---

1.2. Objetivos	4
----------------	---

1.3. Organización del Documento	5
---------------------------------	---

2. Marco Teórico	7
------------------	---

2.1. Diseño y Descubrimiento de Fármacos	7
--	---

2.1.1. Pipeline Tradicional	7
-----------------------------	---

2.1.2. Diseño de Fármacos Asistido por Computadora (CADD)	9
---	---

2.2. Representación de Moléculas	10
----------------------------------	----

2.2.1. SMILES (Simplified Molecular Input Line Entry System)	10
--	----

2.2.2. SELFIES (Self-Referencing Embedded Strings)	11
--	----

2.3. Métricas de Evaluación y Propiedades Moleculares	12
---	----

2.3.1. Reglas de Lipinski y Propiedades Físicoquímicas	12
--	----

2.3.2. QED (Quantitative Estimate of Drug-likeness)	13
---	----

2.3.3. Accesibilidad Sintética (SA Score)	13
---	----

2.3.4. Fracción de Carbonos sp^3 (Fsp3)	14
---	----

2.3.5. Métodos de Docking Molecular y Afinidad de Unión	14
---	----

2.4. Modelos Generativos Aplicados al Diseño de Fármacos	15
--	----

2.4.1. Autoencoders Variacionales (VAE)	15
---	----

2.5. Optimización Multi-Objetivo	17
----------------------------------	----

2.5.1. Aproximaciones Basadas en la Frontera de Pareto	17
2.5.2. Indicadores de Rendimiento Multiobjetivo	20
2.5.3. Metaheurísticas Consideradas en las Experimentaciones	21
2.6. Proteína 1 de Resistencia a Múltiples Fármacos (MRP1)	22
2.7. Trabajos Relacionados	23
2.7.1. Diseño de Fármacos Mediante Redes Generativas y VAEs	23
2.7.2. Optimización del Espacio Latente Mediante Metaheurísticas	27
2.7.3. Diseño de Fármacos Inhibidores de la Proteína MRP1	32
3. Metodología	33
3.1. Visión General de la Metodología	33
3.2. Ajuste de Hiperparámetros Mediante Generación de Fármacos Genéricos	33
3.2.1. Variables Optimizadas	33
3.2.2. Funciones Objetivo	33
3.3. Diseño de Inhibidores de la Proteína MRP1	33
3.3.1. Preparación de la Proteína	33
3.3.2. Funciones Objetivo	33
3.4. Configuración Experimental	33
3.4.1. Representación de la Solución	33
3.4.2. Conjunto de Datos y Preprocesamiento	33
4. Resultados y Discusión	35
4.1. Generación de Fármacos Genéricos para el Ajuste de Hiperparámetros .	35
4.1.1. Análisis de Calidad de Generación de Moléculas	35
4.1.2. Comparación Contra Algoritmos del Estado del Arte	35
4.2. Generación de Inhibidores de la Proteína MRP1	35
4.2.1. Análisis de Calidad de Generación de Moléculas	35
4.2.2. Comparación Contra Algoritmos del Estado del Arte	35
4.2.3. Análisis Detallado de las Mejores Moléculas Candidatas	35

TABLA DE CONTENIDOS

5. Conclusiones y Trabajo Futuro	37
5.1. Conclusiones	37
5.2. Trabajo Futuro	37
 Apéndices	
 A. Showcasing the First Appendix	39
 Anexos	
 L. Showcasing the First Annex	41
 Bibliografía	43
 Glosario	48
 Siglas	49

ÍNDICE DE FIGURAS

2.1. Pipeline tradicional de diseño y desarrollo de fármacos	8
2.2. Bifurcación de las estrategias de diseño de fármacos asistido por computadora (CADD) en métodos basados en estructura (SBDD) y basados en ligando (LBDD), convergiendo en el cribado virtual. Adaptado de [12, 15].	9
2.3. Representación de la molécula de aspirina en notación SMILES y correspondencia con su grafo 2D.	10
2.4. Representación de la molécula de aspirina en notación SELFIES y correspondencia con su grafo 2D.	11
2.5. Diagrama esquemático del proceso de docking molecular.	14
2.6. Diagrama esquemático del funcionamiento de un Autoencoder Variacional (VAE)	16
2.7. Frente de Pareto (soluciones no dominadas) y soluciones dominadas en el espacio de objetivos (f_1 y f_2 a minimizar). El frente delimita el límite óptimo de compromiso entre ambos criterios, adaptado de [9].	19
2.8. Estructura tridimensional de la proteína MRP1 (código PDB: 8VUX). Obtenido de RCSB PDB.	23

ÍNDICE DE TABLAS

2.1. Modelos generativos para diseño molecular.	24
2.2. Métricas de evaluación de los modelos generativos.	24
2.3. Optimización del espacio latente mediante metaheurísticas en diseño de fármacos.	28

INTRODUCCIÓN

1.1. Motivación

El cáncer es un conjunto de enfermedades de las que se tiene registro desde el antiguo Egipto y la Grecia clásica [1], pero que aun con los avances modernos continúa representando uno de los mayores desafíos sanitarios a nivel global, alcanzando más de 20 millones de nuevos diagnósticos anuales [2]. Dentro de este panorama, los cánceres del tracto gastrointestinal representan alrededor del 36 % de la mortalidad oncológica mundial [3]. En este grupo se encuentra el cáncer colorrectal, posicionado como el tercero de mayor incidencia y la segunda causa de muerte por cáncer en el mundo [2]. Si bien hoy en día existen tratamientos quimioterapéuticos estándar basados en fármacos como el 5-fluorouracilo y el oxaliplatino, cerca del 50 % de los pacientes afectados por esta enfermedad en estadios avanzados desarrolla resistencia y sufre recaídas [3, 4]. Estos fracasos en el tratamiento están estrechamente relacionados con la resistencia a múltiples fármacos (MDR), un proceso mediante el cual proteínas transportadoras de la familia ABC expulsan los medicamentos fuera de la célula tumoral y reducen su concentración intracelular [3, 4]. En este escenario, la proteína MRP1 (ABCC1) es una de las principales responsables al impedir la apoptosis y provocar resistencia frente a las terapias habituales [4, 5]. Por ello, es de interés diseñar inhibidores que reduzcan su actividad en las células cancerígenas y así mitigar los efectos de la resistencia frente a los tratamientos convencionales [5].

El descubrimiento de fármacos mediante métodos tradicionales de laboratorio es un proceso lento y costoso, condicionado por el tamaño del espacio químico estimado en más de 10^{60} moléculas posibles [6, 7]. Además, el diseño de fármacos es un problema intrínsecamente multiobjetivo, ya que una molécula viable no solo debe ser capaz de interactuar con la proteína objetivo con alta afinidad, sino también cumplir con perfiles farmacológicos adecuados y una sintetizabilidad viable [7, 8].

Para abordar esta dificultad el diseño de fármacos asistido por computadora y los modelos generativos, como los Autoencoders Variacionales (VAE), permiten comprimir la información molecular en un espacio latente continuo desde el cual generar nuevas estructuras [6]. En este enfoque un codificador aprende a mapear representaciones moleculares discretas a vectores continuos, mientras que un decodificador realiza el proceso

inverso, reconstruyendo o generando nuevas moléculas a partir de puntos de dicho espacio latente [6]. No obstante, muestrear este espacio de manera aleatoria no garantiza la obtención de compuestos con actividad biológica real ni con propiedades farmacológicas adecuadas [6].

Para guiar la exploración de este espacio hacia moléculas útiles es oportuno incorporar métodos de optimización, dentro de este enfoque las metaheurísticas son algoritmos de búsqueda aproximada diseñados para encontrar buenas soluciones en problemas complejos y de gran tamaño [9]. Específicamente, las metaheurísticas multiobjetivo permiten optimizar simultáneamente distintas metas que suelen entrar en conflicto entre sí, como lograr una alta afinidad con la proteína, asegurar que la molécula sea fácil de sintetizar y mantener un buen perfil farmacológico, ofreciendo un conjunto de soluciones compromiso [7, 9].

Esta tesina propone un esquema computacional de dos etapas. En la primera etapa, se entrena un modelo generativo VAE con bases de datos moleculares para crear un espacio latente continuo de compuestos químicos válidos. En la segunda etapa, se integran algoritmos metaheurísticos multiobjetivo para guiar la búsqueda dentro del espacio latente, evaluando iterativamente la aptitud de las moléculas generadas según su afinidad de unión y sus propiedades farmacológicas deseadas.

Bajo esta premisa, la presente tesina de grado se centra en el desarrollo y evaluación de un enfoque computacional que combina la capacidad generativa de los VAEs con la optimización guiada de algoritmos metaheurísticos multiobjetivo, con el propósito de descubrir moléculas candidatas viables y eficaces para inhibir la proteína MRP1.

1.2. Objetivos

El objetivo general de este trabajo final de grado consiste en desarrollar y evaluar un enfoque computacional híbrido que combine modelos generativos con algoritmos metaheurísticos multiobjetivo, con el fin de obtener moléculas capaces de inhibir la resistencia a quimioterápicos en cáncer colorrectal. A partir de este objetivo general, se plantean los siguientes objetivos específicos:

- Diseñar, implementar y evaluar modelos metaheurísticos multiobjetivo para optimizar moléculas generadas por un modelo generativo.
- Generar moléculas que tengan propiedades estables y que sean eficaces para inhibir la resistencia a quimioterápicos en cáncer colorrectal.

1.3. Organización del Documento

Esta tesina de grado se organiza en capítulos donde se establecen los fundamentos teóricos, se detallan los aspectos metodológicos y experimentales, y se presentan los resultados y las conclusiones alcanzadas. El contenido se estructura de la siguiente manera:

- **Capítulo 1 (Introducción):** Expone la motivación, el problema a abordar, los objetivos del trabajo y la estructura general de la tesina.
- **Capítulo 2 (Marco Teórico):** Brinda los fundamentos sobre diseño de fármacos por computadora (CADD), representación molecular, métricas de evaluación, modelos generativos (VAE), optimización multiobjetivo y la proteína MRP1, junto con los trabajos relacionados en el área.
- **Capítulo 3 (Metodología):** Describe el enfoque propuesto, detallando el ajuste de hiperparámetros mediante fármacos genéricos, el diseño de inhibidores específicos contra MRP1 y la configuración experimental utilizada.
- **Capítulo 4 (Resultados y Discusión):** Presenta los resultados obtenidos, analizando la calidad de las moléculas generadas, la comparación con el estado del arte y el estudio de los mejores compuestos candidatos.
- **Capítulo 5 (Conclusiones y Trabajo Futuro):** Resume las principales conclusiones del trabajo, las dificultades encontradas y las líneas de trabajo futuro.

MARCO TEÓRICO

En este capítulo se hace una revisión de los conceptos teóricos que dan base a esta tesis de grado. Se abordan temas como el diseño de fármacos asistido por computadora, las formas de representar moléculas, las métricas de evaluación y el acoplamiento molecular. También se explica el funcionamiento de los autoencoders variacionales y los métodos de optimización multiobjetivo para buscar soluciones en espacios latentes. Finalmente, se describe el rol de la proteína MRP1 en el cáncer colorrectal y se resume el estado del arte en relación con el diseño computacional de fármacos.

2.1. Diseño y Descubrimiento de Fármacos

El descubrimiento de nuevos fármacos es un proceso mediante el cual se buscan, identifican, diseñan y validan nuevas moléculas con el objetivo de tratar enfermedades mediante la inhibición o activación de una proteína diana. Se trata de un proceso largo y costoso, que puede requerir entre 10 y 15 años de investigación y desarrollo, con una inversión que puede superar los 1.000 millones de dólares [10].

Frente a estos desafíos, en la actualidad el diseño de fármacos involucra con frecuencia el uso de herramientas computacionales. En términos generales, es posible distinguir dos perspectivas complementarias dentro de este campo: por un lado, el pipeline tradicional, basado en etapas sucesivas de identificación y validación de blancos, ensayos y optimización de candidatos; por otro lado, el diseño de fármacos asistido por computadora (CADD), que incorpora técnicas y métodos computacionales y de tecnologías de la información para acelerar y optimizar el proceso [11]. A continuación, se describe el pipeline tradicional (subsección 2.1.1) y luego se profundiza en el enfoque computacional (subsección 2.1.2).

2.1.1. Pipeline Tradicional

Históricamente, el descubrimiento de fármacos tiene su origen en pruebas de ensayo y error sobre extractos naturales o compuestos aislados, evaluados directamente en células o animales, sin un blanco molecular específico previamente definido [12].

La figura 2.1 ilustra este proceso metódico y secuencial surgido con el desarrollo de la industria farmacéutica, el cual en términos generales se agrupa en tres fases: el descubrimiento del fármaco, el desarrollo preclínico y los ensayos clínicos en humanos, hasta alcanzar la aprobación regulatoria necesaria [13].




Figura 2.1: Pipeline tradicional de descubrimiento y desarrollo de fármacos, ilustrando la reducción progresiva de candidatos, tiempos e inversión requerida hasta la aprobación regulatoria. Adaptado de [10, 12].

En primera instancia, el descubrimiento temprano de fármacos empieza con la identificación y validación del blanco terapéutico, es decir, la proteína, receptor o vía biológica cuya interacción con el fármaco se espera que tenga un efecto terapéutico. La idea de un blanco puede surgir tanto de la investigación académica y clínica como del sector comercial, y suele requerir años de evidencia de respaldo antes de justificar el inicio de un programa de descubrimiento [10].

En esta etapa se diseña un ensayo que mide si un compuesto interactúa con su diana. Este ensayo se aplica sobre grandes bibliotecas de compuestos mediante un cribado de alto rendimiento, un proceso automatizado que permite probar miles de moléculas en poco tiempo. Los compuestos que dan resultado favorable en este cribado son posteriormente evaluados y optimizados, modificando su estructura para mejorar su perfil farmacológico, hasta llegar a una molécula candidata [10].

Con la molécula candidata definida, se realiza el desarrollo preclínico, donde se estudia la seguridad y la toxicidad en pruebas *in vitro* y con animales, antes de probarse en seres humanos. Si los resultados son satisfactorios, el compuesto avanza a los ensayos clínicos, evaluando la seguridad y la dosis en un grupo reducido de personas, midiendo su eficacia en pacientes y confirmándola finalmente en poblaciones más grandes [13]. Superada esta etapa, el fármaco pasa a la aprobación regulatoria, donde organismos como la ANMAT o la FDA autorizan su comercialización [13, 14].

Este recorrido completo explica por qué el desarrollo de fármacos puede extenderse entre 12 y 15 años y superar los 1.000 millones de dólares de inversión [10]. Miles de compuestos evaluados en las primeras etapas son rechazados posteriormente por distintos factores: falta de interacción con el objetivo, bajo perfil farmacológico, dificultad de

síntesis, entre otros. Solo un número reducido llega a fases preclínicas y de aprobación, lo que evidencia la enorme tasa de descarte de candidatos en cada etapa [12].

2.1.2. Diseño de Fármacos Asistido por Computadora (CADD)

El diseño de fármacos asistido por computadora (CADD) se originó en la década de 1960, cuando la capacidad de generar modelos moleculares tridimensionales por medios computacionales permitió superar las limitaciones de las representaciones bidimensionales de los compuestos. Desde entonces, evolucionó hasta dividirse en dos enfoques principales según la información disponible sobre el blanco terapéutico: el diseño basado en la estructura (SBDD), que parte de la estructura tridimensional del blanco, y el diseño basado en el ligando (LBDD), que se basa en un conjunto de compuestos con actividad biológica ya conocida contra ese blanco [12].




Figura 2.2: Bifurcación de las estrategias de diseño de fármacos asistido por computadora (CADD) en métodos basados en estructura (SBDD) y basados en ligando (LBDD), convergiendo en el cribado virtual. Adaptado de [12, 15].

En el diseño basado en la estructura, el blanco se obtiene mediante cristalografía de rayos X, resonancia magnética nuclear (RMN) o, en ausencia de datos experimentales, mediante modelado por homología a partir de una proteína homóloga. Este diseño presenta dos técnicas principales, el diseño de novo, que construye ligandos nuevos dentro de las restricciones del sitio de unión, y el acoplamiento molecular, que evalúa cómo encajan distintos compuestos en ese sitio y califica su afinidad mediante funciones de puntuación [15]. En el diseño basado en el ligando, se asume que las moléculas con estructuras semejantes tienden a exhibir actividades biológicas similares, su metodología más extendida es el modelado QSAR, el cual correlaciona variaciones estructurales con la actividad biológica observada [12].

Como se observa en la figura 2.2, el cribado virtual converge con ambos enfoques, ya que puede orientarse a partir de la estructura del blanco o de los ligandos de referencia.

Asimismo, este proceso no se restringe a predecir afinidades de unión, sino que cumple un papel esencial al filtrar candidatos según su perfil ADMET (absorción, distribución, metabolismo, excreción y toxicidad), descartando compuestos con baja viabilidad [15]. En años recientes, estas herramientas han incorporado distintas metodologías, tales como redes neuronales profundas para mejorar la capacidad predictiva, así como estrategias híbridas que integran SBDD y LBDD dentro de un mismo flujo de trabajo [12].

2.2. Representación de Moléculas

El diseño de fármacos asistido por computadora requiere describir eficientemente la estructura de las moléculas para que los algoritmos puedan procesarlas y analizarlas. En este contexto, existen diversos formatos, que van desde conformaciones tridimensionales y grafos moleculares hasta secuencias lineales. Estas últimas describen la estructura del compuesto mediante una cadena de texto, lo cual facilita su almacenamiento, indexación y procesamiento. Entre las notaciones lineales más extendidas se destacan SMILES y SELFIES, ambas abordadas en este trabajo.

2.2.1. SMILES (Simplified Molecular Input Line Entry System)

La notación SMILES es una representación lineal ampliamente usada para describir la estructura bidimensional de las moléculas mediante cadenas de texto [16]. Cada átomo se representa por su símbolo químico y los enlaces por caracteres especiales. Su sintaxis captura la conectividad molecular, qué átomos están enlazados entre sí, utilizando paréntesis y dígitos para ciclos. Esta notación es concisa, legible y compatible con la mayoría de las bases de datos químicas (PubChem, ChEMBL, ZINC), lo que facilita su integración en flujos de trabajo computacionales.




Figura 2.3: Representación de la molécula de aspirina en notación SMILES y correspondencia con su grafo 2D.

Como se observa en la figura 2.3, la estructura de la aspirina se divide en tres partes dentro de la secuencia SMILES. A la izquierda se presenta el grafo bidimensional y a la

derecha su correspondencia en texto, donde las ramificaciones se indican con paréntesis y el anillo aromático se delimita con números que abren y cierran el ciclo.

SMILES se ha consolidado como la representación estándar en modelos generativos de moléculas basados en secuencias, análogos a los modelos de lenguaje. Arquitecturas basadas en redes neuronales pueden aprender las reglas químicas implícitas en las cadenas SMILES y generar nuevas estructuras válidas [17-19]. Se ha demostrado además que el uso de SMILES aleatorizados mejora la diversidad y calidad de las moléculas generadas al ampliar el espacio químico de entrenamiento [20].

Sin embargo, SMILES presenta limitaciones. Su sintaxis es sensible a pequeños errores que pueden producir moléculas inválidas o distintas. Además, una misma molécula puede tener múltiples representaciones válidas, lo que complica su comparación directa.

2.2.2. SELFIES (Self-Referencing Embedded Strings)

SELFIES es una representación lineal alternativa a SMILES, diseñada para ser robusta en términos de validez química. Introducida por Krenn et al. entre 2019 y 2020, su objetivo fue eliminar los errores sintácticos comunes de SMILES. En SELFIES, cada símbolo (token) de la cadena corresponde a un elemento químico o una relación estructural, y la gramática está restringida de manera que cualquier secuencia SELFIES decodifica una molécula válida. Es decir, no existen “SELFIES inválidos”, y hasta una cadena aleatoria genera una estructura respetando las valencias permitidas [21].




Figura 2.4: Representación de la molécula de aspirina en notación SELFIES y correspondencia con su grafo 2D.

Como se observa en la figura 2.4, la misma molécula se representa mediante una secuencia de símbolos entre corchetes. Cada parte de la estructura se define con instrucciones directas, donde las ramas y el cierre del anillo indican de forma exacta los enlaces necesarios para mantener la validez molecular.

La principal ventaja de SELFIES es esta robustez, lo que resulta crucial en modelos generativos. Si se emplea en un VAE, RNN o GAN, prácticamente todas las moléculas generadas serán químicamente válidas, eliminando la necesidad de filtrar salidas inválidas como ocurre con SMILES [21]. Esto permite a los algoritmos enfocarse en optimizar propiedades en lugar de aprender reglas gramaticales. SELFIES puede representar las mismas moléculas que SMILES, evitando combinaciones inválidas.

Entre sus limitaciones, las cadenas SELFIES pueden ser menos intuitivas para químicos, ser más largas que su SMILES equivalente y no reflejar de manera simple ciertas transformaciones moleculares. Al igual que SMILES, no incorpora información 3D ni conformacional, y la validez de la secuencia no garantiza que la molécula sea fácil de sintetizar o realista [21].

2.3. Métricas de Evaluación y Propiedades Moleculares

En el diseño de fármacos asistido por computadora, la calidad de las moléculas generadas no depende de una única característica; para que un compuesto sea viable como candidato a fármaco, debe cumplir con una serie de propiedades para asegurar un perfil farmacológico adecuado. Estas propiedades abarcan desde características fisicoquímicas hasta su viabilidad de síntesis y afinidad de unión con el objetivo terapéutico.

2.3.1. Reglas de Lipinski y Propiedades Fisicoquímicas

Uno de los primeros criterios para estimar si un compuesto químico puede cumplir alguna función farmacológica o actividad biológica es la Regla de los Cinco (*Rule of Five*) [22], propuesta en 1997 a partir de un análisis retrospectivo de las propiedades fisicoquímicas de fármacos que habían alcanzado con éxito ensayos clínicos de fase II. La regla establece que una molécula con buena biodisponibilidad oral debe cumplir con las siguientes condiciones:

- Peso Molecular ≤ 500 g/mol
- Coeficiente de partición octanol-agua (LogP) ≤ 5
- Número de aceptores de enlace de hidrógeno ≤ 10
- Número de donadores de enlace de hidrógeno ≤ 5

Esta regla se convirtió en un filtro en las primeras etapas del cribado virtual y diseño de fármacos; sin embargo, no es una regla absoluta, ya que existen fármacos que no cumplen con estas condiciones y son exitosos. Por ello, suele complementarse con métricas más detalladas para evaluar el perfil del compuesto.

2.3.2. QED (Quantitative Estimate of Drug-likeness)

El Quantitative Estimate of Drug-likeness (QED) es una métrica que permite evaluar la probabilidad de que una molécula sea un fármaco viable a partir del análisis de las propiedades fisicoquímicas de una colección de fármacos aprobados [23]. El QED toma un valor entre 0 y 1, donde un valor cercano a 1 indica una mayor probabilidad de que la molécula sea un fármaco viable.

El QED se construye a partir de ocho propiedades moleculares relevantes en el diseño de fármacos:

- Peso molecular (MW)
- Coeficiente de partición octanol-agua (ALOGP)
- Número de donadores de enlace de hidrógeno (HBD)
- Número de aceptores de enlace de hidrógeno (HBA)
- Área de superficie polar (PSA)
- Número de enlaces rotables (ROTB)
- Número de anillos aromáticos (AROM)
- Número de alertas estructurales (ALERTS)

Cada una de estas propiedades se transforma mediante una función de deseabilidad, derivada de la distribución de estas propiedades en fármacos aprobados; el QED final se calcula como la media geométrica ponderada de estas ocho funciones de deseabilidad.

QED se ha convertido en una de las métricas más utilizadas en los pipelines de diseño de fármacos, debido a que, a diferencia de los filtros discretos como Lipinski, genera una puntuación suave y continua [24].

2.3.3. Accesibilidad Sintética (SA Score)

La accesibilidad sintética es un criterio que evalúa la dificultad de síntesis de una molécula. Esta propiedad constituye un filtro común en el diseño de fármacos asistido por computadora, ya que permite que un compuesto prometedor pueda fabricarse de forma viable y eficiente, afectando directamente tanto la etapa de diseño y optimización de moléculas como la viabilidad de su posterior implementación experimental.

Para cuantificar la accesibilidad sintética se suele utilizar el SA Score [25]; esta métrica asigna a cada molécula un valor entre 1 (fácil de sintetizar) y 10 (difícil de sintetizar). Dicho valor se calcula a partir del número de fragmentos moleculares y la complejidad de las conexiones entre ellos. En la optimización molecular suele emplearse junto con el QED, donde el QED optimiza la deseabilidad farmacológica y el SA Score la viabilidad práctica de obtenerla [24].

2.3.4. Fracción de Carbonos sp^3 (Fsp3)

La fracción de carbonos F_{sp^3} es una métrica que evalúa la proporción de carbonos saturados respecto al número total de átomos de carbono.

$$F_{sp^3} = \frac{\text{Número de carbonos } sp^3}{\text{Número total de carbonos}}$$

Sus valores oscilan entre 0 para moléculas completamente planas y 1 para moléculas totalmente saturadas.

Esta métrica fue propuesta en el trabajo “Escape from Flatland” [26], donde se observó que las moléculas candidatas a fármacos que tendían a ser excesivamente planas mostraban tasas menores de éxito clínico. A través de un análisis de bases de datos de compuestos en distintas etapas se encontró una correlación positiva entre el grado de saturación Fsp3 y la probabilidad de que un compuesto avance a fases clínicas avanzadas. Asimismo, se encontró una correlación positiva entre el Fsp3 y la solubilidad acuosa. Un trabajo posterior [27] expandió este análisis, relacionando nuevamente la saturación sp^3 con la promiscuidad farmacológica, es decir, la tendencia de una molécula a interactuar con dianas biológicas no deseadas, por lo que a mayor complejidad tridimensional, las moléculas tienden a reducir la promiscuidad y con ello el riesgo de efectos adversos fuera de la diana.

2.3.5. Métodos de Docking Molecular y Afinidad de Unión

El docking molecular es una técnica computacional que permite estimar la afinidad de una molécula pequeña hacia una diana, usualmente una proteína. Esta herramienta se utiliza para predecir la fuerza de dicha unión, conocida como afinidad de unión, y la orientación tridimensional de la molécula dentro del sitio de unión de la proteína.

En la figura 2.5 se muestra un diagrama esquemático con las etapas principales del proceso de docking molecular.




Figura 2.5: Diagrama esquemático del proceso de docking molecular.

Una herramienta de docking consiste en general de dos componentes, un algoritmo de búsqueda que explora el espacio de poses del ligando dentro del sitio de unión, y de

una función de puntuación que evalúa cada pose y estima la energía de unión de cada pose y permite ordenarlas [28]. Existen distintas implementaciones que combinan estos componentes, cada una con su propia metodología de búsqueda y de puntuación.

Entre esas herramientas se encuentra AutoDock Vina [29], que combina un algoritmo de búsqueda local iterativo con una función de puntuación híbrida, usando información de estructuras de complejos proteína-ligando ya conocidos y de afinidades medidas en experimentos. El docking demanda recursos computacionales considerables cuando se tiene una gran cantidad de ligandos que evaluar, para reducir este costo existen implementaciones aceleradas por GPU, entre ellas Uni-dock [30] que permite procesar moléculas en lotes. El resultado de la función de puntuación se da como una energía de unión estimada (ΔG) en kcal/mol [28] en la que un valor más negativo indica una unión más favorable.

2.4. Modelos Generativos Aplicados al Diseño de Fármacos

Los métodos basados en inteligencia artificial pueden mejorar enormemente el proceso de diseño de fármacos, en especial los modelos generativos los cuales son capaces de aprender representaciones del espacio químico para generar nuevos compuestos con propiedades deseadas. Al apoyarse en técnicas de aprendizaje profundo, estos modelos no evalúan únicamente las moléculas conocidas, sino que aprenden las reglas y patrones de la representación molecular para generar nuevos compuestos. Entre estos modelos los Autoencoders Variacionales destacan por su capacidad de estructurar un espacio latente navegable.

2.4.1. Autoencoders Variacionales (VAE)

Los Autoencoders Variacionales (VAE) son una arquitectura de aprendizaje profundo de tipo generativo [31]. Su estructura se basa en dos redes neuronales conectadas: un codificador que procesa los datos y un decodificador que intenta reconstruirlos.

Para entender su funcionamiento específico, es necesario contrastarlos con los autoencoders tradicionales. Un autoencoder tradicional toma un dato de entrada y lo comprime en un vector fijo en el espacio latente. El problema de este enfoque es que, por sí solo, no puede generar directamente ejemplos nuevos a partir de la distribución de los datos [32].

El VAE trata con este problema modificando la naturaleza del espacio latente. En lugar de codificar la entrada como un punto fijo, la red predice una distribución estadística, definida por una media y una desviación estándar [31]. En la figura 2.6 se ilustra este flujo, desde la estimación de μ y σ hasta la reconstrucción de la entrada a partir de z .




Figura 2.6: Diagrama esquemático del funcionamiento de un Autoencoder Variacional (VAE). Adaptado de [33].

En el diseño de fármacos, la entrada x es una molécula representada como una cadena de texto (SMILES o SELFIES). El codificador convierte esa cadena en una distribución sobre el espacio latente, de la que se toma una muestra z , y el decodificador convierte z de nuevo en una cadena. Como este espacio es continuo, se pueden generar moléculas nuevas decodificando vectores aleatorios, perturbando moléculas conocidas o interpolando entre ellas, y también aplicar métodos de optimización para buscar moléculas con mejores propiedades [34].

El entrenamiento de los VAE presenta un desafío técnico, para generar datos el modelo necesita tomar una muestra aleatoria de esa distribución estadística, pero fijar el vector latente a un valor muestreado bloquea la propagación del error hacia el codificador, por lo que sus pesos no se pueden actualizar [32]. Para solucionarlo se emplea el «truco de reparametrización» [31], que obtiene el vector latente z mediante una ecuación que separa la aleatoriedad de los parámetros aprendibles:

$$z = \mu + \sigma \odot \epsilon \quad (2.1)$$

donde μ y σ son la media y la desviación estándar que predice el codificador, $\odot$ es el producto elemento a elemento y ϵ es un ruido aleatorio externo que debe seguir una distribución normal estándar. De esta forma, la red puede usar la aleatoriedad para generar variedad, pero mantiene una conexión matemática directa que le permite propagar los gradientes hacia el codificador.

Función de pérdida. Para que el modelo generativo aprenda correctamente, no basta con medir la precisión con la que reconstruye los datos de entrada. Es fundamental asegurar también que el espacio latente posea una estructura estadística coherente que permita la generación de nuevas muestras. Para lograr esto, se utiliza una función de pérdida con dos términos:

$$\mathcal{L} = \mathcal{L}_{recon} + \beta \cdot \mathcal{D}_{KL} (q_{\phi}(z|x) \| p(z)) \quad (2.2)$$

donde $q_\phi(z|x)$ es la distribución que predice el codificador y $p(z)$ es una distribución normal estándar $\mathcal{N}(0, I)$ [31]. Cuando $\beta = 1$, esta función corresponde al negativo del ELBO (*Evidence Lower Bound*), la cota inferior de la verosimilitud que el VAE busca maximizar [31, 32]; el coeficiente β permite ponderar la divergencia KL. En la práctica, este peso puede variar durante el entrenamiento: en *Chemical VAE*, por ejemplo, la pérdida variacional se introduce con un calendario sigmoide (*annealing*) [34].

Esta ecuación actúa como un mecanismo de balance entre dos objetivos contrapuestos durante el entrenamiento:

- **Pérdida de reconstrucción ($\mathcal{L}_{recon}$):** Es el primer término de la ecuación. Su función es comparar el dato generado por el decodificador con el dato original de entrada. Cuanto mayor sea la diferencia o el error en la recuperación de la información, mayor será este valor. Su objetivo es forzar a la red a mantener la fidelidad respecto a los datos reales.
- **Divergencia de Kullback-Leibler ($\mathcal{D}_{KL}$):** Es el segundo término y actúa como un regularizador [31] ponderado por el coeficiente β . Mide la discrepancia entre la distribución aprendida por el codificador y la distribución a priori. Este término funciona como un componente variacional que organiza el espacio latente. Su objetivo principal es forzar a que la distribución que aprende el modelo se parezca lo más posible a la distribución normal estándar, creando un espacio continuo y ordenado.

El objetivo final de esta función es encontrar un equilibrio óptimo: reconstruir los datos con alta precisión sin perder la capacidad de generar nuevas muestras válidas al interpolar en el espacio latente.

2.5. Optimización Multi-Objetivo

La optimización molecular requiere equilibrar múltiples propiedades que suelen competir entre sí, tales como maximizar la afinidad hacia una diana, mientras se preserva la facilidad de síntesis o la similitud a fármacos. Al no existir una solución única que satisfaga todos los criterios, la optimización multiobjetivo aborda este desafío identificando las mejores soluciones de compromiso.

2.5.1. Aproximaciones Basadas en la Frontera de Pareto

La optimización de soluciones en la naturaleza frecuentemente requiere explorar espacios de búsqueda vastos y de alta dimensionalidad, donde los métodos exactos resultan inviables. Estos problemas raramente se pueden reducir a un único objetivo a optimizar, sino que presentan múltiples metas u objetivos en conflicto.

La solución óptima para estos problemas no es una simple solución, sino que es un conjunto de soluciones definidas como soluciones óptimas de Pareto, donde no es posible mejorar un objetivo específico sin que ello conlleve al deterioro de otro. Es decir, estas soluciones representan un compromiso entre diferentes objetivos en conflicto por lo que la finalidad es encontrar este conjunto óptimo, y consecuentemente la Frontera de Pareto [9].

Problema de optimización multiobjetivo. Un problema de optimización multiobjetivo puede definirse como [9]:

$$\begin{cases} \text{Min } F(x) = (f_1(x), f_2(x), \dots, f_n(x)) \\ \text{s.c. } x \in S \end{cases} \quad (2.3)$$

Donde $F(x)$ es el vector de los n objetivos a optimizar ($n \geq 2$), mientras que x y S mantienen las definiciones de variables de decisión y espacio factible ya establecidas. En este contexto, la búsqueda se orienta a encontrar un equilibrio entre los distintos criterios de aptitud en conflicto.

Los objetivos que deben maximizarse se transforman en objetivos de minimización invirtiendo su signo, de modo que la formulación (2.3) abarca ambos sentidos de optimización [9].

Dominancia de Pareto. Un vector objetivo $u = (u_1, \dots, u_n)$ se dice que domina a $v = (v_1, \dots, v_n)$ (denotado por $u < v$) si y solo si ninguna componente de v es menor que la componente correspondiente de u y al menos una componente de u es estrictamente menor [9]:

$$\forall i \in \{1, \dots, n\} : u_i \leq v_i \wedge \exists i \in \{1, \dots, n\} : u_i < v_i \quad (2.4)$$

Dominancia Débil ($u \leq v$). u domina débilmente a v si [9]:

$$\forall i \in \{1, \dots, n\}, \quad u_i \leq v_i \quad (2.5)$$

Dominancia restringida. Cuando el problema de optimización multiobjetivo incorpora restricciones, la comparación entre soluciones debe contemplar además su factibilidad. Bajo el principio de *dominancia restringida*, una solución x_i domina a una solución x_j si se verifica alguna de las siguientes condiciones [35]:

1. x_i es factible y x_j no lo es.
2. Ambas soluciones son infactibles, pero x_i presenta una menor violación de restricciones.

3. Ambas soluciones son factibles y x_i domina a x_j en el sentido de la ecuación (2.4).

Este criterio permite incorporar restricciones sin recurrir a funciones de penalización, que exigirían el ajuste de parámetros adicionales [35].

Optimalidad de Pareto. Una solución $x^* \in S$ es *Pareto óptima* si para cada $x \in S$, $F(x)$ no domina a $F(x^*)$, es decir, $F(x) \not\prec F(x^*)$ [9].

En general, la búsqueda en un problema mono-objetivo conduce al hallazgo de una única solución óptima global. Un problema de optimización multiobjetivo puede tener un conjunto de soluciones conocido como el *conjunto Pareto óptimo*. La imagen de este conjunto en el espacio de objetivos se denomina el frente de Pareto [9].

Frente de Pareto. Para un problema de optimización multiobjetivo (F, S) dado y su conjunto óptimo de Pareto P^* , el **frente de Pareto** se define como [9]:

$$PF^* = \{F(x) \mid x \in P^*\} \quad (2.6)$$

El frente de Pareto es la imagen del conjunto óptimo de Pareto en el espacio de los objetivos, y su obtención constituye el propósito central de la optimización multiobjetivo. Dado que este frente puede ser sumamente extenso, se busca una aproximación finita que garantice tanto la convergencia hacia la frontera teórica como una distribución uniforme de las soluciones sobre la misma [9].

En la figura 2.7 se ilustra la representación de soluciones dominadas y soluciones pertenecientes al frente de Pareto en un espacio bidimensional.




Figura 2.7: Frente de Pareto (soluciones no dominadas) y soluciones dominadas en el espacio de objetivos (f_1 y f_2 a minimizar). El frente delimita el límite óptimo de compromiso entre ambos criterios, adaptado de [9].

2.5.2. Indicadores de Rendimiento Multiobjetivo

La evaluación de metaheurísticas multiobjetivo representa un desafío particular: el resultado del proceso de optimización no es una única solución, sino un conjunto de soluciones que aproxima el frente de Pareto. Por lo tanto, para evaluar el rendimiento de diferentes algoritmos es necesario comparar conjuntos enteros de soluciones no dominadas.

No existe un estándar único para evaluar las soluciones; los indicadores de calidad o métricas de desempeño se clasifican según sus propiedades y según el objetivo que evalúan [9]:

- **Indicadores de convergencia:** Evalúan la eficacia de las soluciones en términos de su cercanía al frente de Pareto óptimo (teórico). Ejemplos destacados incluyen la Distancia Generacional (GD), que calcula la distancia promedio entre el conjunto aproximado y un conjunto de referencia exacto, y el Indicador ϵ , que determina el factor mínimo de traslación necesario para que una aproximación domine a otra.
- **Indicadores de diversidad:** Miden la uniformidad y extensión de la distribución de las soluciones obtenidas a lo largo del frente. Indicadores como el Espaciado (*Spread*) o la Entropía penalizan los frentes donde las soluciones se agrupan excesivamente en una sola región del espacio de objetivos. Suelen tener un costo computacional mayor que los indicadores de convergencia.
- **Indicadores híbridos:** Evalúan simultáneamente tanto la convergencia como la diversidad del conjunto de soluciones. El estándar actual en la literatura es el Hipervolumen (HV), un indicador unario que calcula el volumen del espacio de objetivos que es débilmente dominado por el conjunto de aproximación respecto a un punto de referencia predefinido [9].

A partir de esta clasificación, los indicadores de rendimiento considerados en este trabajo para evaluar el desempeño de las metaheurísticas son los siguientes:

Hipervolumen (HV). Mide el volumen de la región del espacio de objetivos que domina el conjunto de soluciones obtenido, acotada por un punto de referencia. Cuanto mayor es ese volumen, mejor es el conjunto tanto en convergencia como en diversidad, de modo que resume ambos aspectos en un único valor. Su ventaja práctica es que no exige conocer el frente de Pareto óptimo, sino únicamente el punto de referencia.

Distancia generacional invertida modificada (IGD⁺). Promedia la distancia que separa a cada punto de un conjunto de referencia de la solución más próxima del conjunto obtenido, contabilizando solo las componentes en las que esa solución es peor. Valores bajos indican que el frente obtenido se aproxima al de referencia.

Indicador ϵ aditivo. Expresa cuánto habría que desplazar el conjunto obtenido para que llegue a dominar débilmente al de referencia. Cuanto menor es ese desplazamiento,

to, más próximos están ambos frentes, y un valor no positivo significa que el conjunto obtenido ya lo domina.

Espaciamiento (*Spacing*). Refleja con qué uniformidad se reparten las soluciones a lo largo del frente, a partir de la dispersión de las distancias entre soluciones vecinas. Valores bajos corresponden a frentes donde las soluciones están espaciadas de manera regular, sin acumulaciones ni huecos.

Tamaño del frente de Pareto. Cuenta las soluciones no dominadas obtenidas, esto es, cuántas alternativas de compromiso distintas llega a ofrecer el algoritmo. Por sí solo no permite juzgar la calidad del frente.

Los dos indicadores basados en distancias, IGD^+ y el indicador ϵ aditivo, necesitan un conjunto de referencia que aproxime el frente de Pareto óptimo. Como en el diseño de moléculas ese frente no se conoce, dicho conjunto se construye de forma empírica [36].

2.5.3. Metaheurísticas Consideradas en las Experimentaciones

Esta tesina de grado considera cinco algoritmos metaheurísticos multiobjetivo para la experimentación, todos ellos operan sobre el espacio latente continuo del autoencoder variacional.

NSGA-II (Non-dominated Sorting Genetic Algorithm II). Es el algoritmo evolutivo multiobjetivo de referencia y se apoya en la profundidad de dominancia. En cada generación ordena la población en frentes sucesivos de no dominancia mediante un procedimiento de ordenamiento rápido. Los empates dentro de un mismo frente se resuelven con la *distancia de apiñamiento* (*crowding distance*), que mide qué tan poblado está el entorno de cada individuo y favorece a los que se encuentran en regiones menos densas. Estos dos mecanismos, junto con una estrategia elitista, le permiten mantener a la vez convergencia y diversidad [35].

NSGA-III. Conserva el esquema anterior, pero reemplaza la distancia de apiñamiento por un mecanismo de nichos basado en puntos de referencia distribuidos sobre un hiperplano normalizado. Cada solución se asocia al punto de referencia más cercano y sobreviven primero las soluciones asociadas a los puntos con menos representantes. De esta forma se logra una cobertura uniforme del frente incluso cuando crece el número de objetivos, situación en la que la distancia de apiñamiento pierde capacidad de discriminación [37].

MOEA/D (Multiobjective Evolutionary Algorithm Based on Decomposition). Descompone el problema multiobjetivo en un conjunto de subproblemas escalares, definidos por vectores de pesos, y los optimiza de forma simultánea. Cada subproblema se resuelve usando solo la información de sus subproblemas vecinos. La distribución de las soluciones sobre el frente depende de cómo se distribuyan los vectores de pesos, y no de un mecanismo explícito de preservación de la diversidad [38].

CMOPSO (Competitive Mechanism Based Multi-objective Particle Swarm Optimizer). Pertenece a la familia de la optimización por enjambre de partículas. El rendimiento de los optimizadores convencionales de esta familia depende en gran medida de las mejores soluciones globales y personales guardadas en un archivo externo. CMOPSO, en cambio, selecciona en cada generación un conjunto de partículas élite del propio enjambre, según el frente de no dominancia y la distancia de apiñamiento, y actualiza cada partícula mediante una competencia por pares entre dos élites elegidas al azar: gana la que forma el ángulo menor con la partícula [39].

AGE-MOEA (Adaptive Geometry Estimation Based MOEA). Parte de que el desempeño de los algoritmos multiobjetivo depende de la geometría del frente de Pareto, que puede ser una hipersuperficie euclídea, esférica o hiperbólica. Sobre el esquema de NSGA-II, reemplaza la distancia de apiñamiento por un puntaje de supervivencia que combina diversidad y proximidad mediante una norma L_p adaptativa. La estimación de dicha geometría se realiza mediante un procedimiento de complejidad $O(n \times N)$, donde n es el número de objetivos y N el tamaño de la población. De este modo mantiene un rendimiento competitivo ante frentes de geometrías diversas, donde los algoritmos que suponen una geometría fija tienden a degradarse [40].

2.6. Proteína 1 de Resistencia a Múltiples Fármacos (MRP1)

MRP1 (Proteína 1 de Resistencia a Múltiples Fármacos) es una proteína transportadora de la familia ABC (ATP-Binding Cassette) que usa energía del ATP para expulsar fármacos desde el interior de las células hacia el exterior [41, 42]. Al reducir la concentración del fármaco dentro de una célula tumoral, provoca resistencia al mismo. Esta proteína reconoce un conjunto de quimioterápicos, lo que explica la resistencia a fármacos que produce su sobreexpresión [41, 42].

En el cáncer colorrectal existe evidencia experimental sobre el papel de MRP1 en la resistencia a fármacos como el 5-fluorouracilo y el oxaliplatino [5], además de que MRP1 funciona como biomarcador de resistencia al irinotecán [3]. Se encontró que al reducir su producción en células tumorales resistentes, la sensibilidad a ambos fármacos se restablece y la muerte celular de las mismas vuelve a activarse. MRP1 contribuye entonces a la resistencia del cáncer colorrectal, lo que la convierte en un blanco terapéutico de interés [5].

Si bien MRP1 cumple funciones fisiológicas importantes en tejidos sanos, su sobreexpresión en tumores colorrectales representa una barrera terapéutica relevante, por lo que diseñar inhibidores que reduzcan su actividad en células tumorales es un desafío significativo.

Se conoce la estructura tridimensional de MRP1 y el sitio donde se aloja la molécula que transporta [43]. En la Figura 2.8 se observa la conformación tridimensional de esta

proteína (código PDB: 8VUX). Dicho sitio de unión está dividido en dos partes, una con carga positiva y otra hidrofóbica (que repele el agua), y varios de sus aminoácidos cambian de posición cuando una molécula se une. Esa flexibilidad explica por qué la proteína reconoce ligandos tan distintos entre sí, y a la vez ofrece un blanco delimitado contra el cual evaluar moléculas candidatas mediante acoplamiento molecular [43].




Figura 2.8: Estructura tridimensional de la proteína MRP1 (código PDB: 8VUX). Obtenido de RCSB PDB.

2.7. Trabajos Relacionados

En este trabajo se propone un enfoque híbrido, en el que mediante un modelo generativo y metaheurísticas multiobjetivo se busca, en una primera instancia, optimizar el diseño y búsqueda de moléculas con propiedades farmacológicas para, posteriormente, enfocarse en candidatos capaces de acoplarse a la proteína MRP1. Por lo tanto, esta sección revisa los antecedentes de modelos generativos para el diseño molecular, la optimización del espacio latente mediante metaheurísticas y, finalmente, los inhibidores conocidos de la proteína MRP1.

2.7.1. Diseño de Fármacos Mediante Redes Generativas y VAEs

En esta subsección se revisan los principales modelos generativos aplicados al diseño de moléculas. La Tabla 2.1 resume las características de cada uno: el conjunto de datos con el que fue entrenado, la arquitectura sobre la que se construye, la representación molecular que emplea y el año de publicación. La Tabla 2.2 reúne, para esos mismos modelos, las métricas de calidad de generación que reporta cada trabajo, es decir, la validez, la unicidad y la novedad de las moléculas producidas.

En [34], Gómez-Bombarelli et al. presentan el *Chemical Variational Autoencoder* (Chemical VAE), uno de los primeros modelos en mapear representaciones moleculares dis-

Tabla 2.1: Modelos generativos para diseño molecular.

Modelo	Dataset	Arquitectura	Representación molecular	Año
Chemical VAE	QM9 / ZINC	VAE (CNN Enc / GRU Dec)	SMILES	2018
MolGAN	QM9	Implicit GAN (Relational GCN + RL)	Grafo molecular	2018
MOLER	ZINC	Reward shaping sobre JTVAE	Grafo molecular	2022
D-MolVAE	QM9 / ZINC	Graph-based VAE	Grafo molecular	2022
PS-VAE	ZINC250K / QM9	Junction Tree VAE	Subgrafos (Grafos)	2022
PCF-VAE	MOSES	VAE (RNN)	GenSMILES	2025
FRATTVAE	MOSES	Graph Transformer VAE	Grafo molecular	2025
RGCVAE	QM9 / ZINC	Relational Graph VAE	Grafo molecular	2025

Tabla 2.2: Métricas de evaluación de los modelos generativos.

Modelo	Dataset	Validez (%)	Unicidad (%)	Novedad (%)
Chemical VAE	ZINC	73.00–79.00	–	–
MolGAN	QM9	98.10	10.40	94.20
MOLER	ZINC	–	–	–
D-MolVAE	QM9	100.00	98.66	95.85
PS-VAE	ZINC250K	100.00	99.70	99.70
PCF-VAE	MOSES	98.01	100.00	93.77
FRATTVAE	MOSES	100.00	99.97	97.42
RGCVAE	QM9	99.90	94.00	96.40

Nota: el guion (–) indica que el trabajo original no reporta dicha métrica.

cretas (SMILES) a un espacio latente continuo. Entrenado con los conjuntos QM9 y ZINC, permitió explorar y optimizar moléculas mediante operaciones continuas en dicho espacio. Aunque introdujo una base sólida para modelos generativos posteriores, su principal limitación radica en la generación de moléculas inválidas debido a la rigidez sintáctica de SMILES. En sus experimentos, el modelo alcanzó una validez del 73–79 % al decodificar puntos cercanos a moléculas reales.

En [44], De Cao y Kipf presentan MolGAN, un modelo generativo adversario que opera directamente sobre grafos moleculares pequeños. El modelo genera de manera simultánea los átomos y los enlaces e incorpora, junto con el entrenamiento adversario, una red de recompensa basada en aprendizaje por refuerzo para guiar la generación hacia mejores propiedades químicas (p. ej., QED, $\log P$ y sintetizabilidad). Está orientado a moléculas de tamaño reducido (entrenado en QM9). Sus principales limitaciones radican en una baja unicidad debido al colapso de modos y dificultades de escalabilidad a grafos mayores. En QM9 reporta una validez del 98.10 %, una unicidad del 10.40 % y una novedad del 94.20 %.

Fu et al. [45] proponen MOLER, un esquema de optimización condicionada que incorpora recompensas a nivel molecular para guiar modelos generativos basados en grafos (acoplable a arquitecturas como JTVAE, VJTNN y CORE). El método añade términos de recompensa y penalización orientados a maximizar la similitud con el compuesto de partida y penalizar la desviación de tamaño, manteniendo así la proximidad estructural mientras se optimiza una propiedad objetivo (QED, afinidad DRD2 o $\log P$). En sus evaluaciones, MOLER incrementa consistentemente la tasa de éxito y la mejora de propiedades respecto de las líneas base (hasta ~20 %) con bajo costo computacional y alta novedad. Como limitaciones, está concebido para optimización local en lugar de generación totalmente *de novo*, no reporta validez ni unicidad bajo protocolos estandarizados (como MOSES o GuacaMol) y su desempeño depende de la calibración de los pesos de similitud y tamaño.

Du et al. [46] introducen *D-MolVAE*, un autoencoder variacional sobre grafos moleculares enfocado en el aprendizaje de representaciones desentrelazadas (*disentangled representation learning*). Esta arquitectura permite aislar factores latentes asociados a distintas propiedades químicas, generando moléculas válidas, únicas y novedosas con una mayor interpretabilidad del espacio latente. Como limitación, el modelo se enfoca en propiedades globales y el desacoplamiento latente se realiza de manera no supervisada, lo que restringe el control determinista sobre propiedades dirigidas específicas.

Kong et al. [47] proponen *PS-VAE* (*Principal Subgraph Variational Auto-Encoder*), un marco generativo que introduce el concepto de «subgrafos principales»: motivos estructurales recurrentes extraídos automáticamente del conjunto de datos mediante un algoritmo de minería *merge-and-update*, prescindiendo de vocabularios predefinidos manualmente. El modelo sigue un procedimiento en dos etapas: primero emplea un VAE con decodificador autorregresivo (GRU) para generar una secuencia de subgrafos y, pos-

teriormente, ensambla dichos fragmentos prediciendo las conexiones interfragmentarias mediante una red neuronal de grafos (GNN). Este enfoque preserva la valencia química y reduce la dependencia del orden de permutación. En el benchmark GuacaMol sobre ZINC250K, PS-VAE alcanza una validez del 100 % (respaldada por verificación de valencias en inferencia), con 99.70 % de unicidad y 99.70 % de novedad. Como contrapartida, la granularidad a nivel de subgrafos dificulta modificaciones atómicas mínimas en tareas de optimización molecular altamente restringidas.

Bhadwal et al. [48] desarrollan PCF-VAE (*Posterior Collapse-Free Variational Autoencoder*), una arquitectura condicional orientada a mitigar el problema del colapso del espacio latente (*posterior collapse*). El modelo utiliza la representación GenSMILES, la cual simplifica las reglas sintácticas convencionales de SMILES e incrementa la tasa de estructuras químicamente viables. Adicionalmente, implementa una función de pérdida con ponderación dinámica y una capa de control de diversidad estructural. En el benchmark MOSES, reporta una validez del 98.01 %, una unicidad del 100.00 % y una novedad del 93.77 %. No obstante, niveles elevados de diversidad inducen estructuras químicamente inestables, y el desempeño global permanece condicionado a los hiperparámetros de regularización y al preprocesamiento de GenSMILES.

Inukai et al. [49] presentan FRATTVAE (*Fragment Tree-Transformer based VAE*), un modelo generativo que representa cada molécula como una estructura de árbol en la que los nodos corresponden a fragmentos moleculares. Sobre dicha representación, se aplica una codificación posicional en árbol que preserva las relaciones jerárquicas y un mecanismo de autoatención tipo Transformer para capturar dependencias de largo alcance entre fragmentos. Este diseño busca resolver las limitaciones de los modelos basados en cadenas lineales ante compuestos de alta complejidad topológica. Evaluado en el benchmark MOSES, reporta una validez del 100.00 %, una unicidad del 99.97 % y una novedad del 97.42 %. Entre sus limitaciones, el espacio de generación depende estrechamente de las reglas de fragmentación adoptadas y el costo computacional de la atención en árbol es considerable frente a modelos recurrentes tradicionales.

Rigoni et al. [50] proponen RGCVAE (*Relational Graph Conditioned Variational Autoencoder*), un modelo generativo para grafos moleculares que incorpora en su codificador una red *Relational Graph Isomorphism Network* (RGIN). Esta red es capaz de capturar atributos relacionales complejos, tales como órdenes de enlace y estereoquímica tridimensional. La decodificación se ejecuta en dos pasos paralelizables: primero se seleccionan los tipos atómicos conforme a restricciones de valencia y luego se predicen simultáneamente las conexiones entre ellos. Este esquema agiliza los tiempos de convergencia y asegura una elevada precisión de reconstrucción. No obstante, el modelo manifiesta sensibilidad al equilibrio de hiperparámetros: priorizar excesivamente la exactitud de reconstrucción reduce la diversidad y unicidad de las moléculas generadas en conjuntos complejos como ZINC.

2.7.2. Optimización del Espacio Latente Mediante Metaheurísticas

En esta subsección se revisan los principales métodos metaheurísticos que operan sobre el espacio latente de modelos generativos moleculares. La Tabla 2.3 resume las características de cada uno: la descripción del método y el modelo generativo sobre el que actúa, la configuración experimental empleada, las métricas de evaluación reportadas y el blanco terapéutico u objetivo de optimización abordado.

Tabla 2.3: Optimización del espacio latente mediante metaheurísticas en diseño de fármacos.

Método (Año)	Descripción	Configuraciones	Métricas	Target / Objetivo
MSO (2019)	Particle Swarm Optimization (PSO) sobre un espacio latente continuo construido a partir de representaciones SMILES.	50 o 200 partículas; 100 o 200 iteraciones. Puntos de inicio: benceno o ChEMBL.	Continuas: afinidad a blanco, QED, log <i>P</i> penalizado, SA y solubilidad. Binarias: filtros de toxicidad y peso molecular.	Optimización mono y multiobjetivo para compuestos contra los blancos EGFR y BACE1.
ADEL (2022)	Deep Evolutionary Learning (DEL) sobre el espacio latente continuo de un autoencoder adversarial (AAE) entrenado con secuencias SMILES, con reentrenamiento iterativo incorporando nuevas moléculas generadas.	Población de 20 000 individuos, 10 generaciones.	Continuas: QED, log <i>P</i> , SAS y afinidad de unión (<i>docking</i>). Binarias: validez, novedad y unicidad.	Optimización multiobjetivo (QED, log <i>P</i> y SAS). Filtrado de la última población para cribado virtual contra CA9.
LEOMol (2024)	Algoritmos evolutivos (GA y evolución diferencial) en el espacio latente continuo de un VAE que utiliza representación SELFIES.	Población de 20 individuos, 20 generaciones, tasa de cruce de 0.8 y mutación de 0.4.	Continuas: log <i>P</i> , QED, peso molecular y similitud de Tanimoto. Binarias: restricción de toxicidad.	Optimización maximizando propiedades fisicoquímicas (log <i>P</i> , QED).
Transformer + MO (2024)	MOEA/DD, GrEA, HypE, KnEA, A-NSGA-III y NMP SO sobre un espacio latente continuo basado en SELFIES.	Predicción ADMET con MTL-BERT y <i>docking</i> con QuickVina2-GPU.	Continuas: afinidad, SA, log <i>P</i> y toxicidad aguda (LD ₅₀). Binarias: validez, unicidad, novedad y filtros de toxicidad (ClinTox).	Optimización de solubilidad y biodisponibilidad minimizando toxicidad, SAS y afinidad al receptor LPA1.

Continúa en la siguiente página...

Tabla 2.3 – Continuación

Método (Año)	Descripción	Configuraciones	Métricas	Target / Objetivo
MOMO (2024)	Marco de optimización multiobjetivo basado en dominancia de Pareto para guiar la búsqueda evolutiva en el espacio latente de un modelo codificador-decodificador entrenado con secuencias SMILES.	Población inicial perturbada con ruido gaussiano. Operadores: selección por torneo binario, cruce lineal combinado y mutación ($p = 0.5$).	Continuas: QED, similitud de Tanimoto, eficiencia del ligando (LE), puntuación de <i>docking</i> , actividad DRD2, inhibición de GSK3 β y SA.	Optimización simultánea multiobjetivo (de 2 a 4 propiedades). Evaluación contra blancos biológicos 1SYH y 4LDE.
MO-LSO (2024)	Optimización multiobjetivo en el espacio latente continuo de un JT-VAE mediante reentrenamiento iterativo ponderado por eficiencia de Pareto.	Entrenamiento inicial con ZINC. Reentrenamiento iterativo ajustado por parámetro de peso (k). Exploración latente por muestreo aleatorio.	Continuas: $\log P$, SAS, similitud a productos naturales (NP score) y probabilidad de inhibición de DRD2 mediante aprendizaje automático.	Optimización multiobjetivo simultánea (hasta 3 propiedades) para maximizar $\log P$, NP score e inhibición de DRD2, y minimizar SAS.
Paddy (2025)	Algoritmo evolutivo basado en el <i>Paddy field algorithm</i> , aplicado sobre el espacio latente continuo de un JT-VAE.	Operadores evolutivos inspirados en la dispersión de plantas de arrozal, con tasa de dispersión adaptativa que regula la proximidad y número de nuevas soluciones.	Continuas: $\log P$, SA, número de ciclos con más de 6 átomos y similitud de Tversky.	Optimización de múltiples parámetros integrados en una función objetivo.

Winter et al. [51] proponen *Molecule Swarm Optimization* (MSO), un método que combina una representación continua del espacio químico con el algoritmo metaheurístico de optimización por enjambre de partículas (PSO). El modelo utiliza un espacio latente preentrenado mediante una arquitectura codificador-decodificador que procesa representaciones SMILES, lo que permite desacoplar la generación de moléculas del proceso de optimización multiobjetivo. Su principal innovación radica en el empleo de PSO para explorar dicho espacio latente, lo que reduce drásticamente el costo computacional y permite manejar con eficiencia la alta dimensionalidad del espacio de búsqueda. MSO logró generar moléculas con alta afinidad predicha hacia los blancos biológicos EGFR y BACE1. Como limitaciones, los autores señalan que al depender de modelos predictivos de relación estructura-actividad cuantitativa (QSAR) para evaluar la función objetivo, el algoritmo puede ser conducido hacia regiones fuera del dominio de aplicabilidad o generar moléculas con artefactos estructurales si no se imponen restricciones adecuadas durante la optimización.

Abouchekeir et al. [52] presentan *ADEL* (*Adversarial Deep Evolutionary Learning*), un marco que combina autoencoders adversariales (AAE) y algoritmos evolutivos para el diseño de fármacos. A diferencia de enfoques previos, emplea redes recurrentes (LSTM) junto con un discriminador para estructurar de forma más regular el espacio latente de cadenas SMILES. Posteriormente, aplica el algoritmo genético multiobjetivo NSGA-II para operar mediante cruce y mutación sobre los vectores latentes, refinando el modelo de manera iterativa al incorporar las nuevas soluciones generadas a la población de entrenamiento. En sus evaluaciones, ADEL generó compuestos que optimizan simultáneamente múltiples propiedades fisicoquímicas (QED, $\log P$ y accesibilidad sintética), identificando moléculas con favorable energía de unión en simulaciones de acoplamiento molecular contra el biomarcador tumoral CA9. Como limitación metodológica, la optimización evolutiva se restringe a descriptores generales, delegando la selectividad hacia el blanco a una etapa posterior de filtrado sobre la última población.

El modelo *LEOMol*, introducido por Siddhartha Reddy et al. [53], aborda el diseño de fármacos integrando un autoencoder variacional con algoritmos genéticos y evolución diferencial. Al adoptar la representación robusta SELFIES, el sistema garantiza un 100 % de validez química en todas las estructuras decodificadas. Su principal ventaja radica en explorar el espacio latente mediante operadores estocásticos poblacionales en lugar de métodos basados en gradientes continuos, lo que facilita optimizar funciones de aptitud complejas evaluadas con herramientas quimioinformáticas estándar. En sus experimentos, demostró alta eficacia para generar compuestos que satisfacen múltiples criterios concurrentes, destacando la generación de moléculas exentas de toxicidad. No obstante, el algoritmo presenta dificultades para converger hacia soluciones viables cuando se le exige preservar una elevada similitud estructural con respecto a un compuesto de partida.

Aksamit et al. [54] proponen un marco de trabajo que integra la arquitectura Transformer con algoritmos metaheurísticos de muchos objetivos (*many-objective optimization*) para el diseño molecular. Este enfoque busca optimizar simultáneamente perfiles farmacocinéticos ADMET y la afinidad de unión estimada mediante acoplamiento molecular. Empleando el modelo ReLSO para proyectar las moléculas en un espacio latente continuo basado en SELFIES, el estudio evalúa y compara el desempeño de diversas metaheurísticas (tales como MOEA/DD, GrEA, HypE, KnEA, A-NSGA-III y NMPSO) en la búsqueda de ligandos dirigidos al receptor LPA1. Como principal limitación, los autores destacan el elevado costo computacional derivado de evaluar el acoplamiento molecular en cada evaluación de aptitud, lo que restringe la sintonización exhaustiva de los hiperparámetros del optimizador.

Xia et al. [55] desarrollan MOMO (*Multiobjective Molecule Optimization*), un marco metodológico que guía la búsqueda evolutiva en el espacio químico fundamentándose en el principio de dominancia de Pareto. El método utiliza un codificador-decodificador preentrenado sobre secuencias SMILES para mapear las estructuras moleculares a vectores continuos, sobre los cuales aplica selección por torneo binario, cruce lineal combinado y perturbaciones de mutación. Su fortaleza radica en superar el rendimiento de algoritmos convencionales del estado del arte, reportando mejoras notables en tasa de éxito, novedad e hipervolumen en problemas de optimización de dos a cuatro propiedades simultáneas (incluyendo afinidad contra dianas 1SYH y 4LDE). Como debilidad, el modelo manifiesta susceptibilidad a producir ciertas estructuras químicamente poco realistas si no se imponen restricciones de valencia y filtros estructurales rigurosos durante la fase de decodificación.

Abeer et al. [56] introducen MO-LSO (*Multi-Objective Latent Space Optimization*), un método que optimiza el espacio latente de modelos preentrenados tipo JT-VAE a través de un esquema de reentrenamiento iterativo ponderado por la eficiencia de Pareto de las moléculas muestreadas. Esta estrategia permite equilibrar compromisos entre propiedades fisicoquímicas contrapuestas, generando moléculas de alta calidad (como potenciales inhibidores del receptor DRD2) incluso a partir de conjuntos de datos iniciales desprovistos de ligandos activos. Como contrapartida, el procedimiento iterativo tiende a concentrar las soluciones en regiones localizadas del espacio químico, reduciendo la diversidad estructural de los compuestos finales, a lo que se suma el incremento del costo computacional derivado de los ciclos sucesivos de reentrenamiento.

Beck et al. [57] presentan *Paddy*, un algoritmo de optimización evolutiva inspirado en la dispersión reproductiva de las plantas de arrozal (*paddy field algorithm*), diseñado para explorar sistemas y espacios químicos complejos. A diferencia de los algoritmos genéticos convencionales que dependen de operadores de recombinación cromosómica, *Paddy* propaga soluciones en el espacio latente de un modelo JT-VAE mediante mutaciones gaussianas reguladas por la densidad local de las soluciones y su aptitud. Esto proporciona una exploración rápida y flexible del espacio paramétrico continuo. Sin em-

bargo, en su formulación para optimización molecular monoproyectada sobre una única función escalar agregada, el método tiende a simplificar las relaciones de compromiso no lineales inherentes a la optimización multiobjetivo de propiedades farmacológicas.

2.7.3. Diseño de Fármacos Inhibidores de la Proteína MRP1

El diseño de inhibidores de MRP1 se basó durante décadas en probar, mediante campañas de cribado masivo de la industria farmacéutica, compuestos ya conocidos por otras propiedades (como el verapamilo o la ciclosporina A) y una amplia variedad de productos naturales. Ninguno de estos compuestos llegó a aprobarse como fármaco [58]. En paralelo, desde que se resolvió por cristalografía de rayos X una parte de MRP1 en 2006, varios trabajos computacionales combinaron esa estructura parcial con modelos por homología del resto de la proteína para buscar inhibidores mediante virtual screening y acoplamiento molecular. Rungsardthong et al. [59] identificaron 20 compuestos candidatos dirigidos a esa parte, y Dhasmana et al. [60] propusieron el citrato de potasio como el mejor candidato de una biblioteca de fármacos aprobados por la FDA.

La estructura completa de MRP1, resuelta por criomicroscopía electrónica (una técnica que permite ver la forma de una proteína a partir de miles de copias congeladas) en 2017, reveló por primera vez otra parte de la proteína: la zona donde se une a los fármacos que va a expulsar, distinta de la que usaron los trabajos anteriores. Belhadj et al. [61] utilizan esa estructura para caracterizar ZW-1226, un compuesto que mediante acoplamiento molecular ocupa esa zona de enganche, y que en líneas celulares revierte la resistencia mediada por MRP1 a dos fármacos de quimioterapia.

METODOLOGÍA

3.1. Visión General de la Metodología

3.2. Ajuste de Hiperparámetros Mediante Generación de Fármacos Genéricos

3.2.1. Variables Optimizadas

3.2.2. Funciones Objetivo

3.3. Diseño de Inhibidores de la Proteína MRP1

3.3.1. Preparación de la Proteína

3.3.2. Funciones Objetivo

3.4. Configuración Experimental

3.4.1. Representación de la Solución

3.4.2. Conjunto de Datos y Preprocesamiento

RESULTADOS Y DISCUSIÓN

4.1. Generación de Fármacos Genéricos para el Ajuste de Hiperparámetros

4.1.1. Análisis de Calidad de Generación de Moléculas

4.1.2. Comparación Contra Algoritmos del Estado del Arte

4.2. Generación de Inhibidores de la Proteína MRP1

4.2.1. Análisis de Calidad de Generación de Moléculas

4.2.2. Comparación Contra Algoritmos del Estado del Arte

4.2.3. Análisis Detallado de las Mejores Moléculas Candidatas

CONCLUSIONES Y TRABAJO FUTURO

5.1. Conclusiones

5.2. Trabajo Futuro

Apéndice

SHOWCASING THE FIRST APPENDIX

Writing Guidance

Appendices contain supplementary material **created by the author** that enhances the reader's understanding of the dissertation while not being essential for following the primary narrative. These sections often include detailed tables, figures, complex calculations, or materials like survey questions and interview transcripts produced in the course of the research. The appendices allow readers to explore the research in greater detail, offering a deeper insight into methods and findings without interrupting the main body of work.

Anexos

SHOWCASING THE FIRST ANNEX

Writing Guidance

Annexes are supplementary sections in a dissertation that provide additional information or external documents not essential to the main arguments but that support or complement the research. Unlike appendices, **annexes generally contain material that was not developed by the author**, such as reports, legal documents, or published datasets from external sources. This information is placed separately to keep the main content concise, allowing readers access to relevant external references without disrupting the dissertation's flow.

BIBLIOGRAFÍA

- [1] American Cancer Society. *Breve historia del cáncer*. <https://www.cancer.org/es/cancer/entendimiento-del-cancer/historia-del-cancer.html>. Accedido: 2026. 2026.
- [2] Hyuna Sung et al. «Global cancer statistics 2024: GLOBOCAN estimates of incidence and mortality worldwide for 34 cancers in 186 countries». En: *CA: A Cancer Journal for Clinicians* 76.4 (2026), e70090. DOI: 10.3322/caac.70090.
- [3] Jose J. G. Marin et al. «Expression of Chemoresistance-Associated ABC Proteins in Hepatobiliary, Pancreatic and Gastrointestinal Cancers». En: *Cancers* 14.14 (2022), pág. 3524. DOI: 10.3390/cancers14143524.
- [4] Fang-fang Qi et al. «Long non-coding RNAs: Key regulators in oxaliplatin resistance of colorectal cancer». En: *Biomedicine & Pharmacotherapy* 128 (2020), pág. 110329. DOI: 10.1016/j.biopha.2020.110329.
- [5] Dongxing Cao et al. «The role of MRP1 in the multidrug resistance of colorectal cancer». En: *Oncology Letters* 13.4 (2017), págs. 2471-2476. ISSN: 1792-1074. DOI: 10.3892/ol.2017.5741.
- [6] Uddalak Das. «Generative AI for drug discovery and protein design: the next frontier in AI-driven molecular science». En: *Medicine in Drug Discovery* 27 (2025), pág. 100213. DOI: 10.1016/j.medidd.2025.100213.
- [7] Sohvi Luukkonen et al. «Artificial intelligence in multi-objective drug design». En: *Current Opinion in Structural Biology* 79 (2023), pág. 102537. DOI: 10.1016/j.sbi.2023.102537.
- [8] Zijian Zhang et al. «Molecular Knowledge Representations in the Era of Artificial Intelligence». En: *ChemRxiv* (2026). DOI: 10.26434/chemrxiv.15002830/v1.
- [9] El-Ghazali Talbi. *Metaheuristics: From Design to Implementation*. 1.^a ed. Hoboken, New Jersey: John Wiley & Sons, 2009. ISBN: 978-0-470-27858-1. DOI: 10.1002/9780470496916. URL: <https://onlinelibrary.wiley.com/doi/book/10.1002/9780470496916>.
- [10] J. P. Hughes et al. «Principles of early drug discovery». En: *British Journal of Pharmacology* 162.6 (2011), págs. 1239-1249. DOI: 10.1111/j.1476-5381.2010.01127.x.
- [11] Shujun Zhang et al. «The role and application of bioinformatics techniques and tools in drug discovery». En: *Frontiers in Pharmacology* 16 (2025), pág. 1547131. DOI: 10.3389/fphar.2025.1547131.

- [12] Pooja A. Chawla et al., eds. *Computational Drug Discovery: Molecular Simulation for Medicinal Chemistry*. De Gruyter, 2024. ISBN: 978-3-11-120711-7. DOI: 10.1515/9783111207117.
- [13] Grazyna Biala et al. «Research in the Field of Drug Design and Development». En: *Pharmaceuticals* 16.9 (2023), pág. 1283. DOI: 10.3390/ph16091283.
- [14] Carlos E. Durán et al. «Regulatory reliance to approve new medicinal products in Latin American and Caribbean countries». En: *Revista Panamericana de Salud Pública* 45 (2021), e10. DOI: 10.26633/RPSP.2021.10.
- [15] Stephani Joy Y. Macalino et al. «Role of computer-aided drug design in modern drug discovery». En: *Archives of Pharmacal Research* 38.9 (2015), págs. 1686-1701. DOI: 10.1007/s12272-015-0640-5.
- [16] David Weininger. «SMILES, a chemical language and information system. 1. Introduction to methodology and encoding rules». En: *Journal of Chemical Information and Computer Sciences* 28.1 (1988), págs. 31-36. DOI: 10.1021/ci00057a005.
- [17] Weiya Kong et al. «Application of SMILES-based molecular generative model in new drug design». En: *Frontiers in Pharmacology* 13 (2022), pág. 1046524. DOI: 10.3389/fphar.2022.1046524.
- [18] Marwin H. S. Segler et al. «Generating focused molecule libraries for drug discovery with recurrent neural networks». En: *ACS Central Science* 4.1 (2018), págs. 120-131. DOI: 10.1021/acscentsci.7b00512.
- [19] Marcus Olivecrona et al. «Molecular de-novo design through deep reinforcement learning». En: *Journal of Cheminformatics* 9 (2017), pág. 48. DOI: 10.1186/s13321-017-0235-x.
- [20] Josep Arús-Pous et al. «Randomized SMILES strings improve the quality of molecular generative models». En: *Journal of Cheminformatics* 11 (2019), pág. 71. DOI: 10.1186/s13321-019-0393-0.
- [21] Mario Krenn et al. «SELFIES: a robust representation of semantically constrained graphs with an example application in chemistry». En: *Machine Learning: Science and Technology* 1.4 (2020), pág. 045024. DOI: 10.1088/2632-2153/aba947.
- [22] Christopher A. Lipinski et al. «Experimental and computational approaches to estimate solubility and permeability in drug discovery and development settings». En: *Advanced Drug Delivery Reviews* 23.1-3 (1997), págs. 3-25. DOI: 10.1016/S0169-409X(96)00423-1.
- [23] G. Richard Bickerton et al. «Quantifying the chemical beauty of drugs». En: *Nature Chemistry* 4.2 (2012), págs. 90-98. DOI: 10.1038/nchem.1243.

- [24] Yuhang Xia et al. «A comprehensive review of molecular optimization in artificial intelligence-based drug discovery». En: *Quantitative Biology* 12.1 (2024), págs. 15-29. DOI: 10.1002/qub2.30.
- [25] Peter Ertl et al. «Estimation of synthetic accessibility score of drug-like molecules based on molecular complexity and fragment contributions». En: *Journal of Cheminformatics* 1 (2009), pág. 8. DOI: 10.1186/1758-2946-1-8.
- [26] Frank Lovering et al. «Escape from Flatland: Increasing Saturation as an Approach to Improving Clinical Success». En: *Journal of Medicinal Chemistry* 52.21 (2009), págs. 6752-6756. DOI: 10.1021/jm901241e.
- [27] Frank Lovering. «Escape from Flatland 2: complexity and promiscuity». En: *MedChemComm* 4.3 (2013), págs. 515-519. DOI: 10.1039/C2MD20347B.
- [28] Nataraj S. Pagadala et al. «Software for molecular docking: a review». En: *Biophysical Reviews* 9.2 (2017), págs. 91-102. DOI: 10.1007/s12551-016-0247-1. URL: <https://doi.org/10.1007/s12551-016-0247-1>.
- [29] Oleg Trott et al. «AutoDock Vina: Improving the speed and accuracy of docking with a new scoring function, efficient optimization, and multithreading». En: *Journal of Computational Chemistry* 31.2 (2010), págs. 455-461. DOI: 10.1002/jcc.21334.
- [30] Yuejiang Yu et al. «Uni-Dock: GPU-accelerated docking enables ultralarge virtual screening». En: *Journal of Chemical Theory and Computation* 19.11 (2023), págs. 3336-3345. DOI: 10.1021/acs.jctc.2c01145. URL: <https://doi.org/10.1021/acs.jctc.2c01145>.
- [31] Diederik P. Kingma et al. «Auto-Encoding Variational Bayes». En: *arXiv preprint arXiv:1312.6114* (2013).
- [32] Christopher M. Bishop et al. *Deep Learning: Foundations and Concepts*. Cham, Switzerland: Springer, 2024. DOI: 10.1007/978-3-031-45468-4.
- [33] Joseph Taewoo Kim. *Exploring Effectiveness of Multimodal Variational Autoencoders on Text-Image Tasks*. Inf. téc. Stanford University, 2024. URL: <https://github.com/josephkim/Multimodal-VAE>.
- [34] Rafael Gómez-Bombarelli et al. «Automatic Chemical Design Using a Data-Driven Continuous Representation of Molecules». En: *ACS Central Science* 4.2 (2018), págs. 268-276. DOI: 10.1021/acscentsci.7b00572. URL: <https://doi.org/10.1021/acscentsci.7b00572>.
- [35] K. Deb et al. «A fast and elitist multiobjective genetic algorithm: NSGA-II». En: *IEEE Transactions on Evolutionary Computation* 6.2 (2002), págs. 182-197. DOI: 10.1109/4235.996017. URL: <http://ieeexplore.ieee.org/document/996017/>.

- [36] Miqing Li et al. «Quality Evaluation of Solution Sets in Multiobjective Optimisation: A Survey». En: *ACM Computing Surveys* 52.2 (2019), 26:1-26:38. DOI: 10.1145/3300148. URL: <https://doi.org/10.1145/3300148>.
- [37] Kalyanmoy Deb et al. «An Evolutionary Many-Objective Optimization Algorithm Using Reference-Point-Based Nondominated Sorting Approach, Part I: Solving Problems With Box Constraints». En: *IEEE Transactions on Evolutionary Computation* 18.4 (2014), págs. 577-601. DOI: 10.1109/TEVC.2013.2281535. URL: <https://doi.org/10.1109/tevc.2013.2281535>.
- [38] Qingfu Zhang et al. «MOEA/D: A Multiobjective Evolutionary Algorithm Based on Decomposition». En: *IEEE Transactions on Evolutionary Computation* 11.6 (2007), págs. 712-731. DOI: 10.1109/TEVC.2007.892759. URL: <http://ieeexplore.ieee.org/document/4358754/>.
- [39] Xingyi Zhang et al. «A competitive mechanism based multi-objective particle swarm optimizer with fast convergence». En: *Information Sciences* 427 (2018), págs. 63-76. DOI: 10.1016/j.ins.2017.10.037. URL: <https://linkinghub.elsevier.com/retrieve/pii/S0020025517310344>.
- [40] Annibale Panichella. «An adaptive evolutionary algorithm based on non-euclidean geometry for many-objective optimization». En: *Proceedings of the Genetic and Evolutionary Computation Conference*. Prague, Czech Republic: ACM, 2019, págs. 595-603. ISBN: 978-1-4503-6111-8. DOI: 10.1145/3321707.3321839. URL: <https://dl.acm.org/doi/10.1145/3321707.3321839>.
- [41] Susan P. C. Cole. «Targeting Multidrug Resistance Protein 1 (MRP1, ABCC1): Past, Present, and Future». En: *Annual Review of Pharmacology and Toxicology* 54.1 (2014), págs. 95-117. ISSN: 0362-1642. DOI: 10.1146/annurev-pharmtox-011613-135959.
- [42] Jamie F. Lu et al. «MRP1 and its role in anticancer drug resistance». En: *Drug Metabolism Reviews* 47.4 (2015), págs. 406-419. ISSN: 0360-2532. DOI: 10.3109/03602532.2015.1105253.
- [43] Zachary Lee Johnson et al. «Structural Basis of Substrate Recognition by the Multidrug Resistance Protein MRP1». En: *Cell* 168.6 (2017), págs. 1075-1085. ISSN: 0092-8674. DOI: 10.1016/j.cell.2017.01.041.
- [44] Nicola De Cao et al. *MolGAN: An implicit generative model for small molecular graphs*. Mayo de 2018. DOI: 10.48550/arXiv.1805.11973. URL: <http://arxiv.org/abs/1805.11973>.
- [45] Tianfan Fu et al. «MOLER: Incorporate Molecule-Level Reward to Enhance Deep Generative Model for Molecule Optimization». en. En: *IEEE Transactions on Knowledge and Data Engineering* 34.11 (nov. de 2022), págs. 5459-5471. ISSN: 1041-4347, 1558-2191, 2326-3865. DOI: 10.1109/TKDE.2021.3052150. URL: <https://ieeexplore.ieee.org/document/9330796/>.

- [46] Yuanqi Du et al. «Small molecule generation via disentangled representation learning». En: *Bioinformatics* 38.12 (jun. de 2022), págs. 3200-3208. ISSN: 1367-4803. DOI: 10.1093/bioinformatics/btac296. URL: <https://doi.org/10.1093/bioinformatics/btac296>.
- [47] Xiangzhe Kong et al. *Molecule Generation by Principal Subgraph Mining and Assembling*. 2022. URL: <https://arxiv.org/abs/2106.15098>.
- [48] Arun Singh Bhadwal et al. «PCF-VAE: posterior collapse free variational auto-encoder for de novo drug design». en. En: *Scientific Reports* 15.1 (oct. de 2025), pág. 34152. ISSN: 2045-2322. DOI: 10.1038/s41598-025-14285-5. URL: <https://www.nature.com/articles/s41598-025-14285-5>.
- [49] Tensei Inukai et al. «Leveraging tree-transformer VAE with fragment tokenization for high-performance large chemical model generation». en. En: *Communications Chemistry* 8.1 (ago. de 2025), pág. 228. ISSN: 2399-3669. DOI: 10.1038/s42004-025-01640-w. URL: <https://www.nature.com/articles/s42004-025-01640-w>.
- [50] Davide Rigoni et al. «RGCVAE: relational graph conditioned variational autoencoder for molecule design». en. En: *Machine Learning* 114.2 (ene. de 2025), pág. 47. ISSN: 1573-0565. DOI: 10.1007/s10994-024-06638-4. URL: <https://doi.org/10.1007/s10994-024-06638-4>.
- [51] Robin Winter et al. «Efficient multi-objective molecular optimization in a continuous latent space». En: *Chemical Science* 10 (2019), págs. 8016-8024. DOI: 10.1039/c9sc01928f. URL: <https://doi.org/10.1039/c9sc01928f>.
- [52] Sherif Abouchekeir et al. «Adversarial deep evolutionary learning for drug design». En: *BioSystems* 222 (2022), pág. 104790. DOI: 10.1016/j.biosystems.2022.104790.
- [53] Siddhartha Reddy N et al. «Leveraging Latent Evolutionary Optimization for Targeted Molecule Generation». En: *2024 IEEE Congress on Evolutionary Computation (CEC)*. arXiv:2407.13779. 2024.
- [54] Nicholas Aksamit et al. «Integrating transformers and many-objective optimization for drug design». En: *BMC Bioinformatics* 25.1 (2024), pág. 208. DOI: 10.1186/s12859-024-05822-6. URL: <https://doi.org/10.1186/s12859-024-05822-6>.
- [55] Xin Xia et al. «Evolutionary Multiobjective Molecule Optimization in an Implicit Chemical Space». En: *Journal of Chemical Information and Modeling* 64 (2024), págs. 5161-5174. DOI: 10.1021/acs.jcim.4c00031. URL: <https://doi.org/10.1021/acs.jcim.4c00031>.
- [56] AN M Nafiz Abeer et al. «Multi-Objective Latent Space Optimization of Generative Molecular Design Models». En: *arXiv preprint arXiv:2203.00526v3* (2024). URL: <https://arxiv.org/abs/2203.00526v3>.

- [57] Armen G. Beck et al. «Paddy: an evolutionary optimization algorithm for chemical systems and spaces». En: *Digital Discovery* 4 (2025), págs. 1352-1371. doi: 10.1039/d4dd00226a. URL: <https://doi.org/10.1039/d4dd00226a>.
- [58] Sven Marcel Stefan et al. «Small-molecule inhibitors of multidrug resistance-associated protein 1 and related processes: A historic approach and recent advances». En: *Medicinal Research Reviews* 39 (2019), págs. 176-264. doi: 10.1002/med.21510.
- [59] Kanin Rungsardthong et al. «Virtual screening of ABCC1 transporter nucleotide-binding domains as a therapeutic target in multidrug resistant cancer». En: *Bioinformatics* 8.19 (2012), págs. 907-911. doi: 10.6026/97320630008907.
- [60] Divya Dhasmana et al. «Targeting Nucleotide Binding Domain of Multidrug Resistance-associated Protein-1 (MRP1) for the Reversal of Multi Drug Resistance in Cancer». En: *Scientific Reports* 8 (2018), pág. 11973. doi: 10.1038/s41598-018-30420-x.
- [61] Zakia Belhadj et al. «Characterization of a deazaflavin analog as a potent inhibitor of multidrug resistance-associated protein 1». En: *Biomedicine & Pharmacotherapy* 178 (2024), pág. 117167. doi: 10.1016/j.biopha.2024.117167.

GLOSARIO

Término Descripción o definición del término de ejemplo.. (p. 48)

SIGLAS

SIGLA Significado de la sigla de ejemplo. (*p. 48*)

